

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO

ĐỒ ÁN CHUYÊN NGÀNH
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

**Ứng dụng mô hình ngôn ngữ lớn (LLM) trong hệ thống gợi ý
và tư vấn trên sàn thương mại điện tử**

HỘI ĐỒNG: Khoa học máy tính

GVHD: Ths. Võ Thanh Hùng

—o0o—

SVTH1: Đàm Đức Huy(2211157)

SVTH2: Huỳnh Quốc Huy(2211180)

SVTH3: Nguyễn Gia Huy(2211212)

TP. HỒ CHÍ MINH, 12/2025

Lời cảm ơn

Đồ án tốt nghiệp được hoàn thành dưới sự hướng dẫn của và ThS. Võ Thanh Hùng, Khoa Khoa học và Kỹ thuật Máy tính, Trường Đại học Bách khoa - Đại học Quốc gia Thành phố Hồ Chí Minh. Nhóm thực hiện xin chân thành cảm ơn ThS. Võ Thanh Hùng, đã giúp đỡ chúng em kiến thức chuyên môn, thảo luận, đưa ra gợi ý và tạo điều kiện thuận lợi cho chúng em hoàn thành đồ án.

Chúng em cũng xin gửi lời cảm ơn đặc biệt đến quý thầy cô phản biện, những người đã đọc và đóng góp ý kiến để chúng em hoàn thiện Đồ án tốt nghiệp của mình.

Nhóm thực hiện cũng xin bày tỏ lòng biết ơn sâu sắc đến quý thầy cô Khoa Khoa học và Kỹ thuật Máy tính, Trường Đại học Bách khoa - Đại học Quốc gia Thành phố Hồ Chí Minh, là những người đã truyền thụ kiến thức chuyên môn, đã tạo điều kiện cho chúng em học tập và phát triển trong suốt quãng thời gian vừa qua.

Đặc biệt, chúng em muốn bày tỏ lòng biết ơn sâu sắc đến gia đình, những người đã luôn là chỗ dựa tinh thần vững chắc, động viên và tạo điều kiện tốt nhất để chúng em có thể tập trung học tập và hoàn thành đồ án này. Sự hy sinh và hỗ trợ không ngừng nghỉ của gia đình là nguồn động lực to lớn giúp chúng em vượt qua mọi khó khăn.

Kính chúc quý thầy cô sức khỏe, thành công và tiếp tục đào tạo những thế hệ sinh viên mới trong tương lai.

Chúng em xin chân thành cảm ơn.

Nhóm thực hiện

Huỳnh Quốc Huy

Đàm Đức Huy

Nguyễn Gia Huy

Lời cam đoan

Chúng tôi xin cam đoan Đồ án tốt nghiệp này là công trình nghiên cứu khoa học nghiêm túc và trung thực của nhóm dưới sự hướng dẫn của ThS Võ Thanh Hùng.

Tất cả nội dung được trình bày trong Đồ án tốt nghiệp này, ngoại trừ những phần đã được chú thích, trích nguồn rõ ràng trong phần tài liệu tham khảo, đều là do chính bản thân nhóm thực hiện.

Chúng tôi xin chịu trách nhiệm hoàn toàn nếu có bất kỳ sự gian lận nào về nội dung Đồ án tốt nghiệp của nhóm.

Nhóm thực hiện

Huỳnh Quốc Huy

Đàm Đức Huy

Nguyễn Gia Huy

Tóm tắt

Nghiên cứu này tập trung phát triển hệ thống gợi ý tuần tự đa phương thức ứng dụng trên tập dữ liệu Amazon Gift Cards, nhằm tối ưu hóa trải nghiệm tìm kiếm và mua sắm quà tặng trực tuyến. Mục tiêu cốt lõi của hệ thống là hỗ trợ người dùng tìm kiếm sản phẩm phù hợp nhất thông qua việc phân tích sâu nội dung đa phương thức bao gồm văn bản và hình ảnh, kết hợp với chuỗi hành vi và sở thích lịch sử để đưa ra các gợi ý có tính cá nhân hóa cao.

Về mặt phương pháp, hệ thống được xây dựng dựa trên kiến trúc Two-Tower kết hợp với chiến lược tìm kiếm lai. Cụ thể, tháp sản phẩm ứng dụng cơ chế cổng liên kết (Fusion Gate) để tổng hợp và học biểu diễn từ các đặc trưng văn bản trích xuất từ BERT, đặc trưng hình ảnh từ ViT và dữ liệu bảng. Trong khi đó, tháp người dùng mô hình hóa chuỗi tương tác tuần tự bằng kiến trúc Transformer Encoder cải tiến từ mô hình SASRec. Điểm đặc biệt là sự tích hợp khả năng nhận biết cảm xúc, cho phép hệ thống phân biệt và học hỏi từ các phản hồi tích cực cũng như tiêu cực của người dùng.

Quá trình suy luận diễn ra qua quy trình ba giai đoạn chặt chẽ: truy xuất ứng viên dựa trên ngữ nghĩa; xếp hạng lại sơ bộ thông qua việc kết hợp điểm số giữa ý định tìm kiếm và sở thích cá nhân; và cuối cùng là tinh chỉnh xếp hạng chuyên sâu sử dụng Mô hình Ngôn ngữ Lớn (LLM). Tại bước cuối cùng, LLM đóng vai trò đánh giá ngữ cảnh và suy luận mối liên hệ giữa nhu cầu hiện tại với lịch sử hành vi để chọn lọc danh sách kết quả tối ưu. Ngoài ra, vấn đề khởi động lạnh đối với người dùng mới được giải quyết thông qua thuật toán đánh giá có trọng số. Kết quả thực nghiệm cho thấy mô hình không chỉ nắm bắt hiệu quả các mối quan hệ ngữ nghĩa đa phương thức và diễn biến sở thích người dùng, mà còn tận dụng tốt khả năng suy luận của LLM để nâng cao chất lượng gợi ý cuối cùng.

Bảng 1: Bảng phân công vai trò và nhiệm vụ chi tiết của nhóm

Thành viên	Vai trò chuyên môn	Nhiệm vụ chi tiết & Kết quả thực hiện
Huỳnh Quốc Huy	Xử lý dữ liệu & Tích hợp AI Tạo sinh	1. Tiền xử lý dữ liệu (Data Preprocessing): - Thu thập, làm sạch và chuẩn hóa các nguồn dữ liệu đa phương thức (hình ảnh, văn bản, thông số kỹ thuật). - Xây dựng pipeline xử lý dữ liệu tự động để phục vụ quá trình huấn luyện. 2. Xây dựng Hệ thống Demo (Web Application): - Thiết kế và phát triển giao diện người dùng (Frontend) cho Web Demo. - Xây dựng Backend API để kết nối giữa giao diện và các mô hình gợi ý, hiển thị kết quả trực quan cho người dùng. 3. Tích hợp LLM (Explainability): - Nghiên cứu và tích hợp mô hình ngôn ngữ lớn (LLM) để sinh văn bản giải thích lý do gợi ý. - Thiết kế kỹ thuật <i>Prompt Engineering</i> để tạo ra các giải thích tự nhiên và phù hợp ngữ cảnh.
Nguyễn Gia Huy	Mô hình hóa Sản phẩm & Nghiên cứu Nâng cao	1. Xây dựng Tháp Sản phẩm (Item Tower): - Thiết kế và cài đặt các bộ mã hóa đặc trưng (ImageEncoder, TextEncoder, TabularEncoder). - Hiện thực hóa cơ chế <i>Item Fusion</i> để tạo vector đại diện sản phẩm thống nhất. 2. Nghiên cứu Cross-Encoder: - Tìm hiểu cơ sở lý thuyết và kiến trúc của mô hình Cross-Encoder cho bài toán Re-ranking. - Đề xuất giải pháp và kiến trúc tích hợp Cross-Encoder để cải thiện độ chính xác (định hướng phát triển tương lai).
Đàm Huy Đức	Mô hình hóa Người dùng	Xây dựng Tháp Người dùng (User Tower): - Cài đặt kiến trúc <i>Transformer/SASRec</i> để mô hình hóa chuỗi hành vi tuần tự của người dùng. - Hiện thực hóa các kỹ thuật <i>Masked Mean Pooling</i> và <i>Positional Encoding</i>.

Bảng 2: Kế hoạch thực hiện đề tài

Tuần (Thời gian)	Nội dung thực hiện
w37 (08/09 – 14/09)	Tìm hiểu tổng quan, xác định phạm vi đề tài và dataset.
w38 (15/09 – 21/09)	Thu thập, phân tích và làm sạch bộ dữ liệu <i>Amazon Reviews</i> .
w39 (22/09 – 28/09)	Thực hiện embedding dữ liệu sản phẩm và người dùng.
w40 (29/09 – 05/10)	Xây dựng và cài đặt Item Tower (Tích hợp Fusion Gate).
w41 (06/10 – 12/10)	Xây dựng User Tower với kiến trúc SASRec để mô hình hóa chuỗi hành vi.
w42 (13/10 – 19/10)	Huấn luyện mô hình Two-Tower (Loss function: <i>InfoNCE</i> + In-batch Negatives).
w43 (20/10 – 26/10)	Triển khai cơ chế Retrieval và chiến lược Hybrid Reranking.
w44 (27/10 – 02/11)	Tối ưu hóa mô hình: Tinh chỉnh Hyperparameters (α, β , Learning rate) để cải thiện chỉ số NDCG/Recall.
w45 (03/11 – 09/11)	Xây dựng Demo (FastAPI/ReactJS) và tích hợp nhanh API LLM để giải thích kết quả.
w46 (10/11 – 16/11)	Đánh giá toàn diện hệ thống: So sánh với các baseline và phân tích trường hợp lỗi (Error Analysis).
w47 (17/11 – 23/11)	Tổng hợp kết quả thực nghiệm, vẽ biểu đồ so sánh hiệu năng.
w48 (24/11 – 30/11)	Viết báo cáo chương 1–3 (Lý thuyết, Thiết kế hệ thống).
w49 (01/12 – 07/12)	Viết báo cáo chương 4–5 (Thực nghiệm, Kết luận, Hướng phát triển tương lai).
w50 (08/12 – 14/12)	Rà soát lần cuối và hoàn thiện slide thuyết trình.

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nghĩa đầy đủ (Tiếng Anh / Tiếng Việt)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BERT	Bidirectional Encoder Representations from Transformers (Biểu diễn mã hóa hai chiều từ Transformer)
CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
CTR	Click-Through Rate (Tỷ lệ nhấp chuột)
DL	Deep Learning (Học sâu)
GPT	Generative Pre-trained Transformer (Mô hình Transformer sinh văn bản tiền huấn luyện)
GRU	Gated Recurrent Unit (Đơn vị hồi quy có cổng)
InfoNCE	Info Noise Contrastive Estimation (Hàm mất mát ước lượng tương phản nhiễu)
LLM	Large Language Model (Mô hình ngôn ngữ lớn)
LSTM	Long Short-Term Memory (Bộ nhớ ngắn-dài hạn)
MLP	Multi-Layer Perceptron (Mạng nơ-ron đa lớp)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách gần)
ReLU	Rectified Linear Unit (Đơn vị chỉnh lưu tuyến tính)
RLHF	Reinforcement Learning from Human Feedback (Học tăng cường từ phản hồi con người)
ResSys	Recommender Systems (Hệ thống đề xuất)
RNN	Recurrent Neural Network (Mạng nơ-ron hồi quy)
SASRec	Self-Attentive Sequential Recommendation (Gợi ý tuần tự dựa trên cơ chế tự chú ý)
SFT	Supervised Fine-Tuning (Tinh chỉnh có giám sát)
ViT	Vision Transformer (Mô hình Transformer cho thị giác máy tính)

Contents

Danh mục từ viết tắt	3
1 Tổng quan về đề tài	1
1.1 Lý do chọn đề tài	1
1.2 Mục tiêu đề tài	2
1.3 Đối tượng và Phạm vi nghiên cứu	3
1.4 Định nghĩa bài toán	4
2 Cơ sở lý thuyết	5
2.1 Tổng quan về Hệ thống Gợi ý	5
2.1.1 Lọc dựa trên Nội dung	5
2.1.2 Lọc Cộng tác	6
2.1.3 Hệ thống Gợi ý Lai	8
2.1.4 Kiến trúc Two-Tower	9
2.2 Các Hàm Mục tiêu	11
2.2.1 Binary Cross Entropy	11
2.2.2 Triplet Loss	12
2.2.3 InfoNCE	12
2.3 Biểu diễn Đa phương thức	13
2.3.1 Biểu diễn Văn bản: BERT	13
2.3.2 Biểu diễn Hình ảnh: ViT	15
2.3.3 Cơ chế Hợp nhất Không gian Vector	18
2.4 Nắm bắt chuỗi hành vi trong ResSys	19
2.4.1 Chuỗi Markov trong Gợi ý Tuần tự	19
2.4.2 Mạng Nơ-ron Tái phát	20
2.4.3 Kiến trúc SASRec	22
2.4.4 Kiến trúc Hai tháp cho Truy xuất Ứng viên	23
2.5 Cơ sở Lý thuyết về Mô hình Ngôn ngữ Lớn	25
2.5.1 Tổng quan về Mô hình Ngôn ngữ Lớn	25
2.5.2 Kiến trúc Transformer Decoder-only	25
2.5.3 Quy trình Huấn luyện Mô hình GPT	26
2.5.4 LLM trong Hệ thống Gợi ý	27
3 Phương pháp đề xuất	28
3.1 Kiến trúc tổng thể	28
3.2 Tiền xử lý	30
3.3 Xây dựng Tháp Sản phẩm	34

3.3.1	Text Encoder: Mô-đun Mã hóa Văn bản	35
3.3.2	Image Encoder: Mô-đun Mã hóa Hình ảnh	37
3.3.3	Tabular Encoder: Mô-đun Mã hóa Dữ liệu Bảng	40
3.3.4	Cơ chế Hợp nhất Dữ liệu Đa phương thức (Fusion Gate)	41
3.4	Xây dựng Tháp Người dùng	42
3.4.1	Tổng quan và Nền tảng Kỹ thuật	42
3.4.2	Cơ chế Biểu diễn Người dùng	42
3.5	Chiến lược Huấn luyện	48
3.6	Tích hợp LLM trong Giai đoạn Hậu Truy xuất	50
3.6.1	Quy trình Xử lý Dữ liệu	50
3.6.2	Cấu trúc Prompt Minh họa	51
3.6.3	Vai trò của LLM trong Hệ thống	51
4	Thực nghiệm và Đánh giá	52
4.1	Mô tả tập dữ liệu	52
4.1.1	Tổng quan về nguồn dữ liệu	52
4.1.2	Phân tích chất lượng dữ liệu và Giá trị khuyết	55
4.1.3	Quy trình Tiền xử lý dữ liệu	56
4.1.4	Phân tích độ thừa dữ liệu	58
4.2	Thiết lập thực nghiệm	60
4.2.1	Môi trường phần cứng và phần mềm	60
4.2.2	Cấu hình Siêu tham số	61
4.3	Đầu vào và đầu ra	62
4.3.1	Xây dựng Item Tower	62
4.3.2	Xây dựng User Tower	65
4.4	Các độ đo đánh giá	67
4.4.1	Recall@K	67
4.4.2	MRR@K	68
4.4.3	NDCG@K	68
4.5	Kết quả thực nghiệm	69
4.5.1	Quá trình huấn luyện	69
4.5.2	Kết quả đánh giá chính	71
4.6	Phân tích vai trò từng thành phần	73
4.6.1	Ảnh hưởng của Đa phương thức	73
4.6.2	Phân tích đặc thù miền dữ liệu và Hiệu quả Fusion	73
4.6.3	Hiệu quả của chiến lược Reranking	74
4.7	Triển khai và Thử nghiệm trên Hệ thống thực tế	77
4.7.1	Kiến trúc hệ thống	77
4.7.2	Quy trình xử lý một yêu cầu gợi ý	79
4.7.3	Minh họa hệ thống	80
4.8	Kết luận chương	81
5	Hướng phát triển	82
5.1	Hoàn thiện hệ thống	82
5.1.1	Hiện đại hóa Kiến trúc dữ liệu	82
5.1.2	Tối ưu hóa Backend và Cơ chế suy luận	82
5.1.3	Nâng cao trải nghiệm người dùng	83

5.2	Bổ sung cơ chế Reranking	83
5.2.1	Cơ sở lý thuyết về Cross-Encoder	84
5.2.2	Phương pháp đề xuất và Kiến trúc hệ thống	86
5.3	Kế hoạch thực hiện đề tài	98

Danh sách hình vẽ

2.1	Phương pháp lọc dựa trên nội dung.	5
2.2	Phương pháp lọc cộng tác.	7
2.3	Phương pháp lọc cộng tác.	10
2.4	Quy trình Tiền huấn luyện và Tinh chỉnh của BERT.	14
2.5	Sơ đồ kiến trúc Vision Transformer.	17
2.6	Sơ đồ kiến trúc Multi-Modality Fusion.	18
2.7	Sơ đồ kiến trúc RNN.	21
3.1	Mô hình two-tower	29
3.2	Quá trình Truy xuất sản phẩm	30
3.3	Kiến trúc Item Tower: Quy trình mã hóa và hợp nhất dữ liệu Đa phương thức	35
3.4	Quy trình Tính toán và Tổng hợp Đặc trưng Hình ảnh	39
3.5	Minh họa trực quan giá trị Positional Encoding trên 4 chiều ẩn đầu tiên. Các đường cong hình sin với tần số khác nhau giúp mô hình phân biệt vị trí trong chuỗi.	45
3.6	Kiến trúc chi tiết Tháp Người dùng với cơ chế mô hình hóa chuỗi đa phương thức.	47
4.1	Diễn biến hàm mất mát trong quá trình huấn luyện Item Tower	69
4.2	Diễn biến hàm mất mát trong quá trình huấn luyện User Tower	70
4.3	Biểu đồ trực quan hóa hiệu năng các độ đo tại Top-10 và Top-20	72
4.4	Kiến trúc hệ thống gợi ý Two-Tower triển khai thực tế	78
4.5	Giao diện hiển thị kết quả tìm kiếm	80
4.6	Log xử lý thời gian thực tại Backend	80
5.1	Sơ đồ kiến trúc Cross-Encoder với đầu vào ghép đôi và đầu ra phân loại	84
5.2	Sơ đồ so sánh kiến trúc giữa Bi-Encoder (trái) và Cross-Encoder (phải) .	85
5.3	Sơ đồ quy trình phễu lọc hai giai đoạn: Từ hàng triệu sản phẩm xuống Top 10	86
5.4	Sơ đồ quy trình Knowledge Distillation: Mô hình Student học cách mô phỏng phân phối xác suất (Logits) của Teacher.	87
5.5	Tổng quan kiến trúc Deep Self-Attention Distillation của MiniLM.	89
5.6	Quy trình phát triển mô hình: Từ kiến trúc MiniLM gốc, qua bước tinh chỉnh (Fine-tuning) trên dữ liệu MS MARCO để tạo thành Cross-Encoder hoàn chỉnh.	92

Danh sách bảng

1	Bảng phân công vai trò và nhiệm vụ chi tiết của nhóm	1
2	Kế hoạch thực hiện đề tài	2
3.1	Các loại Mặt nạ sử dụng trong cơ chế Attention	34
3.2	Minh họa cơ chế In-batch Negatives với Batch size = 3	49
4.1	Mô tả chi tiết các trường thông tin trong tập dữ liệu User Reviews	53
4.2	Mô tả chi tiết các trường thông tin trong tập dữ liệu Item Metadata	54
4.3	Thống kê tỷ lệ dữ liệu khuyết trên Item Metadata	55
4.4	Thống kê tập dữ liệu Amazon Gift Cards sau khi tiền xử lý	58
4.5	Cấu hình siêu tham số cho Item Tower	62
4.6	Cấu hình siêu tham số cho User Tower	62
4.7	Đặc tả luồng dữ liệu và kích thước trong Text Encoder	63
4.8	Đặc tả luồng dữ liệu và kích thước trong Image Encoder	64
4.9	Đặc tả luồng dữ liệu trong Tabular Encoder	64
4.10	Đặc tả các luồng dữ liệu đầu vào cho User Tower	66
4.11	Kết quả đánh giá hiệu năng mô hình Hybrid trên tập Test	71
4.12	Hiệu năng mô hình theo từng phương thức đầu vào	73
4.13	Tác động của trọng số α và β lên độ chính xác	76
5.1	Ví dụ mẫu dữ liệu Triplet trong MS MARCO với Hard Negative	91
5.2	Ví dụ minh họa và chiến lược gán nhãn nhị phân cho ESCI	93
5.3	Ví dụ minh họa và chiến lược gán nhãn nhị phân cho ESCI	93
5.4	Ví dụ minh họa quy trình sinh dữ liệu tổng hợp từ Review	95
5.5	Kế hoạch thực hiện đề tài (15 Tuần)	98

Chương 1

Tổng quan về đề tài

Nội dung chương 1 trình bày sơ lược về đề tài, bối cảnh hiện nay và làm rõ lý do đề tài được chọn. Từ đó, xác định mục tiêu cần đạt được khi thực hiện và phạm vi của đề tài.

1.1 Lý do chọn đề tài

Trong bối cảnh nền kinh tế số toàn cầu đang bước vào giai đoạn phát triển bùng nổ, việc lựa chọn nghiên cứu đề tài Hệ thống gợi ý sản phẩm trên các sàn thương mại điện tử xuất phát từ sự hội tụ của ba động lực chính: tính cấp thiết của thị trường, giá trị kinh tế khổng lồ và bước ngoặt công nghệ mang tính cách mạng. Chúng ta đang sống trong một kỷ nguyên mà khả năng sản xuất và cung ứng hàng hóa đã vượt xa khả năng xử lý thông tin của con người. Với doanh số thương mại điện tử toàn cầu ước tính đạt 6,33 nghìn tỷ USD vào năm 2024 và dự kiến tiếp tục tăng trưởng lên 6,86 nghìn tỷ USD vào năm 2025, người tiêu dùng đang bị bủa vây bởi một biển hàng hóa. Đặc biệt, khi thương mại di động chiếm tới 57% tổng doanh số và dự báo đạt 2,51 nghìn tỷ USD vào năm 2025, không gian hiển thị trên màn hình điện thoại trở nên vô cùng khan hiếm [1]. Sự mâu thuẫn giữa số lượng sản phẩm khổng lồ và giới hạn nhận thức của người dùng đã tạo ra nhu cầu bức thiết cho những cơ chế lọc thông minh, có khả năng thấu hiểu và dự đoán nhu cầu trước khi người dùng nhận thức được chúng.

Về mặt kinh tế, hệ thống gợi ý đã chuyển mình từ một tính năng phụ trợ trở thành động cơ doanh thu quyết định sự sống còn của doanh nghiệp. Các dữ liệu thực nghiệm từ những tập đoàn công nghệ hàng đầu đã minh chứng rõ nét cho luận điểm này. Amazon, gã khổng lồ bán lẻ trực tuyến, tạo ra tới 35% tổng doanh thu từ các cơ chế gợi ý cá nhân hóa [2]. Trong lĩnh vực nội dung số, Netflix tiết kiệm khoảng 1 tỷ USD mỗi năm và giữ chân người dùng nhờ vào hệ thống gợi ý đóng góp tới 75-80% thời lượng xem [2]. Đối với các doanh nghiệp vừa và nhỏ, việc áp dụng cá nhân hóa bằng AI có thể giúp tăng doanh thu từ 10-40% và cải thiện tỷ lệ chuyển đổi trung bình khoảng 26% [3]. Ngược lại, sự thiếu vắng một hệ thống gợi ý hiệu quả dẫn đến cái giá rất đắt: hiện tượng bỏ dở tìm kiếm xảy ra ngày càng nhiều, khi người dùng rời bỏ trang web vì không tìm thấy sản phẩm ưng ý, đang gây thiệt hại cho ngành bán lẻ toàn cầu hơn 2.000 tỷ USD mỗi năm [4]. Do đó, nghiên cứu xây dựng hệ thống gợi ý không chỉ là bài toán kỹ thuật mà là giải pháp tối ưu hóa dòng tiền và lợi nhuận thiết yếu.

Xét trên khía cạnh tâm lý học hành vi, đề tài này giải quyết vấn đề cốt lõi của người tiêu dùng hiện đại: sự tê liệt khi lựa chọn. Các nghiên cứu chỉ ra rằng khi đối mặt với quá nhiều tùy chọn, não bộ con người rơi vào trạng thái mệt mỏi nhận thức, dẫn đến việc trì hoãn hoặc từ bỏ mua sắm. Hơn nữa, hành vi người dùng đang chuyển dịch mạnh mẽ từ tìm kiếm dựa trên từ khóa sang khám phá dựa trên gợi ý, đặc biệt là tại các thị trường mới nổi như Việt Nam. Với quy mô thị trường thương mại điện tử Việt Nam, doanh thu của bốn nền tảng thương mại điện tử Shopee, TikTok Shop, Lazada và Tiki trong quý I 2024 là 79,12 nghìn tỷ đồng, trong đó TikTok Shop chiếm lĩnh 23,2% thị phần chỉ sau thời gian ngắn[17], người tiêu dùng ngày càng mong đợi các trải nghiệm mua sắm mang tính giải trí, ngẫu hứng và được cá nhân hóa cao độ. Hệ thống gợi ý chính là chìa khóa để đáp ứng kỳ vọng này, đóng vai trò như một người trợ lý ảo thấu hiểu tâm lý, giúp điều hướng người dùng trong mê cung hàng hóa và kích thích hành vi mua sắm.

Cuối cùng, lý do quan trọng để thực hiện đề tài này ngay tại thời điểm hiện tại nằm ở sự tiến hóa vượt bậc của công nghệ. Lĩnh vực hệ thống gợi ý đang trải qua một cuộc cách mạng với sự xuất hiện của Generative AI và các Mô hình ngôn ngữ lớn. Các phương pháp truyền thống như Lọc cộng tác đang dần bộc lộ hạn chế trong việc xử lý vấn đề khởi động lạnh và thiếu khả năng giải thích lý do gợi ý. Sự tích hợp LLM vào hệ thống gợi ý đang mở ra hướng đi mới, cho phép hệ thống không chỉ phân tích hành vi click chuột mà còn đọc hiểu được ý định của người dùng thông qua ngôn ngữ tự nhiên, giúp cải thiện các chỉ số dự đoán quan trọng như AUC lên tới 5% và NDCG lên tới 170% trong các tác vụ gợi ý tuần tự [5]. Hơn thế nữa, sự phát triển của các AI Agents trong năm 2025 hứa hẹn đưa cá nhân hóa lên một tầm cao mới, nơi AI có thể tự chủ lập kế hoạch và thực hiện các tác vụ mua sắm phức tạp thay cho con người.

Hệ thống gợi ý sản phẩm trong sàn thương mại điện tử đang là một lựa chọn mang tính chiến lược, đón đầu xu hướng công nghệ của giai đoạn 2025-2026. Nó không chỉ có ý nghĩa khoa học trong việc ứng dụng các thành tựu AI mới nhất mà còn mang lại giá trị thực tiễn to lớn, giúp giải quyết bài toán hiệu quả kinh doanh cho doanh nghiệp và nâng cao trải nghiệm cho người tiêu dùng trong nền kinh tế số.

1.2 Mục tiêu đề tài

Từ những lợi ích thiết thực trên, nhóm đã lên kế hoạch thực hiện một hệ thống gợi ý sản phẩm thông minh thể hệ mới cho thương mại điện tử, hoạt động như một trợ lý mua sắm ảo có khả năng thấu hiểu đa chiều. Hệ thống nhằm giải quyết bài toán quá tải lựa chọn của người tiêu dùng, giúp người dùng tìm được sản phẩm ưng ý nhanh nhất với ít thao tác nhất.

Để đạt được mục tiêu tổng quát nêu trên, nhóm nghiên cứu tập trung vào việc xây dựng khả năng thấu hiểu dữ liệu đa phương thức, khắc phục hạn chế của các hệ thống truyền thống vốn chỉ dựa trên từ khóa hoặc định danh sản phẩm. Hệ thống được thiết kế để xử lý và trích xuất đặc trưng sâu từ cả hình ảnh và văn bản mô tả chi tiết, cho phép nhận diện chính xác các yếu tố về kiểu dáng, màu sắc và phong cách để đưa ra các gợi ý có độ tương đồng cao về mặt thị giác và ngữ nghĩa. Bên cạnh đó, đề tài cũng chú trọng thiết lập cơ chế theo dõi và phân tích chuỗi tương tác thời gian thực, giúp hệ thống nắm bắt được sở thích nhất thời và sự thay đổi trong gu thẩm mỹ của người dùng, đảm bảo các

sản phẩm được đề xuất luôn phù hợp với ý định mua sắm tại thời điểm hiện tại.

Trong quá trình xác định giải pháp công nghệ cho hệ thống, nhóm nghiên cứu đã tiến hành phân tích và so sánh kỹ lưỡng giữa các hướng tiếp cận phổ biến hiện nay nhằm tìm ra phương án tối ưu nhất. Đối với các phương pháp truyền thống như Lọc cộng tác hay Lọc theo nội dung, ưu điểm nằm ở sự đơn giản và chi phí tính toán thấp, tuy nhiên chúng bộc lộ nhược điểm chí mạng về vấn đề khởi động lạnh cũng như khả năng xử lý dữ liệu thưa kém, dẫn đến việc không thể đưa ra gợi ý chính xác cho người dùng mới hoặc sản phẩm mới chưa có lịch sử tương tác. Trong khi đó, các mô hình học sâu thuần túy tuy cải thiện được độ chính xác nhờ khả năng nắm bắt các mối quan hệ phi tuyến tính trong chuỗi hành vi, nhưng lại thường hạn chế trong việc hiểu sâu ngữ nghĩa đa phương thức của hình ảnh và văn bản, đồng thời hoạt động như một hộp đen thiếu tính minh bạch. Riêng đối với các Mô hình ngôn ngữ lớn (LLMs), mặc dù sở hữu năng lực thấu hiểu ngữ cảnh và suy luận ý định vượt trội, nhưng việc triển khai độc lập cho toàn bộ quy trình lại vấp phải rào cản lớn về chi phí tính toán khổng lồ và độ trễ cao, khiến chúng trở nên kém khả thi khi phải xử lý xếp hạng hàng triệu sản phẩm trong thời gian thực. Chính vì những lý do trên, nhóm quyết định lựa chọn giải pháp kiến trúc lai hiện đại, kết hợp mô hình Two-Tower đóng vai trò bộ lọc sơ cấp để tối ưu hóa khả năng truy xuất ứng viên tốc độ cao, song hành cùng khả năng thấu hiểu sâu của LLM và RAG ở tầng tinh chỉnh. Lựa chọn này được đánh giá là ưu việt nhất vì nó đạt được sự cân bằng lý tưởng: vừa đảm bảo hiệu năng vận hành nhanh chóng của hệ thống lớn, vừa tận dụng được trí tuệ của AI để giải quyết bài toán khởi động lạnh và cá nhân hóa trải nghiệm người dùng một cách chính xác nhất.

1.3 Đối tượng và Phạm vi nghiên cứu

Đối tượng nghiên cứu trung tâm của đề tài là các hệ thống gợi ý thể hệ mới trong thương mại điện tử, phản ánh xu hướng chuyển dịch mạnh mẽ từ các phương pháp lọc cộng tác dựa trên định danh đơn thuần sang các mô hình học sâu có khả năng nhận thức ngữ cảnh. Cụ thể, đề tài đi sâu vào phân tích ba khía cạnh cốt lõi cấu thành nên hệ thống. Đầu tiên là việc mô hình hóa chuỗi hành vi người dùng, tập trung khai thác sự diễn biến động của sở thích theo trục thời gian thông qua các trình tự tương tác liên tục như xem, mua hay đánh giá nhằm nắm bắt quy luật chuyển đổi nhu cầu ngắn hạn và dài hạn. Song song với đó là nghiên cứu cơ chế biểu diễn tri thức sản phẩm đa phương thức, cho phép máy tính thực sự thấu hiểu nội dung hàng hóa nhờ việc hợp nhất các luồng thông tin phức tạp từ thị giác, ngôn ngữ đến dữ liệu cấu trúc thay vì chỉ coi sản phẩm là các mã định danh vô nghĩa. Cuối cùng, đề tài tập trung vào cơ chế suy luận và xếp hạng lại, trong đó ứng dụng các Mô hình ngôn ngữ lớn như những tác nhân thông minh để đánh giá lại độ phù hợp dựa trên ngữ cảnh truy vấn phức tạp, qua đó đảm bảo kết quả gợi ý đạt được tính chính xác cao đi kèm với sự minh bạch trong lý do đề xuất.

Phạm vi thực hiện của đề tài được xác định rõ ràng thông qua ba khía cạnh chính bao gồm không gian ứng dụng, dữ liệu, công nghệ. Về không gian, nghiên cứu tập trung vào bối cảnh các nền tảng Thương mại điện tử, nơi dữ liệu thường mang đặc thù thưa thớt và chứa nhiều nhiễu, với mục tiêu tối ưu hóa trải nghiệm khám phá cho người dùng cuối. Để thực hiện điều này, đề tài giới hạn phạm vi dữ liệu vào việc khai thác nguồn thông tin đa phương thức phong phú, kết hợp chặt chẽ giữa dữ liệu phi cấu trúc như văn bản mô tả, hình ảnh sản phẩm và dữ liệu có cấu trúc gồm lịch sử tương tác gắn nhãn thời gian. Trên

nền tảng đó, nghiên cứu ứng dụng các công nghệ tiên tiến của Trí tuệ nhân tạo, trọng tâm là kỹ thuật Học sâu để trích xuất đặc trưng và các Mô hình ngôn ngữ lớn giúp thấu hiểu ý định người dùng.

1.4 Định nghĩa bài toán

Bài toán cụ thể được đặt ra trong nghiên cứu này là bài toán dự đoán và xếp hạng tuần tự dựa trên dữ liệu đa phương thức, nơi hệ thống phải đối mặt với thách thức xác định chính xác nhu cầu tiếp theo của người dùng trong không gian tìm kiếm khổng lồ của thương mại điện tử. Cụ thể, với đầu vào là chuỗi lịch sử tương tác biến thiên theo thời gian thực kết hợp cùng dữ liệu định danh và nội dung phong phú của sản phẩm như hình ảnh hay mô tả, nhiệm vụ đặt ra là xây dựng một hàm mục tiêu tối ưu có khả năng xếp hạng hàng triệu ứng viên sao cho các sản phẩm ở vị trí đầu tiên có xác suất tương thích lớn nhất với ý định hiện tại của khách hàng. Điểm mấu chốt của bài toán không chỉ dừng lại ở việc khớp lệnh hành vi quá khứ, mà còn phải giải quyết triệt để mâu thuẫn giữa tính thừa thớt của dữ liệu tương tác và sự phong phú của dữ liệu ngữ nghĩa, đặc biệt trong các kịch bản khởi động lạnh khi thông tin hành vi hoàn toàn vắng bóng. Do đó, bài toán yêu cầu một cơ chế suy luận phức hợp, có khả năng chuyển đổi các tín hiệu phi cấu trúc thành các biểu diễn vector đồng nhất trong không gian tiềm ẩn để lấp đầy khoảng trống thông tin mà các phương pháp dựa trên ID truyền thống không thể xử lý được.

Quy trình vận hành tổng thể của hệ thống được thiết kế theo kiến trúc đường ống xử lý dữ liệu phân tầng, khởi tạo từ việc tiếp nhận đầu vào phức hợp bao gồm hồ sơ người dùng, chuỗi lịch sử tương tác thời gian thực và dữ liệu đa phương thức của sản phẩm như hình ảnh, mô tả văn bản chi tiết. Luồng thông tin này trước tiên được đưa qua tầng mã hóa đặc trưng để chuyển đổi thành các vector biểu diễn trong không gian tiềm ẩn, phục vụ cho giai đoạn truy xuất ứng viên. Tại đây, mô hình Two-Tower đóng vai trò bộ lọc sơ cấp, thực hiện quét nhanh trên không gian dữ liệu quy mô lớn để sàng lọc ra một tập hợp nhỏ các sản phẩm tiềm năng nhất dựa trên độ tương đồng vector. Ngay sau đó, tập ứng viên này được chuyển tiếp đến phân hệ Mô hình ngôn ngữ lớn để thực hiện bước tinh chỉnh thứ cấp và tái xếp hạng dựa trên sự thấu hiểu ngữ nghĩa sâu sắc cũng như ngữ cảnh cụ thể của phiên mua sắm hiện tại. Kết quả đầu ra cuối cùng của hệ thống là một danh sách xếp hạng các sản phẩm có độ phù hợp cao nhất với ý định người dùng, được hiển thị trực quan đi kèm với các thông tin giải thích ngữ nghĩa minh bạch, giúp tối ưu hóa quyết định mua hàng một cách chính xác và thuyết phục.

Chương 2

Cơ sở lý thuyết


Chương 2 trình bày các cơ sở lý thuyết và các nghiên cứu liên quan đến quá trình xây dựng hệ thống.

2.1 Tổng quan về Hệ thống Gợi ý

Hệ thống gợi ý, hay còn được gọi là Recommender Systems - ResSys, được định nghĩa là một phân lớp của hệ thống lọc thông tin, có nhiệm vụ dự đoán mức độ quan tâm hoặc khả năng tương tác của người dùng đối với các thực thể. Dựa trên phương pháp tiếp cận dữ liệu, các hệ thống gợi ý truyền thống và hiện đại thường được phân loại thành ba nhóm chính: Lọc dựa trên nội dung, Lọc cộng tác và Hệ thống lai.

2.1.1 Lọc dựa trên Nội dung

Phương pháp Lọc theo nội dung vận hành dựa trên nguyên lý cốt lõi về sự nhất quán trong sở thích của người dùng: nếu một khách hàng đã thể hiện sự quan tâm đến một sản phẩm cụ thể trong quá khứ, họ sẽ có xu hướng yêu thích các sản phẩm mang những đặc tính tương tự. Khác với các phương pháp dựa trên đám đông, thuật toán này hoạt động độc lập với hành vi của những người dùng khác, tập trung hoàn toàn vào việc khai thác mối tương quan giữa hồ sơ định danh của sản phẩm và hồ sơ sở thích của người dùng.



Hình 2.1: Phương pháp lọc dựa trên nội dung.

Phần này trình bày các nguyên lý cơ bản và kiến trúc của hệ thống lọc theo nội dung, được tổng hợp và tham khảo chính từ nghiên cứu của Gediminas và Alexander[18].


Về cơ chế kỹ thuật, quy trình bắt đầu bằng việc xây dựng biểu diễn vector cho từng sản phẩm. Hệ thống tiến hành trích xuất các đặc trưng nội tại từ dữ liệu thô, thường là các dữ liệu văn bản, các kỹ thuật xử lý ngôn ngữ tự nhiên từ cơ bản như TF-IDF đến nâng cao như Word Embeddings được áp dụng để chuyển đổi từ ngữ thành các vector số học. Song song đó, chân dung người dùng được phác họa như một vector tổng hợp, thường được tính toán bằng trung bình trọng số của các vector sản phẩm mà họ đã tương tác. Để đưa ra gợi ý, hệ thống tính toán độ tương đồng giữa vector người dùng và vector sản phẩm ứng viên trong không gian nhiều chiều, phổ biến nhất là sử dụng độ đo Cosine Similarity.

Ưu điểm nổi bật và quan trọng nhất của phương pháp này là khả năng giải quyết bài toán Khô động lạnh cho sản phẩm. Trong môi trường thương mại điện tử nơi hàng nghìn sản phẩm mới được nhập kho mỗi ngày, các phương pháp lọc cộng tác sẽ thất bại vì không có dữ liệu lịch sử mua hàng. Ngược lại, lọc theo nội dung có thể đề xuất các sản phẩm này ngay lập tức chỉ dựa vào các thuộc tính sẵn có như danh mục, thương hiệu hay mô tả. Bên cạnh đó, tính giải thích của mô hình rất cao; hệ thống có thể minh bạch hóa lý do gợi ý cho người dùng bằng các thông điệp trực quan như "Gợi ý vì bạn thích các sản phẩm màu đỏ" hoặc "Tương tự với chiếc áo len bạn vừa xem", giúp xây dựng lòng tin và tăng tỷ lệ chuyển đổi.

Tuy nhiên, phương pháp này tồn tại những hạn chế mang tính hệ thống, đáng kể nhất là vấn đề Overspecialization. Do thuật toán chỉ tập trung tìm kiếm các sản phẩm có đặc điểm giống với quá khứ, nó triệt tiêu khả năng khám phá của người dùng. Một khách hàng vừa mua điện thoại sẽ liên tục nhận được gợi ý về điện thoại khác thay vì các phụ kiện liên quan, dẫn đến trải nghiệm nhàm chán và thiếu sự đa dạng. Thêm vào đó, thách thức về Khoảng cách ngữ nghĩa cũng là một rào cản lớn; việc trích xuất đặc trưng thủ công hoặc dùng các mô hình nông thường không nắm bắt được ý nghĩa sâu sắc của dữ liệu phi cấu trúc (ví dụ: không phân biệt được sự khác nhau về phong cách giữa hai chiếc áo cùng màu), đòi hỏi sự đầu tư lớn vào các mô hình Học sâu phức tạp để cải thiện độ chính xác.

2.1.2 Lọc Cộng tác

Lọc cộng tác được xem là một trong những kỹ thuật nền tảng và thành công nhất trong lịch sử phát triển của hệ thống gợi ý. Nguyên lý cốt lõi của phương pháp này dựa trên giả định xã hội học về sự đồng nhất hành vi, nghĩa là những người dùng có xu hướng đánh giá tương tự nhau đối với các sản phẩm trong quá khứ sẽ có khả năng cao chia sẻ cùng một sở thích trong tương lai. Điểm khác biệt căn bản so với phương pháp lọc theo nội dung là việc hoàn toàn bỏ qua các đặc tính nội tại của sản phẩm như màu sắc, thương hiệu hay mô tả chi tiết. Thay vào đó, thuật toán tập trung khai thác toàn diện ma trận tương tác giữa người dùng và sản phẩm. Dữ liệu đầu vào của hệ thống có thể là phản hồi hiện như điểm đánh giá hoặc phản hồi ẩn như lịch sử truy cập và lượt thêm vào giỏ hàng, cho phép mô hình hoạt động hiệu quả ngay cả trong những lĩnh vực mà việc phân tích nội dung là bất khả thi hoặc tốn kém.



Hình 2.2: Phương pháp lọc cộng tác.

Nội dung trong mục này được tổng hợp dựa trên các định nghĩa nền tảng trong nghiên cứu của Gediminas và Alexander[18]

Về mặt kỹ thuật, các thuật toán lọc cộng tác được phân chia thành hai nhánh tiếp cận chính, trong đó nhánh dựa trên bộ nhớ là hướng đi cổ điển nhất. Phương pháp này sử dụng toàn bộ cơ sở dữ liệu để tính toán độ tương đồng trực tiếp giữa các đối tượng thông qua thuật toán láng giềng gần nhất. Có hai biến thể phổ biến là lọc dựa trên người dùng nhằm tìm kiếm những cá nhân có sở thích tương đồng để gợi ý chéo cho nhau, và lọc dựa trên sản phẩm nhằm tìm kiếm các mặt hàng thường xuyên được tiêu thụ cùng nhau bởi một nhóm người. Độ tương đồng trong phương pháp này thường được định lượng bằng các công thức toán học như hệ số tương quan Pearson hoặc độ tương đồng Cosine trên các vector hàng hoặc cột của ma trận dữ liệu.

Để khắc phục các hạn chế về khả năng mở rộng của phương pháp dựa trên bộ nhớ, nhánh tiếp cận dựa trên mô hình đã ra đời và trở thành tiêu chuẩn cho các hệ thống hiện đại. Thay vì tính toán trực tiếp trên dữ liệu thô, phương pháp này ứng dụng các kỹ thuật học máy tiên tiến như phân rã ma trận hay các mạng nơ-ron sâu. Cơ chế hoạt động chủ yếu là nén ma trận tương tác khổng lồ ban đầu thành các ma trận nhỏ hơn trong một không gian ẩn có số chiều thấp. Tại không gian này, mỗi người dùng và sản phẩm được đại diện bởi một vector ẩn và mức độ yêu thích được dự đoán thông qua tích vô hướng của hai vector đó. Cách tiếp cận này không chỉ giúp giảm tải khối lượng tính toán mà còn có khả năng nắm bắt được các mẫu tiềm ẩn phức tạp trong dữ liệu hành vi.

Sức mạnh vượt trội của lọc cộng tác nằm ở khả năng mang lại tính khám phá ngẫu nhiên cao cho người dùng. Do không phụ thuộc vào nội dung, hệ thống có thể đề xuất những sản phẩm hoàn toàn mới lạ hoặc thuộc các danh mục khác nhau mà người dùng chưa từng nghĩ đến, miễn là cộng đồng có cùng sở thích đánh giá cao. Tuy nhiên, phương pháp này đối mặt với những rào cản kỹ thuật nghiêm trọng như vấn đề khởi động lạnh và tính thưa thớt của dữ liệu. Hệ thống gần như mất khả năng dự đoán khi đối mặt với người dùng mới hoặc sản phẩm mới do thiếu lịch sử tương tác để tính toán độ tương đồng. Đồng thời, trong các hệ thống thương mại điện tử lớn với hàng triệu sản phẩm, ma trận tương tác thường có mật độ dữ liệu rất thấp, khiến việc tìm kiếm láng giềng chính xác trở nên

khó khăn và dễ dẫn đến sai số lớn nếu không có các kỹ thuật xử lý chuyên biệt.

2.1.3 Hệ thống Gợi ý Lai

Sự ra đời của hệ thống gợi ý lai đánh dấu bước phát triển quan trọng nhằm khắc phục các hạn chế cố hữu khi triển khai độc lập phương pháp lọc cộng tác hoặc lọc dựa trên nội dung. Mục tiêu cốt lõi của hướng tiếp cận này là tối ưu hóa hiệu suất dự đoán thông qua việc tổng hợp sức mạnh từ cả dữ liệu hành vi người dùng và các thông tin đặc tả phong phú của sản phẩm. Trong giai đoạn trước khi học sâu trở nên phổ biến, các kiến trúc lai truyền thống thường được áp dụng dựa trên ba chiến lược kết hợp chủ đạo nhằm dung hòa các thuật toán nền tảng.

Đầu tiên là phương pháp lai trọng số, được xem là kỹ thuật cộng gộp đơn giản nhất trong các mô hình lai. Cơ chế vận hành của nó dựa trên việc triển khai song song các mô hình thành phần, sau đó tính toán điểm số xếp hạng cuối cùng bằng tổng có trọng số của các kết quả dự đoán riêng lẻ[18]. Mặc dù ưu điểm là dễ triển khai, phương pháp này gặp hạn chế lớn do giả định mỗi quan hệ giữa các mô hình luôn là tuyến tính và đòi hỏi quá trình tinh chỉnh tham số thủ công rất kỹ lưỡng để cân bằng hiệu quả giữa các thành phần.

Chiến lược thứ hai là phương pháp lai chuyển đổi, hoạt động tương tự như một cơ chế điều hướng thông minh dựa trên trạng thái dữ liệu thực tế. Hệ thống sẽ linh hoạt lựa chọn thuật toán phù hợp nhất cho từng ngữ cảnh cụ thể, điển hình là việc ưu tiên sử dụng lọc theo nội dung đối với người dùng mới để giải quyết vấn đề khởi động lạnh, sau đó tự động chuyển sang lọc cộng tác khi đã thu thập đủ lịch sử tương tác tin cậy[18]. Tuy nhiên, nhược điểm của chiến lược này nằm ở sự thiếu tính liên tục, dẫn đến trải nghiệm gợi ý có thể bị đứt gãy hoặc thiếu sự mượt mà trong quá trình chuyển giao giữa các mô hình.

Chiến lược kết hợp đặc trưng đại diện cho một bước chuyển dịch quan trọng trong kiến trúc hệ thống gợi ý lai, nơi ranh giới giữa dữ liệu nội dung và dữ liệu hành vi được xóa bỏ để hướng tới một không gian biểu diễn thống nhất. Khác với các phương pháp lai ghép lỏng lẻo như lai trọng số hay lai chuyển đổi vốn xử lý các mô hình thành phần một cách độc lập, phương pháp này chủ động hợp nhất các nguồn thông tin ngay từ giai đoạn đầu vào. Mục tiêu cốt lõi là làm giàu không gian đặc trưng, cho phép thuật toán học được sự tương quan chéo giữa các đặc tính nội tại của sản phẩm với hành vi tương tác của người dùng, thay vì chỉ dựa vào các mã định danh thừa thớt.

Kế thừa và phát triển tư duy này để giải quyết triệt để bài toán khởi động lạnh, Kula[20] đã giới thiệu mô hình LightFM, một kiến trúc lai hiệu quả kết hợp ưu điểm của cả lọc cộng tác và lọc theo nội dung. Điểm đột phá của LightFM nằm ở cơ chế biểu diễn vector linh hoạt, trong đó biểu diễn của một người dùng hoặc sản phẩm được xác định bằng tổng các vector nhúng của định danh và các vector nhúng của các thuộc tính mô tả đi kèm. Nhờ cơ chế cộng gộp này, hệ thống có khả năng suy luận độ tương đồng dựa trên các đặc điểm chung ngay cả khi sản phẩm đó chưa từng có lịch sử tương tác, đảm bảo luồng gợi ý được duy trì liên tục và chính xác cho các thực thể mới.

Tuy nhiên, mặc dù các phương pháp kết hợp đặc trưng như Factorization Machines hay LightFM đã đạt được những thành công nhất định, chúng vẫn tồn tại những hạn chế về khả năng biểu diễn các mẫu dữ liệu phức tạp. Như Cheng và cộng sự[21] đã phân tích trong công trình về kiến trúc Wide & Deep, các mô hình dựa trên tích vô hướng hoặc biến đổi tuyến tính thường thiên về khả năng ghi nhớ các mẫu đồng xuất hiện trong quá khứ nhưng lại hạn chế trong việc tổng quát hóa các mối quan hệ phi tuyến tính mức cao.

Nhận định này đã mở đường cho sự phát triển của các kiến trúc mạng nơ-ron sâu hiện đại, nơi các lớp ẩn đa tầng được sử dụng để trích xuất và kết hợp đặc trưng một cách tinh vi hơn nhằm thấu hiểu sâu sắc ý định người dùng.

2.1.4 Kiến trúc Two-Tower

Mặc dù các mô hình lai kết hợp đặc trưng như LightFM đã giải quyết được phần nào bài toán khởi động lạnh, chúng vẫn bộc lộ những hạn chế căn bản về năng lực biểu diễn khi phải đối mặt với các tập dữ liệu đa chiều phức tạp. Bản chất toán học của các phương pháp này chủ yếu dựa trên phép biến đổi tuyến tính và tích vô hướng đơn giản, dẫn đến việc thiếu hụt khả năng nắm bắt các mối quan hệ phi tuyến tính tinh vi giữa hành vi người dùng và các thuộc tính sản phẩm đa phương thức. Nhận thức rõ ràng cảnh kỹ thuật này, nhóm nghiên cứu quyết định lựa chọn và triển khai kiến trúc Two-Tower hiện đại, dựa trên nền tảng lý thuyết vững chắc được Xinyang Yi và các cộng sự đề xuất trong công trình nghiên cứu về hệ thống gợi ý quy mô lớn[8].

Kiến trúc Two-Tower, hay còn được biết đến với tên gọi mạng nơ-ron tháp đôi, là một mô hình học sâu tiên tiến được thiết kế chuyên biệt cho bài toán truy xuất thông tin và gợi ý quy mô lớn. Nguyên lý vận hành cốt lõi của kiến trúc này nằm ở cơ chế ánh xạ song song, trong đó hai thực thể người dùng và sản phẩm được xử lý bởi hai mạng nơ-ron độc lập để chuyển đổi từ dữ liệu thô ban đầu thành các vector biểu diễn trong cùng một không gian tiềm ẩn chung. Đặc điểm định danh quan trọng nhất của mô hình là sự tách biệt hoàn toàn về mặt cấu trúc xử lý giữa hai luồng dữ liệu cho đến tận lớp tính toán cuối cùng, cho phép hệ thống tối ưu hóa tốc độ truy vấn và khả năng lưu trữ.


Về mặt cấu trúc chi tiết, hệ thống được phân tách thành hai nhánh xử lý riêng biệt nhưng đồng bộ. Tháp người dùng (User Tower) đảm nhận nhiệm vụ tổng hợp toàn diện thông tin liên quan đến khách hàng, xử lý nguồn dữ liệu lai ghép đa dạng từ định danh, các đặc điểm nhân khẩu học tĩnh như tuổi tác, giới tính cho đến các yếu tố ngữ cảnh động như thiết bị truy cập hay thời gian thực. Quan trọng hơn, tháp này còn chịu trách nhiệm mã hóa chuỗi lịch sử hành vi quá khứ để nắm bắt sở thích dài hạn, với kết quả đầu ra là một vector nhúng $\mathbf{u}$ đại diện trọn vẹn cho chân dung và ý định của người dùng. Ở phía đối diện, Tháp sản phẩm (Item Tower) tập trung xử lý các luồng dữ liệu đa phương thức phong phú của hàng hóa. Thay vì chỉ dựa vào mã sản phẩm đơn thuần, tháp này tích hợp các mạng nơ-ron chuyên sâu như BERT để hiểu văn bản mô tả hay CNN và Vision Transformers để trích xuất đặc trưng thị giác từ hình ảnh, kết hợp cùng thông tin danh mục và giá cả để tạo ra vector biểu diễn sản phẩm $\mathbf{v}$.

Cơ chế hoạt động của mô hình dựa trên nguyên tắc tối ưu hóa hình học trong không gian vector, với mục tiêu huấn luyện là cực đại hóa sự tương đồng giữa vector người dùng và vector của các sản phẩm mà họ quan tâm, đồng thời cực tiểu hóa khoảng cách với các sản phẩm không phù hợp. Độ tương thích hay điểm số gợi ý giữa một cặp người dùng và sản phẩm cụ thể được định lượng trực tiếp thông qua phép tính tích vô hướng (Dot Product) hoặc độ tương đồng Cosine giữa hai vector đầu ra của hai tháp:

$$Score(\mathbf{u}, \mathbf{v}) = \mathbf{u}^T \cdot \mathbf{v} \quad (2.1)$$

Chính nhờ cơ chế này, Two-Tower thể hiện khả năng lai ghép vượt trội khi không tách rời máy móc giữa lọc cộng tác và lọc theo nội dung. Mô hình học được một biểu diễn tổng quát nhất quán, trong đó vector người dùng là sự tổng hòa tinh tế giữa thói quen hành vi

trong quá khứ và các đặc điểm hồ sơ cá nhân, tạo tiền đề cho các dự đoán chính xác và mang tính cá nhân hóa cao ngay cả trong bối cảnh dữ liệu phức tạp.



Hình 2.3: Phương pháp lọc cộng tác.

Hình 2.3 minh họa kiến trúc mạng nơ-ron hai nhánh chuyên biệt cho bài toán truy xuất của YouTube [8] với cấu trúc vận hành song song giữa hai khối xử lý độc lập nhằm tối ưu hóa khả năng khớp nối giữa người dùng và nội dung video. Tháp Truy vấn phía bên trái chịu trách nhiệm mã hóa ngữ cảnh người dùng thông qua việc tổng hợp các đặc trưng gieo mầm (seed features) – bao gồm thông tin về video và kênh đang được theo dõi – kết hợp cùng chuỗi lịch sử hành vi xem video trong quá khứ. Trong khi đó, Tháp Ứng viên phía bên phải tập trung xử lý các thông tin định danh kết hợp cùng các chỉ số thống kê định lượng của video mục tiêu. Cả hai luồng dữ liệu này sau khi được chuyển đổi qua các lớp nhúng sẽ đi qua các tầng mạng truyền thẳng đa lớp sử dụng hàm kích hoạt phi tuyến ReLU với kích thước giảm dần theo độ sâu để trích xuất các đặc trưng ngữ nghĩa cô đọng nhất. Tại tầng cuối cùng, các vector đầu ra bắt buộc phải trải qua bước chuẩn hóa L2 nhằm triệt tiêu sự ảnh hưởng của độ lớn vector và biến phép nhân vô hướng thành thước đo độ tương đồng Cosine chuẩn xác. Quá trình này phục vụ cho việc huấn luyện sử dụng hàm mục tiêu Softmax trên từng lô dữ liệu, đồng thời cho phép lập chỉ mục vector ngoại tuyến để truy xuất thời gian thực danh sách các video đề xuất tiềm năng nhất cho người dùng.

Kiến trúc Two-Tower đã khẳng định vị thế là chuẩn mực vàng cho giai đoạn lọc thô trong các hệ thống gợi ý quy mô lớn nhờ sở hữu những ưu điểm vượt trội về hiệu năng vận hành. Sức mạnh cốt lõi của kiến trúc này nằm ở khả năng mở rộng ấn tượng; nhờ sự tách biệt hoàn toàn giữa hai luồng xử lý, vector biểu diễn của sản phẩm có thể được tính toán trước và lập chỉ mục ngoại tuyến (offline indexing). Cơ chế này cho phép hệ thống dễ dàng quản lý kho dữ liệu lên tới hàng tỷ bản ghi mà không gặp trở ngại về tài nguyên tính toán trực tuyến. Hệ quả tất yếu là độ trễ phản hồi đạt mức cực thấp trong thời gian thực, khi hệ thống chỉ cần thực hiện suy diễn một lần duy nhất để tạo vector người dùng và tìm kiếm kết quả thông qua các phép tính tích vô hướng hoặc tìm kiếm lân cận gần đúng (ANN), đảm bảo tốc độ trả về chỉ trong vài mili-giây. Bên cạnh đó, tính linh hoạt trong biểu diễn dữ liệu cho phép mô hình dễ dàng tích hợp đa dạng các loại đặc trưng từ hình ảnh, văn bản đến nhân khẩu học, giúp hệ thống vượt qua giới hạn của việc khớp từ khóa đơn thuần để học được ngữ nghĩa sâu sắc của dữ liệu.

Vận dụng những ưu thế kỹ thuật trên vào bài toán cụ thể của đề án, nhóm nghiên cứu đề xuất triển khai một biến thể tiên tiến của kiến trúc Two-Tower nhằm tối ưu hóa khả

năng truy xuất ứng viên. Cụ thể, Tháp Sản phẩm được thiết kế chuyên biệt để học biểu diễn đa phương thức, tập trung trích xuất và hợp nhất các đặc trưng thị giác từ hình ảnh và ngữ nghĩa từ văn bản mô tả. Trong khi đó, Tháp Người dùng được tích hợp mô hình SASRec (Self-Attentive Sequential Recommendation)[7], đóng vai trò then chốt trong việc mã hóa chuỗi hành vi tương tác. Sự kết hợp này cho phép hệ thống không chỉ hiểu sâu về nội dung sản phẩm mà còn nắm bắt chính xác sự biến thiên sở thích theo thời gian thực của người dùng, tạo tiền đề vững chắc cho các bước xếp hạng tinh vi tiếp theo.

2.2 Các Hàm Mục tiêu

Trong các bài toán học biểu diễn cho hệ thống gợi ý, việc xác định chiến lược huấn luyện đóng vai trò then chốt trong việc định hình cấu trúc tô-pô của không gian vector tiềm ẩn. Chất lượng của mô hình không chỉ phụ thuộc vào kiến trúc mạng mà còn được quyết định bởi cách thức mô hình học từ dữ liệu thông qua hàm mất mát. Trong phạm vi nghiên cứu, đồ án tập trung phân tích và so sánh hai hướng tiếp cận nền tảng: Học phân loại theo điểm và Học tương phản.

Đầu tiên, hướng tiếp cận theo điểm (Pointwise Approach) là phương pháp truyền thống, nơi mô hình xem xét từng cặp đối tượng ($User, Item$) như các biến cố độc lập để xử lý. Dưới góc độ này, bài toán gợi ý được chuyển đổi thành bài toán phân loại nhị phân, trong đó mục tiêu là dự đoán chính xác xác suất tương tác của người dùng đối với một sản phẩm cụ thể. Hàm mất mát tiêu biểu đại diện cho hướng đi này là Binary Cross-Entropy, tập trung tối ưu hóa độ chính xác tuyệt đối của từng dự đoán riêng lẻ, đảm bảo rằng xác suất dự đoán cho các mẫu dương tiến dần về 1 và mẫu âm tiến dần về 0. Tuy nhiên, hạn chế của phương pháp này là bỏ qua mối tương quan xếp hạng giữa các sản phẩm, đôi khi dẫn đến việc tối ưu quá mức cho các tương tác ngẫu nhiên mà không nắm bắt được sở thích ưu tiên thực sự.

Ngược lại, hướng tiếp cận tương phản (Contrastive Approach) vận hành dựa trên nguyên lý so sánh tương quan, được xem là chuẩn mực cho các mô hình truy xuất hiện đại. Thay vì đánh giá một sản phẩm một cách cô lập, mô hình học cách phân biệt sự khác nhau tương đối giữa các cặp dữ liệu. Mục tiêu tối thượng của chiến lược này là tối ưu hóa khoảng cách hình học trong không gian ẩn: lực hấp dẫn sẽ kéo các cặp tương đồng (Positive Pairs - người dùng và sản phẩm họ thích) lại gần nhau, trong khi lực đẩy sẽ tách các cặp không tương đồng (Negative Pairs) ra xa nhau. Cơ chế kéo-dẩy này giúp không gian vector có tính phân tách cao hơn, hỗ trợ đắc lực cho việc truy xuất láng giềng gần nhất (ANN) và giải quyết tốt hơn vấn đề mất cân bằng dữ liệu so với phương pháp phân loại truyền thống.

Sự phát triển của các chiến lược huấn luyện trong hệ thống gợi ý đã trải qua một quá trình tiến hóa dài, tương ứng với sự chuyển dịch từ các mô hình dự đoán tương tác đơn lẻ sang các mô hình học biểu diễn không gian vector phức tạp. Trong phạm vi nghiên cứu, đồ án phân tích ba lớp hàm mục tiêu đại diện cho các trường phái tiếp cận khác nhau, từ học phân loại, học metric đến học tương phản hiện đại

2.2.1 Binary Cross Entropy

Đây là hàm mất mát tiêu chuẩn được áp dụng rộng rãi trong các bài toán dự đoán tỷ lệ nhấp (CTR Prediction) và các mô hình Lọc cộng tác nơ-ron (Neural Collaborative

Filtering) như đề xuất của Xiangnan He và cộng sự[22], nó cũng được sử dụng trong kiến trúc SASRec của Wang-Cheng Kang và Julian McAuley[7]. Dưới góc độ tiếp cận theo điểm Pointwise Approach, hàm mục tiêu này chuyển đổi bài toán gợi ý thành bài toán phân loại nhị phân, trong đó mô hình xem xét mỗi cặp người dùng - sản phẩm (u, i) như một biến cố độc lập. Mục tiêu là tối thiểu hóa sai số giữa nhãn thực tế y_{ui} (nhận giá trị 1 nếu có tương tác, 0 nếu không) và xác suất dự đoán p_{ui} của mô hình:

$$\mathcal{L}_{\text{BCE}} = - \sum_{(u,i) \in \mathcal{D}} [y_{ui} \cdot \log(p_{ui}) + (1 - y_{ui}) \cdot \log(1 - p_{ui})] \quad (2.2)$$

Ưu điểm cốt lõi của phương pháp này là khả năng hiệu chuẩn xác suất rất tốt, cho phép hệ thống đánh giá chính xác khả năng tương tác tuyệt đối của từng cặp. Tuy nhiên, hạn chế lớn nhất của nó nằm ở việc bỏ qua cấu trúc thứ tự tương đối; mô hình có thể dự đoán chính xác xác suất mua hàng nhưng lại thất bại trong việc sắp xếp sản phẩm A lên trên sản phẩm B trong danh sách gợi ý, khiến nó kém hiệu quả trong bài toán truy xuất quy mô lớn.

2.2.2 Triplet Loss

Được phổ biến rộng rãi bởi Schroff và đồng nghiệp[23] trong mô hình FaceNet cho bài toán nhận diện khuôn mặt, Triplet Loss là nền tảng của học sâu metric. Thay vì dự đoán xác suất, phương pháp này hướng tới việc tối ưu hóa khoảng cách hình học trong không gian vector. Mô hình nhận đầu vào là một bộ ba (A, P, N) bao gồm: Anchor (Mẫu gốc), Positive (Mẫu cùng loại/người dùng thích) và Negative (Mẫu khác loại). Mục tiêu là đảm bảo khoảng cách giữa Anchor và Positive phải nhỏ hơn khoảng cách giữa Anchor và Negative một đoạn biên độ an toàn α :

$$\mathcal{L}_{\text{Triplet}} = \sum \max(0, d(A, P)^2 - d(A, N)^2 + \alpha) \quad (2.3)$$

Mặc dù giải quyết tốt vấn đề về thứ tự xếp hạng, Triplet Loss đối mặt với thách thức lớn về sự hội tụ. Hiệu suất của hàm này phụ thuộc cực đoan vào chiến lược lấy mẫu. Nếu chọn các mẫu âm quá dễ - tức là các sản phẩm hoàn toàn không liên quan, gradient sẽ nhanh chóng tiến về 0 và mô hình ngừng học. Ngược lại, việc tìm kiếm các mẫu âm khó Hard Negative Mining lại đòi hỏi chi phí tính toán rất lớn, làm chậm quá trình huấn luyện.

2.2.3 InfoNCE

Hàm mất mát InfoNCE được chuẩn hóa trong kiến trúc SimCLR hay Two-Tower của Google[8], hiện được xem là chuẩn mực cho các bài toán truy xuất hiện đại. Khác với Triplet Loss chỉ so sánh cục bộ một cặp dương-âm, InfoNCE mở rộng phạm vi so sánh ra toàn bộ lô dữ liệu

Về bản chất toán học, InfoNCE biến bài toán xác định tương đồng thành bài toán phân loại đa lớp. Đối với một cặp mẫu dương (u, i^+) , mô hình coi tất cả các sản phẩm còn lại trong cùng một batch là mẫu âm (*In-batch Negatives*). Hàm mục tiêu tối đa hóa tỷ lệ tương đồng của cặp dương so với tổng độ tương đồng của tất cả các cặp khác thông qua hàm Softmax:

$$\mathcal{L}_{\text{InfoNCE}} = - \log \frac{\exp(\text{sim}(u, i^+)/\tau)}{\sum_{j=1}^K \exp(\text{sim}(u, i_j)/\tau)} \quad (2.4)$$

Trong đó, τ là tham số nhiệt độ giúp điều chỉnh độ sắc nét của phân phối xác suất. Ưu điểm vượt trội của phương pháp này là tận dụng được số lượng mẫu âm khổng lồ ($K - 1$ mẫu) từ chính kích thước batch mà không tốn chi phí tính toán thêm để đào dữ liệu, giúp gradient mạnh hơn và thúc đẩy mô hình hội tụ nhanh về một không gian vector đẳng hướng. Tuy nhiên, phương pháp này tồn tại rủi ro về Mẫu âm giả – hiện tượng xảy ra khi một sản phẩm người dùng thực sự thích vô tình xuất hiện trong batch nhưng lại bị hệ thống gán nhãn là mẫu âm, dẫn đến nhiễu tín hiệu trong quá trình cập nhật trọng số.

Quyết định lựa chọn InfoNCE làm hàm mục tiêu nòng cốt cho hệ thống xuất phát từ ưu thế vượt trội của nó trong việc tối ưu hóa không gian biểu diễn cho bài toán truy xuất quy mô lớn. Khác với các phương pháp học theo cặp truyền thống vốn phụ thuộc nặng nề vào các chiến lược chọn mẫu khó tốn kém và thiếu ổn định, InfoNCE tận dụng triệt để cơ chế sử dụng mẫu âm trong cùng lô dữ liệu để so sánh đồng thời một mẫu dương với hàng loạt mẫu âm khác. Cách tiếp cận này không chỉ giúp tối đa hóa hiệu suất tính toán mà còn tạo ra các tín hiệu gradient mạnh mẽ hơn, thúc đẩy mô hình hội tụ nhanh về một cấu trúc không gian vector đẳng hướng. Tại đó, các đặc trưng ngữ nghĩa được phân tách rõ ràng, tạo tiền đề vững chắc nhằm đảm bảo độ chính xác cao cho quá trình tìm kiếm láng giềng gần nhất trong các bước xử lý tiếp theo.

2.3 Biểu diễn Đa phương thức

Trong kỷ nguyên dữ liệu lớn, thông tin về sản phẩm không còn bị giới hạn ở các mã định danh hay thuộc tính cấu trúc đơn giản, mà đã mở rộng sang các dạng dữ liệu phi cấu trúc phong phú như văn bản mô tả và hình ảnh minh họa. Học đa phương thức là phương pháp tiếp cận tiên tiến cho phép hệ thống tri nhận và thấu hiểu sâu sắc nội dung sản phẩm, từ đó xây dựng các vector biểu diễn embeddings giàu ngữ nghĩa. Cách tiếp cận này đặc biệt hiệu quả trong việc giải quyết bài toán cold-start đối với các sản phẩm mới chưa có lịch sử tương tác. Để khai thác hai luồng thông tin quan trọng nhất là ngôn ngữ và thị giác, đồ án áp dụng hai kiến trúc nền tảng đã chứng minh được hiệu quả vượt trội trong lĩnh vực này, lần lượt là BERT cho xử lý văn bản và ViT cho xử lý hình ảnh.


2.3.1 Biểu diễn Văn bản: BERT

Sự xuất hiện của mô hình BERT (Bidirectional Encoder Representations from Transformers)[14] đã tạo ra một bước tiến quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên, đặc biệt là ứng dụng trong việc trích xuất đặc trưng văn bản cho các hệ thống gợi ý hiện đại. Trước khi các mô hình ngôn ngữ lớn trở nên phổ biến, các phương pháp nhúng từ truyền thống như Word2Vec[15] hay GloVe chủ yếu dựa trên cơ chế tạo ra các vector nhúng tĩnh. Hạn chế căn bản của cách tiếp cận này là việc gán một vector biểu diễn cố định duy nhất cho mỗi từ vựng, bất kể sự biến thiên về ngữ nghĩa trong các ngữ cảnh khác nhau.

Vấn đề này trở nên đặc biệt nghiêm trọng trong miền dữ liệu thương mại điện tử, nơi các từ khóa thường mang tính đa nghĩa cao. Điển hình như từ khóa "Chuột", ngữ nghĩa của nó thay đổi hoàn toàn khi xuất hiện trong cụm "Chuột máy tính Logitech" thuộc danh mục thiết bị điện tử so với cụm "Thuốc diệt chuột" thuộc danh mục hóa phẩm. Các mô hình tĩnh như Word2Vec không thể phân tách sự khác biệt này, dẫn đến sai lệch trong việc tính toán độ tương đồng sản phẩm. Ngược lại, BERT khắc phục triệt để nhược điểm

trên thông qua cơ chế tạo ra các vector nhúng động, cho phép biểu diễn chính xác ngữ nghĩa của từ dựa trên sự phụ thuộc vào các từ lân cận trong câu.

Về mặt kiến trúc, BERT được xây dựng dựa trên sự chồng xếp của các lớp mã hóa trong kiến trúc Transformer. Khác biệt so với các mô hình tự hồi quy như GPT vốn chỉ xử lý thông tin đơn chiều từ trái sang phải, BERT áp dụng cơ chế Mô hình hóa ngôn ngữ che mặt (Masked Language Modeling - MLM). Cơ chế này cho phép mô hình tiếp nhận và tổng hợp luồng thông tin ngữ cảnh hai chiều đồng thời, giúp nắm bắt cấu trúc cú pháp và ngữ nghĩa sâu sắc hơn. Như được minh họa chi tiết trong Hình 2.4 [14], quy trình vận hành của BERT được chia thành hai giai đoạn kế tiếp nhau trên cùng một nền tảng kiến trúc thống nhất.



Hình 2.4: Quy trình Tiền huấn luyện và Tinh chỉnh của BERT.

Giai đoạn Tiền huấn luyện

Giai đoạn tiền huấn luyện đóng vai trò nền tảng trong quy trình xây dựng mô hình, tại đó hệ thống tiếp thu các biểu diễn ngôn ngữ tổng quát thông qua việc khai thác khối lượng lớn dữ liệu văn bản thô chưa được gán nhãn. Quá trình học tập này vận hành dựa trên cơ chế tự giám sát, tập trung tối ưu hóa đồng thời hai tác vụ cốt lõi nhằm nắm bắt sâu sắc cấu trúc ngôn ngữ.

Đầu tiên là tác vụ mô hình hóa ngôn ngữ che mặt hay còn gọi là MLM. Khác với phương pháp dự đoán từ tiếp theo theo tuần tự truyền thống, tác vụ này yêu cầu hệ thống phải khôi phục và tái tạo chính xác các đơn vị từ vựng đã bị che khuất ngẫu nhiên trong câu. Cơ chế này buộc mô hình phải tổng hợp và thấu hiểu ngữ cảnh hai chiều từ cả phía trước và phía sau của từ mục tiêu để đưa ra suy luận hợp lý nhất. Song song với đó là tác vụ dự đoán câu tiếp theo hay NSP, được thiết kế nhằm mục đích giúp mô hình thấu hiểu mối quan hệ logic và sự liên kết giữa các đoạn văn bản. Cụ thể, hệ thống học cách xác định xem một câu B bất kỳ có phải là câu nối tiếp thực tế về mặt ngữ nghĩa của câu A hay không, qua đó nắm bắt được cấu trúc diễn ngôn ở cấp độ cao hơn so với việc chỉ xử lý các từ ngữ riêng lẻ.

Giai đoạn Tinh chỉnh

Giai đoạn tinh chỉnh đóng vai trò là bước chuyển giao tri thức quan trọng, nơi mô hình áp dụng các biểu diễn ngôn ngữ tổng quát đã học được vào các tác vụ hạ nguồn cụ thể. Về mặt quy trình, thay vì khởi tạo ngẫu nhiên, mô hình kế thừa toàn bộ trọng số tham số từ giai đoạn tiền huấn luyện làm điểm bắt đầu, sau đó tiến hành tối ưu hóa tiếp tục trên các tập dữ liệu có gán nhãn chuyên biệt. Điểm mấu chốt là toàn bộ các tham số của mạng lưới đều được cập nhật đồng bộ trong quá trình này để thích nghi tốt nhất với đặc thù của từng bài toán riêng biệt, từ các tác vụ phân loại cặp câu hay nhận diện thực thể tên riêng

trong MNLI và NER, cho đến các bài toán phức tạp hơn như xác định vị trí đoạn văn chứa câu trả lời trong bộ dữ liệu SQuAD.

Một đặc điểm kiến trúc nổi bật tạo nên sự thành công của BERT chính là tính nhất quán về cấu trúc giữa hai giai đoạn. Hệ thống duy trì nguyên vẹn khối kiến trúc mã hóa Transformer đa tầng xuyên suốt quá trình huấn luyện, đảm bảo luồng xử lý thông tin không bị gián đoạn. Sự thay đổi duy nhất chỉ diễn ra ở lớp đầu ra cuối cùng, nơi được thiết kế lại linh hoạt để tương thích với định dạng dự đoán của từng tác vụ đích, giúp mô hình đạt được hiệu suất cao mà không cần thay đổi đáng kể về mặt cấu trúc lõi.

Cơ chế vận hành cốt lõi tạo nên sức mạnh của BERT là kỹ thuật *Scaled Dot-Product Self-Attention*. Về mặt toán học, với đầu vào là một chuỗi các token embeddings $X \in \mathbb{R}^{n \times d}$, mô hình thực hiện chiếu X thành ba ma trận thành phần bao gồm Query (Q), Key (K) và Value (V). Quá trình tính toán trọng số sự chú ý được định nghĩa thông qua công thức:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.5)$$

Trong biểu thức này, tích vô hướng QK^T đại diện cho mức độ tương đồng ngữ nghĩa giữa các token trong câu, xác định mức độ mà mỗi từ cần chú ý đến các từ khác để cập nhật biểu diễn của chính nó. Đáng chú ý, phép chia cho căn bậc hai của chiều vector key ($\sqrt{d_k}$) đóng vai trò là một kỹ thuật chuẩn hóa thiết yếu. Khi chiều dữ liệu d_k lớn, giá trị tích vô hướng có xu hướng tăng trưởng mạnh về độ lớn, đẩy hàm Softmax vào vùng bão hòa nơi gradient tiệm cận 0, gây trở ngại cho quá trình tối ưu hóa. Việc chia tỷ lệ giúp ổn định phương sai của điểm số attention, đảm bảo mô hình hội tụ hiệu quả hơn.

Để nâng cao năng lực trích xuất đặc trưng, BERT không đơn thuần sử dụng một bộ chú ý duy nhất mà áp dụng cơ chế *Multi-Head Attention*. Kỹ thuật này cho phép mô hình tri giác thông tin từ nhiều không gian biểu diễn con song song tại các vị trí khác nhau; ví dụ, một đầu (*head*) có thể tập trung vào cấu trúc ngữ pháp trong khi đầu khác khai thác các mối quan hệ từ vựng, giúp vector đầu ra phong phú và toàn diện hơn về mặt thông tin. Tuy nhiên, do đặc thù xử lý song song của cơ chế Attention dẫn đến sự thiếu hụt thông tin về trình tự so với các mạng hồi quy (RNN), BERT giải quyết vấn đề này bằng cách cộng thêm các vector Mã hóa vị trí (*Positional Encoding*) vào đầu vào ban đầu, giúp mô hình nhận thức chính xác thứ tự xuất hiện của các từ trong câu mô tả sản phẩm.

Trong ngữ cảnh cụ thể của hệ thống gợi ý, mục tiêu đặt ra là thu được một vector đại diện duy nhất cho toàn bộ văn bản đầu vào. Để thực hiện điều này, BERT bổ sung một token đặc biệt ký hiệu là [CLS] vào vị trí đầu tiên của chuỗi. Sau khi đi qua toàn bộ các lớp mã hóa Transformer, vector đầu ra tương ứng với vị trí [CLS] này được coi là biểu diễn tổng hợp tinh túy nhất của cả câu:

$$h_{[\text{CLS}]} = \text{BERT}(x_1, \dots, x_n) \quad (2.6)$$

Vector $h_{[\text{CLS}]}$ này có khả năng nắm bắt được các đặc trưng ngữ nghĩa bậc cao như danh mục sản phẩm, tính năng nổi bật hay sắc thái cảm xúc trong bài đánh giá, mang lại hiệu quả vượt trội so với các phương pháp biểu diễn thô sơ như *Bag-of-Words* truyền thống.

2.3.2 Biểu diễn Hình ảnh: ViT

Trong giai đoạn trước năm 2020, các kiến trúc mạng nơ-ron tích chập, viết tắt là CNN, với những đại diện tiêu biểu như ResNet hay EfficientNet được xem là chuẩn mực hàng


đầu cho các tác vụ thị giác máy tính. Thành công này chủ yếu bắt nguồn từ khả năng khai thác hiệu quả các quy nạp thiên kiến về tính cục bộ và tính bất biến tịnh tiến đặc trưng của dữ liệu hình ảnh. Đối lập với bức tranh đó, kiến trúc Transformer[12] lại đang khẳng định vị thế độc tôn và tạo ra những bước tiến vượt bậc trong lĩnh vực xử lý ngôn ngữ tự nhiên.

Bối cảnh công nghệ này đã thúc đẩy sự ra đời của Vision Transformer, hay còn gọi là ViT, nhằm giải quyết câu hỏi khoa học về tính khả thi của việc áp dụng trực tiếp kiến trúc Transformer thuần túy lên dữ liệu thị giác. Cách tiếp cận của ViT mang tính đột phá khi loại bỏ hoàn toàn sự phụ thuộc vào các lớp tích chập truyền thống để chuyển sang mô hình hóa bức ảnh dưới dạng một chuỗi các phần tử tuần tự, tương tự như cơ chế xử lý các đoạn văn bản.

Quyết định thay thế mạng tích chập truyền thống bằng kiến trúc Vision Transformer được củng cố bởi nghiên cứu mang tính đột phá của Dosovitskiy và cộng sự[11]. Trong công trình này, nhóm tác giả đã chứng minh tính khả thi và hiệu quả vượt trội của việc áp dụng cơ chế tự chú ý trực tiếp lên dữ liệu hình ảnh quy mô lớn. Thay vì phụ thuộc vào các quy nạp thiên kiến về tính cục bộ như trong mạng ResNet hay EfficientNet, phương pháp này xử lý bức ảnh như một chuỗi các mảnh ghép độc lập, cho phép mô hình nắm bắt được các mối quan hệ ngữ nghĩa toàn cục giữa các vùng ảnh xa nhau ngay từ những lớp đầu tiên.

Rào cản kỹ thuật lớn nhất khi chuyển giao kiến trúc Transformer từ miền dữ liệu chuỗi sang dữ liệu hình ảnh nằm ở gánh nặng tính toán khổng lồ. Do cơ chế tự chú ý sở hữu độ phức tạp thuật toán bậc hai $\mathcal{O}(N^2)$ tỷ lệ thuận với số lượng phần tử đầu vào N , việc mô hình hóa trực tiếp từng điểm ảnh đơn lẻ như một đơn vị *token* sẽ dẫn đến sự bùng nổ về chi phí tài nguyên. Đơn cử, một hình ảnh có kích thước tiêu chuẩn 224×224 sẽ tạo ra một chuỗi đầu vào lên tới 50.176 phần tử, khiến việc xây dựng ma trận chú ý trở nên bất khả thi đối với năng lực phần cứng hiện tại.

Mô hình Vision Transformer giải quyết triệt để vấn đề này thông qua kỹ thuật phân mảnh hay còn gọi là *Patching*. Quy trình xử lý bắt đầu bằng việc chia nhỏ hình ảnh đầu vào $I \in \mathbb{R}^{H \times W \times C}$ thành một lưới các vùng cục bộ không chồng lấn có kích thước cố định $P \times P$, tạo ra tổng cộng $N = \frac{HW}{P^2}$ mảnh con. Tiếp theo, mỗi mảnh ảnh này được trải phẳng thành một vector một chiều và được đưa qua một phép chiếu tuyến tính có thể học được để ánh xạ vào không gian biểu diễn tiềm ẩn với số chiều D . Cuối cùng, nhằm mục đích khôi phục và bảo toàn thông tin về cấu trúc không gian vốn bị phá vỡ trong quá trình trải phẳng, các vector mã hóa vị trí E_{pos} được cộng bổ sung trực tiếp vào các vector đặc trưng của từng mảnh trước khi đưa vào khối mã hóa Transformer. Quy trình xử lý chi tiết được mô tả trực quan thông qua Hình 2.5 [11].



Hình 2.5: Sơ đồ kiến trúc Vision Transformer.

Bước tiếp theo là việc khởi tạo token phân loại. Một vector tham số có thể học được, thường được ký hiệu là token lớp, được chèn vào vị trí đầu tiên của chuỗi các vector mảnh ảnh. Token đặc biệt này đóng vai trò như một bộ thu nhận thông tin toàn cục; sau khi đi qua toàn bộ mạng nơ-ron, trạng thái đầu ra tại vị trí này sẽ được sử dụng làm đại diện tổng quát duy nhất cho toàn bộ bức ảnh, tương tự như cơ chế của token CLS trong mô hình ngôn ngữ BERT.

Chuỗi vector kết hợp này sau đó được đưa vào khối mã hóa Transformer Encoder, bao gồm nhiều lớp xử lý lặp lại liên tiếp. Trong mỗi lớp, cơ chế chú ý đa đầu đóng vai trò hạt nhân, cho phép mỗi mảnh ảnh có khả năng quan sát và liên kết ngữ nghĩa với tất cả các mảnh ảnh khác, bất kể khoảng cách không gian giữa chúng. Dữ liệu sau đó tiếp tục đi qua mạng nơ-ron truyền thẳng MLP để trích xuất các đặc trưng bậc cao. Để đảm bảo sự ổn định và khả năng hội tụ của quá trình huấn luyện sâu, kỹ thuật chuẩn hóa lớp Layer Normalization được áp dụng trước mỗi khối chức năng, kết hợp cùng các kết nối tắt nhằm duy trì dòng chảy thông tin và hạn chế hiện tượng triệt tiêu đạo hàm.

Cuối cùng, tại lớp đầu ra của khối mã hóa, chỉ duy nhất vector ứng với vị trí của token phân loại được trích xuất. Vector này mang trong mình thông tin ngữ nghĩa cô đọng nhất của bức ảnh và được đưa vào khối MLP Head để thực hiện các tác vụ đích như phân loại đối tượng hoặc tạo vector biểu diễn cho hệ thống gợi ý.


Sự khác biệt nền tảng định hình nên ưu thế của Vision Transformer so với mạng tích chập CNN nằm ở bản chất của trường tiếp nhận thông tin. Đối với các mạng tích chập truyền thống, trường tiếp nhận mang tính chất cục bộ nghiêm ngặt, nghĩa là các lớp tích chập khởi đầu chỉ có khả năng ghi nhận và xử lý tín hiệu từ các điểm ảnh lân cận. Sự tổng hợp thông tin toàn cục chỉ có thể đạt được một cách gián tiếp và thụ động thông qua quá trình chồng xếp nhiều lớp mạng sâu nhằm mở rộng dần vùng quan sát. Ngược lại, Vision Transformer tận dụng sức mạnh của cơ chế tự chú ý để phá vỡ giới hạn không gian này. Ngay từ lớp xử lý đầu tiên, mỗi mảnh ảnh đã thiết lập được sự tương tác trực tiếp với tất cả các mảnh ảnh khác, cho phép mô hình có cái nhìn toàn cảnh tức thời về đối tượng.

Đặc tính kỹ thuật này mang lại ý nghĩa quan trọng trong ngữ cảnh của bài toán gợi ý sản phẩm, đặc biệt đối với các ngành hàng đề cao tính thẩm mỹ như thời trang hay nội thất. Trong những lĩnh vực này, vẻ đẹp và giá trị của sản phẩm thường không chỉ nằm ở

các chi tiết riêng lẻ mà phụ thuộc vào bố cục tổng thể cùng sự phối hợp giữa các thành phần nằm cách xa nhau, chẳng hạn như sự tương thích giữa cổ áo và gấu váy hay sự đồng điệu giữa màu sắc giày và họa tiết thương hiệu. Năng lực thấu hiểu các mối quan hệ ngữ nghĩa toàn cục và phức tạp này cho phép Vision Transformer trích xuất được các vector đặc trưng giàu thông tin hơn, mang lại hiệu quả vượt trội cho tác vụ gợi ý so với các phương pháp tích chập truyền thống.

2.3.3 Cơ chế Hợp nhất Không gian Vector

Một sản phẩm trên thực tế có thể có nhiều hình thức biểu diễn như văn bản, hình ảnh, video. Nghiên cứu của Radford [16] đã khẳng định tầm quan trọng của việc khai thác đa phương thức để hiểu sâu ngữ nghĩa đối tượng. Tuy nhiên, thay vì chỉ so khớp đơn thuần, việc hợp nhất các đặc trưng này thành một biểu diễn duy nhất là yêu cầu bắt buộc đối với tháp sản phẩm trong kiến trúc Two-Tower. Hình 2.6 [16] mô tả kiến trúc hợp nhất được đề xuất.



Hình 2.6: Sơ đồ kiến trúc Multi-Modality Fusion.

Hạn chế căn bản của các phương pháp hợp nhất truyền thống như phép nối vector hay phép cộng trung bình nằm ở giả định cứng nhắc rằng mức độ quan trọng của hình ảnh và văn bản là tương đương nhau đối với mọi sản phẩm. Trong thực tế dữ liệu thương mại điện tử luôn tồn tại sự bất cân xứng về chất lượng thông tin khi một số mặt hàng sở hữu hình ảnh trực quan sắc nét nhưng phần mô tả lại sơ sài hoặc ngược lại. Để giải quyết vấn đề này đồ án áp dụng cơ chế Hợp nhất có cổng hay còn gọi là Gated Fusion được phát triển dựa trên nền tảng lý thuyết mạng nơ-ron đa phương thức của Arevalo và cộng sự[24].

Quy trình xử lý dữ liệu để tạo ra vector đại diện sản phẩm được thực hiện qua ba giai đoạn tuần tự, đảm bảo tính đồng bộ về mặt toán học giữa các luồng dữ liệu khác biệt.

Đầu tiên là giai đoạn đồng bộ hóa không gian biểu diễn. Xuất phát từ thực tế rằng đầu ra từ các bộ mã hóa hình ảnh và văn bản (như ViT cho ảnh và BERT cho văn bản) thường sở hữu số chiều khác nhau và nằm trong các phân phối đặc trưng riêng biệt, hệ thống cần áp dụng phép chiếu tuyến tính để dung hòa sự khác biệt này. Cụ thể, hai ma trận trọng số $\mathbf{W}_v$ và $\mathbf{W}_t$ được sử dụng để ánh xạ các đặc trưng thô về cùng một không gian vector tiềm ẩn có kích thước cố định d , tạo tiền đề cho sự tương tác trực tiếp:

$$\mathbf{v}_I = \tanh(\mathbf{W}_v \cdot I_{\text{raw}} + \mathbf{b}_v) \quad (2.7)$$

$$\mathbf{v}_T = \tanh(\mathbf{W}_t \cdot T_{\text{raw}} + \mathbf{b}_t) \quad (2.8)$$

Tiếp theo, các vector đặc trưng sau khi đồng bộ được đưa vào cơ chế Hợp nhất có cổng (*Gated Mechanism*). Đây là thành phần cốt lõi của mô hình, đóng vai trò như một van điều tiết thông minh nhằm xác định mức độ quan trọng của từng luồng thông tin. Một giá trị cổng kiểm soát z được tính toán dựa trên sự kết hợp của cả hai loại dữ liệu, sử dụng hàm kích hoạt Sigmoid σ để nén giá trị về khoảng $(0, 1)$:

$$z = \sigma(\mathbf{W}_z \cdot [\mathbf{v}_I, \mathbf{v}_T] + \mathbf{b}_z) \quad (2.9)$$

Dựa trên giá trị cổng này, vector hợp nhất $\mathbf{v}_{\text{fusion}}$ được xác định bằng tổ hợp tuyến tính có trọng số. Cơ chế này cho phép mô hình linh hoạt chuyển đổi sự tập trung; khi z tiệm cận 1, hệ thống sẽ ưu tiên khai thác tín hiệu thị giác và ngược lại sẽ dựa nhiều vào văn bản khi z tiến về 0:

$$\mathbf{v}_{\text{fusion}} = z \odot \mathbf{v}_I + (1 - z) \odot \mathbf{v}_T \quad (2.10)$$

Cuối cùng, để hoàn thiện biểu diễn của sản phẩm, vector hợp nhất $\mathbf{v}_{\text{fusion}}$ trải qua bước chuẩn hóa theo chuẩn L_2 nhằm tạo ra vector đầu ra $\mathbf{v}_{\text{item}}$:

$$\mathbf{v}_{\text{item}} = \frac{\mathbf{v}_{\text{fusion}}}{\|\mathbf{v}_{\text{fusion}}\|_2} \quad (2.11)$$

Bước xử lý này đảm bảo độ dài của mọi vector đại diện đều bằng 1. Về mặt hình học, điều này giúp phép nhân vô hướng với vector người dùng ở giai đoạn truy xuất sau này trở thành thước đo độ tương đồng Cosine chuẩn xác, đồng thời góp phần ổn định đáng kể quá trình huấn luyện của mạng nơ-ron.

2.4 Nắm bắt chuỗi hành vi trong ResSys

2.4.1 Chuỗi Markov trong Gợi ý Tuần tự

Trong bối cảnh thương mại điện tử hiện đại, sở thích của người dùng không phải là một đặc tính bất biến mà là một quá trình động, thay đổi liên tục theo thời gian và chịu ảnh hưởng mạnh mẽ bởi ngữ cảnh ngắn hạn. Các phương pháp gợi ý truyền thống như Phân rã ma trận hay Lọc cộng tác thường tiếp cận vấn đề dưới góc nhìn tĩnh, do đó gặp nhiều hạn chế trong việc nắm bắt sự dịch chuyển thị hiếu tức thời của khách hàng [1]. Để khắc phục nhược điểm này, các hệ thống gợi ý tuần tự đã được phát triển, trong đó Chuỗi Markov đóng vai trò là nền tảng lý thuyết đầu tiên và quan trọng nhất trước khi kỹ nguyên học sâu bùng nổ.

Về mặt bản chất, Chuỗi Markov là một mô hình ngẫu nhiên dùng để mô tả một dãy các sự kiện, trong đó xác suất xảy ra của một sự kiện trong tương lai được xác định hoàn toàn bởi trạng thái của sự kiện ngay trước đó. Trong bài toán gợi ý sản phẩm, mô hình này xem lịch sử hành vi của người dùng là một chuỗi các trạng thái chuyển đổi giữa các mặt hàng (items). Mục tiêu cốt lõi là tính toán xác suất chuyển đổi từ sản phẩm người dùng đang xem hiện tại sang sản phẩm tiềm năng tiếp theo, dựa trên ma trận xác suất chuyển đổi toàn cục được học từ dữ liệu cộng đồng [25].

Cơ sở toán học của phương pháp này dựa trên *Tính chất Markov*, hay còn gọi là tính chất không nhớ. Giả sử tập hợp hành vi của người dùng là một chuỗi theo thời gian $S = \{i_1, i_2, \dots, i_t\}$. Mô hình Markov bậc một (*First-order Markov Chain*) đưa ra giả định đơn giản hóa rằng hành động tiếp theo i_{t+1} chỉ phụ thuộc duy nhất vào hành động hiện tại i_t và độc lập với toàn bộ chuỗi quá khứ trước đó. Khi đó, xác suất xuất hiện của sản phẩm tiếp theo được công thức hóa như sau:

$$P(i_{t+1} | i_1, i_2, \dots, i_t) = P(i_{t+1} | i_t) \quad (2.12)$$

Cách tiếp cận này cho phép hệ thống tập trung khai thác các mối quan hệ tuần tự ngắn hạn giữa các cặp sản phẩm liên kề. Một trong những đại diện tiêu biểu nhất ứng dụng lý thuyết này là mô hình FPMC (*Factorized Personalized Markov Chains*) do Rendle đề xuất [26], kết hợp giữa Phân rã ma trận và Chuỗi Markov để vừa nắm bắt sở thích dài hạn, vừa mô hình hóa được sự chuyển đổi trạng thái ngắn hạn. Tuy nhiên, hạn chế của giả định Markov bậc thấp là khả năng ghi nhớ kém đối với các chuỗi hành vi dài, điều này sau đó đã thúc đẩy sự ra đời của các kiến trúc mạng nơ-ron như RNN hay Transformer để giải quyết bài toán phụ thuộc xa.

2.4.2 Mạng Nơ-ron Tái phát


Mạng nơ-ron tái phát, thường được biết đến với tên gọi RNN, đại diện cho một lớp mô hình học sâu được thiết kế chuyên biệt để xử lý dữ liệu dạng chuỗi hoặc chuỗi thời gian. Điểm khác biệt căn bản giữa RNN và các mạng truyền thẳng truyền thống nằm ở khả năng duy trì một bộ nhớ nội tại thông qua trạng thái ẩn. Cơ chế này cho phép mạng lưu giữ và tổng hợp thông tin từ quá khứ, từ đó nắm bắt được ngữ cảnh và sự phụ thuộc theo thời gian của dữ liệu đầu vào. Trong bài toán hệ thống gợi ý, đặc tính này giúp RNN mô hình hóa toàn bộ lịch sử hành vi người dùng thành một chuỗi liên tục nhằm trích xuất các sở thích dài hạn thay vì chỉ dựa vào các tương tác tức thời rời rạc.

Về mặt toán học, nguyên lý hoạt động của RNN dựa trên cơ chế lặp lại tuần tự. Tại mỗi bước thời gian t , trạng thái ẩn $\mathbf{h}_t$ được cập nhật dựa trên sự kết hợp giữa tín hiệu đầu vào hiện tại $\mathbf{x}_t$ và trạng thái ẩn của bước ngay trước đó $\mathbf{h}_{t-1}$. Quá trình chuyển đổi trạng thái này được mô tả qua phương trình phi tuyến tính:

$$\mathbf{h}_t = f(\mathbf{W} \cdot \mathbf{x}_t + \mathbf{U} \cdot \mathbf{h}_{t-1} + \mathbf{b}) \quad (2.13)$$

$$\mathbf{y}_t = g(\mathbf{V} \cdot \mathbf{h}_t) \quad (2.14)$$

Trong đó các ma trận trọng số $\mathbf{W}$, $\mathbf{U}$ và $\mathbf{V}$ được chia sẻ xuyên suốt qua mọi bước thời gian, giúp mô hình có khả năng tổng quát hóa các đặc trưng chuỗi bất kể độ dài đầu vào [27]. Đầu ra dự đoán $\mathbf{y}_t$, ví dụ như xác suất của sản phẩm tiếp theo, được tính toán trực tiếp từ trạng thái ẩn hiện tại thông qua hàm kích hoạt phù hợp, ví dụ như softmax.



Hình 2.7: Sơ đồ kiến trúc RNN.

Hình 2.7 [27] mô phỏng luồng xử lý dữ liệu trong một đơn vị RNN cơ bản, bao gồm ba thành phần chính là lớp đầu vào, lớp ẩn và lớp đầu ra. Đặc điểm định danh của kiến trúc này nằm ở các kết nối hồi quy được biểu thị bằng các đường nét đứt màu hồng, tạo thành một vòng lặp thông tin liên tục. Cơ chế này cho phép trạng thái của lớp ẩn tại bước thời gian hiện tại được truyền sang bước thời gian kế tiếp, đóng vai trò như một bộ nhớ nội tại giúp mô hình lưu giữ ngữ cảnh quá khứ và xử lý hiệu quả các dữ liệu dạng chuỗi.

Tuy nhiên, kiến trúc RNN nguyên bản thường gặp khó khăn trong quá trình huấn luyện với các chuỗi dài do hiện tượng triệt tiêu đạo hàm. Để khắc phục vấn đề này, hai biến thể nâng cao là Long Short-Term Memory (LSTM) [28] và Gated Recurrent Unit (GRU) [29] đã được phát triển. Trong khi LSTM sử dụng hệ thống ba cổng kiểm soát phức tạp để điều tiết luồng thông tin ghi nhớ và quên, thì GRU cung cấp một cấu trúc tinh gọn hơn với hiệu năng tương đương nhưng chi phí tính toán thấp hơn. Chính vì lý do này, GRU trở thành nền tảng cho GRU4Rec, một trong những mô hình gợi ý dựa trên phiên làm việc thành công nhất. Mô hình này sử dụng các lớp GRU để cập nhật liên tục trạng thái sở thích của người dùng sau mỗi lần tương tác nhằm đưa ra dự đoán chính xác về hành vi mua sắm kế tiếp [30].

Mặc dù vượt trội hơn mô hình Chuỗi Markov trong việc nắm bắt ngữ nghĩa dài hạn và xử lý linh hoạt các chuỗi có độ dài thay đổi, kiến trúc RNN vẫn tồn tại những hạn chế mang tính hệ thống. Nhược điểm chí mạng nhất ngăn cản sự phát triển của RNN trong kỷ nguyên dữ liệu lớn là tính chất tính toán tuần tự bắt buộc. Do trạng thái tại bước t phụ thuộc hoàn toàn vào kết quả của bước $t - 1$, quá trình huấn luyện không thể được song song hóa trên các phần cứng hiện đại như GPU. Thêm vào đó, khả năng liên kết thông tin giữa các bước thời gian cách xa nhau trong các chuỗi quá dài vẫn còn hạn chế. Những rào cản kỹ thuật này chính là động lực thúc đẩy sự chuyển dịch công nghệ sang các kiến trúc dựa trên cơ chế tự chú ý như Transformer và SASRec trong giai đoạn sau này [12].

2.4.3 Kiến trúc SASRec

Dựa trên sự thành công vang dội của cơ chế Attention trong xử lý ngôn ngữ tự nhiên, Kang và McAuley (2018) [7] đã đề xuất mô hình SASRec. Đây là kiến trúc được đề án lựa chọn làm nòng cốt cho Tháp Người dùng. SASRec thay thế hoàn toàn các lớp hồi quy bằng cơ chế Tự chú ý (Self-Attention), cho phép mô hình xác định trọng số quan trọng của từng sản phẩm trong quá khứ đối với sản phẩm mục tiêu dựa trên mối quan hệ ngữ nghĩa thay vì khoảng cách vị trí cố định. Nội dung trong mục này nói về mô hình SASRec của Kang và McAuley [7].

Mô hình SASRec vận hành thông qua một chuỗi các tầng xử lý tuần tự, khởi đầu với Tầng Nhúng (*Embedding Layer*). Do cơ chế Attention vốn dĩ thiếu khả năng nhận biết thứ tự chuỗi tự nhiên, mô hình buộc phải tích hợp thông tin vị trí vào dữ liệu đầu vào. Điều này được thực hiện bằng cách cộng ma trận nhúng của sản phẩm $\mathbf{M}$ với một ma trận vị trí có thể học được $\mathbf{P}$, tạo thành biểu diễn đầu vào tổng hợp $\mathbf{\hat{E}} = \mathbf{M} + \mathbf{P}$. Kế tiếp là Khối Self-Attention, nơi sử dụng công thức *Scaled Dot-Product Attention*:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{QK}^T}{\sqrt{d}}\right) \mathbf{V} \quad (2.15)$$

để tính toán mức độ tương quan giữa các sản phẩm trong chuỗi hành vi. Một yếu tố kỹ thuật then chốt tại đây là việc áp dụng Mặt nạ nhân quả (*Causal Masking*). Cơ chế này đảm bảo rằng khi dự đoán tại thời điểm t , mô hình chỉ được phép tiếp cận thông tin từ thời điểm 1 đến t , ngăn chặn tuyệt đối việc rò rỉ thông tin từ tương lai và bảo toàn tính nhân quả của dữ liệu chuỗi.

Để khai thác các đặc trưng sâu hơn sau lớp Attention, mô hình tích hợp Mạng truyền thẳng từng điểm (*Point-wise Feed-Forward Network*). Mạng này thực hiện các phép biến đổi phi tuyến cho từng vị trí một cách độc lập nhưng chia sẻ chung bộ trọng số, giúp mô hình nắm bắt các tương tác phức tạp giữa các chiều ẩn. Kiến trúc tổng thể của SASRec được hình thành bằng cách xếp chồng b khối xử lý như vậy nhằm giải quyết vấn đề quá khớp và mất ổn định khi huấn luyện mạng sâu, nhóm tác giả áp dụng cấu trúc tương tự Transformer bao gồm Chuẩn hóa lớp (*Layer Normalization*) để ổn định phân phối, Dropout để điều hòa quá trình học, và Kết nối tắt (*Residual Connections*) để hỗ trợ lan truyền thông tin. Toàn bộ quy trình này được mô hình hóa qua công thức tổng quát cho mỗi lớp con g :

$$g(x) = x + \text{Dropout}(g(\text{LayerNorm}(x))) \quad (2.16)$$

như được mô tả trong tài liệu của Kang và McAuley.

Tại Tầng Dự đoán cuối cùng, sau khi đi qua b khối xử lý, vector đại diện $\mathbf{F}_t^{(b)}$ tại bước t sẽ được sử dụng để dự đoán sản phẩm tiếp theo. Điểm số tương quan $r_{i,t}$ được xác định bằng tích vô hướng giữa vector đại diện này và vector nhúng của sản phẩm mục tiêu $\mathbf{N}_i$. Để tối ưu hóa kích thước mô hình và hạn chế quá khớp, SASRec áp dụng chiến lược Shared Item Embedding, tức là sử dụng chung một ma trận nhúng cho cả đầu vào và đầu ra ($\mathbf{N} = \mathbf{M}$). Các tác giả lập luận rằng tính phi tuyến mạnh mẽ của mạng truyền thẳng là đủ để mô hình giải quyết vấn đề bất đối xứng trong các chuyển đổi hành vi mua sắm mà không cần thiết phải tách biệt hai ma trận này.

Dựa trên các kết quả thực nghiệm được công bố bởi Kang và McAuley, mô hình SASRec đã chứng minh được hiệu năng vượt trội so với các kiến trúc tiền nhiệm như GRU4Rec hay Caser nhờ vào hai ưu thế kỹ thuật then chốt.

Đầu tiên là khả năng nắm bắt các phụ thuộc dài hạn trong chuỗi hành vi. Đối với các mạng hồi quy truyền thống, thông tin buộc phải lan truyền tuần tự qua từng bước thời gian, tạo ra độ dài đường dẫn tỷ lệ thuận với độ dài chuỗi $\mathcal{O}(n)$. Ngược lại, cơ chế Tự chú ý cho phép thiết lập kết nối trực tiếp giữa hai sản phẩm bất kỳ bất kể khoảng cách vị trí. Đặc tính này rút ngắn độ dài đường truyền tín hiệu xuống mức hằng số $\mathcal{O}(1)$, giúp mô hình duy trì và truy xuất hiệu quả các sở thích người dùng đã hình thành từ quá khứ xa mà không bị suy hao thông tin.

Ưu điểm thứ hai nằm ở hiệu suất tính toán và khả năng mở rộng. Khác với tính chất tuần tự bắt buộc của mạng hồi quy khiến quá trình xử lý không thể tận dụng triệt để sức mạnh của GPU, các phép toán ma trận trong SASRec có thể được thực thi song song trên toàn bộ chiều dài chuỗi. Sự cải tiến này mang lại lợi ích to lớn về mặt tốc độ; các thử nghiệm cho thấy thời gian huấn luyện của SASRec nhanh hơn gấp mười lần so với các mô hình dựa trên mạng hồi quy hoặc tích chập, cho phép hệ thống dễ dàng mở rộng để xử lý các tập dữ liệu quy mô lớn.

2.4.4 Kiến trúc Hai tháp cho Truy xuất Ứng viên

Bối cảnh và Vấn đề Quy mô

Trong các hệ sinh thái gợi ý quy mô lớn, thách thức kỹ thuật trọng yếu nằm ở giai đoạn truy xuất, nơi hệ thống buộc phải sàng lọc hàng nghìn ứng viên tiềm năng từ không gian dữ liệu khổng lồ chứa hàng triệu thực thể với độ trễ tối thiểu, thường yêu cầu dưới 100 mili giây. Mặc dù các phương pháp truyền thống như Phân rã ma trận đã chứng minh hiệu quả trong việc nắm bắt tương tác cơ bản giữa người dùng và sản phẩm, chúng lại bộc lộ hạn chế đáng kể khi đối mặt với yêu cầu tích hợp các đặc trưng phi tuyến tính phức tạp và dữ liệu bổ trợ đa phương thức. Để giải quyết bài toán này, kiến trúc Mạng nơ-ron Hai tháp, hay còn được biết đến với tên gọi Bi-Encoder, đã trở thành chuẩn mực công nghiệp hiện đại. Mô hình này được tiên phong ứng dụng bởi YouTube [9] và sau đó được tối ưu hóa hoàn thiện bởi Google [8] cho các tác vụ xếp hạng quy mô lớn.

Cấu trúc Mạng nơ-ron Hai tháp

Về mặt bản chất, kiến trúc Hai tháp hoạt động dựa trên nguyên lý tách biệt quá trình mã hóa thành hai luồng xử lý độc lập nhằm tối ưu hóa tốc độ truy vấn. Cụ thể, hệ thống bao gồm Tháp Người dùng được ký hiệu là bộ mã hóa f_{θ} , chịu trách nhiệm tổng hợp hồ sơ cá nhân và lịch sử hành vi để tạo ra vector biểu diễn người dùng $\mathbf{u}$ thuộc không gian $\mathbb{R}^d$. Song song với đó, Tháp Sản phẩm với bộ mã hóa g_{ϕ} tập trung khai thác các đặc trưng nội tại của vật phẩm để xây dựng vector biểu diễn tương ứng $\mathbf{v}$.

Điểm đặc trưng cốt lõi phân biệt thiết kế này với các mô hình khác là cơ chế *tương tác muộn*. Hai mạng nơ-ron hoàn toàn không chia sẻ thông tin hay tham số trong suốt quá trình trích xuất đặc trưng, mà chỉ thực hiện so khớp ở lớp cuối cùng. Tại đây, độ tương đồng hay mức độ phù hợp giữa người dùng và sản phẩm được ước lượng thông qua phép tính tích vô hướng đơn giản [7]:

$$s(x, y) = \langle u(x, \theta), v(y, \theta) \rangle \quad (2.17)$$

Trong đó, $u(x, \theta)$ là hàm ánh xạ đặc trưng người dùng x , và $v(y, \theta)$ là hàm ánh xạ đặc trưng sản phẩm y dựa trên bộ tham số mô hình θ .

Cơ chế này cho phép hệ thống tính toán trước và lập chỉ mục các vector sản phẩm, giúp giảm đáng kể chi phí tính toán trực tuyến trong giai đoạn truy xuất thời gian thực.

Chiến lược Huấn luyện: Học Tương phản

Trong các kiến trúc Two-Tower hiện đại, chiến lược huấn luyện đã có sự chuyển dịch từ bài toán phân loại nhị phân truyền thống sang khuôn khổ Học tương phản (Contrastive Learning). Thách thức lớn nhất đối với các hệ thống truy xuất quy mô lớn nằm ở hàm mục tiêu: việc tính toán hàm Softmax trên toàn bộ không gian ứng viên (có thể lên tới hàng triệu sản phẩm) để xác định mẫu âm là bất khả thi về mặt tài nguyên tính toán và độ trễ. Để giải quyết vấn đề này, đồ án áp dụng giải pháp được đề xuất bởi Yi và cộng sự (2019) [8], sử dụng hàm mất mát **Sampled Softmax** kết hợp với kỹ thuật lấy mẫu âm trong lô (**In-batch Negatives**).

Kỹ thuật này hoạt động dựa trên giả định thống kê rằng trong một lô dữ liệu ngẫu nhiên, các cặp người dùng và sản phẩm không tương ứng có xác suất rất cao là không liên quan đến nhau. Thay vì tiêu tốn chi phí để truy xuất và đào (mine) các mẫu âm từ kho dữ liệu bên ngoài, hệ thống tận dụng chính các sản phẩm của người dùng khác trong cùng một lô để làm mẫu âm.

Cụ thể, xét một lô dữ liệu có kích thước B . Với mỗi cặp mẫu dương $(\mathbf{u}_i, \mathbf{v}_i)$ (tương ứng với người dùng i và sản phẩm thực tế i):

- **Mẫu dương:** Là chính vector sản phẩm $\mathbf{v}_i$. Mục tiêu của mô hình là tối đa hóa độ tương đồng $s(\mathbf{u}_i, \mathbf{v}_i)$.
- **Mẫu âm:** Là tập hợp toàn bộ các vector sản phẩm $\mathbf{v}_j$ (với $j \neq i$) thuộc về các mẫu dữ liệu khác trong cùng batch đó. Như vậy, mỗi người dùng sẽ được so sánh với 1 mẫu dương và $(B - 1)$ mẫu âm nhân tạo này.

Để tối ưu hóa quá trình học biểu diễn vector, hệ thống sử dụng hàm mất mát InfoNCE (2.4). Hàm này có nhiệm vụ tối đa hóa xác suất dự đoán đúng sản phẩm mục tiêu $\mathbf{v}_i$ trong khi giảm thiểu xác suất của tập hợp $B - 1$ sản phẩm nhiễu.

Phương pháp này không chỉ giải quyết triệt để bài toán hiệu năng tính toán mà còn được chứng minh là giúp mô hình học được các không gian biểu diễn phân tách tốt hơn, nhờ vào sự đa dạng và ngẫu nhiên của các mẫu âm được cập nhật liên tục trong mỗi bước huấn luyện.

Ưu điểm về Triển khai Thực tế

Lý do kiến trúc Two-Tower trở thành chuẩn mực thống trị trong bài toán Truy xuất bắt nguồn từ khả năng tách biệt hoàn toàn quá trình tính toán giữa hai thực thể người dùng và sản phẩm. Đặc tính kỹ thuật này cho phép tối ưu hóa quy trình xử lý thông qua hai giai đoạn riêng biệt. Trong giai đoạn ngoại tuyến (offline), nhờ sự độc lập của Tháp Sản phẩm, hệ thống có thể thực hiện tính toán trước vector biểu diễn cho toàn bộ không gian hàng hóa—có thể lên tới hàng triệu phần tử—và lưu trữ chúng dưới dạng chỉ mục tối ưu trong các cơ sở dữ liệu vector chuyên dụng như Milvus hay Faiss.

Chiến lược này tạo tiền đề cho hiệu suất vượt trội trong giai đoạn phục vụ trực tuyến (online serving). Khi nhận yêu cầu, hệ thống chỉ cần thực thi suy luận một lần duy nhất tại Tháp Người dùng để tạo ra vector truy vấn. Sau đó, thay vì phải quét toàn bộ cơ sở dữ liệu, việc xác định Top-K ứng viên tiềm năng được thực hiện thông qua các thuật toán Tìm kiếm Láng giềng Gần nhất Xấp xỉ (ANN). Cơ chế này cho phép hệ thống duy trì độ trễ phản hồi ở mức dưới mili-giây, đồng thời đảm bảo tốc độ truy xuất không bị suy giảm tuyến tính khi quy mô kho hàng tăng lên, giải quyết triệt để bài toán về khả năng mở rộng của các hệ thống gợi ý hiện đại [9].

2.5 Cơ sở Lý thuyết về Mô hình Ngôn ngữ Lớn

2.5.1 Tổng quan về Mô hình Ngôn ngữ Lớn

Mô hình Ngôn ngữ Lớn (LLM) là các mô hình học sâu được huấn luyện trên lượng dữ liệu văn bản khổng lồ, có khả năng hiểu, tổng hợp và sinh ngữ điệu giống con người. Về bản chất, các LLM hiện đại là các mô hình xác suất, hoạt động dựa trên nguyên lý dự đoán từ tiếp theo (*next-token prediction*) trong một chuỗi, nhằm tối đa hóa xác suất xuất hiện của chuỗi đó dựa trên ngữ cảnh đã cho [36]. Sự phát triển của LLM đánh dấu bước chuyển mình từ các mô hình thống kê truyền thống (N-gram) và mạng nơ-ron hồi quy (RNN/LSTM) sang các kiến trúc dựa trên cơ chế chú ý (*Attention mechanisms*).

2.5.2 Kiến trúc Transformer Decoder-only

Trong khi kiến trúc Transformer nguyên bản do Vaswani và cộng sự đề xuất năm 2017 bao gồm hai thành phần là Bộ mã hóa (*Encoder*) và Bộ giải mã (*Decoder*) để phục vụ bài toán dịch máy [12], các mô hình ngôn ngữ lớn (LLM) hiện đại như dòng GPT hay Llama chủ yếu dựa trên biến thể *Decoder-only*. Đây là kiến trúc được tối ưu hóa chuyên biệt cho tác vụ sinh văn bản tự hồi quy (*Autoregressive Generation*), đóng vai trò cốt lõi trong module giải thích gợi ý của đề án.

Đặc điểm Kiến trúc và Cơ chế Tự hồi quy

Khác với các mô hình *Encoder-only* như BERT vốn có khả năng tiếp cận toàn bộ ngữ cảnh hai chiều (*Bidirectional*) cùng lúc để thực hiện các tác vụ phân loại, kiến trúc *Decoder-only* xử lý dữ liệu theo cơ chế đơn chiều (*Unidirectional*). Tại một bước thời gian t , mô hình chỉ được phép tiếp cận thông tin từ các từ trong quá khứ ($x_1, \dots, x_{t-1}$) và chính nó, tuyệt đối không được truy cập các từ trong tương lai ($x_{t+1}, \dots$). Radford *et al.* đã chứng minh rằng cấu trúc tự hồi quy này, mặc dù hạn chế ngữ cảnh tương lai, lại cho phép mô hình tối ưu hóa khả năng sinh ngôn ngữ tự nhiên và xây dựng các biểu diễn ngữ nghĩa mạnh mẽ thông qua việc huấn luyện trên lượng dữ liệu lớn [37].

Mục tiêu huấn luyện của kiến trúc này là tối đa hóa xác suất của từ tiếp theo dựa trên chuỗi lịch sử (*Next Token Prediction*). Giả sử một câu văn bản là chuỗi $x = \{x_1, x_2, \dots, x_n\}$, xác suất kết hợp của toàn bộ chuỗi được phân rã theo quy tắc chuỗi xác suất [36]:

$$P(x) = \prod_{i=1}^n P(x_i | x_1, x_2, \dots, x_{i-1}; \theta) \quad (2.18)$$

Trong đó θ là bộ tham số của mô hình. Brown *et al.* trong công trình về GPT-3 đã chứng minh rằng việc mở rộng quy mô huấn luyện trên hàm mục tiêu đơn giản này giúp mô hình phát sinh khả năng học vài bước (*Few-shot learning*) vượt trội [38].

Cơ chế Masked Self-Attention

Thành phần kỹ thuật quan trọng nhất đảm bảo tính chất nhân quả (*causality*) của kiến trúc này là cơ chế *Masked Self-Attention* (Tự chú ý có che). Để ngăn chặn luồng thông tin rò rỉ từ tương lai, một ma trận mặt nạ M được áp dụng vào phép tính Attention trước khi đi qua hàm Softmax. Ma trận này thường là một ma trận tam giác trên với các giá trị âm vô cùng ($-\infty$).

Công thức tính toán Attention có thể được định nghĩa như sau:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T + M}{\sqrt{d_k}} \right) V \quad (2.19)$$

Tại đây, các giá trị $-\infty$ trong ma trận M khi đi qua hàm Softmax sẽ chuyển thành xác suất 0. Điều này triệt tiêu hoàn toàn trọng số chú ý đến các token tương lai, buộc mô hình phải học cách suy luận chỉ dựa trên dữ liệu đã biết [12].

Lý do Lựa chọn cho Hệ thống Giải thích

Việc áp dụng kiến trúc *Decoder-only* cho thành phần sinh giải thích trong hệ thống gợi ý mang lại hai lợi thế kỹ thuật lớn. Thứ nhất, kiến trúc này sở hữu khả năng *Zero-shot* mạnh mẽ, cho phép mô hình hiểu và thực hiện các chỉ dẫn phức tạp (*Prompt*) về việc giải thích đặc điểm sản phẩm mà không cần quá trình tinh chỉnh lại từ đầu. Thứ hai, do bản chất được huấn luyện để sinh văn bản tiếp nối tự nhiên, các lời giải thích được tạo ra có cấu trúc ngữ pháp chặt chẽ và văn phong mạch lạc hơn so với các phương pháp điền khuôn mẫu truyền thống [38].

2.5.3 Quy trình Huấn luyện Mô hình GPT

Phương pháp huấn luyện các mô hình ngôn ngữ lớn thuộc họ GPT được xây dựng dựa trên hướng tiếp cận bán giám sát (*Semi-supervised learning*), kết hợp giữa việc học biểu diễn ngôn ngữ tổng quát trên dữ liệu không nhãn và tinh chỉnh chuyên sâu trên dữ liệu có nhãn. Theo Radford và cộng sự (2018), quy trình này bao gồm hai giai đoạn cốt lõi: Tiền huấn luyện sinh mẫu (*Generative Pre-training*) và Tinh chỉnh có giám sát (*Supervised Fine-tuning*) [37]. Đối với các phiên bản hiện đại hơn như ChatGPT (InstructGPT), một giai đoạn thứ ba là Học tăng cường từ phản hồi con người (*RLHF*) được bổ sung để căn chỉnh hành vi của mô hình [39].

2.5.3.1 Giai đoạn 1: Tiền huấn luyện không giám sát (Unsupervised Pre-training)

Trong giai đoạn này, mô hình được huấn luyện trên một kho dữ liệu văn bản khổng lồ (*corpus of tokens*) $\mathcal{U} = \{u_1, \dots, u_n\}$. Mục tiêu của mô hình là học cách dự đoán từ tiếp theo trong chuỗi dựa trên ngữ cảnh quá khứ. Đây là bài toán mô hình hóa ngôn ngữ chuẩn (*Standard Language Modeling*) với hàm mục tiêu là tối đa hóa hàm log-likelihood sau:

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta) \quad (2.20)$$

Trong đó:

- k là kích thước cửa sổ ngữ cảnh (*context window*).
- P là xác suất có điều kiện được ước lượng bởi mạng nơ-ron với tham số Θ .
- Mô hình sử dụng kiến trúc Transformer Decoder đa tầng để tính toán xác suất này thông qua cơ chế Self-Attention có che (*Masked Self-Attention*) [37].

Kết thúc giai đoạn này, mô hình học được các đặc trưng ngữ nghĩa phong phú và kiến thức tổng quát về thế giới, nhưng chưa có khả năng thực hiện các tác vụ cụ thể theo chỉ dẫn của người dùng.

2.5.3.2 Giai đoạn 2: Tinh chỉnh có giám sát (Supervised Fine-tuning - SFT)

Sau khi tiền huấn luyện, mô hình được chuyển sang giai đoạn tinh chỉnh trên một tập dữ liệu nhỏ hơn nhưng có chất lượng cao $\mathcal{C}$, bao gồm các cặp (input, label) hoặc (instruction, output).

Giả sử một tập dữ liệu có nhãn bao gồm các chuỗi đầu vào $x^1, \dots, x^m$ và nhãn tương ứng y . Các đầu vào này được đưa qua mô hình đã tiền huấn luyện để lấy vector trạng thái ẩn cuối cùng h_l^m , sau đó đi qua một lớp tuyến tính bổ sung để dự đoán y [37]:

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y) \quad (2.21)$$

Hàm mục tiêu lúc này là tối đa hóa xác suất đúng của nhãn y với dữ liệu đầu vào x :

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y | x^1, \dots, x^m) \quad (2.22)$$

Radford *et al.* (2018) cũng đề xuất rằng việc thêm hàm mất mát của mô hình ngôn ngữ (L_1) vào quá trình tinh chỉnh dưới dạng hàm phụ trợ sẽ giúp cải thiện khả năng tổng quát hóa và tăng tốc độ hội tụ:

$$L_{\text{total}} = L_2(\mathcal{C}) + \lambda L_1(\mathcal{C}) \quad [37]$$

2.5.3.3 Giai đoạn 3: Học tăng cường từ phản hồi con người (RLHF)

Để khắc phục vấn đề mô hình sinh ra nội dung không đúng sự thật hoặc độc hại, Ouyang *et al.* (2022) đã giới thiệu quy trình RLHF (*Reinforcement Learning from Human Feedback*). Giai đoạn này bao gồm việc huấn luyện một mô hình phần thưởng (*Reward Model - RM*) dựa trên xếp hạng của con người về chất lượng câu trả lời. Sau đó, thuật toán tối ưu hóa PPO (*Proximal Policy Optimization*) được sử dụng để tinh chỉnh chính sách của GPT sao cho tối đa hóa phần thưởng mà RM dự đoán, đảm bảo mô hình tuân thủ các tiêu chí: hữu ích (*helpful*), trung thực (*honest*) và vô hại (*harmless*) [39].

2.5.4 LLM trong Hệ thống Gợi ý

Trong ngữ cảnh của hệ thống gợi ý, LLM không chỉ đóng vai trò xử lý ngôn ngữ tự nhiên mà còn được ứng dụng để tăng tính minh bạch (*Explainability*).

Các phương pháp truyền thống (như *Matrix Factorization*) thường hoạt động như một hộp đen. Việc tích hợp LLM cho phép tận dụng khả năng suy luận chuỗi (*Chain-of-Thought reasoning*) để sinh ra các lời giải thích tự nhiên. Bằng cách cung cấp cho LLM thông tin về đặc trưng sản phẩm và lịch sử tương tác của người dùng thông qua kỹ thuật *Prompt Engineering*, hệ thống có thể tạo ra các văn bản giải thích mang tính cá nhân hóa, giúp người dùng hiểu tại sao sản phẩm đó được gợi ý, từ đó gia tăng niềm tin vào hệ thống [40].


Chương 3

Phương pháp đề xuất

3.1 Kiến trúc tổng thể

Hệ thống được thiết kế linh hoạt để tiếp nhận đầu vào đa dạng, cho phép người dùng tìm kiếm thông qua các câu truy vấn văn bản hoặc tải lên hình ảnh trực tiếp. Dựa trên những dữ liệu đầu vào này, hệ thống sẽ phân tích và đề xuất các sản phẩm chất lượng cao, đảm bảo sự tương thích sát sao nhất với nhu cầu và sở thích cá nhân của từng người dùng. Để hiện thực hóa điều này, nhóm sử dụng bộ dữ liệu Amazon Reviews làm nền tảng huấn luyện. Đây là một tập dữ liệu phong phú bao gồm các đặc trưng từ phía người dùng như nội dung đánh giá, điểm xếp hạng, và mức độ hữu ích của đánh giá đó, kết hợp cùng siêu dữ liệu sản phẩm item metadata như mô tả chi tiết, giá bán và hình ảnh gốc; tất cả được liên kết chặt chẽ với nhau thông qua mã định danh sản phẩm.

Về mặt phương pháp hoạt động, đồ án xây dựng một quy trình xử lý hiện đại kết hợp giữa kiến trúc Two-Tower và LLM nhằm đạt được độ chính xác cao trong việc gợi ý dựa trên hành vi mua sắm quá khứ. Phương pháp Two-Tower (hay Bi-Encoder) là một kiến trúc mạng nơ-ron tiên tiến được sử dụng rộng rãi trong các hệ thống gợi ý và tìm kiếm thông tin quy mô lớn, đóng vai trò then chốt trong giai đoạn truy xuất ứng viên. Kiến trúc này vận hành dựa trên hai nhánh mạng nơ-ron độc lập hoạt động song song: Tháp người dùng (User Tower) chịu trách nhiệm mã hóa các đặc trưng về hành vi, lịch sử và ngữ cảnh của người dùng, trong khi Tháp sản phẩm (Item Tower) xử lý các thông tin thuộc tính đa phương thức của sản phẩm như hình ảnh, văn bản mô tả hay thông số kỹ thuật. Cả hai tháp đều có nhiệm vụ chuyển đổi dữ liệu đầu vào phức tạp thành các vector embedding nén trong cùng một không gian tiềm ẩn, và mức độ phù hợp giữa người dùng và sản phẩm được xác định ở bước cuối cùng thông qua phép tính tích vô hướng hoặc độ tương đồng cosine. Ưu điểm vượt trội của Two-Tower nằm ở khả năng tách biệt quá trình tính toán, cho phép hệ thống lập chỉ mục trước hàng triệu vector sản phẩm, từ đó giải quyết bài toán tìm kiếm và gợi ý trong thời gian thực với độ trễ cực thấp mà vẫn đảm bảo nắm bắt được các mối quan hệ ngữ nghĩa sâu sắc.



Hình 3.1: Mô hình two-tower

Hình 3.1 minh họa kiến trúc tổng quát của mô hình đề xuất, được xây dựng dựa trên khung làm việc Mạng nơ-ron Hai tháp. Mục tiêu cốt lõi của thiết kế này là tách biệt quá trình mã hóa Người dùng (User Modeling) và Sản phẩm (Item Modeling) thành hai luồng xử lý độc lập, cho phép tối ưu hóa hiệu năng trong giai đoạn truy xuất thời gian thực.

Luồng xử lý của hệ thống được chia thành hai nhánh chính:

1. Tháp Người dùng (User Tower - Nhánh bên trái): Tháp này chịu trách nhiệm mô hình hóa sở thích người dùng dựa trên chuỗi lịch sử hành vi. Điểm cải tiến trong kiến trúc này là đầu vào không chỉ bao gồm định danh sản phẩm (Item ID) đơn thuần, mà là một chuỗi các cặp dữ liệu (**Review + Item**).

- Mỗi tương tác quá khứ được biểu diễn kết hợp giữa đặc trưng sản phẩm và nội dung đánh giá (Review) tương ứng, giúp mô hình nắm bắt được ngữ nghĩa và thái độ của người dùng tại thời điểm đó.
- Các thông tin này đi qua các bộ mã hóa User Encoders (nơi chứa khối xử lý chuỗi SASRec) và được tổng hợp tại lớp *Fusion Layer* để tạo ra vector đại diện người dùng cuối cùng $\mathbf{u}$.

2. Tháp Sản phẩm (Item Tower - Nhánh bên phải): Tháp này chịu trách nhiệm mã hóa các đặc trưng đa phương thức của một sản phẩm ứng viên (Candidate Item).


- Đầu vào bao gồm dữ liệu văn bản (Text), hình ảnh (Images) và dữ liệu bảng (Tabular).
- Để đảm bảo tính nhất quán của không gian vector, hệ thống áp dụng kỹ thuật **Shared Embeddings** (Chia sẻ trọng số nhúng) cho các Item ID giữa hai tháp.
- Tương tự, các đặc trưng này được tổng hợp để tạo ra vector đại diện sản phẩm $\mathbf{v}$.

3. Cơ chế Tương tác và Huấn luyện: Hai tháp hoạt động song song và hoàn toàn không chia sẻ thông tin trong quá trình tính toán (Late Interaction). Tại lớp cuối cùng, sự tương đồng giữa người dùng và sản phẩm được tính toán thông qua tích vô hướng (Inner Product).

Mô hình được huấn luyện bằng hàm mất mát InfoNCE Loss theo nguyên lý Học tương phản. Sau khi huấn luyện, các vector người dùng và sản phẩm sẽ được lập chỉ mục vào

các Cơ sở dữ liệu Vector (Vector Index) để phục vụ cho bài toán tìm kiếm láng giềng gần nhất (ANN Search).

Trên cơ sở các biểu diễn vector đặc trưng đã được trích xuất và đồng bộ hóa từ hai nhánh của mô hình, hệ thống chuyển sang giai đoạn truy xuất ứng viên thông qua cơ chế tính toán độ tương đồng trong không gian vector. Hình 3.2 mô tả quá trình này.



Hình 3.2: *Quá trình Truy xuất sản phẩm*

Quy trình tìm kiếm bắt đầu khi người dùng thực hiện một truy vấn chủ động thông qua văn bản hoặc hình ảnh. Dữ liệu đầu vào này được chuyển đến bộ Query Encoders để thực hiện quá trình vector hóa. Tại đây, truy vấn thô được chuyển đổi thành vector nhúng (Query Embedding) nằm trong cùng không gian chiều với các vector sản phẩm đã được lập chỉ mục trước đó. Hệ thống sau đó sử dụng vector truy vấn này để quét qua Item Vector Index, thực hiện các phép toán tìm kiếm láng giềng gần nhất nhằm trích xuất ra tập hợp các ứng viên tiềm năng (Retrieved Candidates). Mục tiêu của giai đoạn này là tối ưu hóa độ phủ (Recall), đảm bảo thu thập được tất cả các sản phẩm có sự tương đồng về mặt ngữ nghĩa với ý định tìm kiếm của người dùng.

Điểm khác biệt của hệ thống so với các công cụ tìm kiếm truyền thống nằm ở cơ chế Personalized Filtering (Lọc cá nhân hóa). Song song với quá trình truy xuất dựa trên từ khóa, hệ thống đồng thời tham chiếu đến User Vector Index để trích xuất vector đặc trưng của người dùng—vốn được tổng hợp từ lịch sử hành vi và sở thích trong quá khứ. Vector người dùng này đóng vai trò như một bộ lọc ngữ cảnh, giúp điều chỉnh danh sách ứng viên ban đầu. Nhờ đó, các kết quả tìm kiếm không chỉ chính xác về mặt nội dung (ví dụ: đúng là "giày thể thao") mà còn phù hợp với gu thẩm mỹ riêng (ví dụ: ưu tiên "thương hiệu Nike" hay "phong cách tối giản") của từng cá nhân.

Sau khi danh sách ứng viên đã được sơ lọc, tập dữ liệu này được chuyển đến module LLM Reranking để thực hiện bước tinh chỉnh cuối cùng. Tại đây, một LLM sẽ phân tích sâu hơn mối quan hệ giữa truy vấn, chân dung người dùng và đặc điểm chi tiết của sản phẩm để sắp xếp lại thứ tự hiển thị. Quá trình này giúp loại bỏ các kết quả nhiễu và đưa các sản phẩm phù hợp nhất lên vị trí ưu tiên. Cuối cùng, hệ thống trả về danh sách sản phẩm kèm theo lời giải thích (List Items and explanation), giúp người dùng hiểu rõ lý do tại sao sản phẩm được đề xuất, qua đó tăng cường tính minh bạch và độ tin cậy của trải nghiệm tìm kiếm.

3.2 Tiền xử lý

Tổng quan Bộ dữ liệu

Để huấn luyện và đánh giá hiệu năng của hệ thống, đồ án sử dụng bộ dữ liệu chuẩn hóa **Amazon Gift Cards**. Cấu trúc dữ liệu được tổ chức thành hai phân hệ chính và lưu trữ dưới định dạng JSON Lines (.jsonl), phục vụ trực tiếp cho hai nhánh của kiến trúc *Two-Tower*:

- **Dữ liệu Đặc trưng Sản phẩm (*Item Metadata*):**

Thành phần này cung cấp các thông tin nội tại của sản phẩm, đóng vai trò là đầu vào đa phương thức cho *Item Tower*. Các trường dữ liệu bao gồm:

- **Định danh và Phân loại:** store (thương hiệu), categories (danh mục sản phẩm), price (giá bán).
- **Đặc trưng Văn bản:** Bao gồm title (tiêu đề), description (mô tả chi tiết), feature (đặc điểm nổi bật) và details (thông số kỹ thuật). Đây là nguồn dữ liệu quan trọng để trích xuất ngữ nghĩa sản phẩm.
- **Đặc trưng Hình ảnh:** images (đường dẫn URL hình ảnh), phục vụ cho việc mã hóa thông tin thị giác.

- **Dữ liệu Tương tác và Phản hồi (*User Reviews*):**

Thành phần này ghi nhận lịch sử hành vi và ngữ cảnh cảm xúc của người dùng, đóng vai trò là dữ liệu huấn luyện cốt lõi cho *User Tower*.

- **Thông tin Tương tác:** user_id và parent_asin (mã sản phẩm) dùng để xác định các cặp tương tác User-Item; timestamp (thời gian) dùng để sắp xếp chuỗi hành vi theo thứ tự thời gian thực.
- **Thông tin Ngữ nghĩa & Cảm xúc:** title và text (nội dung bình luận) cung cấp ngữ cảnh sâu về thái độ của người dùng đối với sản phẩm (được sử dụng làm thông tin bổ trợ - *Side Information*); rating (điểm đánh giá) phản ánh mức độ hài lòng cụ thể.
- **Độ tin cậy:** helpful_vote (lượt bình chọn hữu ích) và verified_purchase (xác thực đã mua hàng) giúp lọc nhiễu và đánh trọng số cho các tương tác chất lượng cao.

Quy trình Tiền xử lý Đa phương thức

Quy trình tiền xử lý dữ liệu được thiết kế theo cơ chế song song, trong đó dữ liệu thô đầu vào được phân tách và xử lý đồng thời qua ba luồng riêng biệt tương ứng với ba định dạng đặc trưng cốt lõi nhằm chuẩn hóa đầu vào cho mô hình huấn luyện.

Đối với **dữ liệu văn bản**, mục tiêu là xây dựng một trường thông tin mô tả thống nhất và sạch sẽ. Hệ thống thực hiện ghép nối các trường dữ liệu rời rạc bao gồm tiêu đề, mô tả chi tiết, đặc điểm và thông số kỹ thuật thành một chuỗi tổng hợp (text_combined). Chuỗi văn bản này sau đó trải qua bước làm sạch kỹ lưỡng để loại bỏ các thẻ HTML dư thừa, chuẩn hóa khoảng trắng và xử lý các giá trị rỗng, đảm bảo tính nhất quán về ngữ nghĩa cho đầu vào của bộ mã hóa ngôn ngữ.

Song song đó, luồng xử lý **dữ liệu hình ảnh** tập trung vào việc thu thập và kiểm định dữ liệu thị giác. Hệ thống triển khai kỹ thuật tải xuống đa luồng để tối ưu hóa tốc độ thu thập hình ảnh từ các đường dẫn URL về bộ nhớ cục bộ. Quy trình này tích hợp cơ chế kiểm soát lỗi chặt chẽ: các trường hợp liên kết hỏng, lỗi kết nối hoặc sản phẩm thiếu hình

ảnh minh họa sẽ được tự động phát hiện để loại bỏ hoặc thay thế bằng các token/mask phù hợp, đảm bảo tính toàn vẹn và ổn định của luồng dữ liệu.

Cuối cùng, **dữ liệu dạng bảng** được xử lý để chuẩn hóa các thông tin định lượng và định danh. Với dữ liệu số (như điểm đánh giá trung bình và số lượng đánh giá), hệ thống xử lý các giá trị khuyết thiếu bằng phương pháp điền trung vị, sau đó áp dụng chuẩn hóa Z-score để đưa dữ liệu về cùng phân phối chuẩn. Đối với dữ liệu phân loại (như danh mục sản phẩm, thương hiệu), hệ thống xây dựng các từ điển ánh xạ (dictionary mapping) để chuyển đổi các chuỗi ký tự sang dạng chỉ số nguyên (integer index), phục vụ cho quá trình Embedding tiếp theo.

Quy trình Xây dựng Chuỗi Hành vi Người dùng

Quy trình xây dựng chuỗi hành vi người dùng đóng vai trò nền tảng trong việc chuẩn bị dữ liệu đầu vào cho mô hình User Tower. Từ dữ liệu thô ban đầu dưới dạng nhật ký giao dịch hỗn hợp chứa hàng triệu dòng log từ tất cả người dùng, hệ thống thực hiện gom nhóm các bản ghi dựa trên mã định danh người dùng nhằm cô lập dòng chảy hành vi của từng cá nhân. Bước xử lý này chuyển đổi cấu trúc dữ liệu từ dạng bảng giao dịch phẳng sang dạng chuỗi phiên làm việc, cho phép mô hình tập trung khai thác sở thích riêng biệt mà không bị nhiễu loạn bởi hành vi của các người dùng khác. Kế đến, các tương tác trong từng nhóm được sắp xếp lại theo trình tự thời gian tăng dần dựa trên dấu thời gian. Thao tác này là bắt buộc để đảm bảo tính nhân quả của dữ liệu, giúp mô hình nhận diện chính xác diễn biến tâm lý và nhu cầu phát sinh theo trật tự logic, ví dụ như việc mua giày thường diễn ra trước khi mua tất hay dây giày thay vì sự xuất hiện ngẫu nhiên không theo quy luật.

Sau khi hoàn tất công đoạn ghép nối và định hình chuỗi hành vi, hệ thống tiến hành tiền xử lý song song đối với hai loại dữ liệu văn bản và cấu trúc dạng bảng, trong khi dữ liệu hình ảnh được lược bỏ tại bước này do tính chất thừa thớt của hình ảnh trong các phản hồi từ người dùng.

Đối với **dữ liệu văn bản**, mục tiêu là tạo ra các chuỗi mô tả sạch và thống nhất. Hệ thống thực hiện ghép nối trường tiêu đề và nội dung chi tiết thành một trường tổng hợp `text_combined`, sau đó áp dụng các kỹ thuật làm sạch để loại bỏ mã HTML dư thừa hay các khoảng trắng không cần thiết, đồng thời xử lý các giá trị rỗng nhằm chuẩn hóa đầu vào ngữ nghĩa.

Để đảm bảo tính ổn định số học và tối ưu hóa quá trình huấn luyện, **dữ liệu số** đầu vào được xử lý thông qua hai chiến lược chuẩn hóa chuyên biệt. Đối với điểm đánh giá, hệ thống áp dụng phép biến đổi tuyến tính theo công thức $x_{\text{norm}} = \frac{x-3.0}{2.0}$ nhằm quy hoạch dải giá trị gốc $[1, 5]$ về khoảng đối xứng $[-1, 1]$ có tâm tại 0, tạo điều kiện thuận lợi cho hoạt động của các hàm kích hoạt. Song song đó, đối với lượt bình chọn hữu ích — vốn mang đặc tính phân phối đuôi dài (*long-tail distribution*) — hệ thống sử dụng phép biến đổi logarit theo công thức $x_{\text{norm}} = \log(1 + \text{ReLU}(x))$. Kỹ thuật này giúp nén dải giá trị để giảm thiểu tác động của các điểm dữ liệu ngoại lai, đồng thời kết hợp hàm ReLU để đảm bảo tính hợp lệ của đầu vào logarit.

Ý nghĩa của Trật tự Thời gian và Nguyên tắc Nhân quả

Sở thích và nhu cầu của người dùng không tồn tại ở trạng thái tĩnh mà biến thiên liên tục theo quy luật thời gian. Việc sắp xếp dữ liệu theo trình tự thời gian là điều kiện tiên quyết giúp mô hình nhận diện được các mẫu chuyển đổi hành vi logic, chẳng hạn như quy luật ưu tiên mua sắm thiết bị chính trước khi mua phụ kiện bổ trợ:

Mua Điện thoại $\xrightarrow{\text{Hợp lý}}$ Mua Ốp lưng

Ngược lại, nếu trật tự này bị đảo lộn, mô hình sẽ học được các tương quan sai lệch thực tế:

Mua Ốp lưng $\xrightarrow{\text{Ít hợp lý}}$ Mua Điện thoại

Quan trọng hơn, thao tác này nhằm đảm bảo nguyên tắc cốt lõi về tính nhân quả (*Causality*) trong các mô hình chuỗi. Nguyên tắc này quy định rằng thông tin từ tương lai không được phép tác động ngược lại quá khứ. Nếu danh sách tương tác bị xáo trộn ngẫu nhiên, mô hình khi dự đoán hành động tại bước thời gian t có nguy cơ tiếp cận được thông tin về sản phẩm thực tế sẽ được mua ở bước $t + k$ (với $k > 0$). Hiện tượng này gây ra lỗi rò rỉ dữ liệu (*Data Leakage*), khiến kết quả đánh giá trở nên thiếu trung thực và mô hình mất khả năng dự báo chính xác trong thực tế.

Về phương diện kỹ thuật huấn luyện, các kiến trúc mô hình tự hồi quy như SASRec hay GPT đều vận hành dựa trên giả định Markov hoặc cơ chế chú ý nhân quả (*Causal Attention*), trong đó sự kiện tại thời điểm t chỉ phụ thuộc vào lịch sử chuỗi sự kiện từ 0 đến $t - 1$. Việc đảm bảo tính thứ tự của timestamp cho phép cơ chế Mặt nạ nhân quả (*Causal Masking*) — thường được hiện thực hóa bằng ma trận tam giác trên — hoạt động chính xác bằng cách che đi các vị trí tương lai, ngăn không cho mô hình nhìn trước đáp án. Đồng thời, kế thừa và phát triển từ nghiên cứu của Kang và McAuley [7], hệ thống đề xuất mở rộng ngữ cảnh đầu vào bằng cách tổng hợp đồng thời thông tin định danh sản phẩm và nội dung đánh giá (*review*) của người dùng, giúp mô hình nắm bắt sâu sắc hơn ý định hành vi trong chuỗi tương tác.

Quy trình Lọc và Phân tách Chuỗi Dữ liệu

Bước đầu tiên trong quy trình chuẩn bị dữ liệu là sàng lọc người dùng. Hệ thống tiến hành loại bỏ các trường hợp có ít hơn 2 tương tác nhằm giải quyết vấn đề khởi động lạnh, đảm bảo mỗi mẫu dữ liệu đều đủ thông tin để kiến tạo cặp Input-Target hợp lệ. Đối với một chuỗi hành vi có độ dài N đã được xác thực, dữ liệu được phân tách thành hai thành phần chuyên biệt: chuỗi đầu vào x bao gồm tổ hợp thông tin đánh giá và sản phẩm từ bước 1 đến $N - 1$ dùng để dự đoán, và chuỗi mục tiêu y bao gồm các sản phẩm thực tế từ bước 2 đến N đóng vai trò làm nhãn huấn luyện.

Chiến lược Cắt giảm và Đệm Chuỗi

Để tối ưu hóa hiệu năng tính toán song song theo lô (*Batch*) trên GPU, toàn bộ chuỗi dữ liệu được chuẩn hóa về một độ dài cố định. Đối với các chuỗi vượt quá giới hạn độ dài quy định, hệ thống áp dụng chiến lược cắt giảm và chỉ giữ lại các hành động gần nhất. Chiến lược này dựa trên giả định rằng sở thích của người dùng thay đổi theo thời gian, do đó chuỗi hành vi gần đây mang giá trị dự báo cao hơn so với quá khứ xa. Ngược lại, đối với các chuỗi ngắn hơn giới hạn, kỹ thuật thêm giá trị đệm (*Padding*) vào phía trước được áp dụng nhằm duy trì cấu trúc ma trận mà không làm sai lệch thứ tự thời gian của các sự kiện thực.

Cơ chế Mặt nạ (Masking) trong Mô hình

Để đảm bảo tính đúng đắn của thuật toán Self-Attention, hệ thống kết hợp hai loại mặt nạ chuyên dụng như mô tả trong Bảng 3.1 dưới đây:

Bảng 3.1: Các loại Mặt nạ sử dụng trong cơ chế Attention

Loại Mask	Mục đích kỹ thuật	Đặc điểm cấu trúc
Causal Mask	Che đi các thông tin ở các bước thời gian tương lai nhằm đảm bảo nguyên tắc nhân quả (chỉ nhìn thấy quá khứ).	Ma trận vuông $[S \times S]$ dạng tam giác trên.
Padding Mask	Chỉ định cho mô hình bỏ qua các vị trí chứa giá trị đệm ($PAD = 0$) vì chúng không mang ý nghĩa thông tin.	Ma trận nhị phân kích thước $[Batch \times 1 \times 1 \times S]$.


3.3 Xây dựng Tháp Sản phẩm

Trọng tâm của các hệ thống gợi ý hiện đại nằm ở khả năng chuyển đổi dữ liệu đa phương thức phức tạp thành các vector biểu diễn trong không gian ẩn, nơi khoảng cách hình học giữa các vector phản ánh trực tiếp mức độ tương đồng về mặt ngữ nghĩa. Trong kiến trúc đề xuất, Tháp Sản phẩm được thiết kế để xử lý song song và mã hóa ba luồng dữ liệu đặc trưng từ tập dữ liệu Amazon Reviews.

Đối với luồng **dữ liệu văn bản**, thông tin đầu vào được tổng hợp từ bốn trường dữ liệu giàu ngữ nghĩa bao gồm tiêu đề, mô tả chi tiết, đặc tính và thông số kỹ thuật của sản phẩm. Khối dữ liệu phi cấu trúc này được mã hóa thông qua mô hình ngôn ngữ BERT, cho phép hệ thống nắm bắt sâu sắc các ngữ cảnh và mối quan hệ từ vựng phức tạp mà các phương pháp nhúng từ truyền thống không thể thực hiện được.

Song song với đó, luồng **dữ liệu thị giác** tận dụng các hình ảnh sản phẩm gốc ở độ phân giải cao từ trường dữ liệu hình ảnh. Hệ thống sử dụng kiến trúc Vision Transformer (ViT) làm bộ trích xuất đặc trưng, giúp chuyển đổi các tín hiệu thị giác thành các vector đặc trưng toàn cục mang tính phân biệt cao, bổ sung thông tin trực quan quan trọng cho việc nhận diện sản phẩm.

Cuối cùng, luồng **dữ liệu dạng bảng** bao gồm các thuộc tính cấu trúc định lượng như điểm đánh giá trung bình, số lượng phản hồi, cùng các thông tin định danh phân loại như danh mục chính, danh mục phụ và thông tin cửa hàng. Các đặc trưng này được xử lý bởi một mạng nơ-ron đa tầng (MLP), có nhiệm vụ học các tương tác phi tuyến tính giữa các thuộc tính số học và phân loại. Đầu ra từ ba nhánh xử lý độc lập nêu trên sau đó được đồng bộ hóa và đi qua một tầng hợp nhất (Fusion Layer) để tạo thành một vector biểu diễn duy nhất, định hình nên bản sắc toàn diện của sản phẩm trong không gian tìm kiếm.



Hình 3.3: Kiến trúc Item Tower: Quy trình mã hóa và hợp nhất dữ liệu Đa phương thức

3.3.1 Text Encoder: Mô-đun Mã hóa Văn bản

TextEncoder là mô-đun mạng nơ-ron kế thừa từ lớp cơ sở `torch.nn.Module`, chịu trách nhiệm chuyển đổi dữ liệu văn bản thô từ trường thông tin tổng hợp `text_combined` thành các vector đặc trưng dày đặc (*dense vectors*) mang ý nghĩa ngữ nghĩa cao. Đây là thành phần đóng vai trò cốt lõi trong việc kiến tạo không gian biểu diễn ngôn ngữ cho toàn bộ kiến trúc tháp sản phẩm.

Cơ sở Lựa chọn và Chiến lược Huấn luyện Mô hình

Thay vì sử dụng các kiến trúc BERT cơ bản thường gặp, đồ án lựa chọn mô hình `all-mpnet-base-v2` làm mạng xương sống (*backbone*) cho tác vụ mã hóa. Đây là mô hình được ghi nhận đạt hiệu năng hàng đầu trong phân khúc mô hình kích thước trung bình trên bảng xếp hạng chuẩn MTEB [6], nhờ được huấn luyện trên tập dữ liệu khổng lồ chứa hơn một tỷ cặp câu [10]. Các kết quả thực nghiệm diện rộng cho thấy kiến trúc MPNet thể hiện khả năng vượt trội trong việc nắm bắt ngữ nghĩa câu và tối ưu hóa cho tác vụ tìm kiếm so với các kiến trúc BERT truyền thống.

Về chiến lược huấn luyện, đồ án áp dụng phương pháp Trích xuất Đặc trưng (*Feature Extraction*) bằng cách đóng băng toàn bộ trọng số của khối MPNet thông qua cơ chế `torch.no_grad()`. Việc này biến mô hình thành một bộ trích xuất tĩnh, giúp hệ thống vừa tiết kiệm đáng kể tài nguyên tính toán, vừa bảo toàn nguyên vẹn tri thức ngôn ngữ đã được huấn luyện trước đó mà không bị hiện tượng quên lãng tri thức (*catastrophic forgetting*) khi tinh chỉnh trên tập dữ liệu mới.

Cấu trúc Nội tại và Quy trình Xử lý

Quá trình khởi tạo và vận hành của mô-đun TextEncoder được xây dựng dựa trên sự

phối hợp của ba thành phần cấu trúc chính:

Đầu tiên là Bộ phân tách từ (*Tokenizer*) sử dụng thuật toán WordPiece tiên tiến. Khác với phương pháp tách từ theo khoảng trắng đơn thuần, quy trình này phân rã văn bản thành các đơn vị từ phụ (*sub-words*), giúp giải quyết triệt để vấn đề từ vựng không xác định (*OOV*) đối với các thuật ngữ hiếm hoặc phức tạp. Các token sau đó được ánh xạ sang các số nguyên định danh (Token ID) và được bổ sung các ký tự điều khiển đặc biệt: [CLS] để đánh dấu điểm bắt đầu phục vụ phân loại, [SEP] để phân cách câu, và [PAD] để đồng bộ hóa độ dài chuỗi đầu vào.

Kế đến là Mô hình Nền tảng sử dụng lớp `AutoModel` để tải kiến trúc `all-mpnet-base-v2` đã huấn luyện trước. Thành phần này tiếp nhận chuỗi token ID và chuyển đổi chúng thành các vector ngữ cảnh (*contextualized vectors*), nắm bắt mối quan hệ phụ thuộc giữa các từ trong câu.

Cuối cùng là Lớp Chiều (*Projection Head*), một tầng mạng tuyến tính (`nn.Linear`) chịu trách nhiệm thực hiện phép biến đổi không gian vector:

$$\mathbb{R}^{D_{\text{hidden}}} \rightarrow \mathbb{R}^{D_{\text{latent}}} \quad (3.1)$$

Phép chiếu này nén không gian đặc trưng từ kích thước đầu ra mặc định của mô hình nền ($D_{\text{hidden}} = 768$) xuống kích thước không gian ẩn mong muốn ($D_{\text{latent}} = 256$). Bước xử lý này không chỉ giúp giảm chiều dữ liệu mà còn đóng vai trò quan trọng trong việc đồng bộ hóa kích thước đặc trưng văn bản với các luồng dữ liệu hình ảnh và bảng, tạo điều kiện thuận lợi cho quá trình hợp nhất đa phương thức sau này. Ngoài ra, một cơ chế chuẩn hóa L2 cũng được tích hợp tùy chọn để điều chuẩn độ lớn của vector đầu ra nhằm tăng tính ổn định khi tính toán độ tương đồng.

Quy trình Tính toán và Trích xuất Đặc trưng Văn bản

Quy trình mã hóa trong hàm `forward` được thiết kế nhằm đảm bảo sự cân bằng giữa độ chính xác của biểu diễn ngữ nghĩa và hiệu quả sử dụng bộ nhớ GPU. Luồng xử lý dữ liệu được hiện thực hóa qua ba giai đoạn chính:

1. Phân lô và Chuẩn hóa Đầu vào

Để khắc phục giới hạn về bộ nhớ khi xử lý lượng lớn dữ liệu văn bản, danh sách đầu vào được chia nhỏ thành các lô con (*mini-batches*) với kích thước mặc định là 128. Tại đây, các chuỗi văn bản được đưa qua bộ `Tokenizer` để chuyển đổi thành các tensor có kích thước cố định, phục vụ cho khả năng tính toán song song. Hệ thống áp dụng đồng thời kỹ thuật Cắt bớt để loại bỏ phần dư thừa của các câu vượt quá giới hạn, và kỹ thuật Đệm để thêm token đặc biệt [PAD] (giá trị 0) vào cuối các câu ngắn. Song song đó, một ma trận Mặt nạ chú ý (*Attention Mask*) được khởi tạo, đóng vai trò như bản đồ chỉ dẫn: gán giá trị 1 cho các token thực mang ngữ nghĩa và giá trị 0 cho các token đệm, qua đó điều hướng cơ chế *Self-Attention* tập trung xử lý thông tin hữu ích. Đáng chú ý, quá trình trích xuất đặc trưng sơ cấp qua mô hình nền tảng được thực hiện trong ngữ cảnh `torch.no_grad()`, tức đóng băng trọng số gradient nhằm giảm tải chi phí tính toán và tập trung quá trình học vào lớp chiếu phía sau.

2. Cơ chế Masked Mean Pooling

Sau khi đi qua mô hình nền tảng, các vector đặc trưng thô cần được tổng hợp thành một vector đại diện duy nhất cho toàn bộ câu. Thay vì chỉ lấy vector của token [CLS] như phương pháp truyền thống, hệ thống sử dụng chiến lược Pooling trung bình có trọng số (*Masked Mean Pooling*) để tận dụng thông tin từ tất cả các từ trong câu. Quá trình này bắt

đầu bằng việc triệt tiêu nhiễu: thực hiện phép nhân từng phần tử giữa tensor đầu ra với ma trận *Attention Mask* nhằm chuyển đổi toàn bộ vector tại các vị trí đệm về vector **0**. Vector đại diện cuối cùng được tính toán dựa trên công thức trung bình cộng của các token thực:

$$\mathbf{e}_{\text{pooled}} = \frac{\sum_{i=1}^L (\mathbf{h}_i \cdot \text{mask}_i)}{\sum_{i=1}^L \text{mask}_i + \varepsilon} \quad (3.2)$$

Trong đó, $\mathbf{e}_{\text{pooled}}$ là vector nhúng kết quả, $\mathbf{h}_i$ là trạng thái ẩn của token thứ i , và mask_i là giá trị mặt nạ tương ứng. Tham số ε (thường là $1e^{-9}$) được thêm vào mẫu số nhằm đảm bảo tính ổn định số học, ngăn chặn lỗi chia cho 0 trong trường hợp ngoại lệ.

3. Chiều Không gian và Chuẩn hóa

Vector tổng hợp $\mathbf{e}_{\text{pooled}}$ (với số chiều mặc định $d = 768$) tiếp tục được đưa qua một lớp Chiều Tuyến tính để nén xuống không gian ẩn có kích thước $d = 256$, đồng bộ với không gian vector của tháp người dùng. Cuối cùng, vector này trải qua bước chuẩn hóa L2 để đưa về dạng vector đơn vị, tối ưu hóa cho hàm mất mát InfoNCE hoạt động dựa trên độ tương đồng Cosine. Kết quả từ các lô con sau đó được nối lại thành một tensor duy nhất, đại diện cho đặc trưng ngữ nghĩa cao cấp của toàn bộ tập dữ liệu đầu vào.

3.3.2 Image Encoder: Mô-đun Mã hóa Hình ảnh

ImageEncoder là mô-đun mạng nơ-ron kế thừa từ lớp cơ sở `torch.nn.Module`, đóng vai trò mã hóa thông tin thị giác trong kiến trúc tổng thể. Nhiệm vụ cốt lõi của mô-đun này là chuyển đổi dữ liệu hình ảnh thô thành các vector đặc trưng nén giàu ngữ nghĩa. Đặc điểm nổi bật trong thiết kế của ImageEncoder là khả năng xử lý đa biến thể hình ảnh cho cùng một sản phẩm — một đặc thù phổ biến trên sàn thương mại điện tử Amazon, nơi mỗi mặt hàng thường đi kèm với nhiều góc chụp khác nhau như ảnh chính diện, ảnh chi tiết góc cạnh hay ảnh bao bì. Thay vì lựa chọn ngẫu nhiên một hình ảnh đại diện hoặc tính trung bình cộng đơn thuần, hệ thống tích hợp cơ chế chú ý (*Attention Mechanism*) để tự động đánh giá và tổng hợp thông tin từ nhiều nguồn ảnh thành một vector đại diện duy nhất, đảm bảo tính toàn diện của dữ liệu đầu vào.

Cơ sở Lựa chọn và Chiến lược Huấn luyện Mô hình

Đối với thành phần trích xuất đặc trưng nền tảng, đề tài lựa chọn kiến trúc Vision Transformer (ViT), cụ thể là phiên bản `vit_base_patch16_224`. Đây là mô hình kích thước trung bình với khoảng 86 triệu tham số, hoạt động dựa trên nguyên lý chia nhỏ ảnh đầu vào độ phân giải 224×224 pixels thành các mảnh (*patches*) kích thước 16×16 pixels để xử lý tuần tự tương tự như văn bản. Trên tập dữ liệu chuẩn ImageNet-1k, ViT-Base đã chứng minh hiệu năng vượt trội với độ chính xác Top-1 đạt tới 84.5% tùy thuộc vào phương pháp tinh chỉnh [11]. Sự cân bằng giữa độ chính xác cao và yêu cầu tài nguyên tính toán hợp lý khiến đây trở thành lựa chọn tối ưu cho hệ thống gợi ý.

Về chiến lược huấn luyện, tương tự như mô hình ngôn ngữ, quá trình tinh chỉnh toàn bộ mô hình ViT đòi hỏi lượng bộ nhớ VRAM rất lớn. Do đó, hệ thống áp dụng chiến lược đóng băng trọng số bằng cách thiết lập `requires_grad = False` cho toàn bộ tham số của mô hình nền. Giải pháp này không chỉ giúp tiết kiệm tài nguyên tính toán mà còn bảo toàn nguyên vẹn các đặc trưng thị giác tổng quát đã được học từ tập dữ liệu khổng lồ ImageNet, tránh hiện tượng quên lãng tri thức (*catastrophic forgetting*) khi chuyển sang miền dữ liệu mới.

Cấu trúc Nội tại và Quy trình Tiền xử lý


Hệ thống được cấu thành từ ba thành phần chính, bắt đầu với Quy trình Tiền xử lý (*Preprocessing Pipeline*). Để đảm bảo tính tương thích tối đa với trọng số đã huấn luyện trước, mọi hình ảnh đầu vào đều trải qua chuỗi 3 bước xử lý tiêu chuẩn:

1. Đầu tiên, ảnh được thay đổi kích thước về độ phân giải cố định 224×224 pixels nhằm đảm bảo tính nhất quán về số lượng token đầu vào cho mạng Transformer.
2. Tiếp theo, dữ liệu ảnh được chuyển đổi từ định dạng số nguyên sang tensor số thực trong khoảng $[0.0, 1.0]$ với cấu trúc kênh đầu (*Channel-first*) theo chuẩn PyTorch.
3. Cuối cùng, và quan trọng nhất, là bước chuẩn hóa thống kê Z-score trên từng kênh màu dựa trên bộ tham số trung bình và độ lệch chuẩn của tập ImageNet. Phép chuẩn hóa này đưa phân phối dữ liệu về dạng chuẩn tắc, giúp loại bỏ các sai lệch về độ sáng màu sắc và thúc đẩy quá trình hội tụ của mô hình.

Thành phần tiếp theo là Lớp Chiếu (*Projection Layer*), một tầng mạng tuyến tính chịu trách nhiệm nén vector đặc trưng đầu ra từ 768 chiều xuống kích thước không gian tiềm ẩn chung $D_{\text{latent}} = 256$, đồng bộ hóa với các vector đặc trưng văn bản và bảng.

Cuối cùng là Cổng Biến thể (*Variant Gate*), một mạng nơ-ron đa tầng (MLP) đóng vai trò như cơ chế chú ý để chấm điểm độ quan trọng cho từng bức ảnh. Mạng này nhận đầu vào là vector đặc trưng 256 chiều của một bức ảnh và trả về một giá trị thực duy nhất biểu thị mức độ ưu tiên. Kiến trúc mạng gồm ba lớp: lớp tuyến tính đầu tiên nén thông tin xuống 128 chiều, lớp kích hoạt ReLU giúp mô hình học các mối quan hệ phi tuyến tính phức tạp (ví dụ: kết hợp nhiều điều kiện logic về màu sắc và bố cục), và lớp tuyến tính cuối cùng tổng hợp thông tin để đưa ra điểm số quyết định. Cơ chế này cho phép hệ thống tự động nhận diện và ưu tiên các hình ảnh mang nhiều thông tin giá trị nhất cho việc nhận dạng sản phẩm.

Quy trình Tính toán và Tổng hợp Đặc trưng Hình ảnh



Hình 3.4: Quy trình Tính toán và Tổng hợp Đặc trưng Hình ảnh

Quy trình mã hóa trong ảnh 3.4 được thiết kế chuyên biệt để xử lý đặc thù dữ liệu không đồng nhất, nơi mỗi sản phẩm sở hữu số lượng biến thể hình ảnh khác nhau. Giai đoạn đầu tiên tập trung vào việc tải và trích xuất đặc trưng cơ sở. Hệ thống duyệt qua từng sản phẩm trong lô dữ liệu để truy xuất danh sách đường dẫn ảnh cục bộ. Hàm đọc ảnh chuyên dụng sẽ chuyển đổi dữ liệu sang hệ màu RGB và áp dụng các bước tiền xử lý chuẩn hóa đã định nghĩa. Các hình ảnh thuộc cùng một sản phẩm sau đó được xếp chồng thành các lô con để đưa qua mô hình nền tảng trong chế độ đóng băng trọng số `torch.no_grad()`. Kết quả đầu ra là các vector đặc trưng thô, tiếp tục được dẫn qua lớp chiếu `self.proj` để tạo thành các embedding sơ cấp.

Điểm cải tiến cốt lõi của quy trình nằm ở cơ chế tổng hợp đa ảnh. Thay vì sử dụng phương pháp trung bình cộng đơn thuần vốn đánh đồng giá trị thông tin của mọi bức ảnh, hệ thống triển khai cơ chế *Gating* thông minh. Cụ thể, vector đặc trưng của từng biến thể ảnh được đưa qua mạng nơ-ron `variant_gate` để tính toán điểm số tầm quan trọng. Các điểm số này sau đó được chuẩn hóa bằng hàm Softmax nhằm tạo ra bộ trọng số có tổng bằng 1. Vector đại diện cuối cùng của sản phẩm được xác định là tổng có trọng số của các vector thành phần theo công thức:

$$\mathbf{v}_{\text{final}} = \sum_{i=1}^N (w_i \cdot \mathbf{v}_i) \quad (3.3)$$

Trong đó N là số lượng ảnh của sản phẩm, w_i là trọng số chú ý và $\mathbf{v}_i$ là vector đặc trưng tương ứng của ảnh thứ i . Cơ chế này cho phép mô hình tự động điều hướng sự tập trung vào các bức ảnh có tính đại diện cao nhất, ví dụ như ảnh chụp mặt trước rõ nét, đồng thời giảm thiểu tác động của các hình ảnh nhiễu hoặc kém chất lượng.

Cuối cùng, để đảm bảo tính toàn vẹn của luồng tính toán, hệ thống tích hợp quy trình

xử lý ngoại lệ đối với các sản phẩm thiếu ảnh hoặc gặp lỗi tải dữ liệu. Các vector đại diện sau khi tính toán sẽ được sắp xếp và phân bổ lại vào đúng vị trí chỉ số trong lô tổng thông qua thuật toán *Scatter*, trong đó các vị trí khuyết dữ liệu được điền mặc định bằng vector **0**. Kết quả đầu ra trải qua bước chuẩn hóa L2 để tạo thành vector đặc trưng $\mathbf{v}_{img}$ hoàn chỉnh, sẵn sàng cho quá trình hợp nhất đa phương thức.

3.3.3 Tabular Encoder: Mô-đun Mã hóa Dữ liệu Bảng

TabularEncoder là mô-đun nhằm mục đích mô hình hóa các thuộc tính cấu trúc (metadata) như giá cả, điểm đánh giá và hệ thống phân loại. Các thông tin này đóng vai trò quan trọng trong việc định hình đặc tính sản phẩm bên cạnh các luồng thông tin thị giác và văn bản. Mô-đun này được thiết kế với khả năng xử lý linh hoạt các đặc trưng hỗn hợp, bao gồm cả dữ liệu định danh và dữ liệu số thực, cũng như các trường dữ liệu đa trị phức tạp như danh mục sản phẩm lồng ghép.

Cơ chế Nhúng Đặc trưng Phân loại

Đối với các đặc trưng định danh, hệ thống tiếp nhận đầu vào là các chỉ số rời rạc đã được mã hóa từ bước tiền xử lý. Thông qua các lớp `nn.Embedding`, các chỉ số này được chuyển đổi thành các vector dày đặc có kích thước cố định, mặc định là 32 chiều. Hệ thống thiết lập ba bảng nhúng riêng biệt tương ứng với ba trường thông tin cốt lõi: bảng nhúng cho Danh mục chính, bảng nhúng cho Thương hiệu hoặc Cửa hàng, và bảng nhúng cho Danh mục chi tiết. Đặc biệt đối với trường Danh mục chi tiết vốn có tính chất đa nhãn, hệ thống áp dụng cơ chế tổng hợp để tạo ra một vector đại diện duy nhất cho toàn bộ danh sách các thẻ phân loại của sản phẩm.

Mạng Chiếu và Biến đổi Đặc trưng Số

Khác với các phương pháp truyền thống thường đưa trực tiếp dữ liệu số vào lớp tổng hợp, hệ thống thiết kế một mạng nơ-ron đa tầng chuyên biệt để xử lý các trường dữ liệu như điểm đánh giá hay số lượt bình chọn hữu ích. Mục tiêu của mạng này là biến đổi các giá trị số thô sang cùng một không gian chiều với các đặc trưng phân loại, đồng thời học các mối quan hệ phi tuyến tính phức tạp giữa các chỉ số định lượng. Kiến trúc mạng bao gồm ba tầng xử lý tuần tự:

Đầu tiên, Tầng Biến đổi Tuyến tính thực hiện chiếu dữ liệu $\mathbf{x}_{num}$ lên một không gian chiều cao hơn, cụ thể là 64 chiều, nhằm mở rộng khả năng biểu diễn thông tin theo công thức:

$$\mathbf{h}_1 = \mathbf{W}_1 \mathbf{x}_{num} + \mathbf{b}_1 \quad (3.4)$$

Trong đó $\mathbf{W}_1$ là ma trận trọng số và $\mathbf{b}_1$ là vector bias.

Tiếp theo, dữ liệu đi qua Tầng Kích hoạt Phi tuyến sử dụng hàm ReLU. Bước này cho phép mạng nắm bắt được các tương quan không đơn điệu của dữ liệu, ví dụ như mối quan hệ giữa số lượng đánh giá và độ tin cậy không phải lúc nào cũng là tuyến tính thuần túy:

$$\mathbf{a}_1 = \max(0, \mathbf{h}_1) \quad (3.5)$$

Cuối cùng, Tầng Chiếu và Nén thực hiện đưa vector ẩn về kích thước mục tiêu 32 chiều, khớp với kích thước của các vector nhúng phân loại để chuẩn bị cho quá trình hợp nhất:

$$\mathbf{e}_{num} = \mathbf{W}_2 \mathbf{a}_1 + \mathbf{b}_2 \quad (3.6)$$

Cơ chế Hợp nhất Đặc trưng

Tại tầng xử lý cuối cùng hay còn gọi là Lớp Hợp nhất, một mạng nơ-ron đa tầng chịu trách nhiệm tiếp nhận đầu vào là chuỗi ghép nối của tất cả các đặc trưng phân loại và đặc trưng số đã qua xử lý. Mạng này thực hiện nén và tổng hợp thông tin để tạo ra vector đầu ra cuối cùng có kích thước không gian ẩn 256 chiều, sẵn sàng để tích hợp đồng bộ với các vector đặc trưng từ tháp văn bản và tháp hình ảnh.

Quy trình Tính toán và Tổng hợp Đặc trưng Bảng

Quy trình tính toán trong hàm forward thực hiện chuỗi các biến đổi và tổng hợp nhằm đồng bộ hóa các luồng dữ liệu không đồng nhất. Giai đoạn đầu tiên bắt đầu với việc xử lý song song các nhóm thuộc tính. Đối với dữ liệu số, tensor đầu vào được đưa qua mạng chiếu chuyên biệt để tạo ra vector biểu diễn số học $\mathbf{v}_{\text{num}}$. Đồng thời, các đặc trưng định danh đơn trị như Danh mục chính và Thương hiệu được tra cứu trực tiếp từ các bảng nhúng tương ứng để trích xuất ra các vector đặc trưng $\mathbf{v}_{\text{main}}$ và $\mathbf{v}_{\text{store}}$.

Riêng đối với thuộc tính danh mục con vốn có tính chất đa trị với độ dài thay đổi, hệ thống áp dụng kỹ thuật Gộp trung bình (*Average Pooling*). Cụ thể, hệ thống truy xuất toàn bộ vector nhúng của các danh mục con liên quan đến sản phẩm, sau đó tính toán trung bình cộng để tạo ra một vector đại diện duy nhất $\mathbf{v}_{\text{cats}}$. Để đảm bảo tính ổn định của luồng tính toán trong các trường hợp ngoại lệ khi sản phẩm không có danh mục con, một vector có giá trị 0 sẽ được sử dụng thay thế.

Sau khi hoàn tất việc trích xuất các thành phần riêng lẻ, toàn bộ các vector đặc trưng được ghép nối lại với nhau theo chiều đặc trưng để tạo thành một tensor tổng hợp:

$$\mathbf{v}_{\text{concat}} = [\mathbf{v}_{\text{num}}; \mathbf{v}_{\text{main}}; \mathbf{v}_{\text{store}}; \mathbf{v}_{\text{cats}}] \quad (3.7)$$

Vector ghép nối này tiếp tục được truyền qua mạng hợp nhất để học các mối quan hệ phi tuyến tính phức tạp giữa các thuộc tính, ví dụ như sự tương quan tiềm ẩn giữa một thương hiệu cụ thể và xu hướng đánh giá cao. Cuối cùng, kết quả đầu ra trải qua bước chuẩn hóa L2 nhằm đưa vector về độ dài đơn vị $\mathbf{v}_{\text{tab}}$, đảm bảo tính tương thích về mặt hình học khi thực hiện các phép tính độ tương đồng trong không gian vector chung.

3.3.4 Cơ chế Hợp nhất Dữ liệu Đa phương thức (Fusion Gate)

FusionGate đóng vai trò là thành phần chốt chặn cuối cùng trong kiến trúc Tháp Sản phẩm, chịu trách nhiệm tổng hợp các vector đặc trưng từ ba luồng dữ liệu riêng biệt gồm văn bản, hình ảnh và dữ liệu bảng. Tương tự như cổng biến thể trong bộ mã hóa hình ảnh, module này áp dụng cơ chế hợp nhất có trọng số động dựa trên nguyên lý của cơ chế sự chú ý (*Attention Mechanism*). Phương pháp này cho phép mô hình tự động học và quyết định mức độ đóng góp của từng loại dữ liệu đối với từng sản phẩm cụ thể, đồng thời cung cấp giải pháp xử lý linh hoạt cho các trường hợp dữ liệu không trọn vẹn, chẳng hạn như sản phẩm thiếu hình ảnh minh họa.

Cấu trúc Mạng Gating

Trung tâm của cơ chế hợp nhất là mạng *Gating*, một mạng perceptron đa lớp được thiết kế để dùng chung cho cả ba luồng dữ liệu nhằm đảm bảo tính nhất quán trong cách đánh giá. Kiến trúc mạng bao gồm các tầng xử lý tuần tự: một lớp tuyến tính nén chiều dữ liệu từ kích thước ban đầu xuống một nửa, đi qua hàm kích hoạt phi tuyến ReLU để

học các mối quan hệ phức tạp, và cuối cùng là một lớp tuyến tính đầu ra để nén vector thành một giá trị thực vô hướng duy nhất. Giá trị này đại diện cho điểm số tin cậy hay lượng thông tin hữu ích mà mỗi nhánh dữ liệu đóng góp vào bản sắc chung của sản phẩm.

Quy trình Tính toán và Hợp nhất

Quy trình xử lý trong hàm *forward* được chia thành bốn giai đoạn tính toán liên tiếp. Đầu tiên, các vector đặc trưng đầu vào từ ba nhánh lần lượt được đưa qua mạng *Gating* để tính toán các điểm số thô. Ngay sau đó, hệ thống thực hiện bước xử lý dữ liệu thiếu — một tính năng quan trọng để đảm bảo tính ổn định. Thông qua một ma trận mặt nạ, hệ thống xác định các nhánh dữ liệu không tồn tại và gán giá trị âm vô cùng (xấp xỉ -10^9) cho điểm số tương ứng. Kỹ thuật này đảm bảo rằng khi đi qua hàm Softmax ở bước kế tiếp, trọng số của các thành phần bị thiếu sẽ triệt tiêu về 0, giúp loại bỏ hoàn toàn nhiễu từ các vector rỗng.

Sau khi đã xử lý các trường hợp ngoại lệ, vector điểm số tổng hợp được đưa qua hàm Softmax để chuyển đổi thành các trọng số xác suất chuẩn hóa có tổng bằng 1. Các trọng số này phản ánh trực tiếp tầm quan trọng tương đối của từng loại dữ liệu:

$$\mathbf{W} = \text{Softmax}(\mathbf{G}) = [w_t, w_i, w_b] \quad (3.8)$$

Vector hợp nhất cuối cùng $\mathbf{v}_{\text{fused}}$ được xác định bằng tổng có trọng số của các vector thành phần theo công thức:

$$\mathbf{v}_{\text{fused}} = w_t \cdot \mathbf{e}_{\text{text}} + w_i \cdot \mathbf{e}_{\text{img}} + w_b \cdot \mathbf{e}_{\text{tab}} \quad (3.9)$$

Kết quả cuối cùng trải qua bước chuẩn hóa L2 để đưa về độ dài đơn vị, tạo thành vector đại diện hoàn chỉnh $\mathbf{v}_{\text{item}}$, sẵn sàng cho các phép tính toán độ tương đồng Cosine trong không gian truy xuất.

3.4 Xây dựng Tháp Người dùng

3.4.1 Tổng quan và Nền tảng Kỹ thuật

Tháp người dùng đảm nhận vai trò mô hình hóa sở thích và hành vi của người dùng dựa trên lịch sử tương tác. Khác biệt với các phương pháp lọc cộng tác truyền thống vốn coi sở thích là yếu tố tĩnh, module này tiếp cận bài toán dưới góc độ Gợi ý Tuần tự (*Sequential Recommendation*). Mục tiêu cốt lõi là học được một vector biểu diễn người dùng $\mathbf{u}_t$ tại thời điểm t , sao cho vector này bao hàm được ý định mua sắm tiếp theo dựa trên chuỗi n tương tác quá khứ $S = \{i_1, i_2, \dots, i_t\}$, trong đó i_k là sản phẩm mà người dùng đã tương tác tại bước thứ k .

Về mặt nền tảng kỹ thuật, hệ thống sử dụng kiến trúc Transformer Encoder lấy cảm hứng từ mô hình SASRec [7]. Việc lựa chọn kiến trúc này cho phép mô hình vượt qua hạn chế của các mạng RNN hay CNN truyền thống trong việc nắm bắt các mối quan hệ phụ thuộc dài hạn, từ đó hiểu sâu hơn về sự chuyển dịch trong thị hiếu người dùng theo thời gian.

3.4.2 Cơ chế Biểu diễn Người dùng

Để kiến tạo không gian biểu diễn người dùng phong phú, hệ thống xử lý chuỗi dữ liệu đầu vào thu được từ giai đoạn tiền xử lý. Mỗi phần tử trong chuỗi này là một tổ hợp thông

tin bao gồm nội dung nhận xét của người dùng về sản phẩm và vector đặc trưng $\mathbf{v}_{item}$ của chính sản phẩm đó. Để đồng bộ hóa dữ liệu văn bản phi cấu trúc vào không gian tính toán chung, nhóm thực hiện biến đổi các nhận xét thông qua bộ mã hóa chuyên biệt dưới đây.

3.4.2.1 ReviewTextEncoder và Chiến lược Chia sẻ Trọng số

Trong kiến trúc Tháp Người dùng, thành phần mã hóa văn bản chịu trách nhiệm chuyển đổi nội dung bình luận tổng hợp thành các vector đặc trưng ngữ nghĩa. Một đặc điểm kiến trúc quan trọng trong thiết kế của hệ thống là việc áp dụng cơ chế Chia sẻ Trọng số (*Weight Sharing*). Cụ thể, bộ mã hóa văn bản trong Tháp Người dùng không được khởi tạo độc lập mà sử dụng chung kiến trúc mạng và toàn bộ tham số đã được huấn luyện của bộ mã hóa trong Tháp Sản phẩm. Điều này đồng nghĩa với việc các văn bản đánh giá của người dùng và mô tả sản phẩm đều được xử lý qua cùng một mô hình ngôn ngữ tiền huấn luyện và cùng một lớp chiếu không gian.

Chiến lược chia sẻ trọng số này mang lại ba lợi ích kỹ thuật thiết yếu. Thứ nhất, nó đảm bảo sự đồng bộ tuyệt đối về không gian ngữ nghĩa, giúp các văn bản từ phía người dùng và sản phẩm được ánh xạ vào cùng một hệ quy chiếu vector, tạo điều kiện thuận lợi cho mô hình trong việc so sánh và tìm kiếm sự tương đồng giữa lời nhận xét và mô tả sản phẩm. Thứ hai, cơ chế này giúp tối ưu hóa tài nguyên tính toán bằng cách giảm đáng kể số lượng tham số cần lưu trữ, tránh việc hệ thống phải duy trì hai mô hình ngôn ngữ lớn riêng biệt. Cuối cùng, Tháp Người dùng có thể thừa hưởng trực tiếp khả năng hiểu ngôn ngữ đã được tinh chỉnh từ quá trình huấn luyện Tháp Sản phẩm, giúp quá trình hội tụ diễn ra nhanh hơn.

Về mặt cài đặt kỹ thuật, module này tiếp nhận đầu vào là danh sách các chuỗi văn bản đánh giá trong lịch sử hành vi và trả về một tensor có kích thước $[B, S, D_{\text{latent}}]$, tương ứng với kích thước lô, độ dài chuỗi lịch sử và kích thước vector đặc trưng 256 chiều.

3.4.2.2 ReviewTabularEncoder: Mô-đun Mã hóa Cấu trúc Đánh giá

Mô-đun ReviewTabularEncoder chịu trách nhiệm mã hóa các thông tin định lượng và định danh gắn liền với bài đánh giá, bao gồm ba trường dữ liệu cốt lõi: điểm đánh giá (*Rating*) trong thang đo 1 – 5, số lượt bình chọn hữu ích (*Helpful Votes*) và trạng thái xác thực mua hàng (*Verified Purchase*). Mục tiêu của mô-đun là chuyển đổi các tín hiệu thô này thành một vector đặc trưng thống nhất, bổ sung ngữ cảnh tin cậy cho nội dung văn bản.

Kiến trúc Mạng và Các Khối Xử lý

Hệ thống được thiết kế với ba khối xử lý chuyên biệt tương ứng với đặc thù của từng loại dữ liệu. Đối với thuộc tính phân loại như trạng thái xác thực mua hàng, hệ thống sử dụng lớp `nn.Embedding` để chuyển đổi dữ liệu rời rạc sang không gian vector liên tục. Không gian nhúng được thiết lập với 3 trạng thái bao gồm giá trị đệm, đã mua và chưa xác thực, được ánh xạ vào vector có kích thước mặc định là 4 chiều.

Đối với dữ liệu số học, một mạng Perceptron đa lớp (MLP) được thiết kế để biến đổi cặp giá trị điểm số và lượt bình chọn từ không gian 2 chiều sang không gian đặc trưng cao chiều hơn. Kiến trúc mạng bao gồm lớp ẩn 64 chiều kết hợp với hàm kích hoạt ReLU, sau đó nén xuống 32 chiều. Thiết kế này cho phép mô hình nắm bắt các tương tác phi tuyến tính phức tạp giữa điểm số và mức độ tin cậy của cộng đồng, ví dụ như sự khác biệt

ngữ nghĩa giữa một đánh giá điểm thấp nhưng nhận được nhiều sự đồng tình so với một đánh giá điểm thấp nhưng ít được quan tâm.

Tại tầng xử lý cuối cùng, Khối Hợp nhất (*Fusion Block*) chịu trách nhiệm tổng hợp thông tin từ nhánh số học 32 chiều và nhánh phân loại 4 chiều. Vector ghép nối có kích thước tổng thể là 36 được đưa qua một mạng nơ-ron đa lớp để tạo ra đầu ra cuối cùng. Điểm đáng lưu ý trong thiết kế là lớp cuối cùng được cấu hình là lớp tuyến tính thuần túy không kèm hàm kích hoạt. Thiết kế này cho phép vector đầu ra nhận các giá trị thực trong toàn miền $(-\infty, +\infty)$, giúp bảo toàn sự phong phú của thông tin (*information richness*) trước khi được tích hợp vào các lớp tiếp theo của Tháp Người dùng.

Quy trình Xử lý Luồng Dữ liệu

Quy trình xử lý diễn ra theo trình tự chặt chẽ nhằm đảm bảo tính toàn vẹn của dữ liệu. Đầu vào bao gồm điểm số, lượt bình chọn và trạng thái xác thực sau khi được làm sạch và chuẩn hóa sẽ được phân tách vào các nhánh xử lý tương ứng. Trạng thái xác thực đi qua lớp Embedding để tạo vector $\mathbf{v}_{cat}$, trong khi điểm số và lượt bình chọn đi qua mạng chiều số học để tạo vector $\mathbf{v}_{num}$. Hai thành phần này sau đó được ghép nối thành vector tổng hợp $\mathbf{v}_{concat}$ theo công thức:

$$\mathbf{v}_{concat} = [\mathbf{v}_{num}; \mathbf{v}_{cat}] \quad (3.10)$$

Cuối cùng, vector tổng hợp được đưa qua mạng Fusion để tạo ra biểu diễn vector đầu ra, đại diện cho ngữ cảnh cấu trúc toàn diện của bài đánh giá.

3.4.2.3 Cổng Hợp nhất Người dùng (User Fusion Gate)

Cổng *GatingFusionLayer* đóng vai trò trung tâm trong việc tổng hợp vector biểu diễn tương tác của người dùng. Nhiệm vụ cốt lõi của thành phần này là kết hợp vector định danh sản phẩm $\mathbf{v}_{item}$ thu được từ Tháp Sản phẩm với ngữ cảnh tương tác cụ thể, bao gồm nội dung đánh giá $\mathbf{v}_{text}$ và các chỉ số định lượng $\mathbf{v}_{tabular}$. Mục tiêu là tạo ra một vector duy nhất $\mathbf{h}_{seq}$ đại diện cho một bước trong chuỗi hành vi thông qua cơ chế *Gating*, cho phép mô hình tự động điều chỉnh mức độ đóng góp của từng nguồn thông tin dựa trên ngữ cảnh thực tế.

Kiến trúc và Các Khối Xử lý

Về mặt kiến trúc, module bao gồm hai khối xử lý song song. Khối Chiều và Đồng bộ sử dụng ba lớp tuyến tính riêng biệt để đưa các vector đầu vào có kích thước khác nhau về cùng một không gian chiều chung $d_{model} = 256$, chuẩn bị cho quá trình cộng gộp. Song song đó, Mạng *Gating* được thiết kế dưới dạng một mạng perceptron đa lớp (Linear $\rightarrow$ ReLU $\rightarrow$ Linear) tiếp nhận toàn bộ dữ liệu ghép nối đầu vào để tính toán điểm số tầm quan trọng cho từng thành phần Item, Text và Tabular.

Quy trình Xử lý


Quy trình xử lý diễn ra tuần tự qua ba bước. Đầu tiên, các vector đặc trưng được chiếu sang không gian chung và áp dụng hàm kích hoạt phi tuyến ReLU để tăng khả năng biểu diễn. Kế đến, hệ thống thực hiện tính toán trọng số thông qua hàm Softmax, tái sử dụng cơ chế hợp nhất động tương tự như đã trình bày tại phần Tháp Sản phẩm, nhưng áp dụng cho ngữ nghĩa kết hợp giữa sản phẩm và phản hồi người dùng. Kết quả đầu ra là một tensor có kích thước $[B, S, D_{latent}]$, sẵn sàng làm đầu vào cho mạng *Transformer Encoder* để mô hình hóa chuỗi thời gian.

3.4.2.4 Module Mã hóa Vị trí (Positional Encoding)

Trong kiến trúc Tháp Người dùng, chuỗi hành vi lịch sử được xử lý thông qua mạng Transformer. Một đặc điểm cốt lõi của cơ chế *Self-Attention* là tính bất biến hoán vị, nghĩa là mô hình xử lý tập hợp đầu vào song song mà không tự nhận biết được thứ tự trước sau của các phần tử. Tuy nhiên, đối với bài toán gợi ý tuần tự, thứ tự tương tác đóng vai trò tối quan trọng, chẳng hạn như hành vi mua điện thoại thường mang tính tiền đề và diễn ra trước khi mua ốp lưng. Để khắc phục hạn chế này, module *PositionalEncoding* được thiết kế nhằm bổ sung thông tin về vị trí tương đối hoặc tuyệt đối vào các vector biểu diễn trước khi chúng được đưa vào các lớp Attention.

Phương pháp Mã hóa Sinusoidal

Hệ thống áp dụng phương pháp Mã hóa Sinusoidal cố định theo kiến trúc Transformer nguyên bản. Phương pháp này tận dụng các hàm lượng giác với tần số biến thiên để tạo ra một đặc trưng vị trí độc nhất cho mỗi bước thời gian.



Hình 3.5: Minh họa trực quan giá trị *Positional Encoding* trên 4 chiều ẩn đầu tiên. Các đường cong hình sin với tần số khác nhau giúp mô hình phân biệt vị trí trong chuỗi.

Hình 3.5 minh họa trực quan sự biến thiên giá trị của vector mã hóa vị trí trên bốn chiều ẩn đầu tiên đối với một chuỗi có độ dài 16 bước. Các đồ thị cho thấy hàm lượng giác dao động trong khoảng từ -1 đến 1 với tần số khác nhau tùy thuộc vào chỉ số của chiều không gian. Cụ thể, các chiều có chỉ số thấp thể hiện tần số dao động cao, trong khi các chiều cao hơn sở hữu bước sóng dài hơn. Cơ chế biến đổi tần số này kiến tạo nên một mẫu hình đặc trưng riêng biệt cho mỗi vị trí pos , hỗ trợ mô hình Transformer dễ dàng học được mối quan hệ vị trí tương đối giữa các token trong chuỗi.

Dựa trên đề xuất của Vaswani và cộng sự [12], giá trị mã hóa tại vị trí pos và chiều i trong không gian vector kích thước d_{model} được xác định bởi công thức toán học sau:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad (3.11)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad (3.12)$$

Trong đó, các chiều chẵn $2i$ được áp dụng hàm Sine và các chiều lẻ $2i + 1$ được áp dụng hàm Cosine. Việc kết hợp hai hàm lượng giác này cho phép mô hình lan truyền và ngoại suy thông tin vị trí một cách hiệu quả ngay cả đối với các chuỗi dài hơn độ dài đã gặp trong quá trình huấn luyện.

Chi tiết Kỹ thuật và Quy trình Cài đặt

Mô-đun được hiện thực hóa dưới dạng một lớp kế thừa từ `nn.Module` với quy trình xử lý được tối ưu hóa ngay từ bước khởi tạo. Cụ thể, một ma trận vị trí `pe` có kích thước $[\text{max_len}, 1, d_{\text{model}}]$ được tính toán trước và lưu trữ vào bộ nhớ đệm thông qua cơ chế `register_buffer`. Kỹ thuật này cho phép hệ thống ghi nhận ma trận như một phần trạng thái bền vững của mô hình nhưng không tham gia vào quá trình cập nhật gradient, giúp cố định thông tin vị trí và giảm tải số lượng tham số cần tối ưu.

Trong quá trình lan truyền xuôi, các vector vị trí tương ứng được cộng trực tiếp vào vector đặc trưng đầu vào theo công thức:

$$\mathbf{x} = \mathbf{x} + \mathbf{PE}[:, \mathbf{x}.\text{size}(0)] \quad (3.13)$$


Phép toán cộng tuyến tính này đóng vai trò quyết định giúp cơ chế *Attention* phân biệt được các thực thể giống nhau nhưng xuất hiện tại các thời điểm khác nhau trong chuỗi hành vi, đảm bảo tính thứ tự của dữ liệu. Nhằm tăng cường khả năng tổng quát hóa, một lớp Dropout với tỷ lệ mặc định 0.1 được áp dụng ngay sau bước cộng mã hóa. Thao tác này giúp ngăn chặn hiện tượng quá khớp bằng cách buộc mô hình học các mẫu cấu trúc tổng quát thay vì phụ thuộc thái quá vào thông tin vị trí tuyệt đối.

Trong ngữ cảnh cụ thể của hệ thống gợi ý, thành phần này nắm giữ vai trò then chốt trong việc mô hình hóa tính gần đây và nguyên tắc nhân quả. Nó cung cấp cơ sở tham chiếu để mô hình nhận thức được khoảng cách thời gian giữa các tương tác, từ đó tạo điều kiện cho cơ chế *Self-Attention* phân bổ trọng số hợp lý: ưu tiên cao hơn cho các hành vi gần đây đại diện cho sở thích ngắn hạn, đồng thời vẫn duy trì ngữ cảnh dài hạn để đảm bảo độ chính xác trong việc dự báo hành động tiếp theo.

3.4.2.5 Cơ chế Tạo và Tổng hợp Vector Người dùng

Nhiệm vụ cốt lõi của phân hệ này là thực hiện chuyển đổi chuỗi các trạng thái ẩn tuần tự — vốn là đầu ra từ mạng *Transformer* — thành một vector duy nhất đại diện cho chân dung sở thích toàn diện của người dùng. Quy trình này được xây dựng dựa trên sự kết hợp chặt chẽ giữa kỹ thuật mô hình hóa chuỗi thời gian và các phương pháp tổng hợp thông tin có chọn lọc.

Quy trình Xử lý và Tổng hợp Vector Người dùng



Hình 3.6: Kiến trúc chi tiết Tháp Người dùng với cơ chế mô hình hóa chuỗi đa phương thức.

Sơ đồ minh họa luồng xử lý dữ liệu tuần tự bên trong Tháp Người dùng, được thiết kế để chuyển đổi lịch sử hành vi phức tạp thành một vector đại diện sở thích duy nhất. Quá trình này diễn ra qua bốn giai đoạn xử lý phân tầng từ dưới lên trên:

- **1. Tầng Mã hóa Đặc trưng Chia sẻ (Shared Encoders Layer):**

Tại mỗi bước thời gian trong chuỗi hành vi, hệ thống tiếp nhận bộ ba dữ liệu đầu vào gồm nội dung văn bản đánh giá, thông tin bảng số liệu và định danh sản phẩm. Các luồng dữ liệu này được đưa qua khối các bộ mã hóa chuyên biệt (*Encoders*).

Điểm đặc biệt trong thiết kế này là cơ chế chia sẻ trọng số (*Share weight*), nghĩa là cùng một bộ tham số mã hóa được sử dụng lặp lại cho mọi bước thời gian và đồng bộ hoàn toàn với các bộ mã hóa tại Tháp Sản phẩm. Điều này đảm bảo tính nhất quán về không gian đặc trưng giữa hai tháp mô hình.

• **2. Tầng Hợp nhất Cục bộ (*Fusion Gate*):**

Sau khi trích xuất đặc trưng sơ cấp, tại mỗi bước thời gian, các vector thành phần được đưa qua cổng hợp nhất *Fusion Gate*. Module này chịu trách nhiệm tổng hợp ba nguồn thông tin không đồng nhất thành một vector đại diện duy nhất (*Vector Review*), gói gọn toàn bộ ngữ cảnh tương tác của người dùng tại thời điểm đó.

• **3. Tầng Mô hình hóa Tuần tự (*Sequence Modeling Layer*):**

Để mô hình nhận thức được thứ tự của các hành vi, giải thuật Mã hóa Vị trí (*Positional Encoding*) được cộng trực tiếp vào các vector đặc trưng. Chuỗi vector sau khi đã tích hợp thông tin vị trí được đưa vào khối *Transformer Encoder Block*. Tại đây, cơ chế *Self-Attention* cho phép mô hình học các mối quan hệ phụ thuộc dài hạn và nắm bắt sự chuyển dịch trong thị hiếu người dùng qua thời gian.

Giai đoạn tiếp theo tập trung vào việc Tổng hợp Đặc trưng. Do độ dài lịch sử hành vi của người dùng mang tính biến thiên, hệ thống áp dụng kỹ thuật *Masked Mean Pooling* để nén toàn bộ chuỗi trạng thái ẩn từ Transformer thành một vector đại diện duy nhất. Để thực hiện điều này, mặt nạ đệm ban đầu được xử lý và mở rộng chiều tương thích với tensor dữ liệu, trong đó các vị trí chứa thông tin thực được gán trọng số 1 và vị trí đệm nhận giá trị 0. Hệ thống tiến hành nhân từng phần tử giữa đầu ra mô hình và mặt nạ trọng số nhằm triệt tiêu hoàn toàn các vector tại vị trí đệm về vector **0**, sau đó cộng dồn các đặc trưng dọc theo trục thời gian. Vector đại diện cuối cùng được xác định bằng cách chia tổng thu được cho số lượng hành vi thực tế, với việc bổ sung một hằng số nhỏ ϵ vào mẫu số để đảm bảo tính ổn định số học:

$$\mathbf{u}_{\text{pooled}} = \frac{\sum_{t=1}^T (\mathbf{h}_t \cdot m_t)}{\sum_{t=1}^T m_t + \epsilon} \quad (3.14)$$

Trong đó $\mathbf{h}_t$ là trạng thái ẩn tại bước t và m_t là giá trị mặt nạ nhị phân.

Quy trình khép lại bằng giai đoạn Tinh chỉnh và Chuẩn hóa. Vector trung bình sau khi tính toán được đưa qua một lớp Tuyến tính cuối cùng đóng vai trò như bộ chuyển đổi đặc trưng cao cấp, tối ưu hóa cho việc so khớp với sản phẩm. Đầu ra cuối cùng trải qua phép chuẩn hóa L2 để đưa về độ dài đơn vị trên mặt cầu, đảm bảo khoảng cách giữa người dùng và sản phẩm được đo lường chính xác và nhất quán thông qua độ tương đồng Cosine.

3.5 Chiến lược Huấn luyện

Thành phần cốt lõi trong chiến lược tối ưu hóa của hệ thống là hàm mất mát dựa trên nguyên lý Học tương phản. Cụ thể, đồ án áp dụng biến thể *Symmetric InfoNCE Loss*, phương pháp đã chứng minh hiệu quả vượt trội qua sự thành công của mô hình CLIP [13]. Khác với các hàm mất mát truyền thống, phương pháp này thực hiện tính toán độ tương đồng chéo giữa các cặp dữ liệu đa phương thức theo cả hai chiều nhằm đồng bộ

hóa không gian biểu diễn chung. Mục tiêu tối thượng là tối ưu hóa không gian vector sao cho các cặp dữ liệu tương ứng như hình ảnh và văn bản của cùng một sản phẩm sẽ có vector biểu diễn gần nhau do lực hút, trong khi các cặp dữ liệu không tương ứng bị đẩy ra xa nhau do lực đẩy.

Cơ chế Mẫu âm tính trong lô (In-batch Negatives)

Hàm mất mát được thiết kế dựa trên chiến lược Mẫu âm tính trong lô. Thay vì tiêu tốn tài nguyên để lấy mẫu âm tính thủ công từ toàn bộ tập dữ liệu, hệ thống tận dụng chính các mẫu dữ liệu khác trong cùng một lô huấn luyện để làm mẫu đối nghịch.

Giả sử một lô huấn luyện có kích thước $N = 3$. Khi xem xét người dùng thứ nhất u_1 , chỉ có sản phẩm v_1 ở cùng chỉ số index được coi là cặp dương tính. Hai sản phẩm còn lại trong lô là v_2 và v_3 sẽ tự động được hệ thống coi là các mẫu âm tính đối với u_1 . Cơ chế này được minh họa chi tiết tại Bảng 3.2.

Bảng 3.2: Minh họa cơ chế In-batch Negatives với Batch size = 3

Query \ Key	Item 1 (v_1)	Item 2 (v_2)	Item 3 (v_3)
User 1 (u_1)	Positive	Negative	Negative
User 2 (u_2)	Negative	Positive	Negative
User 3 (u_3)	Negative	Negative	Positive

Quy trình Tính toán Toán học

Quá trình tối ưu hóa diễn ra qua ba bước tính toán tuần tự:

Đầu tiên, hệ thống xác lập Ma trận Tương đồng từ hai tập hợp vector đặc trưng $\mathbf{V}_1$ và $\mathbf{V}_2$ có cùng kích thước lô N . Phép nhân ma trận hay tích vô hướng được thực hiện để tạo ra ma trận tương đồng $\mathbf{S}$ kích thước $N \times N$, trong đó mỗi phần tử được chuẩn hóa bởi tham số nhiệt độ τ :

$$S_{ij} = \frac{\mathbf{v}_{1,i} \cdot \mathbf{v}_{2,j}^T}{\tau} \quad (3.15)$$

Tham số τ đóng vai trò kiểm soát độ sắc nét của phân phối xác suất. Giá trị τ nhỏ giúp mô hình phân biệt tốt hơn các mẫu khó phân loại, trong khi giá trị lớn giúp làm mượt phân phối nhằm tăng tính ổn định.

Tiếp theo, hệ thống thực hiện Xác định Nhãn dựa trên giả định của học tự giám sát. Phần tử thứ i của tập nguồn chỉ tương ứng duy nhất với phần tử thứ i của tập đích. Do đó, các giá trị nằm trên đường chéo chính của ma trận tương đồng được xác định là *Ground Truth*, trong khi tất cả các vị trí ngoài đường chéo đều được coi là *Negatives*.

Cuối cùng, mô hình tính toán Mất mát Đối xứng theo hai chiều song song. Chiều thuận xét từ $\mathbf{V}_1$ sang $\mathbf{V}_2$ và chiều nghịch xét từ $\mathbf{V}_2$ sang $\mathbf{V}_1$. Hàm *Cross-Entropy* được áp dụng cho cả hai chiều để tối đa hóa điểm số tại đường chéo chính:

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(S_{ii})}{\sum_{k=1}^N \exp(S_{ik})} \quad (3.16)$$

Giá trị mất mát tổng thể $\mathcal{L}_{\text{Total}}$ là trung bình cộng của mất mát hai chiều này, buộc mô hình phải học được mối quan hệ ngữ nghĩa bền vững và nhất quán giữa các phương thức dữ liệu.

Vai trò Chiến lược trong Hệ thống Gợi ý

Trong kiến trúc đa phương thức của đề tài, hàm mất mát tương phản đóng vai trò then chốt trong việc định hình không gian biểu diễn. Chức năng quan trọng nhất của nó là đồng bộ hóa không gian vector, hoạt động như một lực hấp dẫn để kéo các biểu diễn đặc trưng từ các nguồn dữ liệu phân tán như văn bản, hình ảnh và dữ liệu bảng về cùng một không gian ngữ nghĩa thống nhất. Bên cạnh đó, thông qua việc phân biệt rõ ràng giữa các cặp tương ứng và không tương ứng trong lô dữ liệu, mô hình học được khả năng trích xuất các đặc trưng độc đáo mang tính phân biệt cao. Đây là tiền đề quan trọng giúp tối ưu hóa khả năng truy xuất ứng viên, nâng cao độ chính xác trong việc tìm kiếm và gợi ý sản phẩm phù hợp.

3.6 Tích hợp LLM trong Giai đoạn Hậu Truy xuất

Trong kiến trúc tổng thể của hệ thống, Mô hình Ngôn ngữ Lớn Google Gemini được tích hợp vào giai đoạn hậu truy xuất (*Post-Retrieval Stage*). Trong khi mô hình Two-Tower đóng vai trò bộ lọc thô (*Coarse Filter*) giúp truy xuất nhanh các ứng viên tiềm năng dựa trên độ tương đồng vector, thì mô-đun LLM đảm nhận chức năng bộ lọc tinh và tác nhân giải thích (*Explainable Agent*). Thành phần này tận dụng khả năng suy luận ngôn ngữ tự nhiên để cá nhân hóa trải nghiệm người dùng một cách sâu sắc hơn.

3.6.1 Quy trình Xử lý Dữ liệu

Quy trình tích hợp được thực hiện theo cơ chế suy luận trực tuyến (*Online Inference*) thông qua bốn bước xử lý tuần tự:

1. Truy xuất Ứng viên:

Đầu vào của mô-đun là danh sách Top- K sản phẩm được trả về từ mô hình Two-Tower. Tại giai đoạn này, các sản phẩm mới chỉ được định danh đơn giản bằng mã ID và điểm số tương đồng vector.

2. Làm giàu Ngữ cảnh:

Kế đến, hệ thống thực hiện các truy vấn cơ sở dữ liệu để chuyển đổi các ID vô hướng thành thông tin văn bản mang ý nghĩa ngữ nghĩa. Cụ thể:

- **Thông tin sản phẩm:** Hệ thống thu thập tiêu đề, mô tả ngắn, thông số kỹ thuật và giá tiền.
- **Hồ sơ người dùng:** Hệ thống truy xuất chuỗi lịch sử tương tác gần nhất, bao gồm các sản phẩm đã xem, đã mua hoặc được đánh giá cao.

3. Kỹ thuật Prompt Engineering:

Dữ liệu sau khi làm giàu được đưa vào một khuôn mẫu cấu trúc sẵn, thiết kế theo phương pháp *Zero-shot* hoặc *Few-shot*. Cấu trúc này bao gồm ba thành phần chính: định nghĩa vai trò của Gemini là một chuyên gia tư vấn, cung cấp dữ liệu ngữ cảnh (lịch sử người dùng, danh sách ứng viên), và cuối cùng là nhiệm vụ yêu cầu LLM phân tích mối liên hệ sở thích để chọn lọc sản phẩm phù hợp nhất kèm theo giải thích.

4. Sinh Phản hồi:

Cuối cùng, Prompt hoàn chỉnh được gửi đến API của Gemini. Kết quả trả về là văn bản tự nhiên, sau đó được hệ thống phân tích (parse) để hiển thị lên giao diện Web Demo dưới dạng danh sách gợi ý đi kèm lời bình chi tiết.

3.6.2 Cấu trúc Prompt Minh họa

Để LLM thực hiện tác vụ chọn lọc và giải thích mà không cần áp dụng thuật toán xếp hạng lại phức tạp, nhóm nghiên cứu sử dụng cấu trúc Prompt định hướng ngữ nghĩa như sau:

System Instruction: Bạn là một trợ lý AI chuyên nghiệp trong lĩnh vực thương mại điện tử.

User Context: Người dùng này quan tâm đến [Danh sách lịch sử: iPhone 13, Ốp lưng MagSafe, Cáp sạc Type-C].

Candidate Items: Dưới đây là danh sách sản phẩm tiềm năng:

- **ID: 101** Tai nghe AirPods Pro (Chống ồn, Apple Ecosystem)
- **ID: 102** Nồi cơm điện Sharp (1.8L, Nấu nhanh)
- **ID: 103** Sạc dự phòng Anker (20000mAh, Sạc nhanh)

Instruction: Dựa trên lịch sử quan tâm, hãy chọn ra các sản phẩm liên quan nhất từ danh sách ứng viên. Với mỗi sản phẩm được chọn, hãy viết một câu giải thích ngắn gọn, thuyết phục, chỉ ra mối liên hệ với sở thích cũ của họ.

3.6.3 Vai trò của LLM trong Hệ thống

Trong cấu hình hiện tại, LLM không thay đổi thứ tự xếp hạng dựa trên điểm số mà hoạt động như một lớp hậu xử lý định tính (*Qualitative Post-processing*). Cơ chế này giúp khắc phục điểm yếu hộp đen của mô hình Two-Tower bằng cách minh bạch hóa lý do gợi ý. Việc cung cấp thông tin giải thích giúp người dùng hiểu rõ sự phù hợp của sản phẩm, từ đó gia tăng niềm tin và cải thiện tỷ lệ chuyển đổi (*Click-through Rate*) trên hệ thống.

Chương 4

Thực nghiệm và Đánh giá

Chương này trình bày chi tiết về quá trình thực nghiệm nhằm kiểm chứng hiệu quả của mô hình đề xuất Two-Tower Multi-modal Recommendation System. Mục tiêu của các thực nghiệm là trả lời các câu hỏi nghiên cứu sau:

1. Việc kết hợp đa phương thức bao gồm “Văn bản”, “Hình ảnh”, “Dữ liệu bảng” có cải thiện hiệu năng gợi ý so với đơn phương thức hay không?
2. Mô hình giải quyết bài toán dự đoán hành vi tiếp theo Next-Item Prediction và vấn đề Cold-start hiệu quả như thế nào?
3. Cơ chế Hybrid Retrieval, kết hợp Query ngữ nghĩa và Personalization đóng góp ra sao vào trải nghiệm người dùng cuối?
4. Mô hình đề xuất có khả năng triển khai trong môi trường thực tế đảm bảo yêu cầu về độ trễ thấp và tính tương tác thời gian thực hay không?

Nội dung chương bao gồm mô tả tập dữ liệu, thiết lập môi trường thực nghiệm, định nghĩa các độ đo đánh giá, phân tích sâu các kết quả thu được và minh họa hệ thống triển khai thực tế.

4.1 Mô tả tập dữ liệu

4.1.1 Tổng quan về nguồn dữ liệu

Nghiên cứu này sử dụng tập dữ liệu **Amazon Reviews 2023**, một bộ dữ liệu quy chuẩn phổ biến trong cộng đồng nghiên cứu Hệ thống gợi ý. Cụ thể, đồ án tập trung vào phân loại hàng hóa *Gift Cards*. Đây là miền dữ liệu đặc thù với tính chất sản phẩm ít biến động về cấu hình kỹ thuật nhưng phụ thuộc nhiều vào ngữ cảnh tặng quà, hình ảnh minh họa và ý định của người mua.

Cấu trúc dữ liệu của hệ thống được tổ chức một cách khoa học thông qua hai tập tin định dạng JSON Lines riêng biệt. Mặc dù được lưu trữ tách rời để thuận tiện cho quá trình xử lý, hai tập tin này vẫn duy trì mối liên kết logic chặt chẽ nhằm đảm bảo tính toàn vẹn của thông tin. Cụ thể, tập tin **User Reviews** đóng vai trò trung tâm trong việc lưu trữ dữ liệu người dùng, bao gồm toàn bộ lịch sử tương tác, các nội dung phản hồi đánh giá

cũng như mô hình hành vi chi tiết. Song song với đó, tập tin **Item Metadata** bổ trợ bằng cách cung cấp cơ sở dữ liệu chuyên sâu về sản phẩm, bao gồm các thông tin mô tả chi tiết và dữ liệu đa phương thức, giúp định danh và làm rõ ngữ cảnh cho các đối tượng được tương tác.

Dưới đây là phân tích chi tiết từng trường dữ liệu được sử dụng trong quá trình huấn luyện và kiểm thử mô hình.

A. Chi tiết dữ liệu User Reviews

Tập dữ liệu này đóng vai trò là nguồn “Ground Truth” để mô hình học sở thích của người dùng. Mỗi dòng dữ liệu đại diện cho một lần tương tác cụ thể.

Bảng 4.1: Mô tả chi tiết các trường thông tin trong tập dữ liệu User Reviews

Trường dữ liệu	Mô tả và Phương pháp xử lý
user_id (String)	Định danh duy nhất của người dùng. Đây là khóa chính để gom nhóm lịch sử hành vi. Toàn bộ tương tác của cùng một user_id được sắp xếp theo thời gian để làm đầu vào cho User Tower.
parent_asin (String)	Mã định danh cha của sản phẩm, đại diện cho nhóm các biến thể màu sắc và kiểu dáng. Đề án sử dụng trường này làm khóa ngoại liên kết với Metadata nhằm giảm độ thưa dữ liệu.
rating (Float)	Điểm đánh giá đại diện cho tín hiệu phản hồi hiện tại. Các tương tác có rating ≥ 4.0 được xem là tích cực. Giá trị này cũng được dùng làm đặc trưng số học cho Tabular Encoder.
title & text (String)	title tóm tắt cảm xúc chính, còn text chứa nội dung chi tiết phản ánh lý do mua hàng. Hai trường này được nối lại thành chuỗi văn bản đầu vào cho Text Encoder.
timestamp (Integer)	Thời gian đánh giá. Dữ liệu được sắp xếp tăng dần theo trường này để mô phỏng đúng bài toán <i>Sequential Recommendation</i> , tránh rò rỉ dữ liệu tương lai.
verified_purchase (Boolean)	Nhãn xác thực việc mua hàng. Được mã hóa thành Embedding trong Tabular Encoder để giúp mô hình phân biệt độ tin cậy giữa tương tác thật và ảo.
helpful_vote (Integer)	Số lượng người khác thấy bài review hữu ích. Giá trị này được chuẩn hóa Log normalization và đưa vào mô hình như một chỉ số đo lường chất lượng tương tác.

B. Chi tiết dữ liệu Item Metadata

Tập dữ liệu này cung cấp các đặc trưng nội dung để xây dựng Item Tower đa phương thức.

Bảng 4.2: Mô tả chi tiết các trường thông tin trong tập dữ liệu Item Metadata

Trường dữ liệu	Mô tả và Phương pháp xử lý
parent_asin (String)	Khóa chính của sản phẩm. Được dùng để ánh xạ 1-nhiều với dữ liệu trong bảng User Reviews.
title (String)	Tên đầy đủ của sản phẩm, chứa thông tin thương hiệu, mệnh giá và dịp tặng quà. Đây là đặc trưng quan trọng nhất, được mã hóa bởi BERT/MPNet để tạo vector ngữ nghĩa.
images (List)	Danh sách ảnh sản phẩm gồm thumb, large và hi_res. Ảnh chất lượng cao gồm (hi_res/large) được tải về và đưa qua Vision Transformer để trích xuất đặc trưng thị giác.
main_category (String)	Danh mục chính (ví dụ: “Gift Cards”). Giúp định danh miền dữ liệu. Được xử lý bằng One-hot hoặc Embedding cho Tabular Encoder.
categories (List)	Phân cấp sản phẩm. Được xử lý để tạo embedding đại diện nhóm hàng, giúp mô hình gom cụm các sản phẩm tương đồng.
store (String)	Thương hiệu phát hành thẻ (ví dụ: Amazon, Visa). Đây là đặc trưng định danh quan trọng, được chuyển đổi thành chỉ số Index và đưa qua lớp Embedding.
avg_rating (Float) & rating_number (Int)	Điểm trung bình và tổng lượt đánh giá - các chỉ số “Bằng chứng xã hội”. Dữ liệu này được chuẩn hóa để tránh chênh lệch thang đo khi đưa vào mạng nơ-ron.
price (Float)	Giá bán (USD). Cung cấp thông tin phân khúc giá trị. Các giá trị thiếu được xử lý bằng phương pháp gán trung vị.
features, description & details	Các mô tả bổ sung và thông số kỹ thuật dạng key-value. Chúng bổ sung ngữ nghĩa cho tiêu đề và được chuyển đổi thành văn bản để hỗ trợ cho Text Encoder.

C. Mối quan hệ và Thách thức dữ liệu

Mối quan hệ liên kết: Dữ liệu được liên kết thông qua trường parent_asin. Quá trình tiền xử lý thực hiện phép nối Inner Join giữa Review và Metadata. Chỉ những cặp (u, i) mà trong đó sản phẩm i có đầy đủ thông tin, đặc biệt là ảnh và tiêu đề mới được giữ lại để huấn luyện.

Thách thức: Quá trình xử lý dữ liệu đối mặt với hai thách thức chính. Đầu tiên là sự *đa dạng định dạng*, khi tập dữ liệu bao gồm hỗn hợp văn bản phi cấu trúc, hình ảnh, dữ liệu số và danh mục. Sự không đồng nhất này đòi hỏi kiến trúc mạng nơ-ron phải đủ phức tạp để thực hiện fusion hiệu quả các nguồn tin đa phương thức. Thách thức thứ hai đến từ *nhiều dữ liệu*, biểu hiện qua việc thiếu hụt hình ảnh, ảnh chất lượng thấp hoặc các đánh giá ngắn, thiếu ngữ nghĩa. Do đó, quy trình tiền xử lý và làm sạch dữ liệu đóng vai trò then chốt để đảm bảo chất lượng đầu vào cho mô hình.

4.1.2 Phân tích chất lượng dữ liệu và Giá trị khuyết

Để đảm bảo tính tin cậy của đầu vào mô hình, chúng tôi đã thực hiện thống kê chi tiết tỷ lệ dữ liệu khuyết trên cả hai tập dữ liệu chính: Thông tin sản phẩm và Tương tác người dùng.

A. Đối với Dữ liệu sản phẩm

Kết quả thống kê trên tổng số **1,137** sản phẩm cho thấy sự phân hóa rõ rệt về chất lượng giữa các trường thông tin.

Bảng 4.3: Thống kê tỷ lệ dữ liệu khuyết trên Item Metadata

Thuộc tính	SL Thiếu	Tỷ lệ (%)	Phương án xử lý
Title	0	0.00%	Giữ nguyên.
Average Rating	0	0.00%	Sử dụng trực tiếp.
Images	1	0.09%	Loại bỏ sản phẩm hoặc dùng ảnh mặc định.
Store	17	1.50%	Gán nhãn “Unknown”.
Features	105	9.23%	Thay thế bằng chuỗi rỗng.
Main Category	170	14.95%	Gán nhãn danh mục chung hoặc “Gift Cards”.
Description	262	23.04%	Thay thế bằng chuỗi rỗng, tập trung vào Title.
Price	757	66.58%	Gán giá trị trung vị (Median Imputation).
Videos/Subtitle	1137	100.00%	Loại bỏ trường dữ liệu.

Nhận xét và Chiến lược xử lý:

Dựa trên kết quả thống kê, đề án đề xuất chiến lược xử lý dữ liệu tập trung vào hai khía cạnh chính:

Đầu tiên, đối với biến **Giá**, tỷ lệ khuyết dữ liệu lên tới 66.58% phản ánh đặc thù mệnh giá động của loại hình Gift Card. Thay vì loại bỏ trường thông tin quan trọng này, nghiên cứu áp dụng phương pháp *Gán giá trị trung vị*. Phương pháp này giúp duy trì thông tin về phân khúc giá trị sản phẩm đồng thời hạn chế tác động của các giá trị ngoại lai. Tuy nhiên, để đảm bảo tính ổn định, trọng số của nhánh Tabular Encoder sẽ được điều chỉnh giảm so với các nhánh xử lý văn bản và hình ảnh.

Thứ hai, đối với các trường thông tin không mang lại giá trị phân tích hoặc có tỷ lệ khuyết tuyệt đối 100% như `bought_together`, `subtitle` và `author`, chiến lược *Cắt tỉa đặc trưng* được áp dụng triệt để. Việc loại bỏ các trường này không chỉ giúp làm sạch nhiễu mà còn tối ưu hóa tài nguyên bộ nhớ và không gian lưu trữ cho quá trình huấn luyện mô hình.

B. Đối với Dữ liệu tương tác

Trái ngược với đặc điểm phân tán của tập Metadata, dữ liệu Reviews sau quá trình sàng lọc *k-core filtering* thể hiện tính toàn vẹn và độ tin cậy cao. Kết quả thống kê cho thấy tập dữ liệu bao gồm **152,410** tương tác, với tỷ lệ dữ liệu khuyết là **0%** trên tất cả các trường thông tin trọng yếu bao gồm `user_id`, `parent_asin`, `rating` và `timestamp`.

Điều này đảm bảo rằng User Tower sẽ luôn nhận được đầu vào đầy đủ và nhất quán, không cần phải thực hiện các kỹ thuật điền khuyết phức tạp cho chuỗi hành vi, giúp quá trình huấn luyện mô hình tuần tự diễn ra ổn định.

4.1.3 Quy trình Tiền xử lý dữ liệu

Do tính chất đa phương thức và độ nhiễu cao của dữ liệu thương mại điện tử thực tế, quy trình tiền xử lý đóng vai trò then chốt trong việc đảm bảo tính hội tụ và hiệu năng của mô hình. Quy trình này được chia thành 4 giai đoạn chính: Làm sạch dữ liệu, Xử lý đặc trưng đa phương thức, Chuẩn hóa dữ liệu bảng và Xây dựng chuỗi hành vi tuần tự.

Giai đoạn 1: Làm sạch và Lọc dữ liệu

Dữ liệu thô thu thập từ Amazon thường chứa nhiều giá trị bị khuyết và các điểm dữ liệu nhiễu. Quy trình tiền xử lý dữ liệu được tiến hành qua hai giai đoạn trọng tâm nhằm chuẩn hóa đầu vào cho mô hình, các bước xử lý bao gồm:

Giai đoạn thứ nhất tập trung vào **xử lý giá trị khuyết** với các chiến lược riêng biệt cho từng loại dữ liệu. Cụ thể, các mẫu thiếu trường định danh cốt lõi như `title` sẽ bị loại bỏ hoàn toàn để đảm bảo tính nhất quán. Đối với dữ liệu số học như `price`, phương pháp gán giá trị trung vị được ưu tiên áp dụng thay vì giá trị trung bình, giúp giảm thiểu tác động lệch chuẩn gây ra bởi các giá trị ngoại lai. Trong khi đó, các giá trị rỗng tại các trường văn bản bổ trợ như `features` hay `description` được xử lý bằng cách điền thể chuỗi ký tự trống `""` để đảm bảo tính hợp lệ kỹ thuật cho bộ mã hóa.

Giai đoạn thứ hai là **sàng lọc tương tác**, áp dụng kỹ thuật *k-core filtering* với ngưỡng $k = 3$ nhằm tối ưu hóa dữ liệu cho bài toán *Sequential Recommendation*. Về phía người dùng, hệ thống loại bỏ các tài khoản có dưới 3 tương tác, Cold-start Users, do nhóm này không cung cấp đủ độ dài chuỗi lịch sử cần thiết để mô hình Transformer học được các mẫu hành vi phụ thuộc. Song song với đó, các sản phẩm có tần suất xuất hiện quá thấp, dưới 2 lần, cũng được lược bỏ để đảm bảo không gian biểu diễn được học từ dữ liệu đủ dày đặc.

Giai đoạn 2: Xử lý đặc trưng phi cấu trúc

Đây là bước chuẩn bị đầu vào cho hai nhánh mạng nơ-ron chính: Text Encoder và Image Encoder.

1. Xử lý dữ liệu văn bản:

Do thông tin ngữ nghĩa của sản phẩm nằm rải rác ở nhiều trường khác nhau, chúng tôi thực hiện chiến lược nối chuỗi:

$$\text{Text}_{\text{input}} = [\text{Title}] \oplus [\text{Description}] \oplus [\text{Features}] \oplus [\text{Details}] \quad (4.1)$$

Trong đó $\oplus$ là phép nối chuỗi kèm theo ký tự phân cách đặc biệt. Chuỗi văn bản tổng hợp này sau đó được đưa qua bộ phân tách từ của mô hình `all-mpnet-base-v2`. Quá trình Tokenization tuân thủ các quy tắc:

- **Padding:** Các chuỗi ngắn hơn độ dài tối đa sẽ được thêm token [PAD] để đảm bảo kích thước batch đồng nhất.
- **Truncation:** Các chuỗi quá dài sẽ bị cắt bớt để phù hợp với giới hạn đầu vào của BERT, thường là 512 tokens, ưu tiên giữ lại phần đầu của văn bản vì chứa thông tin quan trọng nhất.

2. Xử lý dữ liệu hình ảnh:

Dữ liệu ảnh được tải về từ các đường dẫn URL trong Metadata. Quy trình xử lý ảnh tuân theo chuẩn đầu vào của mô hình Vision Transformer:

- **Tải và Lọc lỗi:** Sử dụng Multi-threading để tải ảnh. Các ảnh bị lỗi định dạng hoặc không thể tải sẽ bị loại bỏ hoặc thay thế bằng ảnh placeholder màu đen.
- **Resize & Center Crop:** Ảnh được thay đổi kích thước về độ phân giải 224×224 pixels.
- **Chuẩn hóa:** Các giá trị pixel trong khoảng $[0, 255]$ được chuyển về khoảng $[0, 1]$ và sau đó được chuẩn hóa theo phân bố của tập dữ liệu ImageNet:

$$x_{norm} = \frac{x - \mu_{ImageNet}}{\sigma_{ImageNet}} \quad (4.2)$$

Với $\mu = [0.485, 0.456, 0.406]$ và $\sigma = [0.229, 0.224, 0.225]$. Bước này giúp mô hình ViT pretrained hoạt động hiệu quả nhất.

Giai đoạn 3: Xử lý dữ liệu bảng

Dữ liệu có cấu trúc bao gồm các biến phân loại và biến số được xử lý riêng biệt.

1. Biến phân loại (main_category, store): Được chuyển đổi sang dạng số nguyên (Integer Mapping) thông qua kỹ thuật Label Encoding. Một từ điển (Vocabulary) được xây dựng để ánh xạ mỗi giá trị duy nhất (ví dụ: “Starbucks”) sang một chỉ số ID (ví dụ: 124). Các giá trị mới xuất hiện trong tập Test sẽ được gán về token đặc biệt <UNK>.

2. Biến danh sách phân loại (categories): Một sản phẩm có thể thuộc nhiều danh mục con (ví dụ: [Gift Cards, Birthday, For Her]). Chúng tôi sử dụng phương pháp *Multi-hot Encoding* kết hợp với *Embedding Pooling*. Cụ thể, các ID của danh mục sẽ được tra cứu trong bảng Embedding, sau đó lấy trung bình (Average Pooling) để tạo ra một vector đại diện duy nhất cho trường này.

3. Biến số (rating, vote, price): Để giúp mạng nơ-ron hội tụ nhanh hơn, các biến số được chuẩn hóa bằng *Standard Scaler* (Z-score normalization):

$$z = \frac{x - \mu}{\sigma} \quad (4.3)$$

Riêng đối với biến `helpful_vote`, do phân bố lệch trái nặng (phần lớn là 0 hoặc số nhỏ), chúng tôi áp dụng biến đổi Logarit trước khi chuẩn hóa: $x' = \log(1 + x)$.

Giai đoạn 4: Xây dựng chuỗi tương tác

Đây là bước quan trọng nhất để huấn luyện User Tower. Dữ liệu tương tác được gom nhóm theo `user_id` và sắp xếp tăng dần theo `timestamp`.

Với mỗi người dùng u , ta có chuỗi hành vi $S_u = \{i_1, i_2, \dots, i_T\}$. Quá trình tạo mẫu huấn luyện (Training Samples) được thực hiện theo cơ chế *Sliding Window*:

- Tại mỗi bước thời gian t ($1 < t \leq T$), mô hình sử dụng chuỗi lịch sử $H_t = \{i_1, \dots, i_{t-1}\}$ để dự đoán item mục tiêu i_t .
- **Padding:** Nếu độ dài chuỗi lịch sử nhỏ hơn độ dài tối đa quy định ($L = 40$), chúng tôi thêm các token [PAD] vào bên trái chuỗi.
- **Masking:** Một ma trận mặt nạ được tạo ra để báo cho lớp Self-Attention trong Transformer biết cần bỏ qua các vị trí là [PAD], đảm bảo tính toán chỉ tập trung vào các tương tác thực tế.

Thông kê chi tiết được trình bày trong Bảng 4.4.

Bảng 4.4: Thông kê tập dữ liệu Amazon Gift Cards sau khi tiền xử lý

Thông số	Số lượng	Mô tả
Tổng số người dùng	73,929	Số lượng người dùng duy nhất.
Tổng số sản phẩm	1,137	Số lượng thẻ quà tặng khác nhau.
Tổng số tương tác	78,095	Tổng số lượt review/rating hợp lệ.
Độ dài chuỗi trung bình	~ 1.06	Số lượng tương tác trung bình trên một người dùng.

Kết quả của quá trình tiền xử lý là các Tensor định dạng PyTorch sẵn sàng được đưa vào GPU để huấn luyện.

4.1.4 Phân tích độ thưa dữ liệu

A. Cơ sở lý thuyết và Định nghĩa

Trong các hệ thống gợi ý, dữ liệu thường được biểu diễn dưới dạng một ma trận tương tác User-Item R có kích thước $|U| \times |I|$, trong đó $|U|$ là tổng số người dùng và $|I|$ là tổng số sản phẩm. Mỗi phần tử r_{ui} trong ma trận biểu thị tương tác của người dùng u lên sản phẩm i .

Độ thưa phản ánh tỷ lệ các phần tử rỗng trong ma trận này. Một ma trận có độ thưa quá cao đồng nghĩa với việc thông tin hành vi người dùng cực kỳ hạn chế, gây khó khăn cho việc tìm kiếm các mẫu tương đồng. Độ thưa được định nghĩa bởi công thức [31]:

$$\text{Sparsity} = 1 - \text{Density} = 1 - \frac{\text{Total Interactions}}{|U| \times |I|} \quad (4.4)$$

B. Tính toán thực nghiệm trên tập dữ liệu Amazon

Dựa trên các thông kê đã trình bày ở Bảng 4.4, chúng tôi tiến hành tính toán độ thưa cụ thể cho tập dữ liệu huấn luyện:

- Tổng số người dùng ($|U|$): 73,929
- Tổng số sản phẩm ($|I|$): 1,137
- Tổng số tương tác quan sát được (N): 78,095

Kích thước không gian mẫu là:

$$|U| \times |I| = 73,929 \times 1,137 \approx 84,057,273$$

Mật độ dữ liệu thực tế:

$$\text{Density} = \frac{78,095}{84,057,273} \approx 0.000929 \text{ (0.09\%)}$$

Từ đó, độ thưa của tập dữ liệu là:

$$\text{Sparsity} = 1 - 0.000929 \approx 0.999071 \text{ (99.91\%)}$$

C. Đánh giá và Tác động đến mô hình

Kết quả tính toán 99.82% cho thấy tập dữ liệu Amazon Gift Cards thuộc nhóm “Extreme Sparsity”. Để so sánh, các tập dữ liệu chuẩn như MovieLens-1M thường có độ thưa khoảng 95 – 96%. Việc độ thưa tiệm cận 100% đặt ra hai thách thức nghiêm trọng:

Thứ nhất, **sự thất bại của Collaborative Filtering thuần túy**: Các thuật toán CF truyền thống như Matrix Factorization dựa vào việc tìm kiếm người dùng có hành vi tương đồng hoặc sản phẩm tương đồng thông qua sự chồng lấp các tương tác. Với mật độ 0.09%, xác suất để hai người dùng bất kỳ cùng đánh giá một sản phẩm là cực thấp, dẫn đến việc mô hình không thể tính toán độ tương đồng tin cậy.

Thứ hai, **vấn đề Cold-start**: Phần lớn người dùng trong tập dữ liệu chỉ có số lượng tương tác tối thiểu khoảng 2-3 tương tác. Mô hình không có đủ lịch sử hành vi để học được vector đại diện User Embedding chính xác nếu chỉ dựa vào ID.

D. Giải pháp tiếp cận: Content-based Multi-modal Learning

Chính vì thách thức về độ thưa nêu trên, đề án này bắt buộc phải chuyển hướng từ việc chỉ khai thác dữ liệu tương tác sang khai thác dữ liệu nội dung.

Cụ thể, kiến trúc Two-Tower được thiết kế để tận dụng các đặc trưng giàu ngữ nghĩa luôn có sẵn, bất kể người dùng đã tương tác hay chưa:

- **Text Encoder (BERT)**: Giúp mô hình hiểu rằng “Visa Gift Card” và “Mastercard Gift Card” là tương đồng về mặt ngữ nghĩa, ngay cả khi chưa có người dùng nào mua cả hai.

- **Image Encoder (ViT):** Giúp liên kết các sản phẩm có hình thức trình bày giống nhau (ví dụ: cùng chủ đề Giáng sinh, Sinh nhật) thông qua đặc trưng thị giác.
- **Tabular Encoder (MLP):** Xử lý các dữ liệu cấu trúc như *Giá bán*, *Điểm đánh giá*, *Thương hiệu*. Nhánh này giúp mô hình học được các ngưỡng lọc quan trọng (ví dụ: người dùng chỉ thích mua thẻ mệnh giá thấp $< \$50$) để thu hẹp không gian tìm kiếm hiệu quả.

Nhờ cơ chế Fusion Gate kết hợp các thông tin này, mô hình có thể lấp đầy các khoảng trống trong ma trận thưa bằng các suy luận dựa trên nội dung, từ đó cải thiện đáng kể độ chính xác gợi ý như Recall hay NDCG sẽ được trình bày trong phần Kết quả thực nghiệm.

4.2 Thiết lập thực nghiệm

4.2.1 Môi trường phần cứng và phần mềm

Cơ sở hạ tầng phần cứng

Các thực nghiệm được triển khai trên nền tảng đám mây **Kaggle Kernels**, tận dụng sức mạnh tính toán hiệu năng cao của Google Cloud Platform (GCP). Việc sử dụng môi trường đám mây giúp giảm thiểu các sai số do sự khác biệt về phần cứng cá nhân và đảm bảo mô hình được huấn luyện trong điều kiện tối ưu.

Chi tiết cấu hình phần cứng như sau:

- **Bộ xử lý đồ họa (GPU) :**
 - *Loại thiết bị:* **NVIDIA Tesla P100-PCIE.**
 - *Kiến trúc:* Pascal.
 - *Bộ nhớ đồ họa (VRAM):* 16 GB **HBM2.**
 - *Lý do lựa chọn:* Mặc dù là kiến trúc Pascal, Tesla P100 sở hữu băng thông bộ nhớ vượt trội (~ 732 GB/s), cao hơn đáng kể so với các dòng GPU sử dụng bộ nhớ GDDR6 thông thường (như Tesla T4). Đặc điểm này cực kỳ tối ưu cho mô hình Two-Tower, nơi tác vụ Embedding Lookup cho hàng nghìn User/Item tiêu tốn tài nguyên băng thông rất lớn.
- **Bộ xử lý trung tâm (CPU):**
 - *Cấu hình:* Intel(R) Xeon(R) CPU @ 2.20GHz (4 cores, 8 threads).
 - *Vai trò:* Chịu trách nhiệm cho các tác vụ tiền xử lý dữ liệu, tải ảnh đa luồng và đưa dữ liệu vào hàng đợi trước khi đẩy sang GPU.
- **Bộ nhớ trong (RAM):**
 - *Dung lượng:* 32 GB System RAM.
 - *Vai trò:* Đảm bảo toàn bộ Meta-data và các vector đặc trưng sau khi trích xuất có thể được lưu trữ trên bộ nhớ đệm, tránh hiện tượng nghẽn cổ chai do đọc/ghi đĩa cứng liên tục.

Hệ sinh thái phần mềm và Thư viện

Mô hình được phát triển dựa trên ngôn ngữ lập trình **Python** phiên bản 3.10, ngôn ngữ tiêu chuẩn trong cộng đồng Trí tuệ nhân tạo hiện nay. Chúng tôi sử dụng các framework mã nguồn mở tiên tiến nhất để xây dựng kiến trúc mạng nơ-ron sâu.

Các thư viện chính bao gồm:

- **PyTorch (v2.0+)**: Framework nền tảng cho Deep Learning. PyTorch được lựa chọn nhờ cơ chế đồ thị tính toán động, giúp linh hoạt trong việc xây dựng các kiến trúc phức tạp như Fusion Gate và tùy chỉnh hàm mất mát Contrastive Loss.
- **Hugging Face Transformers**: Thư viện chuẩn mực cho các mô hình NLP. Chúng tôi sử dụng thư viện này để tải trọng số tiền huấn luyện của mô hình `all-mpnet-base-v2` và thực hiện quy trình Tokenization văn bản.
- **TIMM (PyTorch Image Models)**: Thư viện chuyên dụng cho các mô hình thị giác máy tính hiện đại. TIMM cung cấp kiến trúc `vit_base_patch16_224` cùng các trọng số đã được huấn luyện trên ImageNet, giúp trích xuất đặc trưng ảnh chính xác mà không cần huấn luyện lại từ đầu.
- **Scikit-learn & Pandas**: Sử dụng cho các tác vụ xử lý dữ liệu bảng, phân chia tập dữ liệu, chuẩn hóa dữ liệu và tính toán các độ đo đánh giá cơ bản.
- **Các thư viện hỗ trợ khác**:
 - `tqdm`: Để theo dõi tiến độ huấn luyện trực quan.
 - `matplotlib/seaborn`: Để trực quan hóa dữ liệu và biểu đồ Loss.
 - `PIL (Pillow)`: Để xử lý và biến đổi dữ liệu ảnh thô.

4.2.2 Cấu hình Siêu tham số

Quá trình huấn luyện được chia làm 2 giai đoạn: Huấn luyện Item Tower trước để tạo vector đặc trưng sản phẩm, sau đó dùng các vector này đóng băng hoặc tinh chỉnh nhẹ để huấn luyện User Tower.

Cấu hình Item Tower

Item Tower chịu trách nhiệm mã hóa thông tin đa phương thức của sản phẩm. Các tham số chi tiết được liệt kê trong Bảng 4.5.

Bảng 4.5: Cấu hình siêu tham số cho Item Tower

Tham số	Giá trị	Giải thích
Text Encoder	all-mpnet-base-v2	Mô hình Sentence-BERT tối ưu cho Semantic Search
Image Encoder	vit_base_patch16_224	Vision Transformer pretrained trên ImageNet
Batch Size	128	Kích thước lô dữ liệu
Learning Rate	2×10^{-5}	Tốc độ học thấp để fine-tune
Epochs	70	Số vòng lặp huấn luyện
Temperature (τ)	0.07	Tham số nhiệt độ cho Contrastive Loss
Latent Dimension	256	Kích thước vector nhúng cuối cùng

Cấu hình User Tower

User Tower sử dụng kiến trúc Transformer Encoder để học sự phụ thuộc tuần tự trong lịch sử hành vi người dùng.

Bảng 4.6: Cấu hình siêu tham số cho User Tower

Tham số	Giá trị	Giải thích
Architecture	Transformer Encoder	Sử dụng Self-Attention
Num Layers	2	Số lớp Transformer
Num Heads	4	Số đầu Attention
Max Seq Length	40	Độ dài chuỗi lịch sử tối đa
LR (Base)	1×10^{-4}	Cho các lớp khởi tạo mới (Fusion, Projection)
LR (Pretrained)	1×10^{-6}	Cho các lớp BERT/Embedding (Differential Learning Rates)
Batch Size	64	Giảm batch size do mô hình phức tạp

4.3 Đầu vào và đầu ra

4.3.1 Xây dựng Item Tower

Item Tower đóng vai trò trích xuất đặc trưng từ dữ liệu đa phương thức của sản phẩm để tạo ra một vector đại diện thống nhất. Để đảm bảo tính nhất quán trong tính toán, chúng tôi quy ước các ký hiệu kích thước như sau:

- B : Kích thước Batch Size, ví dụ $B = 128$.
- D_{orig} : Số chiều gốc của các mô hình Pre-trained, với MPNet và ViT-Base là 768.
- D : Số chiều không gian tiềm ẩn đích, thiết lập $D = 256$.

Text Encoder

Hệ thống sử dụng mô hình ngôn ngữ **all-mpnet-base-v2** để chuyển đổi thông tin văn bản gồm Tiêu đề và Mô tả thành vector ngữ nghĩa.

Bảng 4.7: Đặc tả luồng dữ liệu và kích thước trong *Text Encoder*

Tầng xử lý	Kích thước	Giải thích chi tiết
1. Input Raw	List[String] kích thước B	Danh sách các chuỗi văn bản thô đầu vào.
2. Tokenization	(B, L_{max})	Văn bản được phân tách thành các Token IDs. $L_{max} = 512$ là độ dài chuỗi tối đa. Các chuỗi ngắn hơn được padding giá trị 0.
3. Transformer Backbone	$(B, L_{max}, 768)$	Đầu ra từ lớp ẩn cuối cùng của MPNet. Mỗi token trong chuỗi được biểu diễn bởi một vector 768 chiều.
4. Mean Pooling	$(B, 768)$	Thực hiện phép trung bình cộng dọc theo trục chiều dài chuỗi (L_{max}), loại bỏ các token đệm để thu được vector đại diện cho toàn bộ câu.
5. Projection Head	$(B, 256)$	Lớp tuyến tính nén vector từ 768 xuống 256 chiều, đóng vai trò là đầu ra của nhánh văn bản (v_{text}).

Image Encoder

Sử dụng kiến trúc **Vision Transformer ViT-Base-Patch16-224** để trích xuất đặc trưng thị giác từ ảnh sản phẩm.

Bảng 4.8: Đặc tả luồng dữ liệu và kích thước trong Image Encoder

Tầng xử lý	Kích thước	Giải thích chi tiết
1. Input Image	$(B, 3, 224, 224)$	Ảnh RGB gốc được resize về kích thước 224×224 pixels và chuẩn hóa theo phân phối ImageNet.
2. Patch Embedding	$(B, 197, 768)$	Ảnh được chia thành lưới $14 \times 14 = 196$ patches. Cộng thêm 1 token đặc biệt [CLS] ở đầu chuỗi để học đặc trưng toàn cục.
3. Transformer Encoder	$(B, 197, 768)$	Các patch đi qua 12 lớp Self-Attention của ViT. Kích thước không đổi.
4. Feature Extraction	$(B, 768)$	Chỉ lấy vector tại vị trí đầu tiên (index 0, ứng với token [CLS]), đại diện cho nội dung toàn bức ảnh.
5. Projection Head	$(B, 256)$	Chiếu vector đặc trưng về không gian chung 256 chiều (v_{img}).

Tabular Encoder

Xử lý các thông tin định lượng như Giá và Rating, và các thông tin định danh như Danh mục và Thương hiệu.

Bảng 4.9: Đặc tả luồng dữ liệu trong Tabular Encoder

Tầng xử lý	Kích thước (Shape)	Giải thích chi tiết
1. Input Features	(B, N_{feat})	Vector chứa giá trị số đã chuẩn hóa Z-score và index của biến phân loại.
2. Embedding Lookup	$(B, N_{cat} \times D_{emb})$	Các biến phân loại được chuyển thành vector nhúng và nối lại với nhau.
3. Concatenation	(B, D_{total})	Ghép nối vector biến số thực và vector biến phân loại thành một vector dài.
4. MLP Block	$(B, 256)$	Mạng nơ-ron đa tầng (Linear $\rightarrow$ ReLU $\rightarrow$ Linear) biến đổi dữ liệu hỗn hợp thành vector đặc trưng bảng (v_{tab}).

Cơ chế Fusion

Mô-đun **Fusion Gate** chịu trách nhiệm tổng hợp ba nguồn thông tin trên thành một vector duy nhất. Quá trình này diễn ra như sau:

1. **Xếp chồng:** Ba vector đầu ra từ các encoder được xếp chồng lên nhau tạo thành tensor đầu vào V_{in} :

$$V_{in} = [v_{text}, v_{img}, v_{tab}] \in \mathbb{R}^{B \times 3 \times 256}$$

2. **Tính trọng số chú ý:** Một mạng nơ-ron nhỏ (Linear layer) học cách đánh giá độ quan trọng của từng modal dựa trên ngữ cảnh:

$$W_{raw} = V_{in} \times W_{learnable} \in \mathbb{R}^{B \times 3 \times 1}$$

$$\alpha = \text{Softmax}(W_{raw}) \in \mathbb{R}^{B \times 3 \times 1}$$

Trong đó $\sum_{k=1}^3 \alpha_{i,k} = 1$ với mọi mẫu dữ liệu i .

3. **Tổng hợp có trọng số:** Vector sản phẩm cuối cùng là tổng của các vector thành phần nhân với trọng số tương ứng:

$$v_{item} = \sum_{k \in \{text, img, tab\}} \alpha_k \cdot v_k$$

Output: Tensor v_{item} có kích thước (**B, 256**).

Kết quả cuối cùng là mỗi sản phẩm trong hệ thống được đại diện bởi một vector 256 chiều duy nhất, chứa đựng tinh hoa thông tin được chắt lọc từ cả hình ảnh, văn bản và dữ liệu bảng.

4.3.2 Xây dựng User Tower

Khác với các mô hình tuần tự truyền thống như SASRec chỉ dựa vào định danh sản phẩm Item ID, User Tower trong đề án này được thiết kế theo kiến trúc *Mạng Tuần tự Đa phương thức*. Tại mỗi bước thời gian t trong lịch sử hành vi, mô hình không chỉ nhìn thấy sản phẩm mà còn đọc được nội dung bài đánh giá và hiểu được mức độ hài lòng của người dùng tại thời điểm đó.

Quy ước kích thước:

- B : Kích thước Batch Size.
- S : Độ dài chuỗi lịch sử tối đa, thiết lập $S = 50$.
- D : Số chiều không gian tiềm ẩn đích, $D = 256$.

Đầu vào đa nguồn

User Tower tiếp nhận 4 luồng dữ liệu song song đại diện cho chuỗi hành vi của người dùng:

Bảng 4.10: Đặc tả các luồng dữ liệu đầu vào cho User Tower

Luồng dữ liệu	Kích thước	Mô tả chi tiết
1. Item Indices	(B, S)	Chuỗi ID các sản phẩm đã tương tác. Các chuỗi ngắn hơn S được đệm bằng giá trị 0.
2. Review Texts	List[$B \times S$]	Nội dung văn bản mà user đã viết cho từng sản phẩm, ví dụ: “Thẻ này rất tiện”, “Giao hàng chậm”.
3. Context Feats	$(B, S, 3)$	Các đặc trưng ngữ cảnh tại thời điểm tương tác, bao gồm: <i>Rating</i> , <i>Helpful Votes</i> , và <i>Verified Purchase</i> .
4. Padding Mask	(B, S)	Ma trận mặt nạ Boolean, đánh dấu các vị trí là dữ liệu thật để Transformer tập trung xử lý và bỏ qua các vị trí đệm.

Kiến trúc xử lý tuần tự

Quá trình biến đổi từ dữ liệu thô thành vector người dùng diễn ra qua 4 giai đoạn chính:

Giai đoạn 1: Mã hóa đặc trưng thành phần Mỗi nguồn dữ liệu được đưa qua bộ mã hóa riêng biệt để chuyển về cùng không gian vector:

- **Item Embedding Lookup:** $ID \rightarrow v_{item} \in \mathbb{R}^{B \times S \times D}$. Ma trận này được khởi tạo từ Item Tower và cho phép tính chĩnh.
- **Text Encoding:** Sử dụng lại *Text Encoder* (MPNet) của Item Tower để mã hóa nội dung review: $Text \rightarrow v_{text} \in \mathbb{R}^{B \times S \times D}$.
- **Tabular Encoding:** Các biến số như Rating hay Votes đi qua mạng MLP để tạo ra vector ngữ cảnh: $Feats \rightarrow v_{tab} \in \mathbb{R}^{B \times S \times D}$.

Giai đoạn 2: Interaction Fusion Tại mỗi bước thời gian t , thông tin từ ba nguồn trên được tổng hợp bởi cơ chế **Gating Fusion** để tạo ra một vector đại diện duy nhất cho tương tác đó (h_t):

$$h_t = \text{FusionGate}(v_{item}^{(t)}, v_{text}^{(t)}, v_{tab}^{(t)}) \quad (4.5)$$

Kết quả là tensor chuỗi hành vi hợp nhất H_{seq} có kích thước (B, S, D) .

Giai đoạn 3: Mô hình hóa sự phụ thuộc Chuỗi H_{seq} được cộng thêm thông tin vị trí Positional Encoding và đưa qua khối **Transformer Encoder**.

- Cơ chế *Self-Attention* giúp mô hình học được mối quan hệ phụ thuộc dài hạn giữa các lần mua hàng, ví dụ: mua “Thẻ Game” thường dẫn đến mua “Tay cầm chơi game”.
- Đầu ra là chuỗi các trạng thái ẩn $T_{out} \in \mathbb{R}^{B \times S \times D}$.

Giai đoạn 4: Tổng hợp và Chuẩn hóa Thay vì chỉ lấy trạng thái cuối cùng dễ bị nhiễu, mô hình sử dụng kỹ thuật **Masked Mean Pooling** để tổng hợp thông tin từ toàn bộ lịch sử:

$$v_{user_raw} = \frac{\sum_{t=1}^S (T_{out}^{(t)} \cdot mask_t)}{\sum_{t=1}^S mask_t + \epsilon} \quad (4.6)$$

Cuối cùng, vector này đi qua lớp chiếu tuyến tính (Final Projection) và chuẩn hóa L2:

$$\mathbf{v}_{user} = \text{Normalize}(\text{Linear}(v_{user_raw})) \in \mathbb{R}^{B \times 256} \quad (4.7)$$

Đầu ra: Vector $\mathbf{v}_{user}$ có kích thước **(B, 256)**. Đây là vector đặc trưng (User Embedding) cuối cùng, sẵn sàng để thực hiện phép nhân vô hướng (Dot Product) với vector sản phẩm để tính điểm gợi ý.

4.4 Các độ đo đánh giá

Để đánh giá định lượng hiệu năng của hệ thống gợi ý, đặc biệt là đối với bài toán *Next-Item Prediction*, việc lựa chọn các độ đo phù hợp là vô cùng quan trọng. Trong ngữ cảnh của đề án này, tại mỗi bước thời gian t , chỉ có duy nhất một sản phẩm thực tế i_{true} mà người dùng u đã tương tác. Nhiệm vụ của mô hình là xếp hạng sản phẩm i_{true} này càng cao càng tốt trong danh sách K gợi ý $R_u = \{r_1, r_2, \dots, r_K\}$.

Chúng tôi sử dụng bộ ba chỉ số tiêu chuẩn trong lĩnh vực Truy xuất thông tin bao gồm Recall, MRR và NDCG. Mỗi chỉ số phản ánh một khía cạnh khác nhau của chất lượng gợi ý.

4.4.1 Recall@K

Định nghĩa và Công thức

Recall@K, hay còn gọi là Hit Rate@K trong bài toán Next-Item, là độ đo cơ bản nhất, dùng để trả lời câu hỏi: “*Sản phẩm người dùng muốn mua có nằm trong danh sách gợi ý hay không?*”. Nó không quan tâm đến thứ tự xếp hạng trong danh sách, miễn là sản phẩm đích xuất hiện trong Top-K.

Công thức tổng quát được định nghĩa như sau [31]:

$$\text{Recall@K} = \frac{1}{|U|} \sum_{u \in U} \mathbb{I}(i_{true}^{(u)} \in R_u[:K]) \quad (4.8)$$

Trong đó:

- $|U|$ là tổng số lượng người dùng trong tập kiểm thử.
- $R_u[:K]$ là danh sách K sản phẩm có điểm dự đoán cao nhất cho người dùng u .
- $\mathbb{I}(\cdot)$ là hàm chỉ thị (Indicator Function), nhận giá trị 1 nếu biểu thức bên trong đúng và 0 nếu sai.

Ý nghĩa và Vai trò

Trong hệ thống gợi ý thương mại điện tử, Recall@K đo lường *khả năng bao phủ* của mô hình đối với nhu cầu người dùng.

Một chỉ số Recall cao đồng nghĩa với việc hệ thống có khả năng nắm bắt chính xác ý định của người dùng, đảm bảo các sản phẩm phù hợp được đưa vào danh sách đề xuất. Đặc biệt, đối với bài toán sở hữu không gian tìm kiếm rộng lớn với hàng nghìn loại thẻ quà tặng (Gift Cards), việc đạt được Recall cao được xem là thách thức tiên quyết và quan trọng nhất, tạo nền tảng vững chắc trước khi hệ thống tiến hành các bước tối ưu hóa thứ hạng chi tiết.

4.4.2 MRR@K

Định nghĩa và Công thức

Nếu Recall chỉ quan tâm đến sự xuất hiện “Có” hoặc “Không”, thì MRR quan tâm đến *vị trí xuất hiện đầu tiên* của sản phẩm đúng. MRR đánh giá độ chính xác của việc xếp hạng một cách khắt khe: sản phẩm đúng càng nằm gần đầu danh sách, điểm số càng cao; ngược lại điểm số sẽ giảm rất nhanh.

Công thức tính MRR tại ngưỡng cắt K [31]:

$$\text{MRR@K} = \frac{1}{|U|} \sum_{u \in U} \left(\frac{1}{\text{rank}(i_{true}^{(u)})} \cdot \mathbb{I}(\text{rank}(i_{true}^{(u)}) \leq K) \right) \quad (4.9)$$

Trong đó $\text{rank}(i_{true}^{(u)})$ là thứ hạng của sản phẩm đúng trong danh sách gợi ý (bắt đầu từ 1). Nếu sản phẩm không nằm trong Top-K, giá trị nghịch đảo xếp hạng được quy ước là 0.

Phân tích độ nhảy

Chỉ số MRR phản ánh trực tiếp trải nghiệm tìm kiếm của người dùng trong thực tế, nơi thứ hạng hiển thị đóng vai trò quyết định đến mức độ hài lòng. Theo cơ chế này, điểm số sẽ đạt giá trị tối đa là 1.0 nếu hệ thống đưa sản phẩm mục tiêu vào vị trí đầu tiên. Tuy nhiên, mức điểm này sẽ giảm mạnh theo quy luật nghịch đảo: chỉ còn 0.5 tại vị trí thứ hai và xuống mức rất thấp là 0.1 nếu sản phẩm trôi xuống vị trí thứ 10.

Do đặc tính giảm mạnh này, MRR thường được sử dụng để đánh giá các hệ thống yêu cầu độ chính xác tức thời như gợi ý từ khóa tìm kiếm hoặc gợi ý Top-1 sản phẩm thay thế, nơi người dùng hiếm khi cuộn xuống quá sâu.

4.4.3 NDCG@K

Định nghĩa và Công thức

NDCG được coi là *tiêu chuẩn vàng* trong đánh giá xếp hạng. Khác với MRR phạt tuyến tính theo nghịch đảo, NDCG sử dụng hàm Logarit để chiết khấu giá trị của các gợi ý ở vị trí thấp một cách mượt mà hơn, phản ánh tốt hơn sự suy giảm sự chú ý của người dùng.

Với bài toán Next-Item Prediction chỉ có 1 nhãn đúng, công thức NDCG@K được đơn giản hóa như sau [31]:

$$\text{NDCG@K} = \frac{1}{|U|} \sum_{u \in U} \frac{1}{\log_2(\text{rank}(i_{true}^{(u)}) + 1)} \cdot \mathbb{I}(\text{rank}(i_{true}^{(u)}) \leq K) \quad (4.10)$$

Tại sao NDCG ưu việt hơn MRR?

Mặc dù cả MRR và NDCG đều chú trọng các kết quả đứng đầu, NDCG sở hữu cơ chế giảm trọng số nhẹ nhàng hơn ở các thứ hạng thấp nhờ đặc tính của hàm logarit. Sự khác biệt này thể hiện rõ nét khi so sánh mức giảm điểm số giữa vị trí thứ nhất và thứ hai; trong khi MRR tạo ra khoảng cách lớn từ 1.0 xuống 0.5, NDCG lại duy trì mức giảm vừa phải hơn từ 1.0 xuống 0.63. Xét trong ngữ cảnh gợi ý quà tặng, người dùng thường có xu hướng xem xét nhiều lựa chọn khác nhau, do đó việc sản phẩm mục tiêu xuất hiện ở vị trí thứ 3 hay thứ 4 vẫn mang lại giá trị thực tiễn. Vì vậy, NDCG được xem là thước đo phản ánh mức độ hài lòng chính xác hơn. Nhìn chung, việc kết hợp bộ ba chỉ số mang lại góc nhìn toàn diện cho hệ thống: Recall đo lường độ phủ, MRR đánh giá khả năng dự đoán chính xác tuyệt đối và NDCG phản ánh chất lượng trải nghiệm xếp hạng tổng thể.


4.5 Kết quả thực nghiệm

4.5.1 Quá trình huấn luyện

Do kiến trúc Two-Tower được huấn luyện theo quy trình hai giai đoạn, chúng tôi theo dõi và phân tích sự biến thiên của hàm mất mát riêng biệt cho từng mạng. Việc giám sát này không chỉ giúp phát hiện các hiện tượng bất thường như Overfitting hay Underfitting mà còn cung cấp cái nhìn sâu sắc về khả năng học đặc trưng của mô hình.

Giai đoạn 1: Huấn luyện Item Tower

Trong giai đoạn này, mục tiêu là tối ưu hóa không gian biểu diễn chung giữa Văn bản và Hình ảnh. Mô hình được huấn luyện trong 70 Epochs với hàm mất mát Contrastive Loss.




Hình 4.1: Diễn biến hàm mất mát trong quá trình huấn luyện Item Tower

Phân tích Hình 4.1: Quá trình huấn luyện mô hình ghi nhận sự hội tụ ổn định và tích cực thông qua biểu đồ biến thiên của hàm mất mát. Cụ thể, giá trị Loss giảm mượt mà từ mức khởi điểm ~ 21.4 xuống còn ~ 12.6 sau 70 epochs mà không xuất hiện các dấu hiệu bất thường như dao động mạnh hay phân kỳ. Sự ổn định số học này minh chứng cho tính hợp lý của tốc độ học (Learning Rate = $2e^{-5}$) đã được thiết lập. Đáng chú ý, đường cong Loss của tập Validation luôn duy trì khoảng cách rất nhỏ và biến thiên đồng dạng với tập Train, khẳng định mô hình đã tránh được hiện tượng quá khớp. Thay vì ghi nhớ máy móc các mẫu dữ liệu, mạng nơ-ron đã thực sự nắm bắt được mối tương quan ngữ nghĩa trừu tượng giữa tiêu đề văn bản và hình ảnh minh họa. Kết quả này đóng vai trò then chốt, đảm bảo các vector đặc trưng sản phẩm Item Embeddings đầu ra sở hữu tính phân biệt cao, tạo tiền đề vững chắc cho độ chính xác của các thuật toán gợi ý ở giai đoạn tiếp theo.

Giai đoạn 2: Huấn luyện User Tower

Sau khi cố định trọng số của Item Tower, chúng tôi tiến hành huấn luyện User Tower để mô hình hóa chuỗi hành vi người dùng. Quá trình này diễn ra trong 26 Epochs với cơ chế dừng sớm.



Hình 4.2: Diễn biến hàm mất mát trong quá trình huấn luyện User Tower

Phân tích Hình 4.2: Khác biệt với diễn biến của Item Tower, quá trình huấn luyện User Tower ghi nhận tốc độ hội tụ nhanh chóng, đạt trạng thái ổn định chỉ sau khoảng 3 đến 5 Epochs đầu tiên với hàm Loss giảm từ mức khởi điểm ~ 2.94 xuống vùng ~ 2.35 . Ngay sau giai đoạn này, mô hình bước vào vùng bão hòa kéo dài từ Epoch 10 đến Epoch 26, nơi mức cải thiện của Validation Loss trở nên không đáng kể (dao động 0.001 – 0.002). Đây là đặc trưng điển hình của các bài toán dự đoán chuỗi trên tập dữ liệu thưa, phản ánh việc mô hình đã khai thác tối đa các mẫu hành vi tuần tự hiện hữu trong lịch sử tương tác giới hạn của người dùng. Để tối ưu hóa hiệu suất trong bối cảnh này, chiến lược *Model Checkpointing* đã được áp dụng nhằm lưu lại phiên bản mô hình tốt nhất tại Epoch 26 với giá trị Loss đạt 2.3488, phục vụ cho quá trình kiểm thử cuối cùng.

Tổng hợp đánh giá quá trình huấn luyện

Sự chênh lệch rõ rệt trong động học huấn luyện giữa hai nhánh mạng không phải là yếu tố ngẫu nhiên, mà phản ánh chính xác độ phức tạp nội tại của từng loại dữ liệu đầu vào. Cụ thể, **Item Tower** đòi hỏi một chu trình huấn luyện kéo dài tới 70 Epochs do phải giải quyết bài toán khó khăn nhất: lấp đầy khoảng cách ngữ nghĩa từ dữ liệu thô. Mạng nơ-ron phải học cách trích xuất và tổng hợp các đặc trưng mức thấp từ điểm ảnh và câu chữ để tạo ra các biểu diễn trừu tượng, một quá trình tối ưu hóa trên không gian chiều cực lớn và đầy nhiễu.


Ở chiều ngược lại, sự hội tụ nhanh chóng của **User Tower** là kết quả trực tiếp của chiến lược huấn luyện phân tầng. Do đầu vào của tháp này là các vector đặc trưng đã được tinh chế từ giai đoạn trước, mô hình được giải phóng khỏi gánh nặng xử lý tín hiệu sơ cấp. Thay vào đó, nhiệm vụ của nó được khu trú vào việc nhận diện các quy luật sắp xếp và nắm bắt sự phụ thuộc chuỗi trong hành vi người dùng. Vì hoạt động trên không gian vector mật độ cao và ít chiều hơn, bề mặt tối ưu hóa của User Tower trở nên trơn tru hơn, dẫn đến tốc độ hội tụ vượt trội. Việc tách rời hai giai đoạn này giúp chúng tôi kiểm soát tốt hơn quá trình tối ưu hóa và tiết kiệm tài nguyên tính toán đáng kể so với việc huấn luyện End-to-End toàn bộ hệ thống cùng lúc.

4.5.2 Kết quả đánh giá chính

Bảng 4.11 tóm tắt hiệu năng định lượng của mô hình Hybrid Pipeline trên tập kiểm thử tại hai ngưỡng cắt quan trọng là $K = 10$ và $K = 20$. Các chỉ số này phản ánh khả năng dự đoán chính xác hành vi tiêu dùng tiếp theo của hệ thống.

Bảng 4.11: Kết quả đánh giá hiệu năng mô hình Hybrid trên tập Test

Độ đo (Metric)	@Top-10	@Top-20
Recall (Hit Rate)	0.9923	0.9943
MRR (Mean Reciprocal Rank)	0.8616	0.8618
NDCG	0.8941	0.8946



Hình 4.3: Biểu đồ trực quan hóa hiệu năng các độ đo tại Top-10 và Top-20

Phân tích và Bình luận chi tiết

Dựa trên số liệu từ Bảng 4.11 và Hình 4.3, chúng ta có thể rút ra những nhận xét quan trọng sau về hiệu quả của mô hình:

1. Khả năng bao phủ tuyệt đối (Recall tiệm cận 1.0): Kết quả thực nghiệm ghi nhận chỉ số Recall@10 đạt mức ấn tượng **0.9923**, tương đương với việc hệ thống nắm bắt chính xác nhu cầu mua sắm của người dùng trong hơn 99% các phiên kiểm thử. Điều này có nghĩa là sản phẩm đích thực hầu như luôn hiện diện trong danh sách 10 gợi ý đầu tiên, một hiệu suất hiếm thấy đối với các bài toán gợi ý trên tập dữ liệu thưa. Đáng chú ý, khi mở rộng phạm vi tìm kiếm lên 20 sản phẩm, mức tăng trưởng hiệu suất là không đáng kể, chênh lệch dưới 0.002. Sự bão hòa sớm này cho thấy mô hình hoạt động cực kỳ dứt khoát: nó xác định đúng đối tượng ngay từ những bước đầu tiên mà không cần dựa vào danh sách gợi ý dài dòng. Từ góc độ ứng dụng, đặc điểm này có ý nghĩa to lớn trong việc tối ưu hóa giao diện người dùng trên thiết bị di động, nơi không gian hiển thị bị giới hạn và người dùng thường có xu hướng ít kiên nhẫn khi phải cuộn trang quá nhiều.

2. Chất lượng xếp hạng vượt trội: Bên cạnh khả năng tìm kiếm chính xác, User Tower còn thể hiện năng lực sắp xếp thứ tự ưu tiên vượt trội, được phản ánh rõ nét qua chỉ số MRR@10 đạt **0.8616**. Trong ngữ cảnh của bài toán xếp hạng, nếu coi $MRR = 1.0$ là trạng thái lý tưởng và $MRR = 0.5$ tương ứng với vị trí thứ hai, thì con số 0.86 cho phép suy luận rằng trong đại đa số các trường hợp, sản phẩm mục tiêu đang nằm cố định ở vị trí **Top-1 hoặc Top-2**. Nhận định này càng được củng cố bởi chỉ số NDCG@10 đạt **0.8941**, khẳng định hệ thống không chỉ đưa sản phẩm đúng vào danh sách mà còn đẩy nó lên những vị trí dễ nhìn thấy nhất. Việc tối đa hóa thứ hạng này giúp giảm thiểu ma sát trong trải nghiệm tìm kiếm, giúp người dùng ra quyết định nhanh chóng mà không tốn nhiều nỗ lực sàng lọc.

3. Hiệu quả của kiến trúc Đa phương thức: Thành tựu đạt được các chỉ số cao kỷ lục này trên tập dữ liệu Amazon Gift Cards—vốn có độ thưa dữ liệu lên tới 99.8%—là minh chứng thực nghiệm vững chắc cho giả thuyết nghiên cứu ban đầu. Cụ thể, khi dữ liệu tương tác hành vi trở nên quá khan hiếm để các thuật toán Lọc cộng tác truyền thống hoạt động hiệu quả, sự bổ sung thông tin từ các nhánh ngữ nghĩa BERT và thị giác ViT đã đóng vai trò cứu cánh quyết định. Mô hình Two-Tower đã thành công trong việc thiết lập mối liên kết ngầm ẩn giữa sở thích trừu tượng của người dùng và các đặc tính nội dung đa phương thức của sản phẩm. Thay vì chỉ đơn thuần đếm tần suất tương tác, hệ thống đã thực sự hiểu được nội dung sản phẩm để đưa ra gợi ý, chứng minh sức mạnh của hướng tiếp cận Content-based hiện đại trong việc giải quyết bài toán Cold-start và dữ liệu thưa.

Mô hình Two-Tower đã thành công trong việc học được mối liên kết ngầm ẩn giữa sở thích người dùng và đặc tính nội dung của sản phẩm, thay vì chỉ dựa vào việc đếm số lần tương tác như các phương pháp truyền thống.

4.6 Phân tích vai trò từng thành phần

4.6.1 Ảnh hưởng của Đa phương thức

Để định lượng chính xác đóng góp của từng nguồn dữ liệu, chúng tôi thực hiện thí nghiệm cô lập. Trong đó, các nhánh đầu vào của mạng Fusion Gate lần lượt bị vô hiệu hóa, buộc mô hình chỉ được sử dụng một nguồn thông tin duy nhất để truy vấn.

Kết quả thực nghiệm trên tập kiểm thử được trình bày trong Bảng 4.12.

Bảng 4.12: Hiệu năng mô hình theo từng phương thức đầu vào

Phương thức	Recall@10	MRR@10	Đánh giá
Chỉ Text	0.9937	0.8611	Hiệu năng tốt, đóng vai trò nền tảng.
Chỉ Image	0.9998	0.9153	Xuất sắc nhất. Định danh chính xác tuyệt đối.
Fusion	0.9995	0.9009	Đạt sự cân bằng tối ưu giữa độ chính xác và độ tin cậy.

4.6.2 Phân tích đặc thù miền dữ liệu và Hiệu quả Fusion

Các kết quả từ Bảng 4.12 cho thấy những đặc điểm thú vị của tập dữ liệu Gift Cards, đồng thời làm sáng tỏ sự đánh đổi trade-off trong cơ chế kết hợp đa phương thức.

1. Sự thống trị của kênh Thị giác

Kết quả thực nghiệm đối với chế độ **Image-Only** ghi nhận những chỉ số hiệu suất gần như tuyệt đối, với Recall tiệm cận 100% và MRR vượt ngưỡng 0.91. Thành tựu này phản ánh sâu sắc đặc thù của miền dữ liệu Thẻ quà tặng *Gift Cards*, nơi hình ảnh đóng vai trò định danh cực kỳ mạnh mẽ. Khác với các sản phẩm điện tử tiêu dùng - vốn thường chia sẻ ngôn ngữ thiết kế công nghiệp tương đồng và khó phân biệt - mỗi tấm thẻ quà tặng đều

sở hữu thiết kế đồ họa mang tính biểu tượng cao gắn liền với các dịp lễ cụ thể như hình ảnh Bánh sinh nhật, Cây thông Noel hay Nôi em bé. Chính nhờ sự khác biệt rõ rệt này, mô hình Vision Transformer đã phát huy tối đa năng lực trích xuất đặc trưng thị giác, cho phép hệ thống định danh chính xác mục đích và ngữ cảnh sử dụng của thẻ ngay cả khi thiếu vắng hoàn toàn thông tin văn bản.

2. Hạn chế về ngữ nghĩa của dữ liệu Văn bản

Mặc dù chế độ Text-Only duy trì được mức Recall ấn tượng $\approx 99.37\%$, khả năng xếp hạng chi tiết, phản ánh qua chỉ số MRR, lại thua kém đáng kể so với phương thức xử lý hình ảnh. Nguyên nhân cốt lõi nằm ở hiện tượng *trùng lặp ngữ nghĩa* trong dữ liệu văn bản. Cụ thể, tiêu đề sản phẩm thường chứa các cụm từ định danh chung chung lặp lại với tần suất cao như “Amazon.com Gift Card” hay “Gift Card in a Box”. Sự thiếu hụt các từ khóa mang tính phân biệt khiến Text Encoder gặp trở ngại lớn trong việc phân định thứ tự ưu tiên giữa các sản phẩm cùng phân loại nhưng khác biệt thể mẫu mã, dẫn đến sự sụt giảm tất yếu trong chất lượng xếp hạng.

3. Luận giải sự cần thiết của kiến trúc Fusion

Một quan sát thực nghiệm đáng chú ý là hiệu năng của mô hình Fusion 0.9995 thấp hơn một lượng rất nhỏ so với chế độ Image-Only 0.9998. Tuy nhiên, độ lệch 0.0003 này là **không đáng kể về mặt thống kê**, và việc duy trì kiến trúc Fusion vẫn được xác định là yêu cầu bắt buộc dựa trên hai luận điểm kỹ thuật then chốt:

Thứ nhất là bài toán **giải quyết xung đột tín hiệu**. Trong một số trường hợp biên, tín hiệu từ văn bản vốn có độ phân biệt thấp có thể gây nhiễu hoặc mâu thuẫn nhẹ với tín hiệu hình ảnh, làm giảm độ tự tin của mô hình khi ra quyết định xếp hạng, kéo MRR giảm nhẹ từ 0.91 xuống 0.90. Đây được xem là sự đánh đổi chấp nhận được để đổi lấy tính tổng quát hóa của mô hình.

Thứ hai, và quan trọng hơn, là yếu tố **Tính chịu lỗi** trong môi trường vận hành thực tế. Dữ liệu hình ảnh thường đối mặt với các rủi ro kỹ thuật cao như lỗi đường truyền, ảnh không tải được hoặc chất lượng suy giảm. Trong kịch bản đó, một hệ thống phụ thuộc đơn lẻ vào Image-Only sẽ đối mặt với nguy cơ ngưng trệ hoàn toàn. Ngược lại, kiến trúc Fusion với cơ chế cổng kiểm soát sẽ tự động điều hướng trọng số sang nhánh văn bản, vốn vẫn đảm bảo Recall $> 99\%$. Nhờ đó, nhánh văn bản đóng vai trò như một **“Lưới an toàn”**, đảm bảo hệ thống luôn duy trì hoạt động ổn định và bền vững bất chấp các sự cố dữ liệu đầu vào.

Kết luận: Mặc dù Image là đặc trưng mạnh nhất, kiến trúc Fusion là giải pháp tối ưu về mặt kỹ thuật hệ thống, đảm bảo độ chính xác tiệm cận mức tuyệt đối đồng thời duy trì tính bền vững trước các nhiễu động dữ liệu thực tế.

4.6.3 Hiệu quả của chiến lược Reranking

Trong kiến trúc đề xuất, chúng tôi áp dụng cơ chế truy xuất hai giai đoạn, một tiêu chuẩn vàng trong thiết kế các hệ thống gợi ý quy mô lớn. Giai đoạn này giải quyết bài toán cân

bằng Trade-off giữa:

- **Ý định nhất thời:** Người dùng đang tìm kiếm từ khóa gì? (Đại diện bởi *Query Embedding*).
- **Sở thích dài hạn:** Người dùng thường thích thương hiệu nào, mệnh giá bao nhiêu? (Đại diện bởi *User Embedding*).

Để tổng hợp hai nguồn thông tin này, hệ thống sử dụng hàm tổng hợp tuyến tính có trọng số:

$$\text{Score}_{final}(u, i, q) = \alpha \cdot \text{Sim}(q, i) + \beta \cdot \text{Sim}(u, i) \quad (4.11)$$

Trong đó:

- $\text{Sim}(q, i)$: Điểm tương đồng giữa truy vấn (Text/Image) và sản phẩm (Retrieval Score).
- $\text{Sim}(u, i)$: Điểm tương đồng giữa vector người dùng và sản phẩm (Personalization Score).
- α, β : Các siêu tham số kiểm soát mức độ ảnh hưởng, được thiết lập thực nghiệm là $\alpha = 0.7, \beta = 0.3$.

Vai trò then chốt của kích thước tập ứng viên ($k_{retrieval}$)

Một trong những phát hiện quan trọng nhất trong quá trình thực nghiệm là sự tác động của siêu tham số $k_{retrieval}$ (số lượng ứng viên được chọn ở giai đoạn 1 để đưa vào giai đoạn 2). Chúng tôi so sánh hai kịch bản: $k_{retrieval} = 10$ và $k_{retrieval} = 100$.

Kết quả cho thấy việc thiết lập $k_{retrieval} = 100$ mang lại hiệu năng vượt trội. Nguyên nhân nằm ở cơ chế **Hiệu ứng Phễu ngược** được phân tích dưới đây.

1. Vấn đề Tunnel Vision khi k nhỏ: Nếu ta chỉ lấy Top-10 sản phẩm có độ khớp văn bản cao nhất ($k_{retrieval} = 10$):

- Danh sách ứng viên lúc này bị chi phối hoàn toàn bởi sự trùng khớp từ khóa.
- **Hệ quả:** Không gian hoạt động của User Embedding bị giới hạn cực hẹp. Dù người dùng có sở thích đặc biệt, ví dụ: thích thẻ màu đỏ, thích hãng Starbucks, nhưng nếu các sản phẩm này nằm ở vị trí thứ 11, 12 trong danh sách Retrieval, chúng sẽ bị loại bỏ ngay lập tức.
- Lúc này, tham số β trở nên vô nghĩa vì nó chỉ có thể đảo vị trí của 10 item đã được chọn sẵn, không thể đưa thêm các item phù hợp sở thích vào danh sách.

2. Cơ chế Resurrection khi k lớn: Khi mở rộng không gian tìm kiếm lên Top-100 ($k_{\text{retrieval}} = 100$):

- Hệ thống chấp nhận đưa vào những sản phẩm có độ khớp từ khóa thấp hơn, nằm ở vị trí 50-100. Đây thường là những sản phẩm có mô tả văn bản không hoàn toàn trùng khớp với query nhưng lại có đặc tính ẩn phù hợp với người dùng.
- **Ví dụ thực tế:**
 - *Query*: “Happy Birthday Card”.
 - *User Profile*: Thường xuyên mua thẻ game PlayStation, Xbox.
 - *Giai đoạn 1 (Retrieval)*: Các thẻ “PlayStation” có thể chỉ đứng hạng 80 vì tiêu đề của nó ít chứa chữ “Happy Birthday” so với các thẻ thiệp chúc mừng truyền thống.
 - *Giai đoạn 2 (Reranking)*: Nhờ trọng số cá nhân hóa β , điểm số của thẻ “PlayStation” đang ở hạng 80 được cộng thêm một lượng lớn điểm tương đồng User-Item. Kết quả là nó “lội ngược dòng” vươn lên Top-5 trong danh sách cuối cùng.

Phân tích độ nhạy của tham số trộn (α, β)

Để tối ưu hóa hàm mục tiêu Hybrid, chúng tôi khảo sát sự biến thiên hiệu năng của hệ thống khi thay đổi trọng số giữa tính năng Tìm kiếm (α) và Cá nhân hóa (β) trên tập ứng viên đã lọc.

Bảng 4.13: Tác động của trọng số α và β lên độ chính xác

α	β	Recall@10	Cơ chế xếp hạng
1.0	0.0	0.9715	Pure Search: Xếp hạng hoàn toàn dựa trên độ khớp từ khóa/hình ảnh với truy vấn.
0.0	1.0	0.8950	Pure Personalization: Xếp hạng chỉ dựa trên lịch sử mua sắm, bỏ qua mức độ liên quan của từ khóa.
0.7	0.3	0.9923	Hybrid Optimal: Kết hợp tối ưu điểm mạnh của cả hai.

Phân tích kết quả thực nghiệm:

Từ Bảng 4.13, chúng ta rút ra các nhận định phù hợp với giả thuyết ban đầu:

1. **Vai trò chủ đạo của Tìm kiếm:** Kịch bản *Pure Search* đạt Recall rất cao (0.9715) so với *Pure Personalization* (0.8950). Điều này khẳng định rằng trong bài toán Gift Cards, ý định tìm kiếm hiện tại thể hiện qua Query là yếu tố quan trọng nhất. Nếu hệ thống lờ đi độ khớp từ khóa (cho $\alpha = 0$), nó sẽ dễ dàng gợi ý sai các sản phẩm mà người dùng thích nhưng không đúng chủ đề cần mua, ví dụ: thích thẻ Game nhưng đang tìm thẻ Spa.

2. **Giá trị gia tăng của Cá nhân hóa:** Tuy nhiên, Search đơn thuần chưa phải là tốt nhất. Khi kết hợp thêm 30% yếu tố cá nhân hóa ($\beta = 0.3$), Recall tăng vọt từ 0.9715 lên mức kỷ lục 0.9923.
 - Khoảng tăng trưởng $\sim 2.1\%$ này giải quyết các trường hợp **Nhập nhằng**. Ví dụ: Khi User tìm “Gift Card \$50”, có hàng trăm kết quả giống hệt nhau về từ khóa. Lúc này, User Embedding giúp đẩy đúng thương hiệu mà User hay mua lên Top đầu, giúp mô hình đạt độ chính xác gần như tuyệt đối.
3. **Kết luận:** Tỷ lệ phối hợp $\alpha = 0.7$ và $\beta = 0.3$ là điểm cân bằng lý tưởng, đảm bảo hệ thống vừa trả về kết quả đúng ý định tìm kiếm, vừa hợp gu người dùng.

Kết luận về chiến lược


Chiến lược Reranking với không gian ứng viên mở rộng ($k = 100$) kết hợp cùng tỷ lệ trộn hợp lý ($\alpha = 0.7$) đã chứng minh tính hiệu quả vượt trội. Nó biến hệ thống từ một công cụ tìm kiếm khô khan thành một trợ lý ảo thông minh, vừa biết lắng nghe yêu cầu hiện tại, vừa thấu hiểu gu thẩm mỹ quá khứ của người dùng.

4.7 Triển khai và Thử nghiệm trên Hệ thống thực tế

Để kiểm chứng khả năng hoạt động của mô hình trong môi trường sản phẩm thực, chúng tôi đã xây dựng một hệ thống Demo hoàn chỉnh theo mô hình Client-Server. Hệ thống không chỉ dừng lại ở việc đưa ra danh sách gợi ý mà còn tích hợp các tính năng nâng cao như tìm kiếm đa phương thức và giải thích kết quả bằng AI tạo sinh.

4.7.1 Kiến trúc hệ thống

Hệ thống được thiết kế tối ưu cho tốc độ phản hồi thời gian thực (Real-time response), bao gồm 3 tầng chính:



Hình 4.4: Kiến trúc hệ thống gợi ý Two-Tower triển khai thực tế

1. Tầng Dữ liệu và Mô hình:

- **Pre-computation Strategy:** Để đảm bảo độ trễ thấp nhất, toàn bộ 1,137 sản phẩm được đưa qua Item Tower để tạo ra ma trận đặc trưng $E_{item} \in \mathbb{R}^{1137 \times 256}$. Ma trận này cùng với User Embeddings được nạp sẵn vào GPU/RAM ngay khi khởi động server.
- **Dynamic Encoders:** Các mô hình *TextEncoder*, *ImageEncoder* và *FusionGate* được duy trì ở trạng thái chờ để xử lý các truy vấn mới từ người dùng.

2. Tầng Dịch vụ Backend Service - FastAPI:

- Sử dụng **FastAPI** để xây dựng RESTful API hiệu năng cao.
- **API Endpoint chính (/search):** Nhận đầu vào đa dạng, gồm Text, Image, User ID và các tham số điều khiển (α, β).
- **Logic Xử lý:** Tích hợp thuật toán tìm kiếm vector bằng phép nhân ma trận trực tiếp trên GPU, cho phép so khớp hàng nghìn sản phẩm trong tích tắc.
- **Tích hợp AI Tạo sinh:** Hệ thống kết nối với **Google Gemini API** theo kiến trúc *Retrieval-Augmented Generation (RAG)*. Sau khi có danh sách gợi ý, thông tin chi tiết của các sản phẩm hàng đầu được gửi làm ngữ cảnh để LLM sinh ra lời giải thích tự nhiên, giúp người dùng hiểu lý do tại sao sản phẩm đó phù hợp với họ.

3. Tầng Giao diện Frontend Application:

- Xây dựng bằng **ReactJS** và **Vite**, cung cấp giao diện trực quan cho phép người dùng nhập từ khóa, tải ảnh lên để tìm kiếm và xem danh sách gợi ý được cá nhân hóa.

4.7.2 Quy trình xử lý một yêu cầu gợi ý

Dựa trên mã nguồn triển khai, quy trình xử lý một yêu cầu tìm kiếm diễn ra qua 4 bước logic chặt chẽ

Đầu tiên, tại bước **Nhận diện và Xử lý Cold Start**, hệ thống thực hiện xác thực định danh người dùng trong cơ sở dữ liệu vector. Trong trường hợp phát hiện người dùng mới hoặc lịch sử tương tác quá thưa thớt (< 2 items), cơ chế dự phòng **Popularity Fallback** sẽ tự động kích hoạt, áp dụng công thức *Weighted Rating* để đề xuất các sản phẩm thịnh hành dựa trên sự cân bằng giữa điểm đánh giá và số lượng bình chọn. Ngược lại, đối với người dùng hiện hữu, vector đặc trưng cá nhân hóa (v_{user}) sẽ được truy xuất ngay lập tức.

Tiếp theo là giai đoạn **Truy xuất và Hợp nhất thông tin**. Các dữ liệu đầu vào đa phương thức (văn bản, hình ảnh) được chuyển đổi qua các Encoder chuyên biệt, sau đó đi qua cơ chế **Fusion Gate** để tổng hợp thành một biểu diễn vector truy vấn duy nhất (v_{query}). Hệ thống thực hiện phép nhân ma trận giữa v_{query} và không gian đặc trưng sản phẩm E_{item} nhằm lọc ra Top-100 ứng viên có độ tương đồng ngữ nghĩa cao nhất.

Danh sách ứng viên này sau đó bước vào giai đoạn **Xếp hạng lại** thông qua công thức tổng hợp điểm số linh hoạt:

$$Score_{final} = \alpha \times Score_{Retrieval} + \beta \times Score_{User} \quad (4.12)$$


Điểm đột phá của kiến trúc này nằm ở khả năng tham số hóa động: phía Client có thể truyền giá trị α và β trực tiếp qua API để điều chỉnh hành vi của bộ máy gợi ý tùy theo ngữ cảnh trải nghiệm. Ví dụ: tăng trọng số α tại trang Tìm kiếm hoặc tăng β tại trang chủ “Dành cho bạn”.

Cuối cùng, hệ thống tích hợp module **Retrieval-Augmented Generation** để nâng cao tính tương tác. Các sản phẩm sau khi xếp hạng được gửi kèm siêu dữ liệu tới một Mô

hình Ngôn ngữ Lớn, giúp sinh ra các lời giải thích tự nhiên nhằm minh bạch hóa lý do đề xuất cho người dùng.

4.7.3 Minh họa hệ thống

Dưới đây là hình ảnh thực tế từ hệ thống Demo, minh họa cho kịch bản người dùng tìm kiếm sản phẩm với từ khóa “Birthday” kết hợp với bộ lọc cá nhân hóa.



Hình 4.5: Giao diện hiển thị kết quả tìm kiếm

```
=====
Bắt đầu query: 'Birthday' - User: AEAUNTQSGHIUYLI4LWNUDEYSCZAQ
-> Cá nhân hóa cho User: AEAUNTQSGHIUYLI4LWNUDEYSCZAQ
Đã tìm thấy 100 ứng viên.
--- Hoàn tất Reranking ---
🔍 RAG Wrapper: Đang xử lý cho User AEAUNTQSGHIUYLI4LWNUDEYSCZAQ...
-> Converting Item Metadata...
-> Calling Gemini API...
--- Starting RAG Pipeline (Multi-Item Mode) ---
Extracting metadata for Top 5 products...
Extracting purchase history for User AEAUNTQSGHIUYLI4LWNUDEYSCZAQ...
Prompt created. Calling Gemini API (JSON Mode)...
Here is the user's recent purchase history (most recent first):

- (Rated: 5/5) Amazon.com Gift Card in a Polka Dot Reveal (Classic Black Card Design)
- (Rated: 5/5) Amazon.com Gift Card in a Slider
- (Rated: 5/5) Amazon.com $25 Gift Card in a Black Gift Box (Classic Black Card Design)
- (Rated: 5/5) Sears Gift Card
- (Rated: 5/5) Regal Entertainment Gift Cards, Multipack of 3

--- RAG Complete ---
INFO: 127.0.0.1:63279 - "POST /search HTTP/1.1" 200 OK
```

Hình 4.6: Log xử lý thời gian thực tại Backend

Kết quả thử nghiệm cho thấy hệ thống hoạt động ổn định với thời gian phản hồi trung bình < 50ms cho mỗi truy vấn, đáp ứng tốt yêu cầu về trải nghiệm người dùng trong thương mại điện tử.

4.8 Kết luận chương

Chương này đã trình bày một quy trình thực nghiệm toàn diện nhằm đánh giá hiệu năng của mô hình *Two-Tower Multi-modal Recommendation System* trên tập dữ liệu Amazon Gift Cards. Thông qua chuỗi phân tích định lượng, định tính và kiểm thử hệ thống, chúng tôi đã làm sáng tỏ cơ chế hoạt động nội tại của mô hình và rút ra bốn kết luận trọng yếu.

Đầu tiên và quan trọng nhất, nghiên cứu đã **giải quyết triệt để thách thức về dữ liệu thừa**. Trong bối cảnh độ thừa dữ liệu lên tới 99.8% khiến các phương pháp lọc cộng tác truyền thống gần như bị vô hiệu hóa, kiến trúc đề xuất vẫn đạt được độ phủ Recall@10 ấn tượng ở mức **99.23%**. Thành công này là minh chứng thực tiễn khẳng định hướng tiếp cận *Content-based Representation Learning*: thay vì phụ thuộc vào sự trùng lặp tương tác người dùng vốn rất khan hiếm, mô hình đã học cách thiết lập liên kết sâu sắc giữa nhu cầu người dùng và các đặc trưng nội dung, từ đó đưa ra dự đoán chính xác ngay cả trong điều kiện thiếu hụt thông tin hành vi.

Thứ hai, kết quả thực nghiệm làm nổi bật vai trò **Thị giác chủ đạo** đặc thù của miền dữ liệu Gift Cards. Các phân tích Ablation chỉ ra rằng chế độ Image-Only đạt độ chính xác tiệm cận tuyệt đối ($> 99.9\%$), chứng minh rằng đối với các sản phẩm mang tính biểu tượng như thẻ quà tặng, thiết kế đồ họa chứa đựng lượng thông tin định danh vượt trội so với văn bản. Mặc dù vậy, việc duy trì cơ chế **Fusion Gate** vẫn được xác định là thiết yếu. Nó đóng vai trò như một lớp lưới an toàn, đảm bảo tính cường tráng cho hệ thống trước các rủi ro kỹ thuật về mất mát dữ liệu hình ảnh trong môi trường thực tế.

Cuối cùng, tính hiệu quả của mô hình được củng cố thông qua việc **tối ưu hóa chiến lược lai** và kiểm chứng **khả năng triển khai thực tế**. Sự kết hợp trọng số giữa Tìm kiếm ($\alpha = 0.7$) và Cá nhân hóa ($\beta = 0.3$) cùng việc mở rộng không gian ứng viên ($k = 100$) đã giải quyết thành công bài toán Nhập hàng từ khóa, cho phép thuật toán Reranking Resurrect các sản phẩm phù hợp sở thích nhưng có điểm khớp từ khóa thấp. Đồng thời, hệ thống Demo tích hợp FastAPI và ReactJS đã chứng minh tính khả thi với độ trễ suy luận cực thấp ($< 50\text{ms}$) nhờ chiến lược tính toán trước, kết hợp với thuật toán Weighted Rating để xử lý trơn tru vấn đề *Cold Start*.

Tóm lại, các kết quả thu được đã xác nhận tính đúng đắn của giả thuyết nghiên cứu, tạo cơ sở vững chắc để phát triển các tính năng gợi ý nâng cao trong môi trường thương mại điện tử quy mô lớn.

Chương 5

Hướng phát triển

5.1 Hoàn thiện hệ thống

Mặc dù hệ thống hiện tại đã chứng minh được tính hiệu quả của thuật toán gợi ý đa phương thức, việc chuyển đổi từ một mô hình thử nghiệm sang một ứng dụng thương mại quy mô lớn đòi hỏi những nâng cấp đáng kể về mặt kiến trúc phần mềm và cơ sở dữ liệu. Dưới đây là lộ trình phát triển kỹ thuật được đề xuất cho giai đoạn tiếp theo:

5.1.1 Hiện đại hóa Kiến trúc dữ liệu

Trong khuôn khổ đề án, dữ liệu đang được lưu trữ dưới dạng tập tin tĩnh JSONL, điều này hạn chế khả năng cập nhật thời gian thực. Để khắc phục hạn chế của việc lưu trữ file tĩnh, hướng phát triển ưu tiên là xây dựng một hệ sinh thái dữ liệu phân tầng bao gồm ba thành phần cốt lõi:

Đầu tiên, **Cơ sở dữ liệu Người dùng**: Sử dụng RDBMS (như **PostgreSQL**) để quản lý thông tin định danh, tài khoản đăng nhập và hồ sơ cá nhân. Đây là nơi đảm bảo tính bảo mật và toàn vẹn dữ liệu người dùng.

Thứ hai, **Cơ sở dữ liệu Sản phẩm**: Lưu trữ các thông tin hiển thị như tên sản phẩm, giá bán, hình ảnh và mô tả chi tiết. Phần này có thể sử dụng RDBMS hoặc NoSQL (như **MongoDB**) để linh hoạt trong việc mở rộng các trường thông tin sản phẩm mới.

Cuối cùng, **Cơ sở dữ liệu Vector**: Đây là trái tim của hệ thống gợi ý. Các vector đặc trưng của cả User (v_{user}) và Item (v_{item}) sau khi huấn luyện sẽ được đẩy vào các hệ quản trị chuyên dụng như **Milvus** hoặc **Qdrant**. Kiến trúc này cho phép thực hiện truy vấn tìm kiếm tương đồng giữa User và Item với tốc độ cực nhanh trên quy mô lớn.

5.1.2 Tối ưu hóa Backend và Cơ chế suy luận

Để đáp ứng lưu lượng truy cập lớn, kiến trúc Backend cần chuyển dịch từ mô hình nguyên khối Monolithic sang kiến trúc **Microservices**. Module Gợi ý sẽ được tách thành một service độc lập, giao tiếp với Frontend thông qua gRPC để giảm độ trễ. Một chiến lược quan trọng khác là triển khai cơ chế **Caching đa tầng**. Sử dụng **Redis** để lưu trữ các danh sách gợi ý phổ biến hoặc các kết quả tính toán trước cho những người dùng thường xuyên truy cập. Điều này giúp giảm tải đáng kể cho User Tower, cho phép hệ thống chỉ kích hoạt suy luận sâu khi gặp các ngữ cảnh phức tạp hoặc người dùng mới. Ngoài ra, việc xây

dựng một đường ống dữ liệu thời gian thực sử dụng **Apache Kafka** là cần thiết để ghi nhận hành vi click/view của người dùng và cập nhật sở thích vào User Tower ngay lập tức.

5.1.3 Nâng cao trải nghiệm người dùng

Về phía giao diện người dùng, trọng tâm phát triển sẽ là tối ưu hóa trải nghiệm tương tác với danh sách gợi ý. Ứng dụng Frontend ReactJS cần tích hợp kỹ thuật **Virtualization** để hiển thị mượt mà hàng nghìn sản phẩm mà không gây treo trình duyệt. Để giảm thiểu cảm giác chờ đợi khi mô hình đang tính toán, các kỹ thuật như **Skeleton Loading** và **Optimistic UI** cần được áp dụng. Đặc biệt, giao diện cần bổ sung tính năng “Giải thích gợi ý” - hiển thị lý do tại sao sản phẩm được đề xuất (ví dụ: “*Vì bạn đã xem thiệp Giáng sinh*”). Tính năng này không chỉ tận dụng khả năng của module RAG đã xây dựng mà còn giúp tăng niềm tin và tỷ lệ chuyển đổi của người dùng. Cuối cùng, một hệ thống **A/B Testing** cần được tích hợp ngay trên Frontend để liên tục đo lường hiệu quả thực tế của các thuật toán gợi ý khác nhau dựa trên hành vi người dùng thật.

5.2 Bổ sung cơ chế Reranking

Trong khuôn khổ hiện tại của dự án, hệ thống gợi ý đã được hiện thực hóa dựa trên kiến trúc Bi-Encoder (Two-Tower Architecture). Mô hình này, thông qua việc mã hóa độc lập truy vấn người dùng và thông tin sản phẩm vào cùng một không gian vector, đã giải quyết hiệu quả bài toán Retrieval trên quy mô dữ liệu lớn với độ trễ thấp.

Tuy nhiên, kiến trúc này tồn tại những hạn chế cốt lõi về khả năng thấu hiểu ngữ nghĩa sâu. Thứ nhất là hiện tượng “representation bottleneck”, nơi toàn bộ thông tin phức tạp bị nén vào một vector cố định. Thứ hai, và quan trọng hơn, là vấn đề thiếu sự tương tác sớm. Do thông tin truy vấn và sản phẩm được đưa vào hai mạng nơ-ron riêng biệt và chỉ gặp nhau ở bước cuối cùng (tính tích vô hướng), mô hình không thể học được các mối liên kết chi tiết giữa từng từ khóa trong truy vấn với từng đặc điểm cụ thể của sản phẩm (ví dụ: sự khớp nhau giữa một tính từ mô tả nhu cầu và một thông số kỹ thuật). Điều này dẫn đến việc Bi-Encoder thường hoạt động tốt ở mức độ chủ đề nhưng thiếu độ chính xác khi cần phân biệt các sản phẩm có độ tương đồng cao.

Để khắc phục hạn chế trên và tối ưu hóa trải nghiệm người dùng, hướng phát triển trọng tâm của đề tài là xây dựng và tích hợp một giai đoạn thứ hai vào quy trình gợi ý: giai đoạn **Reranking**. Hệ thống sẽ chuyển đổi sang kiến trúc “Retrieve-and-Rerank”, trong đó Bi-Encoder đóng vai trò bộ lọc sơ cấp để thu hẹp không gian tìm kiếm, và Cross-Encoder đóng vai trò bộ lọc thứ cấp để phân tích kỹ lưỡng các ứng viên tiềm năng.


Về mặt hiện thực, module Reranking sẽ được phát triển dựa trên việc tinh chỉnh (fine-tune) mô hình nền tảng cross-encoder/ms-marco-MiniLM-L6-v2. Mặc dù mô hình này đã có khả năng xếp hạng văn bản tốt, nhưng do được huấn luyện trên dữ liệu tìm kiếm web chung (Bing Search), nó cần được điều chỉnh / fine-tune với miền thương mại điện tử. Quá trình fine-tune sẽ sử dụng bộ dữ liệu hành vi thực tế **ESCI** kết hợp với dữ liệu được sinh bởi AI (AI-Generated Data) nhằm giúp mô hình học được các thuật ngữ chuyên ngành, mã sản phẩm và nắm bắt được ý định tìm kiếm phức tạp của người dùng Amazon.

5.2.1 Cơ sở lý thuyết về Cross-Encoder

Phần này trình bày các nền tảng lý thuyết về kiến trúc Cross-Encoder, cơ chế hoạt động của mạng nơ-ron trong việc xử lý cặp câu, và phân tích sự đánh đổi giữa hiệu năng và chi phí tính toán so với kiến trúc Bi-Encoder truyền thống.

5.2.1.1 Kiến trúc và Cơ chế hoạt động

Cross-Encoder là một kiến trúc mạng nơ-ron sâu dựa trên mô hình Transformer, được thiết kế để xử lý đồng thời hai chuỗi văn bản đầu vào nhằm mô hình hóa mối quan hệ ngữ nghĩa giữa chúng [41]. Để hình dung rõ hơn về luồng dữ liệu trong mô hình, hãy xem xét sơ đồ kiến trúc dưới đây:



Hình 5.1: Sơ đồ kiến trúc Cross-Encoder với đầu vào ghép đôi và đầu ra phân loại

Quan sát Hình 5.1, ta có thể phân tích cơ chế hoạt động qua ba giai đoạn chính:

1. Tầng Đầu vào (Input Layer):

Khác với Bi-Encoder xử lý hai nhánh độc lập, hình vẽ cho thấy Sentence A (đại diện cho truy vấn q) và Sentence B (đại diện cho văn bản ứng viên d) được đưa vào cùng một khối xử lý. Trong thực tế, hai chuỗi này được nối lại (concatenated) thành một chuỗi duy nhất, bắt đầu bằng token đặc biệt [CLS] và ngăn cách bởi [SEP]:

$$Input = [CLS] \oplus q \oplus [SEP] \oplus d \oplus [SEP] \quad (5.1)$$

2. Khối xử lý trung tâm (BERT):

Khối “BERT” trong sơ đồ đại diện cho các lớp Encoder của Transformer. Tại đây diễn ra cơ chế **Full Self-Attention** (tương tác sớm). Mỗi token trong Sentence A được phép nhìn thấy và tính toán trọng số chú ý với toàn bộ token trong Sentence B ngay từ những lớp đầu tiên. Điều này giúp mô hình nắm bắt được các sắc thái ngữ nghĩa phức tạp mà phương pháp so sánh vector độc lập thường bỏ sót.


3. Tầng Phân loại (Classifier Head):

Đầu ra của khối BERT là một chuỗi các vector ngữ cảnh, nhưng Cross-Encoder chỉ sử dụng vector tại vị trí [CLS] (h_{CLS}) để làm đại diện cho cả cặp câu. Như minh họa ở phần trên cùng của hình vẽ, vector này được đưa qua khối **Classifier** (thường là một lớp tuyến tính Linear Layer). Cuối cùng, hàm kích hoạt sẽ chuyển đổi kết quả thành một điểm số

thực trong khoảng $0 \dots 1$. Giá trị này chính là xác suất phù hợp $P(y = 1 | q, d)$, dùng để xếp hạng lại (Reranking).

5.2.1.2 So sánh hiệu năng với Bi-Encoder

Việc lựa chọn giữa Cross-Encoder và Bi-Encoder luôn đòi hỏi sự cân nhắc kỹ lưỡng về sự đánh đổi giữa độ chính xác và hiệu suất tính toán. Để làm rõ sự khác biệt về mặt cấu trúc dẫn đến sự đánh đổi này, hãy quan sát sơ đồ so sánh dưới đây:



Hình 5.2: Sơ đồ so sánh kiến trúc giữa Bi-Encoder (trái) và Cross-Encoder (phải)

Quan sát Hình 5.2, ta thấy sự đối lập rõ rệt trong luồng xử lý dữ liệu:

1. Về mặt Độ chính xác (Accuracy):

Mô hình **Cross-Encoder** (bên phải hình vẽ) thể hiện sự vượt trội. Nhờ kiến trúc hợp nhất, cả hai câu (Sentence A và B) được đưa vào cùng một khối BERT ngay từ đầu. Điều này cho phép cơ chế Full Self-Attention hoạt động trên toàn bộ cặp câu, nắm bắt được các phụ thuộc phi tuyến tính phức tạp (non-linear dependencies). Đầu ra đi qua lớp *Classifier* để trả về điểm số xác suất chính xác từ $0 \dots 1$.

Ngược lại, **Bi-Encoder** (bên trái hình vẽ) bị giới hạn bởi cấu trúc song song. Hai luồng thông tin Sentence A và Sentence B đi qua hai tháp BERT riêng biệt để tạo ra vector u và v . Sự tương tác chỉ xảy ra ở bước cuối cùng thông qua hàm *Cosine-Similarity*. Do thiếu sự tương tác sớm, Bi-Encoder thường gặp khó khăn trong các trường hợp đòi hỏi thấu hiểu ngữ nghĩa sâu hoặc khi truy vấn và văn bản có ít từ khóa chung.

2. Về mặt Hiệu suất tính toán (Computational Efficiency):

Tuy nhiên, cấu trúc tách biệt của **Bi-Encoder** lại mang đến lợi thế to lớn về tốc độ. Vì vector v (đại diện cho sản phẩm) không phụ thuộc vào vector u (truy vấn), chúng có thể được tính toán trước (pre-computed) và lưu trữ. Khi có truy vấn mới, hệ thống chỉ cần tính vector u một lần và thực hiện tìm kiếm tương đồng (Approximate Nearest Neighbor Search) với chi phí rất thấp.

Trong khi đó, **Cross-Encoder** không thể mở rộng cho tác vụ tìm kiếm quy mô lớn. Do phải ghép nối truy vấn mới với từng văn bản trong cơ sở dữ liệu để đưa vào mạng Transformer đồ sộ, việc áp dụng trực tiếp là bất khả thi trong thời gian thực. Vì vậy, trong thực tế, Cross-Encoder chỉ được sử dụng tối ưu trong giai đoạn Reranking trên một tập


ứng viên nhỏ (ví dụ: 50 – 100 items) đã được lọc sơ bộ bởi Bi-Encoder.

5.2.2 Phương pháp đề xuất và Kiến trúc hệ thống

Dựa trên các phân tích về hạn chế của mô hình đơn lẻ, dự án đề xuất triển khai chiến lược **Truy xuất và Xếp hạng lại (Retrieve-and-Rerank)**. Chiến lược này tận dụng sức mạnh bổ trợ của hai phương pháp mã hóa văn bản khác nhau nhằm đạt được sự cân bằng tối ưu giữa khả năng mở rộng trên dữ liệu lớn và độ chính xác trong thấu hiểu ngữ nghĩa.

5.2.2.1 Quy trình Truy xuất hai giai đoạn (Two-Stage Retrieval Pipeline)

Để giải quyết bài toán gợi ý sản phẩm với độ chính xác cao trên không gian dữ liệu lớn, hệ thống được thiết kế theo quy trình truy xuất hai giai đoạn (Retrieve-and-Rerank), hoạt động như một bộ lọc phễu từ thô đến tinh. Để hình dung rõ luồng dữ liệu và sự thay đổi về kích thước tập ứng viên qua từng bước, hãy xem xét sơ đồ quy trình dưới đây:



Hình 5.3: Sơ đồ quy trình phễu lọc hai giai đoạn: Từ hàng triệu sản phẩm xuống Top 10

Quan sát Hình 5.3, quy trình xử lý được chia thành hai pha riêng biệt với đặc thù trái ngược nhau về chi phí tính toán và độ chính xác:

- Giai đoạn Sàng lọc thô (Retriever - Bi-Encoder):** Tại bước này (khối màu xanh dương), hệ thống quét nhanh qua toàn bộ cơ sở dữ liệu chứa hàng triệu sản phẩm. Mục tiêu là tốc độ. Đầu ra là tập hợp $K = 100$ ứng viên tiềm năng nhất (khối màu vàng).
- Giai đoạn Sàng lọc tinh (Reranker - Cross-Encoder):** Tập hợp 100 ứng viên được chuyển tiếp sang mô hình Cross-Encoder (khối màu đỏ). Tại đây, mô hình thực hiện phân tích ngữ cảnh sâu (Deep Analysis). Kết quả cuối cùng là Top 10 sản phẩm tối ưu nhất (khối màu xanh lá) được trả về cho người dùng.

Trong dự án này, mô hình cross-encoder/ms-marco-MiniLM-L6-v2 được lựa chọn làm mô hình cơ sở (base model) để tinh chỉnh (fine-tune) trên miền dữ liệu thương mại điện tử. Để mô hình có thể xử lý đồng thời thông tin người dùng và sản phẩm, dữ liệu đầu vào được cấu trúc lại thành một chuỗi token nối tiếp theo định dạng chuẩn của Transformer:

$$[\text{CLS}] \text{ Context } [\text{SEP}] \text{ Candidate } [\text{SEP}] \quad (5.2)$$

Trong cấu trúc trên, thành phần **Context** được xây dựng từ sự kết hợp giữa lịch sử tương tác và truy vấn hiện tại, giúp mô hình đối chiếu nhu cầu tìm kiếm với sở thích cá nhân. Ngay sau token ngăn cách là thành phần **Candidate**, bao gồm tiêu đề và mô tả sản phẩm, cung cấp ngữ cảnh chi tiết để mô hình đánh giá độ tương quan ngữ nghĩa.

Quá trình tính toán kết quả cuối cùng được thực hiện tại lớp đầu ra của mạng nơ-ron. Cụ thể, vector đại diện tại vị trí [CLS] (h_{CLS}) được đưa qua một lớp tuyến tính (Linear Layer) để chiếu về một giá trị thực (logit). Giá trị này sau đó được chuyển đổi thành xác suất $P(y = 1 | \text{Context}, \text{Candidate})$, đại diện cho mức độ phù hợp dùng để xếp hạng sản phẩm.

5.2.2.2 Lựa chọn Mô hình cơ sở: cross-encoder/ms-marco-MiniLM-L6-v2


Để giải quyết bài toán mâu thuẫn giữa độ chính xác cao và thời gian phản hồi thấp trong hệ thống gợi ý thời gian thực, báo cáo này lựa chọn mô hình cross-encoder/ms-marco-MiniLM-L6-v2. Đây là một phiên bản mô hình ngôn ngữ được nén (compressed) từ kiến trúc BERT khổng lồ. Để hiểu rõ cơ sở khoa học của sự lựa chọn này, cần xem xét kỹ thuật nền tảng là Truyền tri thức (Knowledge Distillation) và kiến trúc đặc thù của MiniLM.

5.2.2.2.1 Tổng quan về Knowledge Distillation (KD)

Trong những năm gần đây, sự bùng nổ của các Mô hình Ngôn ngữ Tiên huấn luyện (Pre-trained Language Models - PLMs) như BERT, RoBERTa hay XLNet đã tạo ra những bước đột phá trong xử lý ngôn ngữ tự nhiên. Tuy nhiên, đi kèm với hiệu suất cao là kích thước khổng lồ với hàng trăm triệu tham số. Điều này đặt ra rào cản lớn về tài nguyên tính toán và độ trễ (latency) khi triển khai trên các hệ thống thực tế hoặc thiết bị biên (edge devices).

Để giải quyết bài toán cân bằng giữa hiệu suất và tài nguyên, kỹ thuật **Truyền tri thức (Knowledge Distillation - KD)** được áp dụng như một giải pháp nén mô hình hiệu quả. Về bản chất, KD là quá trình chuyển giao khả năng khái quát hóa từ một mô hình lớn, phức tạp (Teacher) sang một mô hình nhỏ gọn hơn (Student) mà không làm giảm đáng kể độ chính xác.

Để hiểu rõ cơ chế hoạt động bên trong, hãy xem xét sơ đồ quy trình KD dưới đây:



Hình 5.4: Sơ đồ quy trình Knowledge Distillation: Mô hình Student học cách mô phỏng phân phối xác suất (Logits) của Teacher.

Quan sát Hình 5.4, quy trình truyền tri thức bắt đầu bằng việc đưa dữ liệu đầu vào (khối **Data** màu xám) đồng thời vào hai luồng xử lý song song. Nhánh phía trên là mô hình **Teacher** (khối màu đỏ) với đặc điểm kích thước lớn và đã hội tụ, đóng vai trò nguồn tri thức chuẩn nên các trọng số thường được đóng băng để đảm bảo tính ổn định. Nhánh phía dưới là mô hình **Student** (khối màu xanh), đối tượng chính cần huấn luyện với kiến trúc được thiết kế nhỏ gọn hơn nhằm tối ưu hóa tài nguyên và tốc độ suy diễn.

Điểm cốt lõi của phương pháp này nằm ở việc khai thác thông tin từ các khối **Logit** (màu vàng). Thay vì chỉ dựa vào nhãn cứng (Hard Labels) vốn chỉ cung cấp đáp án đúng sai

tuyệt đối, mô hình Student học từ phân phối xác suất đầu ra của Teacher. Các giá trị Logit này chứa đựng **Tri thức tiềm ẩn (Latent Knowledge)**—những thông tin ẩn về mối quan hệ ngữ nghĩa giữa các lớp mà nhãn cứng không thể thể hiện. Ví dụ, thông qua Logit, Teacher có thể chỉ ra rằng một đối tượng “con chó” có nét tương đồng về mặt đặc trưng với “con mèo” nhiều hơn là “xe hơi”. Việc nắm bắt được các sắc thái tinh tế này giúp Student hình thành tư duy tổng quát hóa tốt hơn thay vì chỉ học thuộc lòng đáp án.

Cuối cùng, kết quả dự đoán của hai mô hình được đưa vào khối **Distillation Loss** (màu xanh lá) để so khớp. Đây là thành phần quan trọng nhất dùng để định hướng quá trình học, có nhiệm vụ đo lường khoảng cách giữa phân phối xác suất của Teacher và Student. Mục tiêu của quá trình huấn luyện là cực tiểu hóa sự khác biệt này, ép buộc Student phải mô phỏng lại “cách tư duy” của Teacher. Trong thực tế, hàm mất mát tổng thể thường là sự kết hợp có trọng số giữa hàm mất mát chứng cất (học theo Teacher) và hàm mất mát của tác vụ chính (học theo nhãn thực tế), giúp cân bằng giữa khả năng bắt chước và độ chính xác trên tập dữ liệu.

5.2.2.2.2 Phân tích chuyên sâu về MiniLM và Ứng dụng trong Dự án

Mặc dù phương pháp Knowledge Distillation truyền thống đã chứng minh được hiệu quả, nhưng việc áp dụng trực tiếp vào các mô hình Transformer phức tạp vẫn gặp nhiều hạn chế, đặc biệt là sự ràng buộc về kích thước chiều ẩn (Hidden Dimension) giữa Teacher và Student. Để khắc phục vấn đề này và tối ưu hóa sâu hơn vào cơ chế cốt lõi của Transformer, Wang *et al.*[32] đã đề xuất kiến trúc **MiniLM** (Miniature Language Model).

Khác với các phương pháp nén mô hình thông thường chỉ tập trung vào lớp đầu ra (Output Layer), MiniLM là phương pháp nén không phụ thuộc vào tác vụ (Task-Agnostic), đi sâu vào việc chứng cất thành phần quan trọng nhất tạo nên sức mạnh của Transformer: cơ chế **Self-Attention**.

1. Đặt vấn đề và Kiến thức cơ sở (Preliminary)

Mạng Transformer được xây dựng dựa trên cơ chế Multi-Head Self-Attention. Trong một lớp Transformer, giả sử đầu vào là chuỗi vector X , Multi-Head Self-Attention bao gồm H đầu chú ý. Tại mỗi đầu h , đầu vào được chiếu qua các ma trận trọng số W_Q, W_K, W_V để tạo ra các vector Query (Q_h), Key (K_h) và Value (V_h). Công thức tính toán Standard Attention tại đầu h được định nghĩa [41]:

$$\text{Attention}_h(Q, K, V) = \text{Softmax} \left(\frac{Q_h K_h^T}{\sqrt{d_k}} \right) V_h \quad (5.3)$$


Trong đó d_k là kích thước chiều của vector key.

Giải thích các tham số:

- Q_h, K_h, V_h : Lần lượt là các ma trận Query (Truy vấn), Key (Khóa) và Value (Giá trị) tại đầu chú ý thứ h .
- K_h^T : Ma trận chuyển vị của K_h , dùng để tính tích vô hướng (độ tương đồng) với Q_h .
- d_k : Kích thước chiều (dimension size) của vector Key.
- $\sqrt{d_k}$: Hệ số tỷ lệ (scaling factor) giúp ổn định giá trị tích vô hướng trước khi đưa vào hàm Softmax.

2. Phương pháp Chưng cất Sự chú ý Sâu (Deep Self-Attention Distillation)

MiniLM tập trung chuyển giao tri thức tại **lớp Transformer cuối cùng**, nơi chứa đựng những đặc trưng ngữ nghĩa tinh túy nhất. Quá trình này dựa trên hai thành phần cốt lõi được trình bày tại hình 5.5:



Hình 5.5: Tổng quan kiến trúc Deep Self-Attention Distillation của MiniLM.

Thành phần A: Phân phối Sự chú ý (Self-Attention Distributions).

Ma trận chú ý A_h biểu diễn mối quan hệ phụ thuộc giữa các từ, được tính như sau [32]:

$$A_h = \text{Softmax} \left(\frac{Q_h K_h^T}{\sqrt{d_k}} \right) \quad (5.4)$$

Hàm mất mát Kullback-Leibler (KL-Divergence) được sử dụng để giảm thiểu sự khác biệt giữa Teacher (T) và Student (S):

$$\mathcal{L}_{AT} = \frac{1}{H} \sum_{h=1}^H D_{KL}(A_h^T || A_h^S) \quad (5.5)$$

Thành phần B: Quan hệ Giá trị (Self-Attention Value Relations).

Đây là đóng góp đột phá của MiniLM, sử dụng quan hệ giữa các vector Value ($V - V$) thay vì $Q - K$:

$$VR_h = \text{Softmax} \left(\frac{V_h V_h^T}{\sqrt{d_k}} \right) \quad (5.6)$$

Hàm mất mát tương ứng cho thành phần này là [32]:

$$\mathcal{L}_{VR} = \frac{1}{H} \sum_{h=1}^H D_{KL}(VR_h^T || VR_h^S) \quad (5.7)$$

Giải thích ký hiệu:

- A_h^T, A_h^S : Phân phối chú ý của mô hình Teacher và Student.
- VR_h^T, VR_h^S : Quan hệ giá trị của mô hình Teacher và Student.

- D_{KL} : Độ phân kỳ Kullback-Leibler, đo lường sự khác biệt giữa hai phân phối xác suất.
- H : Tổng số lượng đầu chú ý (Attention Heads).

3. Cơ sở lựa chọn phiên bản MiniLM-L6-v2 cho dự án

Từ nền tảng lý thuyết vững chắc về cơ chế truyền tri thức kép nêu trên, phiên bản cụ thể MiniLM-L6-v2 đã được lựa chọn để triển khai module Reranking cho hệ thống. Quyết định này dựa trên sự cân bằng tối ưu giữa hiệu quả kiến trúc, tốc độ và chất lượng. Cụ thể, với cấu hình thu nhỏ gồm 6 lớp (L6) và chiều ẩn 384, mô hình đã loại bỏ hoàn toàn sự dư thừa tham số thường thấy ở các kiến trúc lớn như BERT-Base, trong khi vẫn duy trì được khả năng suy luận ngữ nghĩa phức tạp nhờ thừa hưởng trọn vẹn Quan hệ Giá trị từ Teacher. Hơn nữa, kết quả thực nghiệm chứng minh MiniLM-L6-v2 đạt tốc độ suy diễn (Inference) nhanh hơn gấp 2 lần so với BERT-Base. Đây là yếu tố tiên quyết đối với bài toán Reranking, giúp giữ độ trễ hệ thống ở mức thấp nhất (low latency) để đảm bảo trải nghiệm người dùng. Mặc dù kích thước giảm đi đáng kể, mô hình vẫn bảo toàn được hơn 90% độ chính xác so với mô hình gốc trên các bảng xếp hạng chuẩn (Benchmarks), qua đó đảm bảo danh sách gợi ý cuối cùng luôn đạt độ tương quan cao nhất.

5.2.2.2.3 Bộ dữ liệu Tiền huấn luyện: MS MARCO (Passage Ranking)

Mô hình cross-encoder/ms-marco-MiniLM-L6-v2 được lựa chọn làm cơ sở cho dự án nhờ vào quá trình tiền huấn luyện (pre-training) bài bản trên bộ dữ liệu **MS MARCO** (Microsoft Machine Reading Comprehension). Theo công bố khoa học của Nguyen *et al.*[42], đây là nền tảng quan trọng giúp mô hình học được các đặc trưng ngôn ngữ tự nhiên và logic xếp hạng thông tin từ quy mô dữ liệu lớn trước khi được tinh chỉnh cho các tác vụ cụ thể.

Điểm làm nên hiệu suất vượt trội của phiên bản mô hình này nằm ở chiến lược dữ liệu được cộng đồng *Sentence-Transformers* áp dụng. Cụ thể, trong quá trình phát triển mô hình gốc, thay vì sử dụng dữ liệu thô ban đầu từ Microsoft, các tác giả đã lựa chọn phiên bản tối ưu hóa có tích hợp kỹ thuật **Hard Negatives mining**

. Kỹ thuật này tạo ra các bộ ba (Triplets) bao gồm Truy vấn, Mẫu dương và Mẫu âm, thay vì ghép cặp ngẫu nhiên. Về mặt quy mô, tập dữ liệu này bao gồm hơn 1.000.000 truy vấn thực tế từ Bing và hơn 8.800.000 đoạn văn bản, tất cả đều được gán nhãn thủ công với độ tin cậy cao.

Chính cấu trúc dữ liệu dạng Triplet này đã định hình khả năng hiểu ngữ nghĩa của mô hình trước khi được đưa vào áp dụng trong dự án. Bảng 5.1 dưới đây minh họa mẫu dữ liệu mà mô hình đã được học, trong đó Hard Negative tuy chứa nhiều từ khóa trùng khớp (lexical overlap) nhưng sai lệch hoàn toàn về ngữ nghĩa hoặc đối tượng.

Thành phần	Nội dung văn bản	Phân tích ngữ nghĩa
Query	“ <i>symptoms of heat exhaustion</i> ” (Triệu chứng kiệt sức do nhiệt)	Truy vấn tìm kiếm thông tin y tế cho người.
Positive	“ <i>Symptoms of heat exhaustion include heavy sweating, rapid pulse...</i> ”	Đoạn văn chứa câu trả lời chính xác, khớp ý định.
Negative	“ <i>Heat exhaustion is a condition whose symptoms... in dogs.</i> ”	Hard Negative: Rất giống query nhưng nói về chó (dogs) thay vì người.

Bảng 5.1: Ví dụ mẫu dữ liệu Triplet trong MS MARCO với Hard Negative

Việc lựa chọn MS MARCO làm tiêu chuẩn vàng (Gold Standard) cho tác vụ này xuất phát từ ba đặc điểm ưu việt. Đầu tiên là tính chất thực tế (Real-world Distribution), nơi các truy vấn phản ánh đúng ngôn ngữ tự nhiên của người dùng bao gồm cả từ lóng hay lỗi chính tả, giúp mô hình bền vững hơn khi triển khai thực tế. Thứ hai là sự đa dạng về chủ đề (Topic Diversity) bao phủ từ y tế, công nghệ đến đời sống, giúp mô hình có khả năng khái quát hóa tốt. Cuối cùng và quan trọng nhất là khả năng chuyển giao (Transferability); nhờ lượng tri thức nền khổng lồ này, mô hình có thể dễ dàng thích nghi và tinh chỉnh (fine-tune) hiệu quả khi chuyển sang miền dữ liệu thương mại điện tử của Amazon.

5.2.2.2.4 Đặc tả Mô hình Cross-Encoder: cross-encoder/ms-marco-MiniLM-L6-v2

Sau khi xác lập kiến trúc nền tảng là MiniLM và bộ dữ liệu nguồn là MS MARCO, dự án lựa chọn phiên bản cụ thể cross-encoder/ms-marco-MiniLM-L6-v2¹ làm điểm khởi đầu (checkpoint) cho quá trình huấn luyện. Đây không phải là một mô hình được khởi tạo ngẫu nhiên, mà là kết quả của một **quy trình huấn luyện kế thừa (Multi-stage Training Pipeline)** được thực hiện bài bản qua nhiều giai đoạn.

1. Nguồn gốc và Quy trình hình thành

Quá trình phát triển mô hình (hình 5.6) bắt đầu từ kiến trúc *MiniLM* gốc của Microsoft, được nén từ BERT để học các biểu diễn ngôn ngữ chung (General Language Understanding). Ở giai đoạn thích nghi (Adaptation), mô hình được chuyển đổi sang định dạng tương thích với thư viện *Sentence-Transformers* (phiên bản nreimers/MiniLM-L6-H384-uncased). Tuy nhiên, bước ngoặt quyết định nằm ở giai đoạn tinh chỉnh (Fine-tuning), nơi mô hình được huấn luyện chuyên sâu trên tập dữ liệu **MS MARCO Passage Ranking**. Mục tiêu của giai đoạn này là trang bị cho mô hình kỹ năng xếp hạng và phân biệt đoạn văn phù hợp với câu hỏi, chuyển hóa từ một mô hình ngôn ngữ chung thành một Cross-Encoder chuyên dụng. Cuối cùng, để tối ưu hóa cho môi trường thực tế, các trọng số đã được Quantized nhằm giảm kích thước và tăng tốc độ suy diễn.

¹Link mô hình: <https://huggingface.co/cross-encoder/ms-marco-MiniLM-L6-v2>



Hình 5.6: Quy trình phát triển mô hình: Từ kiến trúc MiniLM gốc, qua bước tinh chỉnh (Fine-tuning) trên dữ liệu MS MARCO để tạo thành Cross-Encoder hoàn chỉnh.

2. Thông số kỹ thuật và Kiến trúc mạng

Về mặt đặc tả kỹ thuật, mô hình sở hữu cấu trúc gọn nhẹ với **6 lớp Transformer (Layers)**, chiều ẩn (Hidden size) 384 và 12 Attention Head, tổng hợp thành khoảng **22.7 triệu tham số**. Khác với các mô hình BERT tiêu chuẩn (thường có hơn 110 triệu tham số), kích thước này cho phép triển khai hiệu quả trên các hệ thống có tài nguyên hạn chế.

Dữ liệu đầu vào của mô hình được xử lý theo cơ chế nối tiếp cặp văn bản: [CLS] Query [SEP] Passage [SEP], với tổng độ dài tối đa cho phép là **512 tokens**. Tại đầu ra, một lớp tuyến tính (Linear Layer) được gắn trực tiếp trên token [CLS] để thực hiện nhiệm vụ hồi quy, dự đoán điểm số logit $s \in (-\infty, +\infty)$ biểu thị mức độ phù hợp ngữ nghĩa giữa truy vấn và văn bản.

5.2.2.3 Chiến lược Tinh chỉnh mô hình (Fine-tuning Strategy)

Mặc dù mô hình nền tảng cross-encoder/ms-marco-MiniLM-L6-v2 đã sở hữu năng lực xếp hạng văn bản ấn tượng nhờ quá trình tiền huấn luyện trên dữ liệu MS MARCO, việc áp dụng trực tiếp mô hình này vào bài toán thương mại điện tử gặp phải thách thức lớn về sự **sai lệch miền dữ liệu (Domain Shift)**.

Dữ liệu MS MARCO chủ yếu là các câu hỏi tìm kiếm thông tin chung (General Web Search), trong khi truy vấn trên Amazon mang tính chất giao dịch (Transactional Queries), chứa đựng nhiều mã định danh sản phẩm (ASIN), tên thương hiệu cụ thể và các từ khóa đặc thù ngành hàng (như “OLED”, “noise-cancelling”). Hơn nữa, hành vi tìm kiếm của người dùng thương mại điện tử đòi hỏi độ chính xác cực cao.

Do đó, dự án đề xuất chiến lược tinh chỉnh (Fine-tuning) dựa trên nguyên lý **Chuyển giao tri thức (Transfer Learning)**. Mục tiêu là chuyển đổi một mô hình xếp hạng văn bản phổ thông thành một chuyên gia xếp hạng sản phẩm. Quá trình này được thực hiện thông qua việc huấn luyện giám sát trên hai nguồn dữ liệu bổ trợ nhau: dữ liệu hành vi thực tế (ESCI) và dữ liệu tổng hợp từ AI [34].

5.2.2.3.1 Chuẩn bị dữ liệu huấn luyện

Chất lượng của mô hình Cross-Encoder phụ thuộc tiên quyết vào chất lượng của các cặp dữ liệu (Query, Product, Label). Để đạt được sự cân bằng giữa độ chính xác từ khóa và khả năng thấu hiểu ngôn ngữ tự nhiên, hệ thống dữ liệu huấn luyện được xây dựng từ hai nguồn chính.

1. Bộ dữ liệu ESCI (Amazon Shopping Queries)

Nguồn dữ liệu cốt lõi được sử dụng để tinh chỉnh mô hình là bộ dữ liệu **ESCI (Shopping Queries Dataset)**. Đây là tập dữ liệu quy mô lớn được công bố bởi nhóm nghiên cứu Amazon Science, được cộng đồng học thuật công nhận là tiêu chuẩn vàng để đánh giá các thuật toán tìm kiếm sản phẩm [33].

Điểm đặc biệt của bộ dữ liệu này nằm ở hệ thống nhãn đa cấp độ, được viết tắt là **ESCI**, mô tả chính xác sắc thái ngữ nghĩa giữa truy vấn của người dùng và sản phẩm trả về. Cụ thể, bốn mức độ tương quan được định nghĩa như sau:

- **Exact (E - Khớp hoàn toàn):** Sản phẩm đáp ứng chính xác nhu cầu của người dùng về mọi mặt như chức năng, thương hiệu và thông số kỹ thuật (Ví dụ: Tìm “iPhone 12” và kết quả là điện thoại iPhone 12).
- **Substitute (S - Thay thế):** Sản phẩm có chức năng tương đương nhưng khác biệt về một số đặc tính quan trọng như thương hiệu, màu sắc hoặc mẫu mã, mà người dùng có thể cân nhắc nếu sản phẩm chính hết hàng (Ví dụ: Tìm “giày chạy bộ Nike” nhưng kết quả là “giày Adidas”).
- **Complement (C - Bổ trợ):** Sản phẩm không thỏa mãn trực tiếp truy vấn nhưng thường được mua kèm hoặc hỗ trợ cho sản phẩm chính (Ví dụ: Tìm “iPhone 12” nhưng kết quả là “Ốp lưng” hoặc “Dây sạc”).
- **Irrelevant (I - Không liên quan):** Sản phẩm hoàn toàn không liên quan đến truy vấn.

Bảng 5.2: Ví dụ minh họa và chiến lược gán nhãn nhị phân cho ESCI

Truy vấn	Sản phẩm	Nhãn gốc	Chiến lược Cross-Encoder
iphone 12 case	OtterBox Commuter Case for iPhone 12	Exact	Positive (1): Khớp hoàn toàn ý định.
iphone 12 case	iPhone 12 64GB Black (Unlocked)	Irrelevant	Negative (0): Sai loại sản phẩm.
nike running shoes	Adidas Ultraboost 21 Men's Shoe	Substitute	Hard Negative (0): Sai thương hiệu dù cùng chức năng.
camera canon	SD Card 64GB	Complement	Hard Negative (0): Sản phẩm đi kèm, không phải sản phẩm chính.

Bảng 5.3: Ví dụ minh họa và chiến lược gán nhãn nhị phân cho ESCI

Vì Cross-Encoder trong dự án được thiết kế cho bài toán phân loại nhị phân (Binary Classification), hệ thống nhãn ESCI cần được quy hoạch lại một cách chiến lược. Theo đó, chỉ duy nhất nhãn **Exact** được coi là mẫu Dương (Label = 1). Tất cả các nhãn còn lại bao gồm Substitute, Complement và Irrelevant đều được gán là mẫu Âm (Label = 0).

Chiến lược gán nhãn này đóng vai trò quan trọng trong việc tạo ra (**Hard Negatives**). Đặc biệt, việc ép nhãn Substitute và Complement về 0 giúp mô hình học được sự phân biệt tinh tế: dù “Adidas” và “Nike” có sự tương đồng lớn về ngữ nghĩa vector (cùng là giày thể thao), nhưng trong ngữ cảnh tìm kiếm cụ thể, sự sai lệch về thương hiệu là không thể chấp nhận. Điều này giúp Cross-Encoder nắm bắt chặt chẽ các thực thể thương mại và ý định người dùng tốt hơn so với các phương pháp so khớp từ khóa thông thường.

2. Bộ dữ liệu Tổng hợp từ AI (Phương pháp BLAIR)

Một hạn chế lớn của bộ dữ liệu ESCI là các truy vấn thường ngắn, thiên về từ khóa và thiếu cấu trúc ngữ pháp hoàn chỉnh. Trong khi đó, xu hướng người dùng thực tế ngày càng sử dụng các câu hỏi dài, mô tả nhu cầu phức tạp hoặc tìm kiếm bằng ngôn ngữ tự nhiên. Để lấp đầy khoảng trống này, phương pháp tạo dữ liệu tổng hợp dựa trên kỹ thuật **BLAIR** (Bridging Language and Items for Retrieval) được áp dụng để sinh ra các mẫu huấn luyện giàu ngữ nghĩa của Hou *et al.*[34].

Quy trình sinh dữ liệu (Reverse Engineering):

Để giải quyết vấn đề khan hiếm dữ liệu truy vấn phức tạp, quy trình Kỹ thuật đảo ngược được thực hiện bằng cách sử dụng Mô hình Ngôn ngữ Lớn (LLM) như GPT-4 hoặc Gemini. Quy trình này dựa trên giả định rằng nội dung đánh giá chi tiết chính là sự phản ánh nhu cầu tìm kiếm của người dùng nhưng ở thì quá khứ.

Các bước thực hiện cụ thể như sau:

- Lựa chọn nguồn dữ liệu:** Các bài đánh giá từ tập dữ liệu Amazon Reviews 2023 được chọn làm đầu vào. Để đảm bảo chất lượng, dữ liệu được lọc theo tiêu chuẩn nghiêm ngặt: chỉ chọn các đánh giá **5 sao** (thể hiện sự hài lòng tuyệt đối với sản phẩm) và có độ dài tối thiểu **100 ký tự** (đảm bảo cung cấp đủ ngữ cảnh và thông tin chi tiết).
- Prompting (Tạo câu lệnh):** LLM được yêu cầu đóng vai một người mua hàng tiềm năng, đọc nội dung review và viết lại thành một câu truy vấn tìm kiếm (Search Query) dưới góc nhìn thứ nhất, sao cho sản phẩm đó là câu trả lời phù hợp nhất.
- Kết quả đầu ra:** Tạo thành các cặp dữ liệu (Synthetic Query, Product) với nhãn là Positive (1).

Review Gốc (Input)	Synthetic Query (Output bởi AI)	Sản phẩm
“Tôi thường xuyên phải bay đường dài và chiếc tai nghe này thực sự cứu cánh. Chức năng chống ồn chặn hoàn toàn tiếng động cơ máy bay. Pin dùng liên tục 30 tiếng vẫn chưa hết...”	“Tôi cần tìm một chiếc tai nghe chụp tai có khả năng chống ồn chủ động tốt nhất để đi máy bay và làm việc tập trung, yêu cầu thời lượng pin trâu.”	Sony Headphones
“Giày rất êm, phần đệm lót hỗ trợ cực tốt cho người bị bàn chân bệt như tôi. Tôi đã chạy marathon mà không hề bị đau gan bàn chân.”	“Giày chạy bộ chuyên dụng tốt nhất giúp giảm đau và hỗ trợ chỉnh hình cho người có vòm bàn chân thấp hoặc bàn chân bệt.”	Adidas Shoes

Bảng 5.4: Ví dụ minh họa quy trình sinh dữ liệu tổng hợp từ Review

Tác dụng của bộ dữ liệu:

Phương pháp này giúp tạo ra hàng nghìn cặp dữ liệu huấn luyện chất lượng cao. Các truy vấn tổng hợp này mang ngữ nghĩa phong phú hơn rất nhiều so với từ khóa đơn thuần, giúp mô hình Cross-Encoder học được cách xử lý các câu hỏi dài, nắm bắt được nhu cầu ẩn (latent needs) và ngữ cảnh sử dụng cụ thể của người dùng.

5.2.2.3.2 Kỹ thuật khai thác mẫu âm (Hard Negative Mining)

Trong bài toán xếp hạng và truy vấn thông tin, việc lựa chọn dữ liệu huấn luyện đóng vai trò quyết định đến độ chính xác của mô hình. Trong khi các mẫu dương (Positive samples) thường được xác định rõ ràng dựa trên nhãn dữ liệu (ví dụ: sản phẩm người dùng đã mua hoặc đánh giá 5 sao), việc lựa chọn mẫu âm (Negative samples) lại phức tạp hơn nhiều. Dự án áp dụng kỹ thuật **Khai thác mẫu âm khó (Hard Negative Mining)** để tối ưu hóa quá trình huấn luyện Cross-Encoder.

Cơ sở lý thuyết và Sự cần thiết

Thông thường, các phương pháp huấn luyện cơ bản sử dụng *Mẫu âm ngẫu nhiên (Random Negatives)* – tức là ghép một truy vấn bất kỳ với một sản phẩm được chọn ngẫu nhiên từ kho hàng. Tuy nhiên, phương pháp này bộc lộ hạn chế lớn khi áp dụng cho Cross-Encoder:

- **Vấn đề hội tụ chậm (Inefficient Learning):** Trong không gian vector khổng lồ của hàng triệu sản phẩm, đại đa số các sản phẩm ngẫu nhiên là Dễ phân biệt (Easy Negatives). Ví dụ, với truy vấn “*Laptop gaming*”, một mẫu âm ngẫu nhiên như “*Nồi cơm điện*” hoàn toàn khác biệt về mặt ngữ nghĩa. Mô hình sẽ rất nhanh chóng đẩy xác suất của cặp này về 0, dẫn đến giá trị hàm mất mát (Loss) xấp xỉ 0 và triệt tiêu đạo hàm (vanishing gradients). Kết quả là mô hình ngừng học hỏi dù chưa thực sự hiểu sâu về đặc điểm sản phẩm.
- **Nhu cầu về khả năng phân biệt tinh tế:** Các nghiên cứu về Truy vấn thông tin mật độ cao (Dense Retrieval) của Karpukhin *et al.* [35] đã chỉ ra rằng hiệu suất xếp hạng được cải thiện đáng kể khi mô hình được tiếp xúc với các mẫu nằm sát đường ranh giới quyết định (Decision Boundary). Đây là những mẫu sai nhưng nhìn có vẻ đúng.

Do đó, Hard Negative Mining là bắt buộc để ép Cross-Encoder phải học các đặc trưng chi tiết thay vì chỉ dựa vào các từ khóa bề mặt.

Quy trình Khai thác mẫu khó

Quy trình tạo mẫu âm khó được thực hiện trong giai đoạn tiền xử lý dữ liệu (Offline Pre-processing), tận dụng sức mạnh của mô hình Bi-Encoder để sàng lọc ứng viên. Các bước thực hiện cụ thể như sau:

1. **Truy xuất ứng viên (Candidate Retrieval):** Sử dụng một mô hình Bi-Encoder (dạng kiến trúc Sentence-BERT gọn nhẹ) để mã hóa toàn bộ truy vấn trong tập huấn luyện và toàn bộ sản phẩm trong kho hàng thành các vector. Với mỗi truy vấn q , hệ thống thực hiện tìm kiếm Top-K (với $K = 50$) sản phẩm có độ tương đồng vector cao nhất.
2. **Lọc bỏ nhãn dương (Filtering Positives):** Trong danh sách 50 sản phẩm được Bi-Encoder gợi ý, hệ thống loại bỏ các sản phẩm trùng với nhãn dương (Ground Truth – sản phẩm thực tế người dùng đã chọn) dựa trên ID sản phẩm.
3. **Xác định Mẫu âm khó (Hard Negatives Identification):** Các sản phẩm còn lại trong Top-K chính là *Hard Negatives*. Đặc điểm của chúng là có điểm tương đồng vector rất cao với truy vấn (do đó Bi-Encoder mới xếp vào top đầu), nhưng về mặt chức năng hoặc ý định người dùng thì chúng là kết quả sai. Các mẫu này thường chia sẻ nhiều từ khóa quan trọng với truy vấn hoặc thuộc cùng một danh mục sản phẩm, dễ gây nhầm lẫn cho các mô hình đơn giản.

Ví dụ minh họa thực tế

Để làm rõ hiệu quả của phương pháp, hãy xem xét ví dụ với truy vấn “iPhone 12”:

- **Random Negative:** “Giày Adidas” → Quá dễ, Cross-Encoder không học được gì.
- **Hard Negative (Sinh ra từ Bi-Encoder):** “Ốp lưng iPhone 12 Pro Max”.

Sản phẩm ốp lưng này chứa toàn bộ các từ khóa trong truy vấn (“iPhone”, “12”) và vector ngữ nghĩa rất gần với điện thoại. Bi-Encoder thường không phân biệt tốt mối quan hệ giữa “vật thể” (điện thoại) và “phụ kiện” (ốp lưng). Khi đưa cặp (“iPhone 12”, “Ốp lưng iPhone 12 Pro Max”) vào huấn luyện với nhãn 0, Cross-Encoder buộc phải chú ý đến từ khóa “Ốp lưng” (Case) để phạt nặng điểm số xuống thấp. Nhờ đó, mô hình học được sự phân biệt ngữ nghĩa sâu sắc mà Bi-Encoder đã bỏ sót.

5.2.2.3.3 Phương pháp huấn luyện

Để đảm bảo mô hình Cross-Encoder hội tụ ổn định và đạt hiệu suất tối ưu trên miền dữ liệu thương mại điện tử, quá trình huấn luyện được thiết lập dựa trên các kỹ thuật tiêu chuẩn của kiến trúc Transformer hiện đại. Các thành phần chính của quy trình huấn luyện bao gồm:

Hàm mất mát (Loss Function):

Dự án sử dụng hàm **Binary Cross-Entropy with Logits (BCEWithLogitsLoss)**. Vì bản chất của Cross-Encoder trong hệ thống này là giải quyết bài toán phân loại nhị phân (xác định một cặp Query-Product là Phù hợp hoặc Không phù hợp), mô hình sẽ xuất ra một giá trị thực (logits) thể hiện mức độ tương đồng. Hàm BCEWithLogitsLoss tích hợp lớp

Sigmoid và hàm Cross-Entropy vào một bước tính toán duy nhất, giúp đảm bảo tính ổn định số học (numerical stability). Mục tiêu là tối thiểu hóa sai số giữa xác suất dự đoán và nhãn thực tế (1 cho Exact match và 0 cho các trường hợp còn lại).

Trình tối ưu hóa (Optimizer):

Chúng tôi lựa chọn **AdamW** (Adam with Weight Decay) làm thuật toán tối ưu hóa. Đây là tiêu chuẩn vàng cho việc huấn luyện các mô hình ngôn ngữ lớn như BERT hay RoBERTa. Khác với Adam truyền thống, AdamW tách biệt việc suy giảm trọng số (Weight Decay) khỏi việc tính toán gradient, giúp mô hình tổng quát hóa tốt hơn và hạn chế hiện tượng quá khớp (overfitting) trên tập dữ liệu huấn luyện.

Cơ chế lập lịch tốc độ học (Learning Rate Scheduler):

Việc huấn luyện Transformer rất nhạy cảm với tốc độ học. Nếu tốc độ học quá lớn ngay từ đầu, mô hình dễ bị mất ổn định (gradient explosion). Do đó, chiến lược **Linear Warmup** được áp dụng. Cụ thể, trong 10% tổng số bước huấn luyện đầu tiên (warmup steps), tốc độ học sẽ tăng tuyến tính từ 0 lên mức tối đa (ví dụ $2e^{-5}$). Giai đoạn làm nóng này giúp các trọng số của mô hình di chuyển về vùng không gian tham số ổn định trước khi bắt đầu quá trình tối ưu hóa chính thức. Sau đó, tốc độ học giảm dần tuyến tính về 0 để giúp mô hình hội tụ tốt hơn.

Chỉ số đánh giá (Evaluation Metrics):

Do đặc thù của bài toán Reranking là sắp xếp thứ tự ưu tiên, việc sử dụng độ chính xác (Accuracy) đơn thuần là không phản ánh đúng trải nghiệm người dùng. Thay vào đó, hiệu năng mô hình được đo lường bằng các chỉ số xếp hạng chuyên dụng trên tập Validation:

- **NDCG@10 (Normalized Discounted Cumulative Gain):** Đây là chỉ số quan trọng nhất, đo lường chất lượng xếp hạng có trọng số. NDCG đánh giá cao việc đưa các kết quả đúng lên các vị trí đầu tiên (top 1, top 2) hơn là các vị trí thấp hơn trong danh sách top 10.
- **MRR@10 (Mean Reciprocal Rank):** Đo lường nghịch đảo thứ hạng của kết quả đúng đầu tiên tìm được. Chỉ số này cho biết trung bình người dùng phải lướt xuống bao xa để thấy kết quả mong muốn đầu tiên.

5.3 Kế hoạch thực hiện đề tài

Bảng 5.5: Kế hoạch thực hiện đề tài (15 Tuần)

Tuần (Thời gian)	Nội dung thực hiện
Tuần 01 (12/01 – 18/01)	Thiết lập môi trường và quy hoạch nhãn dữ liệu ESCI (Exact=1, còn lại=0).
Tuần 02 (19/01 – 25/01)	Khai thác Hard Negatives từ Demo Bi-Encoder cũ (Lọc các ca dự đoán sai).
Tuần 03 (26/01 – 01/02)	Sinh dữ liệu giả lập BLAIR (Dùng LLM tạo Query từ Review 5 sao).
Tuần 04 (02/02 – 08/02)	Tổng hợp dữ liệu (ESCI + Hard Neg + BLAIR) và phân chia tập Train/Val/Test.
Tuần 05 (09/02 – 15/02)	Huấn luyện Baseline (Fine-tune Cross-Encoder chỉ trên tập ESCI gốc).
Tuần 06 (16/02 – 22/02)	Huấn luyện Nâng cao trên toàn bộ dữ liệu, giám sát hàm Loss để tránh Overfitting.
Tuần 07 (23/02 – 01/03)	Đánh giá mô hình (NDCG@10, MRR@10) trên tập Test và so sánh với Baseline.
Tuần 08 (02/03 – 08/03)	Phân tích lỗi (Error Analysis) và tinh chỉnh Hyperparameters để tối ưu kết quả.
Tuần 09 (09/03 – 15/03)	Xây dựng API Reranking và tích hợp vào hệ thống (Pipeline: Retrieve → Rerank).
Tuần 10 (16/03 – 22/03)	Lượng tử hóa mô hình (Quantization FP32 → INT8) để tối ưu thời gian phản hồi.
Tuần 11 (23/03 – 29/03)	Kiểm tra chịu tải (Stress Test) và đánh giá độ trễ tổng thể của hệ thống.
Tuần 12 (30/03 – 05/04)	Cập nhật Frontend Demo, thu thập số liệu và chụp ảnh minh họa cho báo cáo.
Tuần 13 (06/04 – 12/04)	Viết báo cáo: Cơ sở lý thuyết, Dữ liệu (BLAIR, Hard Negs), Kiến trúc hệ thống.
Tuần 14 (13/04 – 19/04)	Viết báo cáo: Kết quả thực nghiệm, Kết luận. Rà soát lỗi và chỉnh sửa.
Tuần 15 (20/04 – 26/04)	Thiết kế Slide thuyết trình, quay Video Demo và hoàn tất hồ sơ bảo vệ.

Tài liệu tham khảo

- [1] SellersCommerce (19-06-2025), *51 eCommerce Statistics In 2025 (Global and U.S. Data)*, <https://www.sellerscommerce.com/blog/ecommerce-statistics/>
- [2] DIETMAR JANNACH, MICHAEL JUGOVAC(12-2019), *Measuring the Business Value of Recommender Systems*, <https://arxiv.org/pdf/1908.08328>
- [3] ENVIVE (3-2025), *63 AI Personalization in eCommerce Lift Statistics – Driving 400% ROI and Transformative Growth in 2025*, <https://www.envive.ai/post/ai-personalization-in-ecommerce-lift-statistics>
- [4] Carrie Tharp(24-3-2025), *New research: Search abandonment continues to vex retailers worldwide*, <https://cloud.google.com/blog/topics/retail/new-research-on-search-abandonment-in-retail>
- [5] Qijiong Liu(29-10-2025), *Can LLMs Outshine Conventional Recommenders? A Comparative Evaluation*, <https://arxiv.org/pdf/2503.05493>
- [6] Huggingface(5-12-2025), *MTEB Leaderboard*, <https://huggingface.co/spaces/mteb/leaderboard>
- [7] Kang, W. C., & McAuley, J. (2018). *Self-attentive sequential recommendation*, <https://arxiv.org/abs/1808.09781>
- [8] Xinyang Yi, Ji Yang, Lichan Hong, Derek Zhiyuan Cheng, Lukasz Heldt, Aditee Kumthekar, ZheZhao, Li Wei, Ed Chi (2019). *Sampling-Bias-Corrected Neural Modeling for Large Corpus Item Recommendations*, <https://research.google/pubs/sampling-bias-corrected-neural-modeling-for-large-corpus-item-recommendations/>
- [9] Paul Covington, Jay Adams, Emre Sargin (2016). *Deep Neural Networks for YouTube Recommendations*, <https://static.googleusercontent.com/media/research.google.com/en//pubs/archive/45530.pdf>
- [10] HuggingFace (2025). *sentence-transformers/all-mpnet-base-v2*, <https://huggingface.co/sentence-transformers/all-mpnet-base-v2>
- [11] Alexey Dosovitskiy(2021). *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*, <https://arxiv.org/pdf/2010.11929>
- [12] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin (2023). *Attention Is All You Need*, <https://arxiv.org/abs/1706.03762>

- [13] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever (2021). *Learning Transferable Visual Models From Natural Language Supervision*, <https://arxiv.org/abs/2103.00020>
- [14] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*, <https://arxiv.org/abs/1810.04805>
- [15] Tomas Mikolov, Kai Chen, Greg Corrado, Jeffrey Dean (2013). *Efficient Estimation of Word Representations in Vector Space*, <https://arxiv.org/pdf/1301.3781>
- [16] Qidong Liu, Jiayi Hu, Yutian Xiao, Xiangyu Zhao, Jingtong Gao, Wanyu Wang, Qing Li, Jiliang Tang (2024). *Multimodal Recommender Systems: A Survey*, <https://arxiv.org/pdf/2302.03883v2>
- [17] YouNet (2024). *YouNet ECI: Báo cáo doanh thu các sản phẩm thương mại điện tử quý I/2024*, <https://www.brandsvietnam.com/congdong/topic/340383-younet-eci-bao-cao-doanh-thu-cac-san-thuong-mai-dien-tu-quy-i-2024>
- [18] Gediminas Adomavicius, Alexander Tuzhilin (2005). *Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions*, <https://pages.stern.nyu.edu/~atuzhili/pdf/TKDE-Paper-as-Printed.pdf>
- [19] Steffen Rendle (2010). *Factorization Machines*, <https://www.ismll.uni-hildesheim.de/pub/pdfs/Rendle2010FM.pdf>
- [20] Maciej Kula (2015). *Metadata Embeddings for User and Item Cold-start Recommendations*, <https://arxiv.org/pdf/1507.08439>
- [21] Heng-Tze Cheng (2016). *Wide & Deep Learning for Recommender Systems*, <https://arxiv.org/pdf/1606.07792>
- [22] Xiangnan He (2017). *Neural Collaborative Filtering*, <https://arxiv.org/pdf/1708.05031>
- [23] Florian Schroff, Dmitry Kalenichenko, James Philbin (2015). *FaceNet: A Unified Embedding for Face Recognition and Clustering*, <https://arxiv.org/pdf/1503.03832>
- [24] John Arevalo, Manuel Montes-y-Gomez, Thamar Solorio, Fabio A. Gonzalez (2017). *GATED MULTIMODAL UNITS FOR INFORMATION FUSION*, <https://arxiv.org/pdf/1702.01992>
- [25] Ruining He, Julian McAuley (2016). *Fusing Similarity Models with Markov Chains for Sparse Sequential Recommendation*, <https://arxiv.org/pdf/1609.09152>
- [26] Steffen Rendle (2010). *Factorizing Personalized Markov Chains for Next-Basket Recommendation*, <https://cseweb.ucsd.edu/classes/fa17/cse291-b/reading/p811.pdf>

- [27] Zachary C. Lipton, John Berkowitz (2015). *A Critical Review of Recurrent Neural Networks for Sequence Learning*, <https://arxiv.org/pdf/1506.00019>
- [28] Sepp Hochreiter, Jürgen Schmidhuber (1997). *Long Short-Term Memory*, https://www.researchgate.net/publication/13853244_Long_Short-Term_Memory
- [29] Junyoung Chung, Caglar Gulcehre, KyungHyun Cho, Yoshua Bengio (2014). *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*, <https://arxiv.org/pdf/1412.3555>
- [30] Balazs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, Domonkos Tikk (2016). *Session-based Recommendations with Recurrent Neural Networks*, <https://arxiv.org/abs/1511.06939>
- [31] Pratik Aher (2023). *Evaluation Metrics for Recommendation Systems - An Overview*, <https://towardsdatascience.com/evaluation-metrics-for-recommendation-systems-an-overview-71290690ecba/>
- [32] Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, Ming Zhou (2020). *MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers*, <https://arxiv.org/abs/2002.10957>
- [33] Chandan K. Reddy, Lluís Màrquez, Fran Valero, Nikhil Rao, Hugo Zaragoza, Sambaran Bandyopadhyay, Arnab Biswas, Anlu Xing, Karthik Subbian (2022). *Shopping Queries Dataset: A Large-Scale ESCI Benchmark for Improving Product Search*, <https://arxiv.org/pdf/2206.06588>
- [34] Yupeng Hou, Jiacheng Li, Zhankui He, An Yan, Xiusi Chen, Julian McAuley (2024). *Bridging Language and Items for Retrieval and Recommendation*, <https://arxiv.org/abs/2403.03952>
- [35] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, Wen-tau Yih (2020). *Dense Passage Retrieval for Open-Domain Question Answering*, <https://arxiv.org/pdf/2004.04906>
- [36] Yoshua Bengio, Réjean Ducharme, Pascal Vincent, Christian Jauvin (2003). *A Neural Probabilistic Language Model*, <https://www.jmlr.org/papers/volume3/bengio03a/bengio03a.pdf>
- [37] Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever (2018). *Improving Language Understanding by Generative Pre-Training*, https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf
- [38] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah (2020). *Language Models are Few-Shot Learners*, <https://arxiv.org/abs/2005.14165>
- [39] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin (2022). *Training language models to follow instructions with human feedback*, <https://arxiv.org/abs/2203.02155>

- [40] Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge, Yongfeng Zhang (2023). *Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5)*, <https://arxiv.org/pdf/2203.13366>
- [41] Thomas Wolf, Lysandre Debut, Victor Sanh, et al. (2020). *Transformers: State-of-the-Art Natural Language Processing*. <https://www.aclweb.org/anthology/2020.emnlp-demos.6>
- [42] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder, Li Deng (2016). *MS MARCO: A Human Generated Machine Reading Comprehension Dataset*. <https://arxiv.org/abs/1611.09268>