

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO

ĐỒ ÁN CHUYÊN NGÀNH
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

**Ứng dụng mô hình ngôn ngữ lớn (LLM) trong hệ thống gợi ý
và tư vấn trên sàn thương mại điện tử**

HỘI ĐỒNG: Khoa học máy tính

GVHD: Ths. Võ Thanh Hùng

—o0o—

SVTH1: Đàm Đức Huy(2211157)

SVTH2: Huỳnh Quốc Huy(2211180)

SVTH3: Nguyễn Gia Huy(2211212)

TP. HỒ CHÍ MINH, 12/2025

Lời cảm ơn

Đồ án tốt nghiệp được hoàn thành dưới sự hướng dẫn của và ThS. Võ Thanh Hùng, Khoa Khoa học và Kỹ thuật Máy tính, Trường Đại học Bách khoa - Đại học Quốc gia Thành phố Hồ Chí Minh. Nhóm thực hiện xin chân thành cảm ơn ThS. Võ Thanh Hùng, đã giúp đỡ chúng em kiến thức chuyên môn, thảo luận, đưa ra gợi ý và tạo điều kiện thuận lợi cho chúng em hoàn thành đồ án.

Chúng em cũng xin gửi lời cảm ơn đặc biệt đến quý thầy cô phản biện, những người đã đọc và đóng góp ý kiến để chúng em hoàn thiện Đồ án tốt nghiệp của mình.

Nhóm thực hiện cũng xin bày tỏ lòng biết ơn sâu sắc đến quý thầy cô Khoa Khoa học và Kỹ thuật Máy tính, Trường Đại học Bách khoa - Đại học Quốc gia Thành phố Hồ Chí Minh, là những người đã truyền thụ kiến thức chuyên môn, đã tạo điều kiện cho chúng em học tập và phát triển trong suốt quãng thời gian vừa qua.

Đặc biệt, chúng em muốn bày tỏ lòng biết ơn sâu sắc đến gia đình, những người đã luôn là chỗ dựa tinh thần vững chắc, động viên và tạo điều kiện tốt nhất để chúng em có thể tập trung học tập và hoàn thành đồ án này. Sự hy sinh và hỗ trợ không ngừng nghỉ của gia đình là nguồn động lực to lớn giúp chúng em vượt qua mọi khó khăn.

Kính chúc quý thầy cô sức khỏe, thành công và tiếp tục đào tạo những thế hệ sinh viên mới trong tương lai.

Chúng em xin chân thành cảm ơn.

Nhóm thực hiện

Huỳnh Quốc Huy

Đàm Đức Huy

Nguyễn Gia Huy

Lời cam đoan

Chúng tôi xin cam đoan Đồ án tốt nghiệp này là công trình nghiên cứu khoa học nghiêm túc và trung thực của nhóm dưới sự hướng dẫn của ThS Võ Thanh Hùng.

Tất cả nội dung được trình bày trong Đồ án tốt nghiệp này, ngoại trừ những phần đã được chú thích, trích nguồn rõ ràng trong phần tài liệu tham khảo, đều là do chính bản thân nhóm thực hiện.

Chúng tôi xin chịu trách nhiệm hoàn toàn nếu có bất kỳ sự gian lận nào về nội dung Đồ án tốt nghiệp của nhóm.

Nhóm thực hiện

Huỳnh Quốc Huy

Đàm Đức Huy

Nguyễn Gia Huy

Tóm tắt

Nghiên cứu này tập trung phát triển hệ thống gợi ý tuần tự đa phương thức ứng dụng trên tập dữ liệu Amazon Reviews, nhằm tối ưu hóa trải nghiệm tìm kiếm và mua sắm quà tặng trực tuyến. Mục tiêu cốt lõi của hệ thống là hỗ trợ người dùng tìm kiếm sản phẩm phù hợp nhất thông qua việc phân tích sâu nội dung đa phương thức bao gồm văn bản và hình ảnh, kết hợp với chuỗi hành vi và sở thích lịch sử để đưa ra các gợi ý có tính cá nhân hóa cao.

Về mặt phương pháp, hệ thống được xây dựng dựa trên kiến trúc Two-Tower kết hợp với chiến lược tìm kiếm lai. Cụ thể, tháp sản phẩm ứng dụng cơ chế cổng hợp nhất (Fusion Gate) để tổng hợp và học biểu diễn từ các đặc trưng văn bản trích xuất từ BERT, đặc trưng hình ảnh từ ViT và dữ liệu bảng. Trong khi đó, tháp người dùng mô hình hóa chuỗi tương tác tuần tự bằng kiến trúc Transformer Encoder cải tiến từ mô hình SASRec. Điểm đặc biệt là sự tích hợp khả năng nhận biết cảm xúc, cho phép hệ thống phân biệt và học hỏi từ các phản hồi tích cực cũng như tiêu cực của người dùng.

Quá trình suy luận diễn ra qua một quy trình ba giai đoạn chặt chẽ: thứ nhất, truy xuất tập ứng viên sơ bộ dựa trên độ tương đồng ngữ nghĩa trong không gian vector tiềm ẩn; thứ hai, xếp hạng lại thông qua mạng Cross-Encoder nhằm tính toán trực tiếp mức độ giao thoa giữa ý định tìm kiếm của người dùng và từng sản phẩm cụ thể; và cuối cùng, tinh chỉnh thứ hạng chuyên sâu kết hợp sinh lời giải thích minh bạch bằng LLM. Tại bước cuối cùng, LLM đóng vai trò đánh giá ngữ cảnh và suy luận mối liên hệ giữa nhu cầu hiện tại với lịch sử hành vi để chọn lọc danh sách kết quả tối ưu. Ngoài ra, vấn đề khởi động lạnh đối với người dùng mới được giải quyết thông qua thuật toán đánh giá có trọng số. Kết quả thực nghiệm cho thấy mô hình không chỉ nắm bắt hiệu quả các mối quan hệ ngữ nghĩa đa phương thức và diễn biến sở thích người dùng, mà còn tận dụng tốt khả năng suy luận của LLM để nâng cao chất lượng gợi ý cuối cùng.

Bảng 1: Bảng phân công vai trò và nhiệm vụ chi tiết của nhóm

Thành viên	Vai trò chuyên môn	Nhiệm vụ chi tiết & Kết quả thực hiện
Huỳnh Quốc Huy	Xử lý dữ liệu & Tích hợp AI Tạo sinh	1. Tiền xử lý dữ liệu (Data Preprocessing): - Thu thập, làm sạch và chuẩn hóa các nguồn dữ liệu đa phương thức (hình ảnh, văn bản, thông số kỹ thuật). - Xây dựng pipeline xử lý dữ liệu tự động để phục vụ quá trình huấn luyện. 2. Xây dựng Hệ thống Demo (Web Application): - Thiết kế và phát triển giao diện người dùng (Frontend) cho Web Demo. - Xây dựng Backend API để kết nối giữa giao diện và các mô hình gợi ý, hiển thị kết quả trực quan cho người dùng. 3. Tích hợp LLM (Explainability): - Nghiên cứu và tích hợp mô hình ngôn ngữ lớn (LLM) để sinh văn bản giải thích lý do gợi ý. - Thiết kế kỹ thuật <i>Prompt Engineering</i> để tạo ra các giải thích tự nhiên và phù hợp ngữ cảnh.
Nguyễn Gia Huy	Mô hình hóa Sản phẩm & Nghiên cứu Nâng cao	1. Xây dựng Tháp Sản phẩm (Item Tower): - Thiết kế và cài đặt các bộ mã hóa đặc trưng (ImageEncoder, TextEncoder, TabularEncoder). - Hiện thực hóa cơ chế <i>Item Fusion</i> để tạo vector đại diện sản phẩm thống nhất. 2. Nghiên cứu Cross-Encoder: - Tìm hiểu cơ sở lý thuyết và kiến trúc của mô hình Cross-Encoder cho bài toán Re-ranking. - Đề xuất giải pháp và kiến trúc tích hợp Cross-Encoder để cải thiện độ chính xác (định hướng phát triển tương lai).
Đàm Huy Đức	Mô hình hóa Người dùng	Xây dựng Tháp Người dùng (User Tower): - Cài đặt kiến trúc <i>Transformer/SASRec</i> để mô hình hóa chuỗi hành vi tuần tự của người dùng. - Hiện thực hóa các kỹ thuật <i>Masked Mean Pooling</i> và <i>Positional Encoding</i>.

Bảng 2: Kế hoạch thực hiện đề tài

Tuần (Thời gian)	Nội dung thực hiện
w37 (08/09 – 14/09)	Tìm hiểu tổng quan, xác định phạm vi đề tài và dataset.
w38 (15/09 – 21/09)	Thu thập, phân tích và làm sạch bộ dữ liệu <i>Amazon Reviews</i> .
w39 (22/09 – 28/09)	Thực hiện embedding dữ liệu sản phẩm và người dùng.
w40 (29/09 – 05/10)	Xây dựng và cài đặt Item Tower (Tích hợp Fusion Gate).
w41 (06/10 – 12/10)	Xây dựng User Tower với kiến trúc SASRec để mô hình hóa chuỗi hành vi.
w42 (13/10 – 19/10)	Huấn luyện mô hình Two-Tower (Loss function: <i>InfoNCE</i> + In-batch Negatives).
w43 (20/10 – 26/10)	Triển khai cơ chế Retrieval và chiến lược Hybrid Reranking.
w44 (27/10 – 02/11)	Tối ưu hóa mô hình: Tinh chỉnh Hyperparameters (α, β , Learning rate) để cải thiện chỉ số NDCG/Recall.
w45 (03/11 – 09/11)	Xây dựng Demo (FastAPI/ReactJS) và tích hợp nhanh API LLM để giải thích kết quả.
w46 (10/11 – 16/11)	Đánh giá toàn diện hệ thống: So sánh với các baseline và phân tích trường hợp lỗi (Error Analysis).
w47 (17/11 – 23/11)	Tổng hợp kết quả thực nghiệm, vẽ biểu đồ so sánh hiệu năng.
w48 (24/11 – 30/11)	Viết báo cáo chương 1–3 (Lý thuyết, Thiết kế hệ thống).
w49 (01/12 – 07/12)	Viết báo cáo chương 4–5 (Thực nghiệm, Kết luận, Hướng phát triển tương lai).
w50 (08/12 – 14/12)	Rà soát lần cuối và hoàn thiện slide thuyết trình.

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nghĩa đầy đủ (Tiếng Anh / Tiếng Việt)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BERT	Bidirectional Encoder Representations from Transformers (Biểu diễn mã hóa hai chiều từ Transformer)
CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
CTR	Click-Through Rate (Tỷ lệ nhấp chuột)
DL	Deep Learning (Học sâu)
GPT	Generative Pre-trained Transformer (Mô hình Transformer sinh văn bản tiền huấn luyện)
GRU	Gated Recurrent Unit (Đơn vị hồi quy có cổng)
InfoNCE	Info Noise Contrastive Estimation (Hàm mất mát ước lượng tương phản nhiễu)
LLM	Large Language Model (Mô hình ngôn ngữ lớn)
LSTM	Long Short-Term Memory (Bộ nhớ ngắn-dài hạn)
MLP	Multi-Layer Perceptron (Mạng nơ-ron đa lớp)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách gần)
ReLU	Rectified Linear Unit (Đơn vị chỉnh lưu tuyến tính)
RLHF	Reinforcement Learning from Human Feedback (Học tăng cường từ phản hồi con người)
ResSys	Recommender Systems (Hệ thống đề xuất)
RNN	Recurrent Neural Network (Mạng nơ-ron hồi quy)
SASRec	Self-Attentive Sequential Recommendation (Gợi ý tuần tự dựa trên cơ chế tự chú ý)
SFT	Supervised Fine-Tuning (Tinh chỉnh có giám sát)
ViT	Vision Transformer (Mô hình Transformer cho thị giác máy tính)
MLM	Masked Language Modeling (Mô hình hóa ngôn ngữ che mặt nạ)
MLM	Next Sentence Prediction (Dự đoán câu tiếp theo)

Contents

Danh mục từ viết tắt	3
1 Tổng quan về đề tài	1
1.1 Lý do chọn đề tài	1
1.2 Mục tiêu đề tài	2
1.3 Đối tượng và Phạm vi nghiên cứu	3
1.4 Định nghĩa bài toán	4
2 Cơ sở lý thuyết	5
2.1 Tổng quan về Hệ thống Gợi ý	5
2.1.1 Tổng quan về các kỹ thuật gợi ý truyền thống	5
2.1.2 Hệ thống Gợi ý Lai	7
2.1.3 Hệ thống gợi ý đa giai đoạn	8
2.2 Các Hàm Mục tiêu	9
2.2.1 Triplet Loss	9
2.2.2 InfoNCE	10
2.2.3 Symmetric Explicit Contrastive Loss	10
2.2.4 Binary Cross Entropy	11
2.3 Kiến trúc nền tảng: Transformer	11
2.3.1 Cơ chế Scaled Dot-Product Self-Attention	12
2.3.2 Cơ chế Multi-Head Attention	12
2.3.3 Cơ chế Mã hóa Vị trí	12
2.4 Biểu diễn Đa phương thức	14
2.4.1 Biểu diễn Văn bản: BERT	14
2.4.2 Biểu diễn Hình ảnh: ViT	16
2.4.3 Cơ chế Hợp nhất Không gian Vector	18
2.5 Nắm bắt chuỗi hành vi trong ResSys	20
2.5.1 Sự tiến hóa của các Hệ thống Gợi ý Tuần tự: Từ Markov đến RNN	20
2.5.2 Kiến trúc SASRec	20
2.5.3 Kiến trúc Hai tháp cho Truy xuất Ứng viên	22
2.6 Mô hình xếp hạng lại Reranking	24
2.6.1 Lý thuyết Cross Encoder	24
2.6.2 So sánh Cross Encoder và Bi Encoder	25
2.7 Ứng dụng Mô hình Ngôn ngữ Lớn trong Hệ thống Gợi ý	26
2.7.1 Tổng quan về khả năng hiểu ngữ cảnh của LLM	26
2.7.2 Kỹ thuật Prompting trong Hệ thống Gợi ý	27
2.7.3 Định hướng ứng dụng LLM trong Đề án	27

3	Phương pháp đề xuất và Kiến trúc Hệ thống	29
3.1	Kiến trúc tổng thể hệ thống gợi ý đa giai đoạn	29
3.2	Kiến trúc Bi-Encoder	31
3.2.1	Xây dựng Tháp Sản phẩm Đa phương thức	32
3.2.2	Xây dựng Tháp Người dùng và Mô hình hóa Chuỗi hành vi	38
3.2.3	Chiến lược Huấn luyện Hai giai đoạn	41
3.3	Giai đoạn 2: Re-ranker	43
3.3.1	Kiến trúc tổng quan Reranker	43
3.3.2	Embedding Cross Encoder	45
3.3.3	Memory Encoder	46
3.3.4	Mixing Model	47
3.3.5	Chiến thuật Huấn luyện	48
3.4	Tích hợp LLM trong Giai đoạn Hậu Truy xuất	51
3.4.1	Quy trình Xử lý Dữ liệu	51
3.4.2	Cấu trúc Prompt Minh họa	51
3.4.3	Vai trò của LLM trong Hệ thống	52
4	Thực nghiệm và Đánh giá	53
4.1	Mô tả tập dữ liệu	53
4.1.1	Tổng quan về nguồn dữ liệu	53
4.1.2	Phân tích chất lượng dữ liệu và Giá trị khuyết	56
4.1.3	Quy trình Tiền xử lý dữ liệu	57
4.1.4	Phân tích độ thưa dữ liệu	59
4.2	Thiết lập thực nghiệm	61
4.2.1	Môi trường phần cứng và phần mềm	61
4.2.2	Cấu hình Siêu tham số	62
4.3	Đầu vào và đầu ra	63
4.3.1	Xây dựng Item Tower	63
4.3.2	Xây dựng User Tower	66
4.4	Các độ đo đánh giá	68
4.4.1	Recall@K	68
4.4.2	MRR@K	69
4.4.3	NDCG@K	69
4.5	Đánh giá Hiệu suất Truy xuất sơ cấp Bi-Encoder	70
4.5.1	Đánh giá chất lượng biểu diễn Tháp Sản phẩm đa phương thức .	71
4.5.2	Đánh giá năng lực Tháp Người dùng và Hiệu suất Toàn hệ thống	72
4.6	Triển khai và Thử nghiệm trên Hệ thống thực tế	73
4.6.1	Kiến trúc hệ thống	73
4.6.2	Quy trình xử lý một yêu cầu gợi ý	75
4.6.3	Minh họa hệ thống	76
4.7	Kết luận chương	77
5	Hướng phát triển	78
5.1	Tổng kết và Hướng phát triển	78
5.1.1	Kết luận và Kết quả đạt được	78
5.1.2	Hạn chế của đề tài	78
5.1.3	Hướng phát triển hệ thống	79



5.1.4	Thu hoạch của sinh viên	80
-------	-----------------------------------	----

Danh sách hình vẽ

2.1	Mình họa hai phương pháp gợi ý truyền thống.	6
2.2	Kiến trúc hình phổ tiêu biểu của hệ thống gợi ý đa giai đoạn	8
2.3	Mình họa trực quan giá trị Positional Encoding trên 4 chiều ẩn đầu tiên. Các đường cong hình sin với tần số khác nhau giúp mô hình phân biệt vị trí trong chuỗi.	13
2.4	Quy trình Tiền huấn luyện và Tinh chỉnh của BERT.	15
2.5	Sơ đồ kiến trúc Vision Transformer.	17
2.6	Sơ đồ kiến trúc Multi-Modality Fusion.	19
2.7	Kiến trúc tổng quan của mô hình Cross-Encoder	24
2.8	So sánh sự khác biệt giữa kiến trúc Bi-Encoder và Cross-Encoder	25
3.1	Quá trình Truy xuất sản phẩm	30
3.2	Quá trình Truy xuất sản phẩm	31
3.3	Kiến trúc Item Tower: Quy trình mã hóa và hợp nhất dữ liệu Đa phương thức	33
3.4	Quy trình Tính toán và Tổng hợp Đặc trưng Hình ảnh	35
3.5	Kiến trúc chi tiết Tháp Người dùng với cơ chế mô hình hóa chuỗi đa phương thức.	38
3.6	Kiến trúc tổng quan của mô hình xếp hạng lại (Reranker) kết hợp đối sánh ngữ nghĩa và bộ nhớ cá nhân hóa.	44
3.7	Sơ đồ luồng xử lý và trích xuất đặc trưng độc lập của kiến trúc Embedding Cross-Encoder.	45
3.8	Cơ chế hoạt động của Memory Encoder phân tách thành hai luồng: Xử lý ngoại tuyến (chất lọc hồ sơ đa vector) và Xử lý trực tuyến (đối chiếu và tính điểm cá nhân hóa).	47
4.1	Kiến trúc hệ thống gợi ý Two-Tower triển khai thực tế	74
4.2	Giao diện hiển thị kết quả tìm kiếm	76
4.3	Log xử lý thời gian thực tại Backend	76

Danh sách bảng

1	Bảng phân công vai trò và nhiệm vụ chi tiết của nhóm	1
2	Kế hoạch thực hiện đề tài	2
3.1	Mình họa cơ chế lấy mẫu kết hợp với kích thước lô $N = 3$	42
4.1	Mô tả chi tiết các trường thông tin trong tập dữ liệu User Reviews . . .	54
4.2	Mô tả chi tiết các trường thông tin trong tập dữ liệu Item Metadata . . .	55
4.3	Thông kê tỷ lệ dữ liệu khuyết trên Item Metadata	56
4.4	Thông kê tập dữ liệu Amazon Gift Cards sau khi tiền xử lý	59
4.5	Cấu hình siêu tham số cho Item Tower	63
4.6	Cấu hình siêu tham số cho User Tower	63
4.7	Đặc tả luồng dữ liệu và kích thước trong Text Encoder	64
4.8	Đặc tả luồng dữ liệu và kích thước trong Image Encoder	65
4.9	Đặc tả luồng dữ liệu trong Tabular Encoder	65
4.10	Đặc tả các luồng dữ liệu đầu vào cho User Tower	67
4.11	Kết quả đánh giá độ tương quan chéo (Text $\rightarrow$ Image) trên hai tập dữ liệu	71
4.12	Hiệu suất Gợi ý Toàn cục của mô hình Đề xuất trên tập Gift Card (1.307 sản phẩm)	72
4.13	So sánh hiệu suất Gợi ý Toàn cục trên tập dữ liệu All Beauty (10.216 sản phẩm)	72

Chương 1

Tổng quan về đề tài

Nội dung chương 1 trình bày sơ lược về đề tài, bối cảnh hiện nay và làm rõ lý do đề tài được chọn. Từ đó, xác định mục tiêu cần đạt được khi thực hiện và phạm vi của đề tài.

1.1 Lý do chọn đề tài

Trong bối cảnh nền kinh tế số toàn cầu đang bước vào giai đoạn phát triển bùng nổ, việc lựa chọn nghiên cứu đề tài Hệ thống gợi ý sản phẩm trên các sàn thương mại điện tử xuất phát từ sự hội tụ của ba động lực chính: tính cấp thiết của thị trường, giá trị kinh tế khổng lồ và bước ngoặt công nghệ mang tính cách mạng. Chúng ta đang sống trong một kỷ nguyên mà khả năng sản xuất và cung ứng hàng hóa đã vượt xa khả năng xử lý thông tin của con người. Với doanh số thương mại điện tử toàn cầu ước tính đạt 6,33 nghìn tỷ USD vào năm 2024 và dự kiến tiếp tục tăng trưởng lên 6,86 nghìn tỷ USD vào năm 2025, người tiêu dùng đang bị bủa vây bởi một biển hàng hóa. Đặc biệt, khi thương mại di động chiếm tới 57% tổng doanh số và dự báo đạt 2,51 nghìn tỷ USD vào năm 2025, không gian hiển thị trên màn hình điện thoại trở nên vô cùng khan hiếm [1]. Sự mâu thuẫn giữa số lượng sản phẩm khổng lồ và giới hạn nhận thức của người dùng đã tạo ra nhu cầu bức thiết cho những cơ chế lọc thông minh, có khả năng thấu hiểu và dự đoán nhu cầu trước khi người dùng nhận thức được chúng.

Về mặt kinh tế, hệ thống gợi ý đã chuyển mình từ một tính năng phụ trợ trở thành động cơ doanh thu quyết định sự sống còn của doanh nghiệp. Các dữ liệu thực nghiệm từ những tập đoàn công nghệ hàng đầu đã minh chứng rõ nét cho luận điểm này. Amazon, gã khổng lồ bán lẻ trực tuyến, tạo ra tới 35% tổng doanh thu từ các cơ chế gợi ý cá nhân hóa [2]. Trong lĩnh vực nội dung số, Netflix tiết kiệm khoảng 1 tỷ USD mỗi năm và giữ chân người dùng nhờ vào hệ thống gợi ý đóng góp tới 75-80% thời lượng xem [2]. Đối với các doanh nghiệp vừa và nhỏ, việc áp dụng cá nhân hóa bằng AI có thể giúp tăng doanh thu từ 10-40% và cải thiện tỷ lệ chuyển đổi trung bình khoảng 26% [3]. Ngược lại, sự thiếu vắng một hệ thống gợi ý hiệu quả dẫn đến cái giá rất đắt: hiện tượng bỏ dở tìm kiếm xảy ra ngày càng nhiều, khi người dùng rời bỏ trang web vì không tìm thấy sản phẩm ưng ý, đang gây thiệt hại cho ngành bán lẻ toàn cầu hơn 2.000 tỷ USD mỗi năm [4]. Do đó, nghiên cứu xây dựng hệ thống gợi ý không chỉ là bài toán kỹ thuật mà là giải pháp tối ưu hóa dòng tiền và lợi nhuận thiết yếu.

Xét trên khía cạnh tâm lý học hành vi, đề tài này giải quyết vấn đề cốt lõi của người tiêu dùng hiện đại: sự tê liệt khi lựa chọn. Các nghiên cứu chỉ ra rằng khi đối mặt với quá nhiều tùy chọn, não bộ con người rơi vào trạng thái mệt mỏi nhận thức, dẫn đến việc trì hoãn hoặc từ bỏ mua sắm. Hơn nữa, hành vi người dùng đang chuyển dịch mạnh mẽ từ tìm kiếm dựa trên từ khóa sang khám phá dựa trên gợi ý, đặc biệt là tại các thị trường mới nổi như Việt Nam. Với quy mô thị trường thương mại điện tử Việt Nam, doanh thu của bốn nền tảng thương mại điện tử Shopee, TikTok Shop, Lazada và Tiki trong quý I 2024 là 79,12 nghìn tỷ đồng, trong đó TikTok Shop chiếm lĩnh 23,2% thị phần chỉ sau thời gian ngắn[17], người tiêu dùng ngày càng mong đợi các trải nghiệm mua sắm mang tính giải trí, ngẫu hứng và được cá nhân hóa cao độ. Hệ thống gợi ý chính là chìa khóa để đáp ứng kỳ vọng này, đóng vai trò như một người trợ lý ảo thấu hiểu tâm lý, giúp điều hướng người dùng trong mê cung hàng hóa và kích thích hành vi mua sắm.

Cuối cùng, lý do quan trọng để thực hiện đề tài này ngay tại thời điểm hiện tại nằm ở sự tiến hóa vượt bậc của công nghệ. Lĩnh vực hệ thống gợi ý đang trải qua một cuộc cách mạng với sự xuất hiện của Generative AI và các Mô hình ngôn ngữ lớn. Các phương pháp truyền thống như Lọc cộng tác đang dần bộc lộ hạn chế trong việc xử lý vấn đề khởi động lạnh và thiếu khả năng giải thích lý do gợi ý. Sự tích hợp LLM vào hệ thống gợi ý đang mở ra hướng đi mới, cho phép hệ thống không chỉ phân tích hành vi click chuột mà còn đọc hiểu được ý định của người dùng thông qua ngôn ngữ tự nhiên, giúp cải thiện các chỉ số dự đoán quan trọng như AUC lên tới 5% và NDCG lên tới 170% trong các tác vụ gợi ý tuần tự [5]. Hơn thế nữa, sự phát triển của các AI Agents trong năm 2025 hứa hẹn đưa cá nhân hóa lên một tầm cao mới, nơi AI có thể tự chủ lập kế hoạch và thực hiện các tác vụ mua sắm phức tạp thay cho con người.

Hệ thống gợi ý sản phẩm trong sàn thương mại điện tử đang là một lựa chọn mang tính chiến lược, đón đầu xu hướng công nghệ của giai đoạn 2025-2026. Nó không chỉ có ý nghĩa khoa học trong việc ứng dụng các thành tựu AI mới nhất mà còn mang lại giá trị thực tiễn to lớn, giúp giải quyết bài toán hiệu quả kinh doanh cho doanh nghiệp và nâng cao trải nghiệm cho người tiêu dùng trong nền kinh tế số.

1.2 Mục tiêu đề tài

Từ những lợi ích thiết thực trên, nhóm đã lên kế hoạch thực hiện một hệ thống gợi ý sản phẩm thông minh thế hệ mới cho thương mại điện tử, hoạt động như một trợ lý mua sắm ảo có khả năng thấu hiểu đa chiều. Hệ thống nhằm giải quyết bài toán quá tải lựa chọn của người tiêu dùng, giúp người dùng tìm được sản phẩm ưng ý nhanh nhất với ít thao tác nhất.

Để đạt được mục tiêu tổng quát nêu trên, nhóm nghiên cứu tập trung vào việc xây dựng khả năng thấu hiểu dữ liệu đa phương thức, khắc phục hạn chế của các hệ thống truyền thống vốn chỉ dựa trên từ khóa hoặc định danh sản phẩm. Hệ thống được thiết kế để xử lý và trích xuất đặc trưng sâu từ cả hình ảnh và văn bản mô tả chi tiết, cho phép nhận diện chính xác các yếu tố về kiểu dáng, màu sắc và phong cách để đưa ra các gợi ý có độ tương đồng cao về mặt thị giác và ngữ nghĩa. Bên cạnh đó, đề tài cũng chú trọng thiết lập cơ chế theo dõi và phân tích chuỗi tương tác thời gian thực, giúp hệ thống nắm bắt được sở thích nhất thời và sự thay đổi trong gu thẩm mỹ của người dùng, đảm bảo các

sản phẩm được đề xuất luôn phù hợp với ý định mua sắm tại thời điểm hiện tại.

Trong quá trình xác định giải pháp công nghệ cho hệ thống, nhóm nghiên cứu đã tiến hành phân tích và so sánh kỹ lưỡng giữa các hướng tiếp cận phổ biến hiện nay nhằm tìm ra phương án tối ưu nhất. Đối với các phương pháp truyền thống như Lọc cộng tác hay Lọc theo nội dung, ưu điểm nằm ở sự đơn giản và chi phí tính toán thấp, tuy nhiên chúng bộc lộ nhược điểm chí mạng về vấn đề khởi động lạnh cũng như khả năng xử lý dữ liệu thưa kém, dẫn đến việc không thể đưa ra gợi ý chính xác cho người dùng mới hoặc sản phẩm mới chưa có lịch sử tương tác. Trong khi đó, các mô hình học sâu thuần túy tuy cải thiện được độ chính xác nhờ khả năng nắm bắt các mối quan hệ phi tuyến tính trong chuỗi hành vi, nhưng lại thường hạn chế trong việc hiểu sâu ngữ nghĩa đa phương thức của hình ảnh và văn bản, đồng thời hoạt động như một hộp đen thiếu tính minh bạch. Riêng đối với các Mô hình ngôn ngữ lớn, mặc dù sở hữu năng lực thấu hiểu ngữ cảnh và suy luận ý định vượt trội, nhưng việc triển khai độc lập cho toàn bộ quy trình lại vấp phải rào cản lớn về chi phí tính toán khổng lồ và độ trễ cao, khiến chúng trở nên kém khả thi khi phải xử lý xếp hạng hàng triệu sản phẩm trong thời gian thực. Chính vì những lý do trên, nhóm quyết định lựa chọn giải pháp kiến trúc lai hiện đại, thiết lập một đường ống xử lý phân tầng chặt chẽ. Hệ thống sử dụng mô hình Two-Tower làm bộ lọc sơ cấp để tối ưu hóa tốc độ truy xuất ứng viên quy mô lớn, kết hợp với mô hình Cross-Encoder ở tầng trung gian để đánh giá mức độ giao thoa đặc trưng chi tiết, và cuối cùng tận dụng khả năng thấu hiểu sâu sắc của LLM cùng kỹ thuật RAG ở tầng tinh chỉnh tối hậu. Lựa chọn này được đánh giá là ưu việt nhất vì nó đạt được sự cân bằng lý tưởng: vừa đảm bảo hiệu năng vận hành nhanh chóng của hệ thống lớn, vừa tận dụng được trí tuệ của AI để giải quyết bài toán khởi động lạnh và cá nhân hóa trải nghiệm người dùng một cách chính xác nhất.

1.3 Đối tượng và Phạm vi nghiên cứu

Đối tượng nghiên cứu trung tâm của đề tài là các hệ thống gợi ý thể hệ mới trong thương mại điện tử, phản ánh xu hướng chuyển dịch mạnh mẽ từ các phương pháp lọc cộng tác dựa trên định danh đơn thuần sang các mô hình học sâu có khả năng nhận thức ngữ cảnh. Cụ thể, đề tài đi sâu vào phân tích ba khía cạnh cốt lõi cấu thành nên hệ thống. Đầu tiên là việc mô hình hóa chuỗi hành vi người dùng, tập trung khai thác sự diễn biến động của sở thích theo trục thời gian thông qua các trình tự tương tác liên tục như xem, mua hay đánh giá nhằm nắm bắt quy luật chuyển đổi nhu cầu ngắn hạn và dài hạn. Song song với đó là nghiên cứu cơ chế biểu diễn tri thức sản phẩm đa phương thức, cho phép máy tính thực sự thấu hiểu nội dung hàng hóa nhờ việc hợp nhất các luồng thông tin phức tạp từ thị giác, ngôn ngữ đến dữ liệu cấu trúc thay vì chỉ coi sản phẩm là các mã định danh vô nghĩa. Cuối cùng, đề tài tập trung vào cơ chế suy luận và xếp hạng lại, trong đó ứng dụng các Mô hình ngôn ngữ lớn như những tác nhân thông minh để đánh giá lại độ phù hợp dựa trên ngữ cảnh truy vấn phức tạp, qua đó đảm bảo kết quả gợi ý đạt được tính chính xác cao đi kèm với sự minh bạch trong lý do đề xuất.

Phạm vi thực hiện của đề tài được xác định rõ ràng thông qua ba khía cạnh chính bao gồm không gian ứng dụng, dữ liệu, công nghệ. Không gian nghiên cứu tập trung vào bối cảnh các nền tảng Thương mại điện tử, nơi dữ liệu thường mang đặc thù thưa thớt và chứa nhiều nhiễu, với mục tiêu tối ưu hóa trải nghiệm khám phá cho người dùng cuối. Để thực hiện điều này, đề tài giới hạn phạm vi dữ liệu vào việc khai thác nguồn thông tin đa

phương thức phong phú, kết hợp chặt chẽ giữa dữ liệu phi cấu trúc như văn bản mô tả, hình ảnh sản phẩm và dữ liệu có cấu trúc gồm lịch sử tương tác gần nhất thời gian. Trên nền tảng đó, nghiên cứu ứng dụng các công nghệ tiên tiến của Trí tuệ nhân tạo, trọng tâm là kỹ thuật Học sâu để trích xuất đặc trưng và các Mô hình ngôn ngữ lớn giúp thấu hiểu ý định người dùng.

1.4 Định nghĩa bài toán

Bài toán cụ thể được đặt ra trong nghiên cứu này là bài toán dự đoán và xếp hạng tuần tự dựa trên dữ liệu đa phương thức, nơi hệ thống phải đối mặt với thách thức xác định chính xác nhu cầu tiếp theo của người dùng trong không gian tìm kiếm khổng lồ của thương mại điện tử. Cụ thể, với đầu vào là chuỗi lịch sử tương tác tuần tự theo thời gian kết hợp cùng dữ liệu nội dung đa phương thức phong phú của sản phẩm như hình ảnh và văn bản mô tả, nhiệm vụ đặt ra là xây dựng một hàm mục tiêu tối ưu có khả năng xếp hạng hàng triệu ứng viên sao cho các sản phẩm ở vị trí đầu tiên có xác suất tương thích lớn nhất với ý định hiện tại của khách hàng. Điểm mấu chốt của bài toán không chỉ dừng lại ở việc khớp lệnh hành vi quá khứ, mà còn phải giải quyết triệt để mâu thuẫn giữa tính thừa thớt của dữ liệu tương tác và sự phong phú của dữ liệu ngữ nghĩa, đặc biệt trong các kịch bản khởi động lạnh khi thông tin hành vi hoàn toàn vắng bóng. Do đó, bài toán yêu cầu một cơ chế suy luận phức hợp, có khả năng chuyển đổi các tín hiệu phi cấu trúc thành các biểu diễn vector đồng nhất trong không gian tiềm ẩn để lấp đầy khoảng trống thông tin mà các phương pháp dựa trên ID truyền thống không thể xử lý được.

Quy trình vận hành tổng thể của hệ thống được thiết kế theo kiến trúc đường ống xử lý dữ liệu phân tầng, khởi tạo từ việc tiếp nhận đầu vào phức hợp bao gồm hồ sơ người dùng, chuỗi lịch sử tương tác thời gian thực và dữ liệu đa phương thức của sản phẩm như hình ảnh, mô tả văn bản chi tiết. Luồng thông tin này trước tiên được đưa qua tầng mã hóa đặc trưng để chuyển đổi thành các vector biểu diễn trong không gian tiềm ẩn, phục vụ cho giai đoạn truy xuất ứng viên. Tại đây, mô hình Two-Tower đóng vai trò bộ lọc sơ cấp, thực hiện quét nhanh trên không gian dữ liệu quy mô lớn để sàng lọc ra một tập hợp nhỏ các sản phẩm tiềm năng nhất dựa trên độ tương đồng vector. Ngay sau đó, tập ứng viên này được đưa qua mô hình Bộ mã hóa chéo để thực hiện bước đánh giá luân phiên và tính toán chi tiết mức độ giao thoa đặc trưng giữa người dùng và từng sản phẩm. Danh sách sau khi được chấm điểm và xếp hạng lại một lần nữa sẽ được chuyển giao cho phân hệ Mô hình ngôn ngữ lớn. Tại đây, công nghệ trí tuệ nhân tạo tạo sinh không chỉ đóng vai trò tinh chỉnh thứ hạng lần cuối dựa trên tri thức tổng quát, mà còn đảm nhiệm việc sinh ra các lời giải thích ngữ nghĩa minh bạch cho từng gợi ý. Kết quả đầu ra cuối cùng của hệ thống là một danh sách xếp hạng các sản phẩm có độ phù hợp cao nhất với ý định người dùng, được hiển thị trực quan đi kèm với các thông tin giải thích ngữ nghĩa minh bạch, giúp tối ưu hóa quyết định mua hàng một cách chính xác và thuyết phục.

Chương 2

Cơ sở lý thuyết


Chương 2 trình bày các cơ sở lý thuyết và các nghiên cứu liên quan đến quá trình xây dựng hệ thống.

2.1 Tổng quan về Hệ thống Gợi ý

Hệ thống gợi ý, hay còn được gọi là Recommender Systems - ResSys, được định nghĩa là một phân lớp của hệ thống lọc thông tin, có nhiệm vụ dự đoán mức độ quan tâm hoặc khả năng tương tác của người dùng đối với các thực thể. Dựa trên phương pháp tiếp cận dữ liệu, các hệ thống gợi ý truyền thống và hiện đại thường được phân loại thành ba nhóm chính: Lọc dựa trên nội dung, Lọc cộng tác và Hệ thống lai.

2.1.1 Tổng quan về các kỹ thuật gợi ý truyền thống

Trước sự bùng nổ của các kiến trúc học sâu đa phương thức, hệ thống gợi ý chủ yếu được xây dựng dựa trên hai trường phái tiếp cận cốt lõi: Lọc dựa trên nội dung và Lọc cộng tác. Mỗi phương pháp sở hữu những cơ chế định tuyến độc lập, mang lại những ưu thế riêng biệt nhưng đồng thời cũng bộc lộ những hạn chế mang tính hệ thống.



Phương pháp Lọc dựa trên nội dung, hay Content-Based Filtering, hoạt động dựa trên nguyên lý nhất quán về sở thích cá nhân. Kỹ thuật này trích xuất các đặc trưng nội tại của sản phẩm bao gồm văn bản, danh mục hoặc thương hiệu để xây dựng không gian vector, sau đó tính toán độ tương đồng với hồ sơ sở thích của người dùng [18]. Ưu điểm chiến lược của phương pháp này là khả năng giải quyết triệt để bài toán Khởi động lạnh cho sản phẩm mới. Tuy nhiên, thuật toán sẽ bộc lộ hạn chế trong năng lực phân tích nội dung khi tiếp cận với các mặt hàng yêu cầu cảm nhận chủ quan tinh tế, ví dụ như việc đánh giá mức độ hài hước của hai cuốn truyện cười, hoặc khi xử lý những dữ liệu phi cấu trúc phức tạp như phim ảnh. Đồng thời thuật toán này có hiện tượng chuyên biệt hóa quá mức tạo ra vòng lặp gợi ý nhàm chán và có rào cản khởi động lạnh đối với người dùng mới.

Trái ngược với cách tiếp cận trên, phương pháp Lọc cộng tác, thường được biết đến với thuật ngữ Collaborative Filtering [18], bỏ qua hoàn toàn nội dung sản phẩm để tập trung khai thác các mẫu hành vi ẩn trong cộng đồng. Dựa trên ma trận tương tác giữa người dùng và mặt hàng, hệ thống áp dụng phương pháp láng giềng gần nhất thuộc nhóm tiếp cận dựa trên bộ nhớ, hoặc vận dụng các kỹ thuật nén không gian ẩn như Phân rã ma trận thuộc nhóm tiếp cận dựa trên mô hình để tìm ra sự đồng điệu về sở thích. Sức mạnh lớn nhất của kỹ thuật này là khả năng mang lại tính khám phá cao, giúp đề xuất những sản phẩm xuyên danh mục một cách chính xác. Mặc dù mang lại hiệu suất vượt trội, sự phụ thuộc tuyệt đối vào lịch sử tương tác khiến Lọc cộng tác hoàn toàn tê liệt trước bài toán Khởi động lạnh cho cả người dùng lẫn sản phẩm mới. Đồng thời, hệ thống sẽ gặp hiện tượng suy giảm hiệu năng nghiêm trọng khi ma trận dữ liệu trở nên quá thưa thớt ở quy mô công nghiệp.

2.1.2 Hệ thống Gợi ý Lai

Sự ra đời của hệ thống gợi ý lai đánh dấu bước phát triển quan trọng nhằm khắc phục các hạn chế cố hữu khi triển khai độc lập phương pháp lọc cộng tác hoặc lọc dựa trên nội dung. Mục tiêu cốt lõi của hướng tiếp cận này là tối ưu hóa hiệu suất dự đoán thông qua việc tổng hợp sức mạnh từ cả dữ liệu hành vi người dùng và các thông tin đặc tả phong phú của sản phẩm. Trong giai đoạn trước khi học sâu trở nên phổ biến, các kiến trúc lai truyền thống thường được áp dụng dựa trên ba chiến lược kết hợp chủ đạo nhằm dung hòa các thuật toán nền tảng.

Đầu tiên là phương pháp lai trọng số, được xem là kỹ thuật cộng gộp đơn giản nhất trong các mô hình lai. Cơ chế vận hành của nó dựa trên việc triển khai song song các mô hình thành phần, sau đó tính toán điểm số xếp hạng cuối cùng bằng tổng có trọng số của các kết quả dự đoán riêng lẻ[18]. Mặc dù ưu điểm là dễ triển khai, phương pháp này gặp hạn chế lớn do giả định mỗi quan hệ giữa các mô hình luôn là tuyến tính và đòi hỏi quá trình tinh chỉnh tham số thủ công rất kỹ lưỡng để cân bằng hiệu quả giữa các thành phần.

Chiến lược thứ hai là phương pháp lai chuyển đổi, hoạt động tương tự như một cơ chế điều hướng thông minh dựa trên trạng thái dữ liệu thực tế. Hệ thống sẽ linh hoạt lựa chọn thuật toán phù hợp nhất cho từng ngữ cảnh cụ thể, điển hình là việc ưu tiên sử dụng lọc theo nội dung đối với người dùng mới để giải quyết vấn đề khởi động lạnh, sau đó tự động chuyển sang lọc cộng tác khi đã thu thập đủ lịch sử tương tác tin cậy[18]. Tuy nhiên, nhược điểm của chiến lược này nằm ở sự thiếu tính liên tục, dẫn đến trải nghiệm gợi ý có thể bị đứt gãy hoặc thiếu sự mượt mà trong quá trình chuyển giao giữa các mô hình.


Chiến lược kết hợp đặc trưng đại diện cho một bước chuyển dịch quan trọng trong kiến trúc hệ thống gợi ý lai, nơi ranh giới giữa dữ liệu nội dung và dữ liệu hành vi được xóa bỏ để hướng tới một không gian biểu diễn thống nhất. Khác với các phương pháp lai ghép lỏng lẻo như lai trọng số hay lai chuyển đổi vốn xử lý các mô hình thành phần một cách độc lập, phương pháp này chủ động hợp nhất các nguồn thông tin ngay từ giai đoạn đầu vào. Mục tiêu cốt lõi là làm giàu không gian đặc trưng, cho phép thuật toán học được sự tương quan chéo giữa các đặc tính nội tại của sản phẩm với hành vi tương tác của người dùng, thay vì chỉ dựa vào các mã định danh thừa thớt.

Kế thừa và phát triển tư duy này để giải quyết triệt để bài toán khởi động lạnh, Kula[20] đã giới thiệu mô hình LightFM, một kiến trúc lai hiệu quả kết hợp ưu điểm của cả lọc cộng tác và lọc theo nội dung. Điểm đột phá của LightFM nằm ở cơ chế biểu diễn vector linh hoạt, trong đó biểu diễn của một người dùng hoặc sản phẩm được xác định bằng tổng các vector nhúng của định danh và các vector nhúng của các thuộc tính mô tả đi kèm. Nhờ cơ chế cộng gộp này, hệ thống có khả năng suy luận độ tương đồng dựa trên các đặc điểm chung ngay cả khi sản phẩm đó chưa từng có lịch sử tương tác, đảm bảo luồng gợi ý được duy trì liên tục và chính xác cho các thực thể mới.

Tuy nhiên, mặc dù các phương pháp kết hợp đặc trưng như Factorization Machines hay LightFM đã đạt được những thành công nhất định, chúng vẫn tồn tại những hạn chế về khả năng biểu diễn các mẫu dữ liệu phức tạp. Như Cheng và cộng sự[21] đã phân tích trong công trình về kiến trúc Wide & Deep, các mô hình dựa trên tích vô hướng hoặc biến đổi tuyến tính thường thiên về khả năng ghi nhớ các mẫu đồng xuất hiện trong quá khứ nhưng lại hạn chế trong việc tổng quát hóa các mối quan hệ phi tuyến tính mức cao. Nhận định này đã mở đường cho sự phát triển của các kiến trúc mạng nơ-ron sâu hiện đại, nơi các lớp ẩn đa tầng được sử dụng để trích xuất và kết hợp đặc trưng một cách tinh vi hơn nhằm thấu hiểu sâu sắc ý định người dùng.

2.1.3 Hệ thống gợi ý đa giai đoạn

Trong bối cảnh các sàn thương mại điện tử hiện đại như Amazon, Alibaba hay Shopee đang lưu trữ hàng tỷ sản phẩm, việc xây dựng một hệ thống gợi ý vừa đảm bảo độ chính xác tuyệt đối, vừa đáp ứng được thời gian phản hồi theo thời gian thực là một thách thức cực kỳ lớn đối với các kỹ sư máy học. Nếu sử dụng một mô hình ngôn ngữ sâu sắc và phức tạp để tính toán độ tương quan cho toàn bộ kho dữ liệu mỗi khi người dùng thực hiện truy vấn, hệ thống sẽ gặp phải độ trễ không thể chấp nhận được, gây ảnh hưởng trực tiếp đến trải nghiệm và doanh thu. Để giải quyết mâu thuẫn giữa hiệu năng và độ chính xác, kiến trúc Gợi ý Đa giai đoạn đã ra đời và trở thành tiêu chuẩn công nghiệp phổ biến, giúp tối ưu hóa quá trình xử lý thông qua một cấu trúc hình phễu lọc giảm dần về số lượng nhưng tăng dần về độ tinh vi của thuật toán.



Hình 2.2: Kiến trúc hình phễu tiêu biểu của hệ thống gợi ý đa giai đoạn

Như hình 2.2, hệ thống không cố gắng tìm ra kết quả tốt nhất ngay lập tức mà chia quy trình thành các pha tách biệt, trong đó nổi bật nhất là sự phối hợp giữa hai giai đoạn then chốt: Truy xuất (Retrieval) và Xếp hạng lại (Ranking/Reranking). Cách tiếp cận này lần đầu tiên được phổ biến rộng rãi thông qua công trình nghiên cứu kinh điển của Covington và các cộng sự tại Google (2016) về hệ thống gợi ý cho YouTube [30]. Trong nghiên cứu này, các tác giả đã chỉ ra rằng việc sử dụng một mô hình đơn lẻ cho toàn bộ quy trình là không hiệu quả; thay vào đó, hệ thống cần một bộ lọc thô để loại bỏ hàng triệu thực thể không liên quan và những bộ lọc tinh phía sau để sắp xếp các ứng viên tiềm năng nhất vào vị trí hiển thị tối ưu.

Giai đoạn đầu tiên là Truy xuất đóng vai trò như một bộ lọc thô với nhiệm vụ sàng lọc nhanh chóng từ hàng triệu sản phẩm xuống còn khoảng vài trăm ứng viên. Tại giai đoạn này, tốc độ là yếu tố tiên quyết để đảm bảo tính thời gian thực. Kiến trúc chủ đạo thường được sử dụng là Bi-Encoder hay còn gọi là kiến trúc Two-Tower.

Trong kiến trúc này, tháp người dùng và tháp sản phẩm hoạt động độc lập, cho phép hệ thống tính toán trước và lưu trữ các embeddings của toàn bộ kho hàng vào cùng một không gian vector tiềm ẩn. Khi có truy vấn, hệ thống chỉ cần mã hóa câu lệnh người dùng và thực hiện các phép tính đại số đơn giản như tích vô hướng hoặc Cosine Similarity

thông qua các thuật toán tìm kiếm ANN. Điểm mạnh của Bi-Encoder là khả năng quét qua hàng triệu thực thể chỉ trong vài mili-giây. Tuy nhiên, do áp dụng cơ chế Late Interaction, nơi truy vấn và sản phẩm không hề trao đổi thông tin với nhau trong quá trình mã hóa, mô hình thường bỏ lỡ các sắc thái ngữ nghĩa giao thoa chi tiết giữa hai đối tượng.

Ngay sau khi có được danh sách ứng viên từ pha Truy xuất, hệ thống chuyển sang giai đoạn Xếp hạng lại để thực hiện những tính toán chuyên sâu hơn trên tập dữ liệu đã được thu hẹp (thường từ vài chục đến vài trăm sản phẩm như mô tả trong sơ đồ hình phần). Đây là giai đoạn mà độ chính xác được đặt lên hàng đầu nhằm đảm bảo những sản phẩm phù hợp nhất với ý định người dùng và cá nhân hóa sâu sắc sẽ được hiển thị ở những vị trí đầu tiên. Kiến trúc hiệu quả nhất cho giai đoạn này là Cross-Encoder. Khác với Bi-Encoder, Cross-Encoder nhận đầu vào là sự kết hợp đồng thời giữa câu truy vấn và thông tin sản phẩm, cho phép cơ chế Self-Attention của Transformer thực hiện Tương tác sớm. Từng token trong câu lệnh của người dùng có thể soi chiếu và tương tác trực tiếp với từng đặc trưng của sản phẩm ở mọi tầng của mạng nơ-ron. Cơ chế này giúp mô hình nắm bắt được những mối liên hệ ẩn ý, sự tương đồng ngữ nghĩa phức tạp và đặc biệt là khả năng cá nhân hóa dựa trên lịch sử hành vi mua sắm. Việc áp dụng Cross-Encoder ở giai đoạn Reranking giúp hệ thống đạt được sự tối ưu về mặt chất lượng, vì lúc này mô hình chỉ phải xử lý một lượng nhỏ ứng viên, cho phép sử dụng các kiến trúc nặng nề và phức tạp mà vẫn đảm bảo thời gian phản hồi tổng thể.

Sự kết hợp giữa Two-Tower và Cross-Encoder tạo nên một hệ chỉnh thể hoàn chỉnh, giúp hệ thống gợi ý vừa có thể quét qua quy mô dữ liệu khổng lồ, vừa có thể đưa ra những đề xuất mang tính cá nhân hóa cao độ. Kế thừa và tuân thủ trọn vẹn triết lý đa giai đoạn đó, đồ án này tiến hành triển khai kiến trúc Bi-Encoder làm nền tảng cho giai đoạn Truy xuất nhằm khoanh vùng tập ứng viên nhanh chóng, và áp dụng mô hình Cross-Encoder được tích hợp thêm các thành phần hỗ trợ cho giai đoạn Xếp hạng lại. Việc ứng dụng cơ chế này ở pha cuối đóng vai trò như một mảnh ghép chiến lược, bởi nó không chỉ giữ được sức mạnh tương tác ngữ nghĩa sâu của Cross-Encoder truyền thống mà còn tích hợp được cơ chế Item Memory, từ đó tận dụng tối đa sức mạnh biểu diễn của mô hình ngôn ngữ trong việc cá nhân hóa sâu sắc nhu cầu của từng người dùng cuối.

2.2 Các Hàm Mục tiêu

Trong các hệ thống gợi ý hiện đại và tìm kiếm ngữ nghĩa, mục tiêu của học biểu diễn là học một hàm ánh xạ f để đưa các thực thể (người dùng, sản phẩm) vào một không gian vector sao cho các thực thể có mối quan hệ tương quan sẽ nằm gần nhau về mặt hình học (độ tương đồng Cosine cao hoặc khoảng cách L2 thấp).

Để tối ưu hóa không gian này, việc lựa chọn hàm mục tiêu đóng vai trò then chốt. Nhóm đã nghiên cứu và triển khai ba nhóm hàm mục tiêu chính: Triplet Loss, InfoNCE (Contrastive Loss) và Cross-Entropy Loss.

2.2.1 Triplet Loss

Được phổ biến rộng rãi bởi Schroff và đồng nghiệp[23] trong mô hình FaceNet cho bài toán nhận diện khuôn mặt, Triplet Loss là nền tảng của học sâu metric. Thay vì dự đoán xác suất, phương pháp này hướng tới việc tối ưu hóa khoảng cách hình học trong không gian vector. Mô hình nhận đầu vào là một bộ ba (A, P, N) bao gồm: Anchor (Mẫu gốc),

Positive (Mẫu cùng loại/người dùng thích) và Negative (Mẫu khác loại). Mục tiêu là đảm bảo khoảng cách giữa Anchor và Positive phải nhỏ hơn khoảng cách giữa Anchor và Negative một đoạn biên độ an toàn α :

$$\mathcal{L}_{\text{Triplet}} = \sum \max(0, d(A, P)^2 - d(A, N)^2 + \alpha) \quad (2.1)$$

Mặc dù giải quyết tốt vấn đề về thứ tự xếp hạng, Triplet Loss đối mặt với thách thức lớn về sự hội tụ. Hiệu suất của hàm này phụ thuộc cực đoan vào chiến lược lấy mẫu. Nếu chọn các mẫu âm quá dễ - tức là các sản phẩm hoàn toàn không liên quan, gradient sẽ nhanh chóng tiến về 0 và mô hình ngừng học. Ngược lại, việc tìm kiếm các mẫu âm khó Hard Negative Mining lại đòi hỏi chi phí tính toán rất lớn, làm chậm quá trình huấn luyện.

2.2.2 InfoNCE

InfoNCE (Information Noise-Contrastive Estimation) hay còn gọi là Contrastive loss, được chuẩn hóa trong kiến trúc SimCLR hay Two-Tower của Google[8]. Thay vì chỉ so sánh một cặp $P - N$ duy nhất như Triplet Loss, InfoNCE coi bài toán là việc tìm đúng mẫu Positive trong một tập hợp gồm nhiều mẫu Negative.

Công thức toán học của InfoNCE:

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(u, i^+)/\tau)}{\sum_{j=1}^K \exp(\text{sim}(u, i_j)/\tau)} \quad (2.2)$$

Trong đó $\text{sim}(\cdot)$ là độ tương đồng Cosine, τ là tham số nhiệt độ để điều chỉnh độ nhạy của hàm phân phối xác suất.

Ứng dụng trong đồ án: Nhóm triển khai phiên bản **Symmetric Contrastive Loss**. Trong mỗi batch huấn luyện, các sản phẩm của những người dùng khác trong lô huấn luyện sẽ đóng vai trò là mẫu âm tính trong lô. Phương pháp này cho phép mô hình tận dụng tối đa dữ liệu ngay trong batch để tối ưu hóa, tăng tốc độ hội tụ và giúp không gian Embedding đạt được tính đồng nhất.

2.2.3 Symmetric Explicit Contrastive Loss

Dựa trên đặc thù của dữ liệu thương mại điện tử Amazon, việc chỉ sử dụng các mẫu âm tính ngẫu nhiên (những sản phẩm người dùng chưa từng biết tới) là chưa đủ để mô hình học được ranh giới sở thích tinh tế. Nhóm đề xuất sử dụng thêm **Explicit Negatives** được trích xuất trực tiếp từ lịch sử đánh giá của người dùng.

Trong đồ án này, tập dữ liệu tương tác được phân loại dựa trên mức độ hài lòng thực tế:

- **Mẫu Positive:** Các sản phẩm đã tương tác và được người dùng đánh giá từ 3 sao trở lên (≥ 3). Đây là những sản phẩm thể hiện sự phù hợp với sở thích của người dùng.
- **Mẫu Explicit Negative:** Các sản phẩm người dùng đã mua nhưng đánh giá thấp (1 hoặc 2 sao). Khác với các mẫu âm tính ngẫu nhiên, đây là những tín hiệu từ chối mạnh, cho thấy người dùng thực sự không hài lòng với các thuộc tính của sản phẩm đó.

Trong hàm Loss này, bên cạnh các mẫu âm tính trong batch, nhóm đưa thêm các sản phẩm 1-2 sao này vào làm mẫu âm tính cứng. Công thức được mở rộng bằng cách nối kết điểm số của Explicit Negatives vào tập hợp logits trước khi đưa qua hàm Softmax:

$$\text{logits}_{combined} = [\text{sim}(q, p), \text{sim}(q, n_1), \dots, \text{sim}(q, n_K), \text{sim}(q, n_{explicit})] \quad (2.3)$$

Việc bổ sung này buộc mô hình phải học cách phân biệt sự khác biệt giữa sản phẩm người dùng yêu thích và sản phẩm họ ghét, thay vì chỉ phân biệt giữa thứ họ thích và thứ họ chưa biết". Kết quả là không gian vector được tinh chỉnh để đẩy người dùng ra xa khỏi những vùng không gian chứa các thuộc tính sản phẩm không phù hợp, nâng cao độ chính xác cho hệ thống gợi ý.

2.2.4 Binary Cross Entropy

Đây là hàm mất mát tiêu chuẩn được áp dụng rộng rãi trong các bài toán dự đoán tỷ lệ nhấp (CTR Prediction) và các mô hình Lọc cộng tác nơ-ron như đề xuất của Xiangnan He và cộng sự[22], nó cũng được sử dụng trong kiến trúc SASRec của Wang-Cheng Kang và Julian McAuley[7]. Dưới góc độ tiếp cận theo điểm Pointwise Approach, hàm mục tiêu này chuyển đổi bài toán gợi ý thành bài toán phân loại nhị phân, trong đó mô hình xem xét mỗi cặp người dùng - sản phẩm (u, i) như một biến cố độc lập. Mục tiêu là tối thiểu hóa sai số giữa nhãn thực tế y_{ui} (nhận giá trị 1 nếu có tương tác, 0 nếu không) và xác suất dự đoán p_{ui} của mô hình:

$$\mathcal{L}_{BCE} = - \sum_{(u,i) \in \mathcal{D}} [y_{ui} \cdot \log(p_{ui}) + (1 - y_{ui}) \cdot \log(1 - p_{ui})] \quad (2.4)$$

Trong đồ án, BCE Loss đóng vai trò là hàm mục tiêu cho giai đoạn Reranking. Sau khi Bi-Encoder thực hiện truy xuất thô để lọc ra Top-K sản phẩm tiềm năng với tốc độ cao, Cross-Encoder sẽ đánh giá lại các cặp (User, Item) này một cách kỹ lưỡng bằng BCE Loss để tinh chỉnh thứ hạng cuối cùng. Sự kết hợp này mang lại độ chính xác tối đa trước khi hệ thống trả kết quả gợi ý cho người dùng.

2.3 Kiến trúc nền tảng: Transformer

Năm 2017 đánh dấu một bước ngoặt lịch sử trong lĩnh vực trí tuệ nhân tạo khi kiến trúc Transformer chính thức được giới thiệu thông qua bài báo Attention Is All You Need [12]. Khác biệt hoàn toàn so với các mạng nơ-ron tuần tự truyền thống vốn bị giới hạn bởi nút thắt cổ chai về tính toán và suy giảm khả năng ghi nhớ dài hạn, Transformer loại bỏ hoàn toàn các lớp truy hồi để phụ thuộc tuyệt đối vào cơ chế sự chú ý. Bước đột phá này cho phép mô hình xử lý dữ liệu song song trên quy mô khổng lồ, đồng thời thấu hiểu chính xác các mối quan hệ ngữ nghĩa xuyên suốt toàn bộ chuỗi đầu vào. Sự ra đời của kiến trúc ưu việt này không chỉ kiến tạo nền móng vững chắc cho các mô hình ngôn ngữ lớn hiện đại mà còn trực tiếp tái định hình phương pháp luận trong việc trích xuất đặc trưng đa phương thức đối với các hệ thống gợi ý tiên tiến.

2.3.1 Cơ chế Scaled Dot-Product Self-Attention

Cơ chế vận hành cốt lõi tạo nên sức mạnh của các kiến trúc hiện đại là kỹ thuật Scaled Dot-Product Self-Attention. Về mặt toán học, với đầu vào là một chuỗi các vector nhúng $X \in \mathbb{R}^{n \times d}$, mô hình thực hiện phép chiếu không gian để biến X thành ba ma trận thành phần bao gồm: Truy vấn Q , Khóa K và Giá trị V . Quá trình tính toán trọng số sự chú ý được định nghĩa thông qua công thức:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.5)$$

Trong biểu thức này, tích vô hướng QK^T đại diện cho mức độ tương đồng ngữ nghĩa, xác định mức độ mà mỗi phần tử cần chú ý đến các phần tử khác để cập nhật biểu diễn của chính nó. Đáng chú ý, phép chia cho căn bậc hai của chiều vector khóa $\sqrt{d_k}$ đóng vai trò là một kỹ thuật chuẩn hóa thiết yếu. Khi chiều dữ liệu d_k lớn, giá trị tích vô hướng có xu hướng tăng trưởng mạnh về độ lớn, đẩy hàm Softmax vào vùng bão hòa nơi gradient tiệm cận 0, gây trở ngại cho quá trình tối ưu hóa. Việc chia tỷ lệ giúp ổn định phương sai của điểm số attention, đảm bảo mạng nơ-ron hội tụ hiệu quả hơn.

2.3.2 Cơ chế Multi-Head Attention

Tiếp nối cơ chế tự chú ý cốt lõi, Multi-Head Attention là một bước tiến kiến trúc quan trọng giúp mạng nơ-ron Transformer khắc phục giới hạn của việc chỉ có một góc nhìn duy nhất đối với dữ liệu đầu vào. Thay vì thực hiện một phép tính Softmax duy nhất trên các ma trận kích thước lớn, hệ thống sử dụng các ma trận trọng số riêng biệt để chiếu Q , K và V xuống các chiều dữ liệu nhỏ hơn, tạo thành h đầu chú ý hoạt động song song.

Công thức tổng quát của cơ chế này được biểu diễn như sau:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (2.6)$$

Trong đó, mỗi đầu chú ý head_i được tính toán hoàn toàn độc lập thông qua phép nhân với các ma trận trọng số tương ứng W_i^Q , W_i^K , W_i^V :

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2.7)$$

Sau khi tất cả các đầu hoàn thành quá trình tính toán, kết quả của chúng được ghép nối lại với nhau bằng toán tử Concat để tạo thành một vector biểu diễn tổng hợp. Cuối cùng, vector này được nhân với một ma trận trọng số đầu ra W^O nhằm khôi phục lại kích thước chiều ban đầu. Sự ưu việt của phương pháp này nằm ở chỗ nó cho phép mô hình thấu hiểu ngôn ngữ ở cấp độ đa chiều, trong đó mỗi đầu chú ý có thể tự do bắt sóng một khía cạnh ngữ nghĩa hoặc một quy luật đặc thù khác nhau của luồng dữ liệu.

2.3.3 Cơ chế Mã hóa Vị trí

Một giới hạn đặc thù của các kiến trúc dựa trên sự chú ý thuần túy là tính bất biến với thứ tự. Phép toán tích vô hướng trong Self-Attention coi chuỗi đầu vào như một tập hợp các


phần tử không có cấu trúc tuần tự, dẫn đến việc mô hình hoàn toàn mất đi nhận thức về vị trí tương đối hoặc tuyệt đối của dữ liệu. Nhược điểm này là một trở ngại chí mạng đối với các bài toán yêu cầu tính thứ tự nghiêm ngặt như xử lý ngôn ngữ tự nhiên hay dự đoán chuỗi hành vi người dùng.

Để khắc phục, kiến trúc Transformer tích hợp thêm một cơ chế Mã hóa Vị trí, tên tiếng Anh là Positional Encoding. Phương pháp này hoạt động bằng cách cộng trực tiếp một vector thông tin vị trí vào vector nhúng đặc trưng của từng phần tử đầu vào trước khi truyền vào mạng nơ-ron. Biểu diễn toán học của tín hiệu vị trí này thường được khởi tạo thông qua các hàm lượng giác chu kỳ:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2.8)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2.9)$$

Trong đó, pos đại diện cho vị trí của phần tử trong chuỗi, i là chỉ số chiều của vector và d_{model} là tổng số chiều của không gian biểu diễn. Thông qua việc sử dụng các hàm sin và cosin với tần số biến thiên, cơ chế này ép mỗi tọa độ vị trí sinh ra một mẫu vector duy nhất. Khi được dung hợp vào dữ liệu gốc, nó cung cấp cho mô hình một hệ quy chiếu không gian và thời gian chuẩn xác, cho phép các đầu chú ý dễ dàng tính toán khoảng cách và nắm bắt quy luật tuần tự của chuỗi hành vi mà không làm thay đổi kiến trúc song song lõi của hệ thống.



Hình 2.3: Minh họa trực quan giá trị Positional Encoding trên 4 chiều ẩn đầu tiên. Các đường cong hình sin với tần số khác nhau giúp mô hình phân biệt vị trí trong chuỗi.

Hình 2.3 minh họa trực quan sự biến thiên giá trị của vector mã hóa vị trí trên bốn chiều ẩn đầu tiên đối với một chuỗi có độ dài 16 bước. Các đồ thị cho thấy hàm lượng giác dao động trong khoảng từ -1 đến 1 với tần số khác nhau tùy thuộc vào chỉ số của chiều không gian. Cụ thể, các chiều có chỉ số thấp thể hiện tần số dao động cao, trong khi các chiều cao hơn sở hữu bước sóng dài hơn. Cơ chế biến đổi tần số này kiến tạo nên một

mẫu hình đặc trưng riêng biệt cho mỗi vị trí *pos*, hỗ trợ mô hình Transformer dễ dàng học được mối quan hệ vị trí tương đối giữa các token trong chuỗi.

2.4 Biểu diễn Đa phương thức


Trong kỷ nguyên dữ liệu lớn, thông tin về sản phẩm không còn bị giới hạn ở các mã định danh hay thuộc tính cấu trúc đơn giản, mà đã mở rộng sang các dạng dữ liệu phi cấu trúc phong phú như văn bản mô tả và hình ảnh minh họa. Học đa phương thức là phương pháp tiếp cận tiên tiến cho phép hệ thống tri nhận và thấu hiểu sâu sắc nội dung sản phẩm, từ đó xây dựng các vector biểu diễn embeddings giàu ngữ nghĩa. Cách tiếp cận này đặc biệt hiệu quả trong việc giải quyết bài toán cold-start đối với các sản phẩm mới chưa có lịch sử tương tác. Để khai thác hai luồng thông tin quan trọng nhất là ngôn ngữ và thị giác, đồ án áp dụng hai kiến trúc nền tảng đã chứng minh được hiệu quả vượt trội trong lĩnh vực này, lần lượt là BERT cho xử lý văn bản và ViT cho xử lý hình ảnh.

2.4.1 Biểu diễn Văn bản: BERT

Sự xuất hiện của mô hình BERT (Bidirectional Encoder Representations from Transformers)[14] đã tạo ra một bước tiến quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên, đặc biệt là ứng dụng trong việc trích xuất đặc trưng văn bản cho các hệ thống gợi ý hiện đại. Trước khi các mô hình ngôn ngữ lớn trở nên phổ biến, các phương pháp nhúng từ truyền thống như Word2Vec[15] hay GloVe chủ yếu dựa trên cơ chế tạo ra các vector nhúng tĩnh. Hạn chế căn bản của cách tiếp cận này là việc gán một vector biểu diễn cố định duy nhất cho mỗi từ vựng, bất kể sự biến thiên về ngữ nghĩa trong các ngữ cảnh khác nhau.

Vấn đề này trở nên đặc biệt nghiêm trọng trong miền dữ liệu thương mại điện tử, nơi các từ khóa thường mang tính đa nghĩa cao. Điển hình như từ khóa "Chuột", ngữ nghĩa của nó thay đổi hoàn toàn khi xuất hiện trong cụm "Chuột máy tính Logitech" thuộc danh mục thiết bị điện tử so với cụm "Thuốc diệt chuột" thuộc danh mục hóa phẩm. Các mô hình tĩnh như Word2Vec không thể phân tách sự khác biệt này, dẫn đến sai lệch trong việc tính toán độ tương đồng sản phẩm. Ngược lại, BERT khắc phục triệt để nhược điểm trên thông qua cơ chế tạo ra các vector nhúng động, cho phép biểu diễn chính xác ngữ nghĩa của từ dựa trên sự phụ thuộc vào các từ lân cận trong câu.

Về mặt kiến trúc, BERT được xây dựng dựa trên sự chồng xếp của các lớp mã hóa trong kiến trúc Transformer. Khác biệt so với các mô hình tự hồi quy như GPT vốn chỉ xử lý thông tin đơn chiều từ trái sang phải, BERT áp dụng cơ chế Mô hình hóa ngôn ngữ che mặt nạ (Masked Language Modeling - MLM). Cơ chế này cho phép mô hình tiếp nhận và tổng hợp luồng thông tin ngữ cảnh hai chiều đồng thời, giúp nắm bắt cấu trúc cú pháp và ngữ nghĩa sâu sắc hơn. Như được minh họa chi tiết trong Hình 2.4 [14], quy trình vận hành của BERT được chia thành hai giai đoạn kế tiếp nhau trên cùng một nền tảng kiến trúc thống nhất.



Hình 2.4: Quy trình Tiền huấn luyện và Tinh chỉnh của BERT.

Giai đoạn Tiền huấn luyện

Giai đoạn tiền huấn luyện đóng vai trò nền tảng trong quy trình xây dựng mô hình, tại đó hệ thống tiếp thu các biểu diễn ngôn ngữ tổng quát thông qua việc khai thác khối lượng lớn dữ liệu văn bản thô chưa được gán nhãn. Quá trình học tập này vận hành dựa trên cơ chế tự giám sát, tập trung tối ưu hóa đồng thời hai tác vụ cốt lõi nhằm nắm bắt sâu sắc cấu trúc ngôn ngữ.

Đầu tiên là tác vụ Masked Language Modeling - MLM. Khác với phương pháp dự đoán từ tiếp theo theo tuần tự truyền thống, tác vụ này yêu cầu hệ thống phải khôi phục và tái tạo chính xác các đơn vị từ vựng đã bị che khuất ngẫu nhiên trong câu. Cơ chế này buộc mô hình phải tổng hợp và thấu hiểu ngữ cảnh hai chiều từ cả phía trước và phía sau của từ mục tiêu để đưa ra suy luận hợp lý nhất. Song song với đó là tác vụ dự đoán câu tiếp theo hay NSP, được thiết kế nhằm mục đích giúp mô hình thấu hiểu mối quan hệ logic và sự liên kết giữa các đoạn văn bản. Cụ thể, hệ thống học cách xác định xem một câu B bất kỳ có phải là câu nối tiếp thực tế về mặt ngữ nghĩa của câu A hay không, qua đó nắm bắt được cấu trúc diễn ngôn ở cấp độ cao hơn so với việc chỉ xử lý các từ ngữ riêng lẻ.

Giai đoạn Tinh chỉnh

Giai đoạn tinh chỉnh đóng vai trò là bước chuyển giao tri thức quan trọng, nơi mô hình áp dụng các biểu diễn ngôn ngữ tổng quát đã học được vào các tác vụ hạ nguồn cụ thể. Về mặt quy trình, thay vì khởi tạo ngẫu nhiên, mô hình kế thừa toàn bộ trọng số tham số từ giai đoạn tiền huấn luyện làm điểm bắt đầu, sau đó tiến hành tối ưu hóa tiếp tục trên các tập dữ liệu có gán nhãn chuyên biệt. Điểm mấu chốt là toàn bộ các tham số của mạng lưới đều được cập nhật đồng bộ trong quá trình này để thích nghi tốt nhất với đặc thù của từng bài toán riêng biệt. Trong phạm vi của hệ thống gợi ý, thay vì giải quyết các tác vụ ngôn ngữ tổng quát, quá trình tinh chỉnh được thiết kế chuyên biệt nhằm tối ưu hóa khả năng đọc hiểu tiêu đề và mô tả mặt hàng. Mục tiêu cuối cùng là trích xuất ra các vector đặc trưng văn bản chứa đựng trọn vẹn ngữ nghĩa sản phẩm, phục vụ trực tiếp cho việc xây dựng tháp sản phẩm.

Một đặc điểm kiến trúc nổi bật tạo nên sự thành công của BERT chính là tính nhất quán về cấu trúc. Hệ thống duy trì nguyên vẹn khối kiến trúc mã hóa Transformer đa tầng xuyên suốt quá trình huấn luyện sơ bộ và tinh chỉnh, đảm bảo luồng xử lý thông tin không bị gián đoạn. Sự thay đổi duy nhất chỉ diễn ra ở lớp đầu ra cuối cùng, nơi được thiết kế lại linh hoạt để tương thích với định dạng dự đoán của từng tác vụ đích, giúp mô hình đạt được hiệu suất cao mà không cần thay đổi đáng kể về mặt cấu trúc lõi.

Về cơ chế xử lý cốt lõi, thay vì sử dụng các mạng truy hồi truyền thống, BERT kế thừa trực tiếp sức mạnh từ kiến trúc Multi-Head Self-Attention đã được phân tích chi tiết tại Mục 2.3.1. Điểm đột phá của mô hình nằm ở cách khai thác cơ chế sự chú ý này theo hướng hai chiều triệt để. Bằng việc tính toán trọng số thông qua các khối ma trận Truy vấn, Khóa và Giá trị, mỗi token trong câu đầu vào đều có khả năng quan sát và thu thập ngữ cảnh trực tiếp từ tất cả các token còn lại ở cả phía trước và phía sau nó cùng một lúc.

Đồng thời, việc tận dụng kiến trúc chú ý đa đầu cho phép BERT tri giác thông tin văn bản từ nhiều không gian biểu diễn song song. Sự phân công nhiệm vụ tự động giữa các đầu chú ý, ví dụ một đầu chuyên bóc tách cấu trúc cú pháp trong khi đầu khác rà soát mối liên kết từ vựng tầm xa, giúp vector đầu ra của mô hình hội tụ đầy đủ các sắc thái ngôn ngữ. Nhờ sự kế thừa chặt chẽ này, BERT tạo ra các biểu diễn văn bản mang độ sâu ngữ nghĩa vượt trội, đáp ứng hoàn hảo yêu cầu khắt khe về việc thấu hiểu mô tả sản phẩm trong kiến trúc truy xuất đa phương thức.

Trong ngữ cảnh cụ thể của hệ thống gợi ý, mục tiêu đặt ra là thu được một vector đại diện duy nhất cho toàn bộ văn bản đầu vào. Để thực hiện điều này, BERT bổ sung một token đặc biệt ký hiệu là [CLS] vào vị trí đầu tiên của chuỗi. Sau khi đi qua toàn bộ các lớp mã hóa Transformer, vector đầu ra tương ứng với vị trí [CLS] này được coi là biểu diễn tổng hợp tinh túy nhất của cả câu:

$$h_{[\text{CLS}]} = \text{BERT}(x_1, \dots, x_n) \quad (2.10)$$

Vector $h_{[\text{CLS}]}$ này có khả năng nắm bắt được các đặc trưng ngữ nghĩa bậc cao như danh mục sản phẩm, tính năng nổi bật hay sắc thái cảm xúc trong bài đánh giá, mang lại hiệu quả vượt trội so với các phương pháp biểu diễn thô sơ như *Bag-of-Words* truyền thống.

2.4.2 Biểu diễn Hình ảnh: ViT


Trong giai đoạn trước năm 2020, các kiến trúc mạng nơ-ron tích chập, viết tắt là CNN, với những đại diện tiêu biểu như ResNet hay EfficientNet được xem là chuẩn mực hàng đầu cho các tác vụ thị giác máy tính. Thành công này chủ yếu bắt nguồn từ khả năng khai thác hiệu quả các thiên kiến quy nạp về tính cục bộ và tính bất biến tịnh tiến đặc trưng của dữ liệu hình ảnh. Đối lập với bức tranh đó, kiến trúc Transformer[12] lại đang khẳng định vị thế độc tôn và tạo ra những bước tiến vượt bậc trong lĩnh vực xử lý ngôn ngữ tự nhiên.

Bối cảnh công nghệ này đã thúc đẩy sự ra đời của Vision Transformer, hay còn gọi là ViT, nhằm giải quyết câu hỏi khoa học về tính khả thi của việc áp dụng trực tiếp kiến trúc Transformer thuần túy lên dữ liệu thị giác. Cách tiếp cận của ViT mang tính đột phá khi loại bỏ hoàn toàn sự phụ thuộc vào các lớp tích chập truyền thống để chuyển sang mô hình hóa bức ảnh dưới dạng một chuỗi các phần tử tuần tự, tương tự như cơ chế xử lý các đoạn văn bản.

Quyết định thay thế mạng tích chập truyền thống bằng kiến trúc Vision Transformer được củng cố bởi nghiên cứu mang tính đột phá của Dosovitskiy và cộng sự[11]. Trong công trình này, nhóm tác giả đã chứng minh tính khả thi và hiệu quả vượt trội của việc áp dụng cơ chế tự chú ý trực tiếp lên dữ liệu hình ảnh quy mô lớn. Thay vì phụ thuộc vào các thiên kiến quy nạp về tính cục bộ như trong mạng ResNet hay EfficientNet, phương pháp này xử lý bức ảnh như một chuỗi các mảnh ghép độc lập, cho phép mô hình nắm bắt được các mối quan hệ ngữ nghĩa toàn cục giữa các vùng ảnh xa nhau ngay từ những lớp đầu tiên.

Rào cản kỹ thuật lớn nhất khi chuyển giao kiến trúc Transformer từ miền dữ liệu chuỗi sang dữ liệu hình ảnh nằm ở gánh nặng tính toán khổng lồ. Do cơ chế tự chú ý sở hữu độ phức tạp thuật toán bậc hai $\mathcal{O}(N^2)$ tỷ lệ thuận với số lượng phần tử đầu vào N , việc mô hình hóa trực tiếp từng điểm ảnh đơn lẻ như một đơn vị *token* sẽ dẫn đến sự bùng nổ về chi phí tài nguyên. Đơn cử, một hình ảnh có kích thước tiêu chuẩn 224×224 sẽ tạo ra một chuỗi đầu vào lên tới 50.176 phần tử, khiến việc xây dựng ma trận chú ý trở nên bất khả thi đối với năng lực phần cứng hiện tại.

Mô hình Vision Transformer giải quyết triệt để vấn đề này thông qua kỹ thuật phân mảnh hay còn gọi là *Patching*. Quy trình xử lý bắt đầu bằng việc chia nhỏ hình ảnh đầu vào $I \in \mathbb{R}^{H \times W \times C}$ thành một lưới các vùng cục bộ không chồng lấn có kích thước cố định $P \times P$, tạo ra tổng cộng $N = \frac{HW}{P^2}$ mảnh con. Tiếp theo, mỗi mảnh ảnh này được trải phẳng thành một vector một chiều và được đưa qua một phép chiếu tuyến tính có thể học được để ánh xạ vào không gian biểu diễn tiềm ẩn với số chiều D . Cuối cùng, nhằm mục đích khôi phục và bảo toàn thông tin về cấu trúc không gian vốn bị phá vỡ trong quá trình trải phẳng, các vector mã hóa vị trí E_{pos} được cộng bổ sung trực tiếp vào các vector đặc trưng của từng mảnh trước khi đưa vào khối mã hóa Transformer. Quy trình xử lý chi tiết được mô tả trực quan thông qua Hình 2.5 [11].



Hình 2.5: Sơ đồ kiến trúc Vision Transformer.

Bước tiếp theo là việc khởi tạo token phân loại. Một vector tham số có thể học được, thường được ký hiệu là token lớp, được chèn vào vị trí đầu tiên của chuỗi các vector mảnh ảnh. Token đặc biệt này đóng vai trò như một bộ thu nhận thông tin toàn cục; sau khi đi qua toàn bộ mạng nơ-ron, trạng thái đầu ra tại vị trí này sẽ được sử dụng làm đại diện tổng quát duy nhất cho toàn bộ bức ảnh, tương tự như cơ chế của token CLS trong mô hình ngôn ngữ BERT.

Chuỗi vector kết hợp này sau đó được đưa vào khối mã hóa Transformer Encoder, bao gồm nhiều lớp xử lý lặp lại liên tiếp. Trong mỗi lớp, cơ chế chú ý đa đầu đóng vai trò hạt nhân, cho phép mỗi mảnh ảnh có khả năng quan sát và liên kết ngữ nghĩa với tất cả các mảnh ảnh khác, bất kể khoảng cách không gian giữa chúng. Dữ liệu sau đó tiếp tục đi qua mạng nơ-ron truyền thẳng MLP để trích xuất các đặc trưng bậc cao. Để đảm bảo sự ổn định và khả năng hội tụ của quá trình huấn luyện sâu, kỹ thuật chuẩn hóa lớp Layer Normalization được áp dụng trước mỗi khối chức năng, kết hợp cùng các kết nối

tất nhằm duy trì dòng chảy thông tin và hạn chế hiện tượng triệt tiêu đạo hàm.


Cuối cùng, tại lớp đầu ra của khối mã hóa, chỉ duy nhất vector ứng với vị trí của token phân loại được trích xuất. Vector này mang trong mình thông tin ngữ nghĩa cô đọng nhất của bức ảnh và được đưa vào khối MLP Head để thực hiện các tác vụ đích như phân loại đối tượng hoặc tạo vector biểu diễn cho hệ thống gợi ý.

Sự khác biệt nền tảng định hình nên ưu thế của Vision Transformer so với mạng tích chập CNN nằm ở bản chất của trường tiếp nhận thông tin. Đối với các mạng tích chập truyền thống, trường tiếp nhận mang tính chất cục bộ nghiêm ngặt, nghĩa là các lớp tích chập khởi đầu chỉ có khả năng ghi nhận và xử lý tín hiệu từ các điểm ảnh lân cận. Sự tổng hợp thông tin toàn cục chỉ có thể đạt được một cách gián tiếp và thụ động thông qua quá trình chồng xếp nhiều lớp mạng sâu nhằm mở rộng dần vùng quan sát. Ngược lại, Vision Transformer tận dụng sức mạnh của cơ chế tự chú ý để phá vỡ giới hạn không gian này. Ngay từ lớp xử lý đầu tiên, mỗi mảnh ảnh đã thiết lập được sự tương tác trực tiếp với tất cả các mảnh ảnh khác, cho phép mô hình có cái nhìn toàn cảnh tức thời về đối tượng.

Đặc tính kỹ thuật này mang lại ý nghĩa quan trọng trong ngữ cảnh của bài toán gợi ý sản phẩm, đặc biệt đối với các ngành hàng đề cao tính thẩm mỹ như thời trang hay nội thất. Trong những lĩnh vực này, vẻ đẹp và giá trị của sản phẩm thường không chỉ nằm ở các chi tiết riêng lẻ mà phụ thuộc vào bố cục tổng thể cùng sự phối hợp giữa các thành phần nằm cách xa nhau, chẳng hạn như sự tương thích giữa cổ áo và gấu váy hay sự đồng điệu giữa màu sắc giày và họa tiết thương hiệu. Năng lực thấu hiểu các mối quan hệ ngữ nghĩa toàn cục và phức tạp này cho phép Vision Transformer trích xuất được các vector đặc trưng giàu thông tin hơn, mang lại hiệu quả vượt trội cho tác vụ gợi ý so với các phương pháp tích chập truyền thống.

2.4.3 Cơ chế Hợp nhất Không gian Vector

Một sản phẩm trên thực tế có thể có nhiều hình thức biểu diễn như văn bản, hình ảnh, video. Nghiên cứu của Radford [16] đã khẳng định tầm quan trọng của việc khai thác đa phương thức để hiểu sâu ngữ nghĩa đối tượng. Tuy nhiên, thay vì chỉ so khớp đơn thuần, việc hợp nhất các đặc trưng này thành một biểu diễn duy nhất là yêu cầu bắt buộc đối với tháp sản phẩm trong kiến trúc Two-Tower. Hình 2.6 [16] mô tả kiến trúc hợp nhất được đề xuất.



Hình 2.6: Sơ đồ kiến trúc *Multi-Modality Fusion*.

Hạn chế căn bản của các phương pháp hợp nhất truyền thống như phép nối vector hay phép cộng trung bình nằm ở giả định cứng nhắc rằng mức độ quan trọng của hình ảnh và văn bản là tương đương nhau đối với mọi sản phẩm. Trong thực tế dữ liệu thương mại điện tử luôn tồn tại sự bất cân xứng về chất lượng thông tin khi một số mặt hàng sở hữu hình ảnh trực quan sắc nét nhưng phần mô tả lại sơ sài hoặc ngược lại. Để giải quyết vấn đề này đồ án áp dụng cơ chế Hợp nhất có cổng hay còn gọi là *Gated Fusion* được phát triển dựa trên nền tảng lý thuyết mạng nơ-ron đa phương thức của Arevalo và cộng sự[24].

Quy trình xử lý dữ liệu để tạo ra vector đại diện sản phẩm được thực hiện qua ba giai đoạn tuần tự, đảm bảo tính đồng bộ về mặt toán học giữa các luồng dữ liệu khác biệt.

Đầu tiên là giai đoạn đồng bộ hóa không gian biểu diễn. Xuất phát từ thực tế rằng đầu ra từ các bộ mã hóa hình ảnh và văn bản (như ViT cho ảnh và BERT cho văn bản) thường sở hữu số chiều khác nhau và nằm trong các phân phối đặc trưng riêng biệt, hệ thống cần áp dụng phép chiếu tuyến tính để dung hòa sự khác biệt này. Cụ thể, hai ma trận trọng số $\mathbf{W}_v$ và $\mathbf{W}_t$ được sử dụng để ánh xạ các đặc trưng thô về cùng một không gian vector tiềm ẩn có kích thước cố định d , tạo tiền đề cho sự tương tác trực tiếp:

$$\mathbf{v}_I = \tanh(\mathbf{W}_v \cdot I_{\text{raw}} + \mathbf{b}_v) \quad (2.11)$$

$$\mathbf{v}_T = \tanh(\mathbf{W}_t \cdot T_{\text{raw}} + \mathbf{b}_t) \quad (2.12)$$

Tiếp theo, các vector đặc trưng sau khi đồng bộ được đưa vào cơ chế Hợp nhất có cổng (*Gated Mechanism*). Đây là thành phần cốt lõi của mô hình, đóng vai trò như một van điều tiết thông minh nhằm xác định mức độ quan trọng của từng luồng thông tin. Một giá trị cổng kiểm soát z được tính toán dựa trên sự kết hợp của cả hai loại dữ liệu, sử dụng hàm kích hoạt Sigmoid σ để nén giá trị về khoảng $(0, 1)$:

$$z = \sigma(\mathbf{W}_z \cdot [\mathbf{v}_I, \mathbf{v}_T] + \mathbf{b}_z) \quad (2.13)$$

Dựa trên giá trị cổng này, vector hợp nhất $\mathbf{v}_{\text{fusion}}$ được xác định bằng tổ hợp tuyến tính có trọng số. Cơ chế này cho phép mô hình linh hoạt chuyển đổi sự tập trung; khi z tiệm cận 1, hệ thống sẽ ưu tiên khai thác tín hiệu thị giác và ngược lại sẽ dựa nhiều vào văn bản khi z tiến về 0:

$$\mathbf{v}_{\text{fusion}} = z \odot \mathbf{v}_I + (1 - z) \odot \mathbf{v}_T \quad (2.14)$$

Cuối cùng, để hoàn thiện biểu diễn của sản phẩm, vector hợp nhất $\mathbf{v}_{\text{fusion}}$ trải qua bước chuẩn hóa theo chuẩn L_2 nhằm tạo ra vector đầu ra $\mathbf{v}_{\text{item}}$:

$$\mathbf{v}_{\text{item}} = \frac{\mathbf{v}_{\text{fusion}}}{\|\mathbf{v}_{\text{fusion}}\|_2} \quad (2.15)$$

Bước xử lý này đảm bảo độ dài của mọi vector đại diện đều bằng 1. Về mặt hình học, điều này giúp phép nhân vô hướng với vector người dùng ở giai đoạn truy xuất sau này trở thành thước đo độ tương đồng Cosine chuẩn xác, đồng thời góp phần ổn định đáng kể quá trình huấn luyện của mạng nơ-ron.

2.5 Nắm bắt chuỗi hành vi trong ResSys

2.5.1 Sự tiến hóa của các Hệ thống Gợi ý Tuần tự: Từ Markov đến RNN

Trong bối cảnh thương mại điện tử, sở thích của người dùng là một quá trình động, thay đổi liên tục theo thời gian và chịu ảnh hưởng mạnh mẽ bởi ngữ cảnh ngắn hạn. Trước khi kỷ nguyên học sâu bùng nổ, Chuỗi Markov đóng vai trò là nền tảng lý thuyết chủ đạo. Mô hình này, tiêu biểu như FPMC [26], xem lịch sử người dùng là các trạng thái chuyển đổi và đưa ra giả định theo tính chất Markov bậc một: hành động tiếp theo chỉ phụ thuộc duy nhất vào hành động ngay trước đó. Dù hiệu quả trong việc nắm bắt tương tác ngắn hạn giữa các cặp sản phẩm liên kề, Chuỗi Markov lại tỏ ra yếu kém trong việc ghi nhớ các chuỗi hành vi dài.

Để giải quyết bài toán phụ thuộc xa, Mạng nơ-ron tái phát RNN và các biến thể như GRU, LSTM đã được áp dụng. Điển hình là kiến trúc GRU4Rec [30], cho phép mô hình hóa toàn bộ lịch sử hành vi thành một chuỗi liên tục thông qua cơ chế cập nhật trạng thái ẩn, qua đó trích xuất được sở thích dài hạn của người dùng. Mặc dù vượt trội hơn Markov, kiến trúc RNN vẫn tồn tại những nhược điểm chí mạng: bản chất tính toán tuần tự khiến quá trình huấn luyện không thể song song hóa trên các phần cứng hiện đại như GPU, đồng thời hiện tượng triệt tiêu đạo hàm vẫn xảy ra với các chuỗi quá dài. Những rào cản phần cứng và thuật toán này chính là động lực thúc đẩy sự chuyển dịch công nghệ sang các kiến trúc dựa trên cơ chế Tự chú ý trong giai đoạn sau này.

2.5.2 Kiến trúc SASRec

Dựa trên sự thành công vang dội của cơ chế Attention trong xử lý ngôn ngữ tự nhiên, Kang và McAuley (2018) [7] đã đề xuất mô hình SASRec. Đây là kiến trúc được đề án lựa chọn làm nòng cốt cho Tháp Người dùng. SASRec thay thế hoàn toàn các lớp hồi quy bằng cơ chế Tự chú ý (Self-Attention), cho phép mô hình xác định trọng số quan trọng

của từng sản phẩm trong quá khứ đối với sản phẩm mục tiêu dựa trên mối quan hệ ngữ nghĩa thay vì khoảng cách vị trí cố định. Nội dung trong mục này nói về mô hình SASRec của Kang và McAuley [7].

Mô hình SASRec vận hành thông qua một chuỗi các tầng xử lý tuần tự, khởi đầu với Tầng Nhúng. Kế thừa trực tiếp nguyên lý đã được phân tích tại Mục 2.3.3 về giới hạn nhận thức thứ tự của mạng Transformer, hệ thống bắt buộc phải tích hợp thông tin vị trí vào chuỗi đầu vào. Cụ thể, mô hình thực hiện phép cộng trực tiếp ma trận biểu diễn đặc trưng của sản phẩm M với một ma trận vị trí có thể học được P , tạo thành một không gian biểu diễn tổng hợp $\hat{E} = M + P$.

Ngay sau bước chuẩn bị dữ liệu, ma trận tổng hợp này được truyền thẳng vào khối mạng Self-Attention. Dựa trên nền tảng toán học của cơ chế sự chú ý đã được định nghĩa chi tiết tại Mục 2.3.1, SASRec tiến hành điều chỉnh kỹ thuật để tương thích tuyệt đối với bài toán chuỗi thời gian. Cụ thể, mô hình tích hợp thêm cơ chế che chắn nhân quả nhằm giới hạn tầm nhìn của mạng nơ-ron. Cơ chế này ép buộc các đầu chú ý chỉ được phép quét và tính toán mức độ tương quan đối với các sản phẩm mà người dùng đã tương tác trong quá khứ, triệt tiêu hoàn toàn hiện tượng rò rỉ thông tin từ tương lai. Nhờ sự kết hợp này, SASRec có khả năng nắm bắt chính xác dòng chảy biến thiên trong sở thích mua sắm của khách hàng ở từng thời điểm cụ thể. Một yếu tố kỹ thuật then chốt tại đây là việc áp dụng Mặt nạ nhân quả (*Causal Masking*). Cơ chế này đảm bảo rằng khi dự đoán tại thời điểm t , mô hình chỉ được phép tiếp cận thông tin từ thời điểm 1 đến t , ngăn chặn tuyệt đối việc rò rỉ thông tin từ tương lai và bảo toàn tính nhân quả của dữ liệu chuỗi.

Để khai thác các đặc trưng sâu hơn sau lớp Attention, mô hình tích hợp Mạng truyền thẳng từng điểm (*Point-wise Feed-Forward Network*). Mạng này thực hiện các phép biến đổi phi tuyến cho từng vị trí một cách độc lập nhưng chia sẻ chung bộ trọng số, giúp mô hình nắm bắt các tương tác phức tạp giữa các chiều ẩn. Kiến trúc tổng thể của SASRec được hình thành bằng cách xếp chồng b khối xử lý như vậy nhằm giải quyết vấn đề quá khớp và mất ổn định khi huấn luyện mạng sâu, nhóm tác giả áp dụng cấu trúc tương tự Transformer bao gồm Chuẩn hóa lớp (*Layer Normalization*) để ổn định phân phối, Dropout để điều hòa quá trình học, và Kết nối tắt (*Residual Connections*) để hỗ trợ lan truyền thông tin. Toàn bộ quy trình này được mô hình hóa qua công thức tổng quát cho mỗi lớp con g :

$$g(x) = x + \text{Dropout}(g(\text{LayerNorm}(x))) \quad (2.16)$$

như được mô tả trong tài liệu của Kang và McAuley.

Tại Tầng Dự đoán cuối cùng, sau khi đi qua b khối xử lý, vector đại diện $\mathbf{F}_t^{(b)}$ tại bước t sẽ được sử dụng để dự đoán sản phẩm tiếp theo. Điểm số tương quan $r_{i,t}$ được xác định bằng tích vô hướng giữa vector đại diện này và vector nhúng của sản phẩm mục tiêu $\mathbf{N}_i$. Để tối ưu hóa kích thước mô hình và hạn chế quá khớp, SASRec áp dụng chiến lược Shared Item Embedding, tức là sử dụng chung một ma trận nhúng cho cả đầu vào và đầu ra ($\mathbf{N} = \mathbf{M}$). Các tác giả lập luận rằng tính phi tuyến mạnh mẽ của mạng truyền thẳng là đủ để mô hình giải quyết vấn đề bất đối xứng (mua điện thoại thì có thể đề xuất ốp lưng nhưng mua ốp lưng thì không đề xuất điện thoại) trong các chuyển đổi hành vi mua sắm mà không cần thiết phải tách biệt hai ma trận này.

Dựa trên các kết quả thực nghiệm được công bố bởi Kang và McAuley, mô hình SASRec đã chứng minh được hiệu năng vượt trội so với các kiến trúc tiền nhiệm như GRU4Rec hay Caser nhờ vào hai ưu thế kỹ thuật then chốt.

Đầu tiên là khả năng nắm bắt các phụ thuộc dài hạn trong chuỗi hành vi. Đối với các

mạng hồi quy truyền thông, thông tin buộc phải lan truyền tuần tự qua từng bước thời gian, tạo ra độ dài đường dẫn tỷ lệ thuận với độ dài chuỗi $\mathcal{O}(n)$. Ngược lại, cơ chế Tự chú ý cho phép thiết lập kết nối trực tiếp giữa hai sản phẩm bất kỳ bất kể khoảng cách vị trí. Đặc tính này rút ngắn độ dài đường truyền tín hiệu xuống mức hằng số $\mathcal{O}(1)$, giúp mô hình duy trì và truy xuất hiệu quả các sở thích người dùng đã hình thành từ quá khứ xa mà không bị suy hao thông tin.

Ưu điểm thứ hai nằm ở hiệu suất tính toán và khả năng mở rộng. Khác với tính chất tuần tự bắt buộc của mạng hồi quy khiến quá trình xử lý không thể tận dụng triệt để sức mạnh của GPU, các phép toán ma trận trong SASRec có thể được thực thi song song trên toàn bộ chiều dài chuỗi. Sự cải tiến này mang lại lợi ích to lớn về mặt tốc độ; các thử nghiệm cho thấy thời gian huấn luyện của SASRec nhanh hơn gấp mười lần so với các mô hình dựa trên mạng hồi quy hoặc tích chập, cho phép hệ thống dễ dàng mở rộng để xử lý các tập dữ liệu quy mô lớn.

2.5.3 Kiến trúc Hai tháp cho Truy xuất Ứng viên

Bối cảnh và Vấn đề Quy mô

Trong các hệ sinh thái thương mại điện tử quy mô lớn, thách thức kỹ thuật trọng yếu luôn nằm ở giai đoạn truy xuất (Retrieval). Tại đây, hệ thống buộc phải sàng lọc ra hàng trăm ứng viên tiềm năng từ một không gian dữ liệu khổng lồ chứa hàng triệu mặt hàng, với yêu cầu khắt khe về độ trễ tối thiểu, thường phải dưới 100 mili giây.

Trước bài toán này, các phương pháp truyền thống như Phân rã ma trận đã bộc lộ giới hạn do không thể nắm bắt các tương tác phi tuyến tính phức tạp. Quan trọng hơn, ngay cả các mô hình học sâu hiện đại như kiến trúc SASRec nguyên bản [7] cũng vấp phải rào cản lớn khi triển khai thực tế. Do thiết kế theo hướng dự đoán đầu cuối (end-to-end classification) với chiến lược Shared Item Embedding, SASRec gốc trói buộc quá trình nội suy chuỗi hành vi của người dùng với ma trận định danh của toàn bộ sản phẩm vào cùng một đồ thị tính toán. Cấu trúc đóng gói này dẫn đến hai hệ lụy: thứ nhất, nó cản trở việc tích hợp các đặc trưng đa phương thức (văn bản, hình ảnh) để giải quyết bài toán cold-start; thứ hai, nó khiến việc quét và chấm điểm toàn bộ danh mục hàng triệu sản phẩm trong thời gian thực trở thành một gánh nặng tính toán bất khả thi.

Để giải quyết bài toán này, kiến trúc Mạng nơ-ron Hai tháp, hay còn được biết đến với tên gọi Bi-Encoder, đã trở thành chuẩn mực công nghiệp hiện đại. Mô hình này được tiên phong ứng dụng bởi YouTube [9] và sau đó được tối ưu hóa hoàn thiện bởi Google [8] cho các tác vụ xếp hạng quy mô lớn.

Cấu trúc Mạng nơ-ron Hai tháp

Về mặt bản chất, kiến trúc Hai tháp hoạt động dựa trên nguyên lý tách biệt quá trình mã hóa thành hai luồng xử lý độc lập nhằm tối ưu hóa tốc độ truy vấn. Cụ thể, hệ thống bao gồm Tháp Người dùng được ký hiệu là bộ mã hóa f_{θ} , chịu trách nhiệm tổng hợp hồ sơ cá nhân và lịch sử hành vi để tạo ra vector biểu diễn người dùng $\mathbf{u}$ thuộc không gian $\mathbb{R}^d$. Song song với đó, Tháp Sản phẩm với bộ mã hóa g_{ϕ} tập trung khai thác các đặc trưng nội tại của vật phẩm để xây dựng vector biểu diễn tương ứng $\mathbf{v}$.

Điểm đặc trưng cốt lõi phân biệt thiết kế này với các mô hình khác là cơ chế tương tác muộn. Hai mạng nơ-ron hoàn toàn không chia sẻ thông tin hay tham số trong suốt quá trình trích xuất đặc trưng, mà chỉ thực hiện so khớp ở lớp cuối cùng. Tại đây, độ tương đồng hay mức độ phù hợp giữa người dùng và sản phẩm được ước lượng thông qua phép

tính tích vô hướng đơn giản [7]:

$$s(x, y) = \langle u(x, \theta), v(y, \theta) \rangle \quad (2.17)$$

Trong đó, $u(x, \theta)$ là hàm ánh xạ đặc trưng người dùng x , và $v(y, \theta)$ là hàm ánh xạ đặc trưng sản phẩm y dựa trên bộ tham số mô hình θ .

Cơ chế này cho phép hệ thống tính toán trước và lập chỉ mục các vector sản phẩm, giúp giảm đáng kể chi phí tính toán trực tuyến trong giai đoạn truy xuất thời gian thực.

Chiến lược Huấn luyện: Học Tương phản

Trong các kiến trúc Two-Tower hiện đại, chiến lược huấn luyện đã có sự chuyển dịch từ bài toán phân loại nhị phân truyền thống sang khuôn khổ Học tương phản (Contrastive Learning). Thách thức lớn nhất đối với các hệ thống truy xuất quy mô lớn nằm ở hàm mục tiêu: việc tính toán hàm Softmax trên toàn bộ không gian ứng viên (có thể lên tới hàng triệu sản phẩm) để xác định mẫu âm là bất khả thi về mặt tài nguyên tính toán và độ trễ. Để giải quyết vấn đề này, đồ án áp dụng giải pháp được đề xuất bởi Yi và cộng sự (2019) [8], sử dụng hàm mất mát Sampled Softmax kết hợp với kỹ thuật lấy mẫu âm trong lô.

Kỹ thuật này hoạt động dựa trên giả định thống kê rằng trong một lô dữ liệu ngẫu nhiên, các cặp người dùng và sản phẩm không tương ứng có xác suất rất cao là không liên quan đến nhau. Thay vì tiêu tốn chi phí để truy xuất và đào (mine) các mẫu âm từ kho dữ liệu bên ngoài, hệ thống tận dụng chính các sản phẩm của người dùng khác trong cùng một lô để làm mẫu âm.

Cụ thể, xét một lô dữ liệu có kích thước B . Với mỗi cặp mẫu dương $(\mathbf{u}_i, \mathbf{v}_i)$ (tương ứng với người dùng i và sản phẩm thực tế i):

- **Mẫu dương:** Là chính vector sản phẩm $\mathbf{v}_i$. Mục tiêu của mô hình là tối đa hóa độ tương đồng $s(\mathbf{u}_i, \mathbf{v}_i)$.
- **Mẫu âm:** Là tập hợp toàn bộ các vector sản phẩm $\mathbf{v}_j$ (với $j \neq i$) thuộc về các mẫu dữ liệu khác trong cùng batch đó. Như vậy, mỗi người dùng sẽ được so sánh với 1 mẫu dương và $(B - 1)$ mẫu âm nhân tạo này.

Để tối ưu hóa quá trình học biểu diễn vector, hệ thống sử dụng hàm mất mát InfoNCE (2.2). Hàm này có nhiệm vụ tối đa hóa xác suất dự đoán đúng sản phẩm mục tiêu $\mathbf{v}_i$ trong khi giảm thiểu xác suất của tập hợp $B - 1$ sản phẩm nhiễu.

Phương pháp này không chỉ giải quyết triệt để bài toán hiệu năng tính toán mà còn được chứng minh là giúp mô hình học được các không gian biểu diễn phân tách tốt hơn, nhờ vào sự đa dạng và ngẫu nhiên của các mẫu âm được cập nhật liên tục trong mỗi bước huấn luyện.

Ưu điểm về Triển khai Thực tế

Lý do kiến trúc Two-Tower trở thành chuẩn mực thống trị trong bài toán Truy xuất bắt nguồn từ khả năng tách biệt hoàn toàn quá trình tính toán giữa hai thực thể người dùng và sản phẩm. Đặc tính kỹ thuật này cho phép tối ưu hóa quy trình xử lý thông qua hai giai đoạn riêng biệt. Trong giai đoạn ngoại tuyến (offline), nhờ sự độc lập của Tháp Sản phẩm, hệ thống có thể thực hiện tính toán trước vector biểu diễn cho toàn bộ không gian hàng hóa—có thể lên tới hàng triệu phần tử—và lưu trữ chúng dưới dạng chỉ mục tối ưu trong các cơ sở dữ liệu vector chuyên dụng như Milvus hay Faiss.


Chiến lược này tạo tiền đề cho hiệu suất vượt trội trong giai đoạn phục vụ trực tuyến (online serving). Khi nhận yêu cầu, hệ thống chỉ cần thực thi suy luận một lần duy nhất tại Tháp Người dùng để tạo ra vector truy vấn. Sau đó, thay vì phải quét toàn bộ cơ sở dữ liệu, việc xác định Top-K ứng viên tiềm năng được thực hiện thông qua các thuật toán ANN. Cơ chế này cho phép hệ thống duy trì độ trễ phản hồi ở mức dưới mili-giây, đồng thời đảm bảo tốc độ truy xuất không bị suy giảm tuyến tính khi quy mô kho hàng tăng lên, giải quyết triệt để bài toán về khả năng mở rộng của các hệ thống gợi ý hiện đại [9].

2.6 Mô hình xếp hạng lại Reranking

Sau khi giai đoạn Retrieval hoàn thành nhiệm vụ thu hẹp không gian tìm kiếm từ hàng triệu sản phẩm xuống một tập hợp ứng viên giới hạn, hệ thống đòi hỏi một cơ chế tinh vi hơn để phân tích chính xác mức độ phù hợp của từng ứng viên đối với nhu cầu của người dùng. Giai đoạn Reranking đảm nhận vai trò định chuẩn này. Việc chỉ sắp xếp lại vài chục đến vài trăm kết quả cho phép hệ thống triển khai các mô hình ngôn ngữ có độ phức tạp tính toán cao, mà điển hình và mạnh mẽ nhất hiện nay là kiến trúc Cross-Encoder.

2.6.1 Lý thuyết Cross Encoder

Mô hình Cross-Encoder là một kiến trúc mạng nơ-ron học sâu được xây dựng trực tiếp trên nền tảng của khối mã hóa (Encoder) thuộc mô hình Transformer, do Vaswani và cộng sự đề xuất vào năm 2017 [?]. Sự trỗi dậy mạnh mẽ của Cross-Encoder trong lĩnh vực xếp hạng thông tin bắt đầu từ khi Nogueira và Cho (2019) ứng dụng thành công kiến trúc BERT vào bài toán đánh giá mức độ liên quan của văn bản [?]. Nguyên lý hoạt động cốt lõi của Cross-Encoder nằm ở cách nó xử lý dữ liệu đầu vào và khai thác cơ chế tự chú ý.



Hình 2.7: Kiến trúc tổng quan của mô hình Cross-Encoder


Thay vì mã hóa độc lập từng đối tượng, Cross-Encoder yêu cầu ghép nối trực tiếp câu truy vấn (*Query*) và thông tin sản phẩm (*Item*) thành một chuỗi duy nhất trước khi đưa vào mô hình. Chuỗi đầu vào này thường được định dạng bằng các token đặc biệt, ví dụ như [CLS] Query [SEP] Item [SEP]. Ngay từ những lớp đầu tiên của mạng Transformer, cơ chế Tương tác sớm đã được kích hoạt. Thông qua ma trận Self-Attention, mỗi một từ khóa trong câu truy vấn đều có khả năng quan sát, tính toán trọng số và tương tác trực

tiếp với toàn bộ các từ khóa nằm trong phần mô tả sản phẩm, và ngược lại. Quá trình này được lặp đi lặp lại qua nhiều tầng nơ-ron, giúp hệ thống không chỉ đối khớp từ khóa một cách máy móc mà còn thấu hiểu được ngữ cảnh, cấu trúc cú pháp và các hàm ý liên kết phức tạp.

Kết quả của toàn bộ quá trình tương tác chéo này được hội tụ vào token đặc biệt [CLS] ở tầng biểu diễn cuối cùng. Vector biểu diễn của token này mang theo toàn bộ thông tin tổng hợp về mối quan hệ ngữ nghĩa giữa *Query* và *Item*. Cuối cùng, vector này được đưa qua một mạng nơ-ron truyền thẳng (Feed-Forward Network) kết hợp với hàm kích hoạt để chiếu thành một giá trị vô hướng duy nhất. Giá trị này đại diện cho điểm số xếp hạng, phản ánh chính xác mức độ liên quan của sản phẩm đối với mục tiêu tìm kiếm của người dùng.

2.6.2 So sánh Cross Encoder và Bi Encoder

Để hiểu rõ lý do tại sao kiến trúc hệ thống hiện đại bắt buộc phải duy trì hai giai đoạn với hai mô hình khác biệt, cần phải phân tích sự tương phản sâu sắc về cơ chế hoạt động cũng như sự đánh đổi giữa Cross-Encoder và Bi-Encoder. Nghiên cứu của Reimers và Gurevych (2019) về Sentence-BERT đã chỉ ra một cách hệ thống những ranh giới kỹ thuật này [?].



Hình 2.8: So sánh sự khác biệt giữa kiến trúc Bi-Encoder và Cross-Encoder

Bi-Encoder, kiến trúc chủ đạo của giai đoạn Truy xuất, hoạt động dựa trên cơ chế Tương tác muộn. Nó sử dụng hai mạng Transformer độc lập để mã hóa câu truy vấn và sản phẩm thành hai vector dày đặc riêng biệt trong cùng một không gian học thuật. Sự so sánh chỉ diễn ra ở bước cuối cùng thông qua các phép tính đơn giản như độ tương đồng Cosine. Lợi thế tuyệt đối của Bi-Encoder là khả năng tính toán trước. Mọi sản phẩm trong kho đều được chuyển thành vector và lập chỉ mục từ trước, do đó khi có truy vấn, hệ thống chỉ mất vài mili giây để tìm ra các láng giềng gần nhất. Tuy nhiên, cái giá phải trả cho tốc độ là sự suy giảm về khả năng biểu diễn ngữ nghĩa. Việc nén toàn bộ ý nghĩa

của một văn bản dài vào một vector có kích thước cố định gây ra hiện tượng thất cổ chai thông tin. Mô hình mất đi khả năng đối khớp chính xác ở cấp độ từ vựng, dễ dẫn đến sai lệch khi người dùng tìm kiếm các sản phẩm có sự khác biệt rất nhỏ về từ ngữ nhưng khác biệt lớn về bản chất.

Ngược lại, Cross-Encoder khắc phục hoàn toàn nhược điểm này bằng cơ chế Tương tác sớm. Bằng cách cho phép các luồng thông tin giao thoa ngay từ đầu, nó duy trì được bức tranh toàn cảnh về mặt từ vựng và ngữ pháp. Ví dụ, trong ngữ cảnh thương mại điện tử, truy vấn "ốp lưng iPhone 15" và sản phẩm "iPhone 15 màu đen tặng kèm ốp lưng" có thể bị Bi-Encoder đánh giá là rất giống nhau vì không gian vector chứa nhiều từ khóa tương đồng. Tuy nhiên, Cross-Encoder với sự chú ý sâu sắc sẽ nhận ra vai trò chủ thể của cụm "ốp lưng" trong truy vấn không khớp với vai trò phụ trợ của nó trong tên sản phẩm, từ đó cho điểm xếp hạng thấp hơn.

Mặc dù có độ chính xác vượt trội, Cross-Encoder lại gặp phải rào cản chí mạng về khối lượng tính toán. Vì câu truy vấn và sản phẩm phải được ghép nối để tính toán lại từ đầu, độ phức tạp của cơ chế Self-Attention tăng lên theo bình phương độ dài chuỗi đầu vào. Việc áp dụng Cross-Encoder để so sánh một truy vấn với hàng triệu sản phẩm sẽ tiêu tốn một lượng tài nguyên và thời gian khổng lồ, vượt ra ngoài khả năng đáp ứng thời gian thực.

Chính sự bù trừ này đã định hình nên kiến trúc gợi ý đa giai đoạn. Bi-Encoder đóng vai trò như hệ thống lọc nhanh nhẹn, chấp nhận độ sai số nhất định để mang về một tập ứng viên khả thi từ biển dữ liệu rộng lớn. Trong khi đó, Cross-Encoder có vai trò Reranking. Bằng cách chỉ tập trung sức mạnh xử lý vào một số lượng ít các sản phẩm tiềm năng nhất, Cross-Encoder tối đa hóa được độ chính xác của kết quả đầu ra, đảm bảo những sản phẩm hiển thị ở các vị trí top đầu là những lựa chọn hoàn hảo nhất, nâng cao đáng kể tỷ lệ chuyển đổi và trải nghiệm mua sắm của người dùng.

2.7 Ứng dụng Mô hình Ngôn ngữ Lớn trong Hệ thống Gợi ý

Trong những năm gần đây, sự bùng nổ của các Mô hình Ngôn ngữ Lớn đã mở ra một hướng đi hoàn toàn mới cho lĩnh vực Hệ thống Gợi ý. Khác với các mô hình học máy truyền thống thường chỉ tập trung vào việc khai phá ma trận tương tác User-Item hoặc các đặc trưng rời rạc, LLM mang đến khả năng xử lý và suy luận trực tiếp trên ngôn ngữ tự nhiên, biến bài toán gợi ý khó khan thành một cuộc hội thoại tương tác mượt mà.

2.7.1 Tổng quan về khả năng hiểu ngữ cảnh của LLM

Sức mạnh cốt lõi của LLM nằm ở khả năng đọc hiểu và nắm bắt ngữ cảnh phức tạp thông qua hàng tỷ tham số được huấn luyện trên lượng dữ liệu khổng lồ. Trong ngữ cảnh của hệ thống gợi ý, LLM thể hiện những ưu điểm vượt trội sau:

- **Xử lý dữ liệu văn bản phong phú:** Các mô hình gợi ý truyền thống gặp khó khăn trong việc hiểu sâu các nội dung văn bản dài như bài đánh giá, mô tả sản phẩm chi tiết hay lịch sử chat của người dùng. Ngược lại, LLM có thể dễ dàng trích xuất các thông tin ẩn như cảm xúc, sở thích cá nhân, và thậm chí là ý định mua sắm từ những đoạn văn bản này.

- **Suy luận ngữ nghĩa sâu:** LLM không chỉ khớp từ khóa mà còn hiểu được sự tương đồng về mặt ý nghĩa. Ví dụ, nếu người dùng tìm kiếm "đồ giữ ấm đi phượt mùa đông", LLM hiểu rằng người dùng đang cần áo khoác gió, mũ len, hoặc găng tay cách nhiệt, dù trong lịch sử của họ chưa từng xuất hiện cụm từ này.
- **Giải quyết vấn đề Zero-shot/Few-shot:** Nhờ kiến thức nền tảng rộng lớn, LLM có khả năng đưa ra gợi ý khá chính xác ngay cả với những sản phẩm mới hoặc người dùng mới chỉ dựa trên một vài thông tin mô tả cơ bản hoặc thậm chí không cần dữ liệu lịch sử tương tác.

2.7.2 Kỹ thuật Prompting trong Hệ thống Gợi ý

Để khai thác tối đa sức mạnh của LLM, **Prompt Engineering** là một yếu tố không thể thiếu. Việc thiết kế prompt giống như cách ta lập trình LLM bằng ngôn ngữ tự nhiên. Trong hệ thống gợi ý, các kỹ thuật prompting phổ biến bao gồm:

- **In-context Learning:** Cung cấp cho LLM một vài ví dụ về lịch sử tương tác của người dùng ngay trong câu lệnh. Ví dụ: "*Người dùng A đã mua [Điện thoại X, Ốp lưng Y]. Gợi ý sản phẩm tiếp theo cho A...*". Cách này giúp LLM nắm bắt mẫu hành vi mà không cần cập nhật lại trọng số mô hình.
- **Chain-of-Thought:** Khuyến khích LLM giải thích từng bước logic trước khi đưa ra kết quả cuối cùng. Bằng cách thêm cụm từ "*Hãy suy nghĩ từng bước một*", LLM sẽ phân tích: vì sao người dùng thích sản phẩm này, đặc điểm nào phù hợp, từ đó giúp kết quả gợi ý chính xác và có tính thuyết phục cao hơn.
- **Role-playing:** Gán cho LLM một định danh cụ thể, ví dụ: "*Bạn là một chuyên gia tư vấn thời trang AI...*". Kỹ thuật này giúp định hình tông giọng và khoanh vùng không gian ngữ nghĩa, giúp kết quả trả về chuyên nghiệp và sát với lĩnh vực của hệ thống.

2.7.3 Định hướng ứng dụng LLM trong Đề án

Nhận thấy tiềm năng to lớn của LLM, nhóm đề án đã quyết định tích hợp công nghệ này vào hệ thống để giải quyết hai bài toán then chốt, nhằm nâng cao tính tương tác và độ chính xác của quy trình Reranking.

Thứ nhất: Tự động sinh truy vấn huấn luyện cho Cross-Encoder

Để huấn luyện mô hình Cross-Encoder phục vụ cho việc Reranking, hệ thống cần một lượng lớn dữ liệu dạng cặp (Câu truy vấn - Tài liệu). Tuy nhiên, trong tập dữ liệu e-commerce (như Amazon), chúng ta thường chỉ có thông tin sản phẩm và lịch sử mua hàng, thiếu hẳn câu truy vấn thực tế của người dùng. Nhóm sử dụng LLM để đọc mô tả sản phẩm và tự động "tưởng tượng" ra các câu hỏi/truy vấn đa dạng mà người dùng có thể gõ để tìm kiếm sản phẩm đó. Việc tạo ra tập dữ liệu tổng hợp (Synthetic Data) này giúp Cross-Encoder học được sự liên kết ngữ nghĩa phong phú giữa nhu cầu tự nhiên và mô tả kỹ thuật.

Thứ hai: Giải thích kết quả gợi ý

Một trong những điểm yếu của các mô hình Deep Learning là tính "hộp đen", người dùng không biết vì sao họ lại được gợi ý sản phẩm này. Nhóm ứng dụng LLM ở bước cuối

cùng của pipeline: sau khi hệ thống (qua Bi-Encoder và Cross-Encoder) đã chọn ra top các sản phẩm phù hợp nhất, LLM sẽ nhận đầu vào là lịch sử người dùng và thông tin các sản phẩm top đầu. Từ đó, LLM tổng hợp và sinh ra một đoạn văn bản ngắn, cá nhân hóa, giải thích lý do cụ thể vì sao sản phẩm này lại hoàn hảo dành cho họ (ví dụ: *"Dựa trên việc bạn vừa mua một chiếc lều cắm trại, chúng tôi gợi ý chiếc đèn pin này vì nó có khả năng chống nước và thời lượng pin phù hợp cho những chuyến đi qua đêm"*). Điều này giúp tăng cường độ tin cậy và sự hài lòng của người dùng đối với hệ thống.


Chương 3

Phương pháp đề xuất và Kiến trúc Hệ thống

3.1 Kiến trúc tổng thể hệ thống gợi ý đa giai đoạn

Hệ thống được thiết kế linh hoạt để tiếp nhận đầu vào đa dạng, cho phép người dùng tìm kiếm thông qua các câu truy vấn văn bản hoặc tải lên hình ảnh trực tiếp. Dựa trên những dữ liệu đầu vào này, hệ thống sẽ phân tích và đề xuất các sản phẩm chất lượng cao, đảm bảo sự tương thích sát sao nhất với nhu cầu và sở thích cá nhân của từng người dùng. Để hiện thực hóa điều này, nhóm sử dụng bộ dữ liệu Amazon Reviews làm nền tảng huấn luyện. Đây là một tập dữ liệu phong phú bao gồm các đặc trưng từ phía người dùng như nội dung đánh giá, điểm xếp hạng, và mức độ hữu ích của đánh giá đó, kết hợp cùng siêu dữ liệu sản phẩm item metadata như mô tả chi tiết, giá bán và hình ảnh gốc; tất cả được liên kết chặt chẽ với nhau thông qua mã định danh sản phẩm.

Để giải quyết bài toán gợi ý sản phẩm đa phương thức với độ chính xác cao và khả năng giải thích minh bạch, đề tài đề xuất một kiến trúc hệ thống phân tầng toàn diện. Kiến trúc này được thiết kế theo tư duy tách biệt rạch ròi giữa luồng xử lý ngoại tuyến phục vụ công tác huấn luyện và luồng suy luận trực tuyến phục vụ thời gian thực, đồng thời tích hợp cơ chế vòng lặp phản hồi liên tục. Sơ đồ luồng dữ liệu chi tiết được minh họa tại Hình 3.1.



Hình 3.1: Quá trình Truy xuất sản phẩm

Về mặt vận hành, cốt lõi của hệ thống là một đường ống suy luận trải qua ba giai đoạn nối tiếp nhau. Mỗi giai đoạn sử dụng một cấu trúc mạng nơ-ron chuyên biệt nhằm tối ưu hóa sự cân bằng giữa tốc độ tính toán và chiều sâu ngữ nghĩa.

Giai đoạn 1: Truy xuất ứng viên sơ cấp với kiến trúc Two-Tower

Khi người dùng đưa ra một yêu cầu tìm kiếm thông qua văn bản hoặc hình ảnh, hệ thống không thể lập tức quét qua hàng triệu sản phẩm bằng các mạng nơ-ron phức tạp do giới hạn nghiêm ngặt về độ trễ. Tại bước này, kiến trúc Two-Tower hay Bi-Encoder đóng vai trò như một bộ lọc thô siêu tốc. Dữ liệu đầu vào đi qua khối Query Encoder để nén thành một vector biểu diễn duy nhất. Vector này sau đó được đối chiếu với tập Item Vector Index đã được tính toán sẵn từ luồng ngoại tuyến thông qua thuật toán tìm kiếm láng giềng gần nhất xấp xỉ ANN. Kết hợp cùng khối User Vector Index làm nhiệm vụ lấy chuỗi hành vi lịch sử, hệ thống đã được vector hóa để thực hiện sàng lọc cá nhân hóa nhằm thu hẹp không gian tìm kiếm khổng lồ xuống còn một danh sách vài trăm ứng viên tiềm năng nhất.

Giai đoạn 2: Khai phá tương tác sâu với mạng Cross-Encoder

Mặc dù Two-Tower đạt tốc độ truy xuất thời gian thực, việc hai tháp mã hóa thông tin hoàn toàn độc lập khiến mô hình dễ dàng bỏ lỡ các sắc thái giao thoa tinh tế giữa ý định của người dùng và đặc tính sản phẩm. Để khắc phục nhược điểm này, danh sách ứng viên sơ cấp tiếp tục được truyền sang giai đoạn xếp hạng lại Reranking. Tại đây, hệ thống ghép nối trực tiếp bộ ba thông tin bao gồm Truy vấn, Hồ sơ người dùng và Sản phẩm thành các chuỗi đầu vào thống nhất trước khi truyền qua mạng Cross-Encoder. Cơ chế chú ý chéo tương tác sớm Early Interaction của khối kiến trúc này cho phép các luồng thông tin liên tục trao đổi và đánh giá lẫn nhau ở từng tầng vi mô. Kết quả là hệ thống tính toán ra được điểm số tương quan với độ chính xác vượt trội, từ đó sắp xếp lại danh sách ứng viên một lần nữa để tinh tuyển ra nhóm kết quả tối ưu nhất.

Giai đoạn 3: Sinh lời giải thích với Mô hình Ngôn ngữ Lớn LLM


Một hệ thống gợi ý hiện đại không chỉ có nhiệm vụ đưa ra kết quả chính xác mà còn phải thuyết phục được người dùng tại sao kết quả đó lại thực sự phù hợp. Top các sản phẩm xuất sắc nhất từ giai đoạn xếp hạng lại sẽ được tổng hợp cùng toàn bộ ngữ cảnh

về yêu cầu tìm kiếm và lịch sử mua sắm để truyền vào Mô hình Ngôn ngữ Lớn Gemini. Đóng vai trò như một khối suy luận ngôn ngữ cấp cao, LLM phân tích sự giao thoa giữa nhu cầu hiện tại, sở thích trong quá khứ và siêu dữ liệu của từng sản phẩm. Từ đó, mô hình tự động sinh ra các lời giải thích minh bạch, tự nhiên và mang đậm tính cá nhân hóa trước khi hiển thị lên giao diện người dùng cuối.

Cuối cùng, tính bền vững của kiến trúc được duy trì thông qua một vòng lặp phản hồi Feedback Loop. Mọi tương tác mới của người dùng đối với danh sách gợi ý đều được hệ thống thu nhận và kích hoạt cơ chế cập nhật không gian biểu diễn, đảm bảo mô hình không ngừng tự học hỏi và thích nghi với sự thay đổi liên tục trong thị hiếu mua sắm.

3.2 Kiến trúc Bi-Encoder

Mục tiêu cốt lõi của kiến trúc Two-Tower hay Bi-Encoder trong hệ thống là thiết lập một không gian vector tiềm ẩn dùng chung, nơi cả ý định tìm kiếm của người dùng và đặc trưng của sản phẩm đều có thể được biểu diễn và so sánh trực tiếp. Quá trình huấn luyện mô hình được thiết kế theo cấu trúc đối xứng phân nhánh, tập trung vào việc tối ưu hóa mức độ tương đồng giữa hai tháp thông qua học đối nghịch Contrastive Learning. Sơ đồ luồng tính toán gradient và cập nhật trọng số được minh họa chi tiết tại Hình 3.2.



Hình 3.2: Quá trình Truy xuất sản phẩm

Về mặt vận hành, luồng xử lý dữ liệu được chia thành hai nhánh độc lập trước khi hội tụ tại tầng đánh giá cuối cùng:

Tháp Sản phẩm Item Tower: Nhánh bên phải chịu trách nhiệm mô hình hóa các đặc trưng tĩnh của sản phẩm ứng viên. Khác với các hệ thống lọc cộng tác truyền thống vốn phụ thuộc vào mã định danh vô tri, hệ thống này trích xuất ngữ nghĩa trực tiếp từ nội dung. Các luồng dữ liệu văn bản Text, hình ảnh Images và siêu dữ liệu bảng Tabular được truyền qua các bộ mã hóa chuyên biệt độc lập. Các biểu diễn không gian con này sau đó

được hội tụ tại khối Fusion Layer, nén thành một vector đại diện duy nhất mang toàn bộ đặc tính đa phương thức của sản phẩm.

Tháp Người dùng User Tower:

Nhánh bên trái đảm nhiệm vai trò nắm bắt dòng chảy biến thiên trong sở thích của người dùng thông qua chuỗi tương tác lịch sử. Điểm đột phá trong thiết kế của tháp này là cơ chế kế thừa không gian đặc trưng: thay vì khởi tạo ngẫu nhiên ma trận nhúng cho mã sản phẩm, hệ thống thực hiện truy xuất trực tiếp các vector sản phẩm đa phương thức Item Embedding Lookup từ tháp bên phải. Song song đó, các phản hồi định tính của người dùng Review cũng được xử lý qua khối Review Encoders. Hai luồng thông tin này kết hợp lại tạo thành chuỗi hành vi phong phú, được đưa vào khối kiến trúc tuần tự SASRec Layers để mô hình hóa và xuất ra vector đại diện cho ý định mua sắm ở thời điểm hiện tại.


Cơ chế Hợp nhất và Tối ưu hóa Trọng số:

Tại tầng đỉnh của kiến trúc, vector đại diện người dùng $\mathbf{u}$ và vector đại diện sản phẩm $\mathbf{v}$ được kết hợp thông qua phép toán Tích vô hướng Inner Product nhằm tính toán điểm số tương đồng ngữ nghĩa. Quá trình huấn luyện được dẫn dắt bởi hàm mất mát InfoNCE Loss. Dựa trên tín hiệu sai số từ hàm mục tiêu này, thuật toán lan truyền ngược sẽ điều chỉnh toàn bộ trọng số mạng nơ-ron nhằm kéo gần khoảng cách giữa người dùng và sản phẩm họ thực sự tương tác trong không gian vector, đồng thời đẩy lùi các ứng viên không liên quan mẫu âm, từ đó tối ưu hóa năng lực truy xuất của toàn bộ hệ thống.

3.2.1 Xây dựng Tháp Sản phẩm Đa phương thức

Tháp Sản phẩm đóng vai trò hạt nhân trong việc mô hình hóa các đặc trưng tĩnh của hàng triệu ứng viên tiềm năng trên hệ thống. Nhiệm vụ cốt lõi của tháp là chuyển đổi dữ liệu thô đa định dạng thành một không gian biểu diễn đồng nhất, phục vụ trực tiếp cho quá trình đối chiếu với ý định của người dùng ở các giai đoạn truy xuất và xếp hạng phía sau.

Kiến trúc luồng tổng quan của khối mã hóa sản phẩm được minh họa tại Hình 3.3. Để đảm bảo tính module hóa và tối ưu năng lực trích xuất đặc trưng, quy trình xử lý dữ liệu được thiết kế theo dạng đường ống song song ba nhánh. Mỗi nhánh tiếp nhận một phương thức dữ liệu chuyên biệt và truyền qua các khối mã hóa cấp cao tương ứng:



Hình 3.3: Kiến trúc Item Tower: Quy trình mã hóa và hợp nhất dữ liệu Đa phương thức

- **Nhánh Văn bản:** Dữ liệu tiêu đề và mô tả sản phẩm đi qua khối Text Encoder. Về bản chất nội tại, khối này vận hành dựa trên mô hình ngôn ngữ MPNet đã được đóng băng trọng số kết hợp cùng một lớp chiếu không gian tuyến tính.
- **Nhánh Hình ảnh:** Các biến thể hình ảnh của sản phẩm được truyền vào khối Image Encoder. Khối xử lý này bao bọc mạng thị giác ViT tính đồng hành cùng cơ chế Cổng Biến thể nhằm tự động đánh giá và tổng hợp thông tin từ nhiều góc chụp khác nhau.
- **Nhánh Dữ liệu Bảng:** Các thuộc tính siêu dữ liệu bao gồm giá cả và phân loại định danh được xử lý qua khối Tabular Encoder, thực chất là một mạng nơ-ron đa tầng MLP chuyên dụng cho dữ liệu số và phân loại rời rạc.

Kết quả đầu ra từ ba nhánh là các vector không gian con độc lập mang ngữ nghĩa chuyên biệt. Chúng hội tụ tại khối Fusion, nơi hệ thống thực hiện phép nối chuỗi toàn cục và nén đặc trưng thông qua một mạng phi tuyến. Quá trình này xuất ra một vector nhúng sản phẩm Item Embedding duy nhất mang kích thước không gian ẩn tiêu chuẩn 256 chiều. Cấu trúc nội tại chi tiết và cơ sở toán học của từng khối mã hóa thành phần sẽ được phân tích chuyên sâu tại các tiểu mục tiếp theo.

3.2.1.1 Text Encoder: Mô-đun Mã hóa Văn bản

TextEncoder là mô-đun mạng nơ-ron kế thừa từ `torch.nn.Module`, chịu trách nhiệm chuyển đổi dữ liệu văn bản thô (như tiêu đề, mô tả sản phẩm) thành các vector đặc trưng dày đặc (dense vectors). Đây là thành phần cốt lõi kiến tạo không gian biểu diễn ngôn ngữ cho toàn bộ kiến trúc tháp sản phẩm.

1. Lựa chọn Mô hình và Chiến lược Huấn luyện

Hệ thống tích hợp mô hình all-mpnet-base-v2 làm mạng xương sống. Dựa trên bảng xếp hạng MTEB, kiến trúc MPNet thể hiện hiệu năng vượt trội trong phân khúc mô hình tầm trung [6] đối với tác vụ tìm kiếm ngữ nghĩa, nhờ được huấn luyện trước trên hơn một tỷ cặp câu [10].

Về chiến lược huấn luyện, hệ thống áp dụng cơ chế Trích xuất Đặc trưng (Feature Extraction) bằng cách đóng băng toàn bộ trọng số của khối MPNet thông qua `torch.no_grad()`. Thiết kế này biến mô hình ngôn ngữ thành một bộ trích xuất tĩnh, giúp hệ thống tiết kiệm tối đa tài nguyên bộ nhớ GPU, đồng thời bảo toàn nguyên vẹn tri thức ngữ nghĩa gốc, tránh hiện tượng quên thảm khốc (catastrophic forgetting) khi huấn luyện trên miền dữ liệu thương mại điện tử mới.

2. Luồng Xử lý Dữ liệu (Data Pipeline)

Để đảm bảo hiệu năng, danh sách văn bản đầu vào được chia nhỏ thành các lô (mini-batches) và xử lý qua ba giai đoạn nối tiếp:

- **Giai đoạn 1: Phân mảnh và Chuẩn bị ma trận chú ý (Tokenization):** Hệ thống sử dụng thuật toán WordPiece để phân rã câu thành các từ phụ (sub-words), giải quyết triệt để vấn đề từ vựng ngoài từ điển. Các chuỗi được đệm hoặc cắt bớt để đồng bộ chiều dài. Song song đó, một ma trận Mặt nạ chú ý được sinh ra, gán giá trị 1 cho token mang ngữ nghĩa và giá trị 0 cho token đệm, nhằm định tuyến chính xác sự tập trung của cơ chế Self-Attention.
- **Giai đoạn 2: Trích xuất đặc trưng và Masked Mean Pooling:** Chuỗi token được đưa qua khối MPNet tĩnh để sinh ra các vector ngữ cảnh. Nghiên cứu của Nils Reimers và cộng sự [45] đã chỉ ra rằng sử dụng Mean Pooling để lấy vector đại diện cho câu sẽ cho kết quả tốt hơn trong tác vụ đo độ tương đồng Cosine thay vì sử dụng token [CLS] của BERT. Do đó, hệ thống áp dụng kỹ thuật Pooling trung bình có trọng số. Cụ thể, các vị trí token đệm bị triệt tiêu về 0, và vector đại diện cuối cùng được tính bằng trung bình cộng của các token thực:

$$e_{\text{pooled}} = \frac{\sum_{i=1}^L (h_i \cdot \text{mask}_i)}{\sum_{i=1}^L \text{mask}_i + \varepsilon} \quad (3.1)$$

Trong đó, h_i là trạng thái ẩn của token thứ i , mask_i là mặt nạ tương ứng, và ε là hằng số cực nhỏ (10^{-9}) nhằm duy trì độ ổn định số học.

- **Giai đoạn 3: Chiếu không gian và Chuẩn hóa:** Vector tổng hợp e_{pooled} đi qua một tầng mạng tuyến tính (`nn.Linear`) để thực hiện phép nén không gian ẩn:

$$\mathbb{R}^{768} \rightarrow \mathbb{R}^{256} \quad (3.2)$$

Phép biến đổi này đóng vai trò đồng bộ hóa kích thước đặc trưng văn bản với tháp người dùng và các luồng dữ liệu hình ảnh. Cuối cùng, vector đầu ra trải qua bước chuẩn hóa L2, đưa về dạng vector đơn vị nhằm tối ưu hóa cho hàm Contrastive Loss hoạt động dựa trên độ tương đồng Cosine.

3.2.1.2 Image Encoder: Mô-đun Mã hóa Hình ảnh

ImageEncoder chịu trách nhiệm chuyển đổi dữ liệu hình ảnh thô thành các vector đặc trưng nén. Đặc thù của sàn thương mại điện tử là một sản phẩm thường sở hữu nhiều biến


thể hình ảnh (ảnh chính diện, góc cạnh, bao bì). Thay vì chọn ngẫu nhiên hoặc tính trung bình cộng đơn thuần, điểm nhấn thiết kế của mô-đun này là việc tích hợp cơ chế Gating thông minh nhằm tự động đánh giá và tổng hợp thông tin từ nhiều nguồn ảnh thành một đại diện duy nhất.

1. Lựa chọn Mô hình và Chiến lược Huấn luyện

Hệ thống sử dụng kiến trúc Vision Transformer (ViT), cụ thể là biến thể `vit_base_patch16_224`. Mô hình này chia ảnh đầu vào thành các mảnh (*patches*) kích thước 16×16 pixels để xử lý tuần tự, mang lại sự cân bằng tối ưu giữa độ chính xác và chi phí tài nguyên [11].

Tương tự như mô đun ngôn ngữ, chiến lược Trích xuất Đặc trưng được áp dụng bằng cách đóng băng toàn bộ trọng số mạng nền (`requires_grad = False`). Kỹ thuật này triệt tiêu chi phí tính toán gradient, đồng thời bảo toàn các đặc trưng thị giác cốt lõi đã được mạng ViT học từ tập ImageNet, tránh hiện tượng quên thảm khốc (*catastrophic forgetting*).

2. Luồng Xử lý Dữ liệu (Data Pipeline)



Hình 3.4: Quy trình Tính toán và Tổng hợp Đặc trưng Hình ảnh

Dựa trên sơ đồ kiến trúc tại Hình 3.4, luồng xử lý hình ảnh được hiện thực hóa qua ba giai đoạn nổi tiếp:

- **Giai đoạn 1: Tiền xử lý (Preprocessing):** Nhằm đảm bảo tương thích với trọng số huấn luyện trước, mỗi hình ảnh được thay đổi kích thước về 224×224 pixels, chuyển đổi thành tensor *Channel-first* trong khoảng $[0.0, 1.0]$, và cuối cùng được chuẩn hóa Z-score theo phân phối thống kê của tập ImageNet để đẩy nhanh tốc độ hội tụ.

- **Giai đoạn 2: Trích xuất đặc trưng và Chiều không gian:** Các lô hình ảnh được đưa qua mô hình nền ViT tính để sinh ra các vector đặc trưng thô. Ngay sau đó, một lớp tuyến tính (`self.proj`) thực hiện phép biến đổi không gian:

$$\mathbb{R}^{768} \rightarrow \mathbb{R}^{256} \quad (3.3)$$

Phép nén này đồng bộ hóa hoàn toàn kích thước đặc trưng thị giác với tháp người dùng và luồng văn bản.

- **Giai đoạn 3: Tổng hợp đa ảnh và Chuẩn hóa:** Để xử lý bài toán không đồng nhất về số lượng biến thể ảnh, hệ thống áp dụng trực tiếp nguyên lý của Cơ chế Hợp nhất Không gian Vector đã được thiết lập lý thuyết tại Mục 2.4.3. Luồng xử lý tại đây sử dụng một Cổng Biến thể đóng vai trò như mạng lưới sự chú ý để tự động học và phân bổ trọng số cho từng vector đặc trưng 256 chiều. Dựa trên bộ trọng số này, hệ thống thực hiện phép tính tổng có trọng số nhằm hội tụ các ảnh thành phần thành một vector đại diện duy nhất. Cơ chế này ép mô hình tự động điều hướng sự tập trung vào các bức ảnh sắc nét nhất mang tính đại diện cao và triệt tiêu tác động của ảnh nhiễu. Cuối cùng, hệ thống xử lý các vị trí khuyết dữ liệu đối với sản phẩm không có ảnh bằng cách điền ma trận không, đồng thời áp dụng chuẩn hóa L2 để xuất ra vector đặc trưng thị giác hoàn chỉnh, sẵn sàng cho khối hợp nhất đa phương thức phía sau.

3.2.1.3 Tabular Encoder: Mô-đun Mã hóa Dữ liệu Bảng

TabularEncoder chịu trách nhiệm mô hình hóa các thuộc tính siêu dữ liệu bao gồm điểm đánh giá và hệ thống phân loại. Mô-đun này được thiết kế theo luồng xử lý song song nhằm giải quyết hiệu quả bản chất hỗn hợp của dữ liệu bảng trước khi đồng bộ hóa không gian đặc trưng.

1. Nhánh Xử lý Đặc trưng Phân loại

Đối với các dữ liệu định danh rời rạc, hệ thống sử dụng các lớp mạng nhúng chuẩn `nn.Embedding` để ánh xạ chỉ số thành các vector đặc trưng không gian 32 chiều. Thiết kế bao gồm ba bảng nhúng độc lập phục vụ cho ba trường thông tin cốt lõi: Danh mục chính, Thương hiệu và Danh mục chi tiết. Riêng đối với trường Danh mục chi tiết mang đặc thù đa nhãn, một cơ chế tổng hợp nội bộ được áp dụng để tính toán ra một vector đại diện duy nhất cho toàn bộ tập hợp thể phân loại của sản phẩm.

2. Nhánh Xử lý Đặc trưng Số thực

Thay vì truyền trực tiếp dữ liệu thô vào lớp hợp nhất, hệ thống thiết lập một mạng nơ-ron đa tầng chuyên biệt để xử lý các thuộc tính định lượng như điểm đánh giá hay số lượt bình chọn hữu ích. Mạng nơ-ron này thực hiện chuỗi ba phép biến đổi liên tiếp: đầu tiên là phép chiếu mở rộng dữ liệu thô lên không gian ẩn 64 chiều, tiếp nối bằng hàm kích hoạt phi tuyến ReLU nhằm nắm bắt các tương quan không đơn điệu, và kết thúc bằng một lớp nén đưa dữ liệu về lại không gian mục tiêu 32 chiều.

Sự thiết kế song song này đảm bảo toàn bộ đặc trưng định lượng và định danh đều được quy chuẩn về cùng một kích thước chiều, tạo điều kiện trộn tru nhất để nối ghép thành một vector dữ liệu bảng hoàn chỉnh, sẵn sàng tích hợp cùng đặc trưng văn bản và hình ảnh ở khối hợp nhất đa phương thức cuối cùng.

3. Nhánh Hợp nhất Đặc trưng Bảng

Tại tầng xử lý cuối cùng hay còn gọi là Lớp Hợp nhất, hệ thống thực hiện phép ghép nối chuỗi cho toàn bộ các vector đặc trưng phân loại và số thực đã qua tiền xử lý ở hai nhánh trên. Khối tensor tổng hợp này sau đó được truyền qua một mạng nơ-ron đa tầng để thực hiện ép kiểu và nén thông tin. Kết quả đầu ra là một vector đại diện duy nhất có kích thước không gian ẩn 256 chiều. Phép chiếu không gian ở giai đoạn cuối này đóng vai trò chốt chặn thiết yếu, đảm bảo đặc trưng siêu dữ liệu của sản phẩm được đồng bộ hoàn toàn về mặt kích thước với mô-đun văn bản và mô-đun hình ảnh, tạo tiền đề hoàn hảo cho giai đoạn dung hợp đa phương thức toàn cục.

3.2.1.4 Cơ chế hợp nhất dữ liệu đa phương thức

Đóng vai trò là thành phần chốt chặn cuối cùng trong kiến trúc Tháp Sản phẩm, cơ chế cổng hợp nhất chịu trách nhiệm tổng hợp các vector đặc trưng từ ba luồng dữ liệu riêng biệt: văn bản, hình ảnh và dữ liệu bảng. Dựa trên nền tảng lý thuyết về cơ chế chú ý đã được phân tích chi tiết tại 2.4.3, đồ án tùy chỉnh module này để thực hiện phép hợp nhất có trọng số động. Cách tiếp cận này không chỉ giúp hệ thống tự động đánh giá mức độ đóng góp của từng phương thức dữ liệu đối với một mặt hàng cụ thể, mà còn cung cấp cơ chế xử lý linh hoạt cho thực trạng dữ liệu khuyết thiếu thường gặp trong môi trường thương mại điện tử.

Tùy biến Mạng Gating dùng chung

Thay vì sử dụng các mạng đánh giá độc lập, đồ án thiết kế một mạng Gating dùng chung cho toàn bộ các luồng dữ liệu nhằm đảm bảo sự công bằng và nhất quán trong thang đo. Kế thừa kiến trúc mạng truyền thẳng cơ sở, module này bao gồm một lớp tuyến tính nén phân nửa số chiều dữ liệu, kết hợp cùng hàm kích hoạt phi tuyến ReLU và một lớp đầu ra vô hướng. Điểm số vô hướng sinh ra đại diện cho mức độ tin cậy hay hàm lượng thông tin hữu ích mà mỗi nhánh dữ liệu mang lại cho bản sắc chung của sản phẩm.

Quy trình tính toán và Xử lý khuyết thiếu

Quy trình tính toán thực tế của đồ án được triển khai qua các bước tinh chỉnh chặt chẽ. Sau khi mạng Gating sinh ra các điểm số thô cho ba nhánh, hệ thống kích hoạt cơ chế xử lý ngoại lệ thông qua một ma trận mặt nạ. Ma trận này làm nhiệm vụ quét và phát hiện các luồng thông tin không tồn tại, chẳng hạn như sản phẩm thiếu ảnh minh họa, từ đó gán ngay một giá trị âm vô cùng xấp xỉ -10^9 cho điểm số tương ứng. Bước can thiệp kỹ thuật này đóng vai trò sống còn trước khi đưa dữ liệu qua hàm Softmax, đảm bảo trọng số phân bổ cho các thành phần bị khuyết sẽ tự động triệt tiêu về 0, qua đó cách ly hoàn toàn xung nhiễu khỏi vector tổng hợp.

Sau bước lọc nhiễu, hệ thống áp dụng hàm Softmax để chuyển hóa các điểm số thô thành một phân phối xác suất có tổng bằng 1. Trọng số động của luồng văn bản, hình ảnh và dữ liệu bảng lần lượt được xác định qua ma trận:

$$\mathbf{W} = \text{Softmax}(\mathbf{G}) = [w_t, w_i, w_b] \quad (3.4)$$


Vector hợp nhất cuối cùng $\mathbf{v}_{\text{fused}}$ được đồ án thiết lập dựa trên phép cộng có trọng số của các vector thành phần:

$$\mathbf{v}_{\text{fused}} = w_t \cdot \mathbf{e}_{\text{text}} + w_i \cdot \mathbf{e}_{\text{img}} + w_b \cdot \mathbf{e}_{\text{tab}} \quad (3.5)$$

Để hoàn thiện, kết quả này trải qua phép chuẩn hóa L2 nhằm đưa vector về độ dài đơn vị. Bước chuẩn hóa này tạo ra vector đại diện sản phẩm hoàn chỉnh, đảm bảo tính ổn định và tính đẳng hướng tối đa khi tham gia vào các phép tính toán độ tương đồng Cosine trong không gian truy xuất toàn cục phía sau.

3.2.2 Xây dựng Tháp Người dùng và Mô hình hóa Chuỗi hành vi

Nếu Tháp Sản phẩm đóng vai trò xây dựng không gian ngữ nghĩa tĩnh, thì Tháp Người dùng User Tower đảm nhiệm trọng trách phức tạp hơn: nắm bắt dòng chảy biến thiên trong ý định mua sắm của khách hàng thông qua mô hình hóa chuỗi hành vi lịch sử. Đồ án áp dụng tư duy của hệ thống gợi ý tuần tự Sequential Recommendation, kết hợp cùng sức mạnh của mạng tự chú ý để phân tích các mẫu hình tương tác theo thời gian. Sơ đồ kiến trúc tổng quan của Tháp Người dùng được minh họa chi tiết tại Hình 3.5.



Hình 3.5: Kiến trúc chi tiết Tháp Người dùng với cơ chế mô hình hóa chuỗi đa phương thức.

Khác với các phương pháp gom cụm hay tính trung bình cộng truyền thống vốn làm mất đi thông tin về thứ tự trước sau, luồng xử lý dữ liệu tại đây được thiết kế thành một đường ống phân tầng nghiêm ngặt, bao gồm ba tầng tính toán chính:

Tầng 1: Trích xuất Đặc trưng Tương tác Cục bộ

Tại tầng đáy của kiến trúc, mỗi bước tương tác trong lịch sử của người dùng không chỉ là một mã định danh vô tri, mà được bóc tách thành một bộ ba thông tin đa chiều bao gồm: Sản phẩm, Nội dung đánh giá Review và Điểm số Rating. Điểm đột phá về mặt hiệu năng nằm ở việc xử lý mã sản phẩm. Thay vì tốn tài nguyên mã hóa lại từ đầu, hệ thống sử dụng khối Item Embedding Lookup để truy xuất trực tiếp các vector sản phẩm đa phương thức đã được tính toán sẵn từ Tháp Sản phẩm. Song song đó, văn bản đánh giá

và điểm số được truyền qua các khối Review Encoder và Rating Encoder để trích xuất các đặc trưng định tính và định lượng tương ứng.

Tầng 2: Hợp nhất Trạng thái và Mã hóa Vị trí

Ba luồng đặc trưng độc lập của mỗi bước tương tác sau đó hội tụ tại Cổng Hợp nhất Fusion Gate. Khối mạng nơ-ron này làm nhiệm vụ dung hợp thông tin, sinh ra một vector trạng thái Interaction Vector duy nhất, đại diện trọn vẹn cho trải nghiệm của người dùng với sản phẩm đó tại một thời điểm cụ thể. Để hệ thống nhận thức được tính tuần tự trước sau của các hành vi, một ma trận mã hóa vị trí Positional Encoding được cộng trực tiếp vào chuỗi vector tương tác, qua đó tiêm thông tin về dòng thời gian vào không gian biểu diễn mà không làm thay đổi kích thước chiều dữ liệu.

Tầng 3: Mô hình hóa Tuần tự với mạng Transformer

Chuỗi tương tác sau khi được gắn nhãn thời gian sẽ đi vào hạt nhân tính toán của Tháp Người dùng: khối mạng nơ-ron tự chú ý Transformer Encoder Block kế thừa từ kiến trúc SASRec. Cơ chế Self-Attention cho phép mô hình tự động đánh giá mức độ quan trọng chéo giữa các hành vi trong quá khứ, từ đó tìm ra những tương tác mang tính quyết định đối với sở thích hiện tại. Cuối cùng, để giải quyết bài toán độ dài chuỗi hành vi không đồng đều giữa các người dùng, hệ thống áp dụng kỹ thuật gộp Masked Mean Pooling. Cơ chế này kết hợp cùng ma trận mặt nạ nhằm triệt tiêu hoàn toàn nhiễu từ các vị trí đệm Padding, xuất ra một vector đại diện người dùng User Embedding 256 chiều duy nhất. Vector này mang trong mình toàn bộ động lực mua sắm hiện tại, sẵn sàng cho phép tính đối chiếu với kho sản phẩm ở giai đoạn truy xuất ứng viên.

3.2.2.1 Trích xuất Đặc trưng Tương tác Cục bộ

Tại bước khởi đầu của mạng tuần tự, mỗi tương tác lịch sử được bóc tách thành ba luồng tín hiệu độc lập: định danh sản phẩm, nội dung văn bản đánh giá và cấu trúc siêu dữ liệu. Nhằm tối ưu hóa tài nguyên tính toán, định danh sản phẩm không được mã hóa lại từ đầu mà sử dụng kỹ thuật *Item Embedding Lookup* để truy xuất trực tiếp vector đa phương thức 256 chiều đã cấu trúc sẵn từ Tháp Sản phẩm.

Mã hóa Văn bản với Chiến lược Chia sẻ Trọng số

Nội dung nhận xét được xử lý qua khối ReviewTextEncoder. Thay vì khởi tạo một mô hình ngôn ngữ độc lập, đề án áp dụng triệt để cơ chế Chia sẻ Trọng số (*Weight Sharing*) – tái sử dụng toàn bộ kiến trúc mạng và bộ tham số tĩnh từ khối mã hóa văn bản của Tháp Sản phẩm. Thiết kế này mang lại lợi ích kép: vừa giải phóng đáng kể áp lực lên VRAM, vừa ép buộc ngôn từ đa dạng của người dùng và mô tả chuẩn mực của sản phẩm hội tụ tuyệt đối về cùng một hệ quy chiếu vector ngữ nghĩa. Kết quả đầu ra là một tensor đặc trưng văn bản có kích thước $[B, S, 256]$, với B là kích thước lô và S là độ dài chuỗi lịch sử.

Mã hóa Siêu dữ liệu Đánh giá

Các tín hiệu định lượng bổ trợ (điểm đánh giá 1 – 5, số lượt hữu ích) và định danh (trạng thái xác thực mua hàng) được xử lý đồng thời qua khối ReviewTabularEncoder phân nhánh nhằm bổ sung ngữ cảnh tin cậy:

- **Nhánh phân loại:** Trạng thái xác thực đi qua ma trận nhúng $nn.Embedding$ để chuyển đổi thành vector liên tục $\mathbf{v}_{cat}$ 4 chiều.

- **Nhánh số học:** Cặp giá trị (điểm số, lượt hữu ích) đi qua mạng MLP ẩn 64 chiều kết hợp hàm kích hoạt ReLU. Phép chiếu phi tuyến này giúp mô hình nắm bắt các tương quan nghịch (ví dụ: đánh giá điểm thấp nhưng độ tin cậy cộng đồng cao), nén thông tin thành vector $\mathbf{v}_{\text{num}}$ 32 chiều.

Hai nhánh sau đó được ghép nối tạo thành vector đặc trưng tổng hợp 36 chiều:

$$\mathbf{v}_{\text{concat}} = [\mathbf{v}_{\text{num}}; \mathbf{v}_{\text{cat}}]$$

Vector tổng hợp này cuối cùng được truyền qua một khối chiếu không gian tuyến tính thuần túy. Việc chủ đích loại bỏ hàm kích hoạt phi tuyến ở tầng chốt chặn này cho phép các giá trị nhận được mở rộng trên toàn miền $(-\infty, +\infty)$, qua đó bảo toàn trọn vẹn sự phong phú của thông tin (*information richness*) trước khi tiến vào Cổng hợp nhất trạng thái ở tầng tiếp theo.

3.2.2.2 Hợp nhất Trạng thái và Mã hóa Vị trí

Sau khi trích xuất thành công, ba luồng đặc trưng cục bộ bao gồm định danh sản phẩm $\mathbf{v}_{\text{item}}$, văn bản đánh giá $\mathbf{v}_{\text{text}}$ và siêu dữ liệu $\mathbf{v}_{\text{tabular}}$ tiếp tục được hội tụ để tạo thành một trạng thái tương tác nguyên khối. Quá trình này và việc xác định thứ tự thời gian được thực hiện thông qua hai khối xử lý nối tiếp:

Cổng Hợp nhất Người dùng User Fusion Gate

Kế thừa cơ sở lý thuyết về cơ chế hợp nhất động đã được trình bày chi tiết tại 2.4.3, hệ thống sử dụng khối Gating Fusion Layer để tổng hợp ba luồng thông tin. Đầu tiên, các vector đầu vào được chiếu không gian về cùng kích thước chiều $d_{\text{model}} = 256$. Tiếp theo, một mạng perceptron đa lớp kết hợp cùng hàm Softmax được sử dụng để tự động tính toán trọng số tầm quan trọng cho từng thành phần. Cơ chế này cho phép mô hình linh hoạt điều tiết hàm lượng thông tin dựa trên ngữ cảnh thực tế (ví dụ: ưu tiên văn bản nếu người dùng viết đánh giá rất dài). Kết quả đầu ra là một vector trạng thái duy nhất $\mathbf{h}_{\text{seq}}$, đại diện trọn vẹn cho một bước trong chuỗi hành vi.

Bổ sung Mã hóa Vị trí Positional Encoding

Do mạng Transformer sắp được sử dụng ở tầng tiếp theo mang đặc tính bất biến hoán vị, hệ thống bắt buộc phải tiêm thông tin về thứ tự thời gian vào chuỗi vector $\mathbf{h}_{\text{seq}}$. Dựa trên nền tảng toán học của phương pháp Mã hóa hình sin Sinusoidal Encoding đã được thiết lập tại 2.3.3, đồ án tùy biến module này để tối ưu hóa tốc độ tính toán phần cứng.

Cụ thể, toàn bộ ma trận mã hóa vị trí được tính toán sẵn ngay từ lúc khởi tạo và đưa vào bộ nhớ đệm thông qua cơ chế `register_buffer`. Kỹ thuật này cố định ma trận như một trạng thái bền vững, cách ly hoàn toàn khỏi quá trình cập nhật gradient để giảm tải VRAM. Trong luồng lan truyền xuôi, tín hiệu vị trí được cộng trực tiếp vào vector trạng thái. Ngay sau đó, một lớp Dropout với tỷ lệ 0.1 được áp dụng nhằm ngăn chặn hiện tượng quá khớp, buộc hệ thống phải học các mẫu hình tương tác tổng quát thay vì ghi nhớ máy móc vị trí tuyệt đối của từng sản phẩm. Bước xử lý này cung cấp cơ sở tham chiếu sống còn để hệ thống nhận thức được tính gần đây và nguyên tắc nhân quả trước khi tiến vào hạt nhân tự chú ý.

3.2.2.3 Mô hình hóa Tuần tự và Tổng hợp Vector Đại diện

Sau khi tích hợp mã hóa vị trí, chuỗi vector trạng thái chính thức tiến vào hạt nhân tính toán của Tháp Người dùng: khối mạng *Transformer Encoder Block* kế thừa từ kiến trúc SASRec. Tại đây, cơ chế *Self-Attention* cho phép mô hình học các mối quan hệ phụ thuộc chéo giữa mọi điểm neo trong lịch sử, từ đó nắm bắt chính xác sự chuyển dịch trong thị hiếu mua sắm của người dùng qua thời gian. Kết quả đầu ra là một chuỗi các trạng thái ẩn tuần tự mang chiều sâu ngữ nghĩa cao.

Cơ chế Masked Mean Pooling

Thách thức kỹ thuật lớn nhất tại bước này là sự biến thiên về độ dài lịch sử hành vi giữa các người dùng. Để nén toàn bộ chuỗi trạng thái ẩn thành một vector đại diện duy nhất mà không bị sai lệch bởi các vị trí đệm (*padding*), hệ thống áp dụng kỹ thuật *Masked Mean Pooling*.

Cụ thể, một ma trận mặt nạ nhị phân được khởi tạo và đồng bộ chiều tương thích với tensor dữ liệu, trong đó các vị trí tương tác thực nhận trọng số 1 và vị trí đệm nhận giá trị 0. Hệ thống tiến hành phép nhân Hadamard (nhân từng phần tử) giữa đầu ra của mô hình và mặt nạ nhằm triệt tiêu hoàn toàn tín hiệu nhiễu tại vị trí đệm về 0. Sau đó, các vector đặc trưng được cộng dồn dọc theo trục thời gian và chia cho số lượng hành vi thực tế. Một hằng số cực nhỏ ϵ được bổ sung vào mẫu số nhằm duy trì độ ổn định số học:

$$\mathbf{u}_{\text{pooled}} = \frac{\sum_{t=1}^T (\mathbf{h}_t \cdot m_t)}{\sum_{t=1}^T m_t + \epsilon}$$

Trong đó, $\mathbf{h}_t$ là trạng thái ẩn tại bước t và m_t là giá trị mặt nạ nhị phân tại vị trí tương ứng.

Tinh chỉnh và Chuẩn hóa Đặc trưng

Quy trình khép lại bằng việc đưa vector trung bình $\mathbf{u}_{\text{pooled}}$ qua một lớp mạng tuyến tính cuối cùng. Lớp này đóng vai trò như một bộ chuyển đổi đặc trưng cấp cao, hiệu chỉnh biểu diễn người dùng về không gian phân phối mục tiêu. Cuối cùng, đầu ra trải qua phép chuẩn hóa L2 để chiếu lên mặt cầu không gian đơn vị $\mathbb{R}^{256}$. Bước chuẩn hóa hình học này là điều kiện tiên quyết, đảm bảo khoảng cách giữa ý định của người dùng và các ứng viên sản phẩm được đo lường một cách chính xác, công bằng và nhất quán thông qua độ tương đồng Cosine ở giai đoạn truy xuất ứng viên phía sau.

3.2.3 Chiến lược Huấn luyện Hai giai đoạn

Việc tối ưu hóa đồng thời mạng nội bộ tháp sản phẩm và đối chiếu toàn cục giữa hai tháp trong một đồ thị tính toán duy nhất thường dẫn đến hiện tượng xung đột đạo hàm và quá tải VRAM. Để đảm bảo mô hình hội tụ ổn định, hệ thống được thiết kế theo chiến lược huấn luyện hai giai đoạn, tách biệt hoàn toàn việc thấu hiểu nội dung sản phẩm và việc nắm bắt chuỗi hành vi người dùng.

3.2.3.1 Tiền huấn luyện độc lập Tháp Sản phẩm

Trong giai đoạn này, cấu trúc Tháp Người dùng bị đóng băng hoặc loại bỏ khỏi đồ thị tính toán. Hệ thống tập trung tối ưu hóa các bộ mã hóa đa phương thức của Tháp Sản phẩm dựa trên cơ sở dữ liệu tĩnh (văn bản, hình ảnh, thông số).

Quá trình tiền huấn luyện sử dụng biến thể *Symmetric InfoNCE Loss* để đồng bộ hóa không gian biểu diễn chung giữa các phương thức dữ liệu (ví dụ: ép vector hình ảnh và vector mô tả của cùng một sản phẩm phải hội tụ về một điểm). Tuy nhiên, đặc thù của các tập dữ liệu thương mại điện tử như All Beauty là độ hạt mịn (fine-grained) cực kỳ cao. Các sản phẩm mỹ phẩm cùng chủng loại nhưng khác thương hiệu thường có vector biểu diễn chồng chéo lên nhau. Hàm InfoNCE gốc phân bố lực đẩy đồng đều lên mọi mẫu âm tính trong lô, dẫn đến việc thiếu sức ép để phân tách các sản phẩm quá giống nhau này.

Để khắc phục, hệ thống tích hợp thêm hàm *Batch-Hard Triplet Loss*. Phương pháp này bỏ qua các mẫu dễ và chỉ tập trung phạt mẫu đối nghịch khó nhất — tức là sản phẩm nhiều nằm gần với sản phẩm mục tiêu nhất trong không gian vector. Bằng cách thiết lập một biên độ an toàn (margin) m , thuật toán ép buộc hệ thống phải chất lọc được những đặc trưng định danh vi tế nhất, giúp phân biệt rạch ròi các mặt hàng mỹ phẩm có ngoại quan hoặc mô tả gần như tương đồng.

3.2.3.2 Tinh chỉnh toàn cục đa tháp

Sau khi Tháp Sản phẩm đã hình thành không gian vector chuẩn xác, Tháp Người dùng được kích hoạt để tiến hành tinh chỉnh toàn cục. Mục tiêu cốt lõi là dạy cho hệ thống cách biên dịch mượt mà từ ngôn ngữ hành vi sang ngôn ngữ nội dung.

Cơ chế Mẫu âm tính kết hợp (Combined Negative Sampling)

Hệ thống không chỉ tận dụng các sản phẩm khác trong lô làm mẫu đối nghịch giả định (In-batch negatives), mà còn thêm vào các mẫu âm tính rõ ràng (Explicit negatives) — chính là những sản phẩm người dùng đã trực tiếp đánh giá thấp (rating 1-2 sao). Cơ chế tạo rào cản ngữ nghĩa khắt khe này được minh họa tại Bảng 3.1.

Bảng 3.1: Minh họa cơ chế lấy mẫu kết hợp với kích thước lô $N = 3$

Người dùng \ Sản phẩm	Sản phẩm 1 (v_1^+)	Sản phẩm 2 (v_2^+)	Sản phẩm 3 (v_3^+)	Mẫu đánh giá thấp (v_i^-)
Người dùng 1 (u_1)	Dương tính	Âm tính	Âm tính	Âm tính rõ ràng (v_1^-)
Người dùng 2 (u_2)	Âm tính	Dương tính	Âm tính	Âm tính rõ ràng (v_2^-)
Người dùng 3 (u_3)	Âm tính	Âm tính	Dương tính	Âm tính rõ ràng (v_3^-)

Toán học Tối ưu hóa Bất đối xứng

Dựa trên ma trận tương đồng Cosine $\mathbf{S}$ có kích thước $N \times N$, hệ thống tính toán điểm số tương quan giữa vector người dùng $\mathbf{u}_i$ và sản phẩm mục tiêu $\mathbf{v}_j^+$ được chuẩn hóa bởi nhiệt độ τ :

$$S_{i,j} = \frac{\mathbf{u}_i \cdot (\mathbf{v}_j^+)^T}{\tau}$$

Đồng thời, điểm số tương quan đối với sản phẩm bị đánh giá thấp v_i^- được xác định:

$$E_i = \frac{\mathbf{u}_i \cdot (\mathbf{v}_i^-)^T}{\tau}$$

Hàm mất mát được thiết kế theo hướng bất đối xứng để phù hợp với bản chất luồng dữ liệu:

1. Chiều từ Người dùng đến Sản phẩm ($\mathcal{L}_{U \rightarrow I}$): Không gian đối nghịch được mở rộng từ N lên $N + 1$. Vector người dùng bị ép phải hướng tới sản phẩm mục tiêu, đồng thời đẩy lùi toàn bộ $N - 1$ sản phẩm nhiễu trong lô và đặc biệt bị phạt nặng bởi thành phần $\exp(E_i)$ nếu tiến lại gần sản phẩm đã bị đánh giá thấp:

$$\mathcal{L}_{U \rightarrow I} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(S_{i,i})}{\sum_{j=1}^N \exp(S_{i,j}) + \exp(E_i)}$$

2. Chiều từ Sản phẩm đến Người dùng ($\mathcal{L}_{I \rightarrow U}$): Nhằm bảo toàn đặc tính phân cụm tự nhiên của lọc cộng tác, chiều này không sử dụng mẫu âm tính rõ ràng. Sản phẩm chỉ có nhiệm vụ tìm đúng người dùng đã tương tác với nó giữa tập hợp người dùng trong lô:

$$\mathcal{L}_{I \rightarrow U} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(S_{i,i})}{\sum_{j=1}^N \exp(S_{j,i})}$$

Giá trị mất mát tổng thể $\mathcal{L}_{\text{Total}}$ là trung bình cộng của hai chiều tính toán trên. Sức ép tối ưu hóa từ môi trường tương phản khốc liệt này đóng vai trò chốt chặn, buộc mạng lưới nơ-ron phải quy hoạch không gian biểu diễn một cách rành mạch. Đây là tiền đề sống còn giúp thuật toán Tìm kiếm Lân cận Gần nhất ANN có thể truy xuất ứng viên siêu tốc và chính xác trong môi trường thực tế.

3.3 Giai đoạn 2: Re-ranker


3.3.1 Kiến trúc tổng quan Reranker

Trong lĩnh vực tìm kiếm thông tin, việc chỉ dựa vào độ phù hợp ngữ nghĩa giữa truy vấn và tài liệu thường không đáp ứng đủ nhu cầu đa dạng của người dùng. Ngược lại, việc áp dụng cá nhân hóa một cách cứng nhắc lại có nguy cơ làm giảm tính đa dạng của kết quả và khiến hệ thống trở nên thiếu minh bạch, khó kiểm soát. Từ đó, một bài toán cốt lõi được đặt ra là làm thế nào để kết hợp hài hòa giữa tín hiệu đối sánh ngữ nghĩa truyền thống và tín hiệu sở thích cá nhân, đồng thời cấp cho hệ thống khả năng tự động đánh giá và điều chỉnh mức độ cá nhân hóa tùy thuộc vào từng ngữ cảnh truy vấn cụ thể.

Để giải quyết triệt để vấn đề này, một kiến trúc xếp hạng lại (reranker) tổng hợp được đề xuất, hoạt động dựa trên cơ chế kết hợp giữa mô hình mã hóa chéo (Embedding Cross-Encoder) và bộ nhớ người dùng (User Memory). Cụ thể, điểm số đánh giá mức độ phù hợp của một tài liệu, ký hiệu là s_d , được xác định thông qua hàm $f_{Ret}(\mathcal{P}_u, q, d)$, trong đó q là câu truy vấn, d là tài liệu ứng viên được trích xuất từ danh sách của mô hình xếp hạng bước một, và $\mathcal{P}_u$ là hồ sơ lịch sử của người dùng. Kiến trúc này vận hành bằng cách tính toán hai nguồn điểm số độc lập nhưng bổ trợ cho nhau: điểm phù hợp ngữ nghĩa giữa truy vấn và tài liệu (s_d^q) được xuất ra từ mô hình Cross-Encoder (f_{CE}), và điểm phù

hợp cá nhân hóa (s_d^u) được tính toán thông qua mô hình Memory Encoder (f_{Mem}). Thay vì cộng gộp một cách tuyến tính và cố định, hai giá trị này được dung hợp thông qua một mô hình trộn (Mixing Model), ký hiệu là g_{Mix} . Mô hình kết hợp này sinh ra một trọng số w , cho phép tính toán điểm số xếp hạng cuối cùng theo phương trình:

$$s_d = w \cdot s_d^q + (1 - w) \cdot s_d^u = w \cdot f_{CE}(q, d) + (1 - w) \cdot f_{Mem}(\mathcal{P}_u, q, d)$$



Hình 3.6: Kiến trúc tổng quan của mô hình xếp hạng lại (Reranker) kết hợp đối sánh ngữ nghĩa và bộ nhớ cá nhân hóa.


Sự khác biệt của kiến trúc này so với các mạng Cross-Encoder tiêu chuẩn nằm ở phương pháp biểu diễn đặc trưng. Các mô hình Cross-Encoder truyền thống thường gộp chung truy vấn và tài liệu thành một chuỗi thống nhất, làm hạn chế khả năng tách biệt và tái sử dụng đặc trưng của tài liệu cho các tác vụ khác. Ngược lại, mô hình đề xuất sử dụng kiến trúc Embedding Cross-Encoder, cho phép học các biểu diễn vector tách biệt nhưng vẫn chứa đựng thông tin ngữ cảnh chéo (cross-encoded) cho cả truy vấn (q) và tài liệu (d). Nhờ cấu trúc phân mảnh này, vector biểu diễn của tài liệu có thể trực tiếp tương tác với các vector đa chiều V_i trong hồ sơ người dùng $\mathcal{P}_u$ thông qua thành phần f_{Mem} . Đồng thời, trọng số w được sinh ra đóng vai trò như một bộ dự báo hiệu suất, giúp hệ thống đánh giá mức độ tin cậy của tín hiệu từ Cross-Encoder, qua đó quyết định xem có cần sự can thiệp từ bộ nhớ cá nhân hay không. Cấu trúc phân tách điểm số này cũng cung cấp một cơ chế điều khiển thiết yếu, cho phép hệ thống dễ dàng quay về trạng thái không cá nhân hóa thông qua thao tác loại bỏ thành phần s_d^u khỏi phương trình tính toán khi không cần thiết.

Tổng thể kiến trúc của giai đoạn xếp hạng lại được xây dựng theo dạng mô-đun nhằm cân bằng giữa việc phân tích ngữ nghĩa và khai thác thông tin cá nhân hóa. Cách tiếp cận này giúp hệ thống khắc phục được tính cứng nhắc của các phương pháp truyền thống, đồng thời cho phép kiểm soát linh hoạt mức độ can thiệp của dữ liệu lịch sử đối với từng

truy vấn cụ thể. Thiết kế phân tách rõ ràng giữa các thành phần học ngữ nghĩa và thành phần trộn điểm cũng tạo nền tảng thuận lợi cho việc tối ưu hóa độc lập trong các quá trình huấn luyện tiếp theo.

3.3.2 Embedding Cross Encoder

Các kiến trúc Cross-Encoder tiêu chuẩn hiện đóng vai trò nền tảng trong nhiều hệ thống xếp hạng văn bản tiên tiến nhờ khả năng phân tích ngữ nghĩa sâu sắc và đánh giá mức độ liên quan với độ chính xác cao. Theo cách tiếp cận truyền thống, các mô hình này tiến hành ghép nối trực tiếp câu truy vấn và tài liệu ứng viên thành một chuỗi duy nhất thông qua các token phân cách, sau đó nạp toàn bộ chuỗi này qua các tầng tự chú ý (self-attention) của mô hình ngôn ngữ. Mặc dù phương pháp này tối ưu hóa được việc học các tương tác từ vựng chéo ở mức độ token (token-level cross-attention), nó lại bộc lộ một rào cản kiến trúc nghiêm trọng khi được tích hợp vào các hệ thống đòi hỏi tính cá nhân hóa. Nguyên nhân cốt lõi nằm ở việc các mô hình này thường nén toàn bộ thông tin của cặp truy vấn - tài liệu vào một token đại diện duy nhất (thường là token [CLS]) để tính toán ra một điểm số vô hướng cuối cùng. Sự hợp nhất này làm xóa nhòa ranh giới đặc trưng không gian của tài liệu. Khi không thể trích xuất được một biểu diễn vector độc lập đại diện cho tài liệu, hệ thống hoàn toàn thiếu đi cơ sở dữ liệu véc-tơ để tiếp tục đối chiếu với các nguồn thông tin khác, đặc biệt là không gian vector đa chiều chứa bộ nhớ về lịch sử tương tác của người dùng.



Hình 3.7: Sơ đồ luồng xử lý và trích xuất đặc trưng độc lập của kiến trúc Embedding Cross-Encoder.

Để vượt qua giới hạn kiến trúc này, một cơ chế mang tên Embedding Cross-Encoder được triển khai, sử dụng mô hình ngôn ngữ MPNet làm lõi xử lý trung tâm. Lõi MPNet được ưu tiên lựa chọn nhờ khả năng nắm bắt ngữ nghĩa toàn cục vượt trội, bắt nguồn từ phương pháp huấn luyện kết hợp giữa cơ chế che giấu từ (masked language modeling) và hoán vị từ (permuted language modeling), giúp mô hình hiểu được cấu trúc ngữ cảnh phức tạp của các chuỗi văn bản dài. Quá trình xử lý của Embedding Cross-Encoder vẫn duy trì bước khởi đầu quen thuộc: nạp chuỗi ghép nối giữa truy vấn và tài liệu vào mô hình để trích xuất các biểu diễn token mang tính ngữ cảnh (contextualized token embeddings) từ tầng ẩn cuối cùng. Tuy nhiên, sự khác biệt mang tính đột phá nhằm giải quyết bài toán biểu diễn nằm ở bước phân tách đặc trưng. Thay vì sử dụng đầu ra từ token [CLS], hệ thống tận dụng các chuỗi định danh (sequence IDs) do bộ phân tách từ ngữ (tokenizer) cung cấp để xác định rõ ranh giới ngữ nghĩa. Dựa trên các định danh này, các ma trận mặt nạ (attention mask) chuyên biệt được tạo ra để định vị và cô lập chính xác tập hợp các token thuộc về câu truy vấn và tập hợp các token thuộc về tài liệu ứng viên.


Ngay sau khi quá trình cô lập nhóm token hoàn tất, kỹ thuật gộp trung bình (mean pooling) được áp dụng một cách độc lập lên từng nhóm token tương ứng với mặt nạ phân bổ của chúng. Kết quả của phép toán này là sự hình thành của hai biểu diễn vector hoàn toàn tách biệt có cùng không gian số chiều: một vector đại diện cho truy vấn (q) và một vector đại diện cho tài liệu (d). Nhằm đảm bảo tính ổn định và đồng nhất trong hình học không gian vector, cả hai biểu diễn này đều tiếp tục trải qua quá trình chuẩn hóa L2 (L2 Normalization), đưa toàn bộ các giá trị về cùng một không gian độ đo chuẩn mực. Sau khi được chuẩn hóa, điểm số đánh giá mức độ phù hợp ngữ nghĩa cốt lõi giữa truy vấn và tài liệu được tính toán trực tiếp thông qua phép toán tích vô hướng của hai vector này. Nhờ sự hiện diện của bước chuẩn hóa trước đó, tích vô hướng ở công đoạn này mang ý nghĩa toán học tương đương với việc đo lường độ cosine similarity, phản ánh một cách trực quan và chính xác sự hội tụ về mặt ý nghĩa giữa ý định tìm kiếm của người dùng và nội dung cốt lõi của văn bản.

Nhìn chung, việc thiết kế và ứng dụng cơ chế Embedding Cross-Encoder mang lại những lợi ích mang tính bản lề cho toàn bộ kiến trúc của giai đoạn xếp hạng lại. Một mặt, kiến trúc này vẫn kế thừa trọn vẹn khả năng phân tích sự phụ thuộc từ vựng phức tạp nhờ cơ chế tự chú ý chéo diễn ra liên tục trong các tầng sâu của mô hình MPNet, qua đó bảo chứng cho độ chính xác cao của tín hiệu tìm kiếm ngữ nghĩa độc lập. Mặt khác, sự can thiệp mang tính cấu trúc ở lớp đầu ra đã giải phóng đặc trưng của tài liệu khỏi trạng thái nén cứng nhắc truyền thống. Vector tài liệu (d) được trích xuất ra mang một đặc tính lai độc đáo: nó vừa tồn tại như một thực thể toán học độc lập trong không gian vector, vừa chứa đựng dấu ấn ngữ cảnh sâu sắc từ sự tương tác trực tiếp với câu truy vấn. Chính biểu diễn tài liệu đã được ngữ cảnh hóa này sẽ đóng vai trò là đầu vào tiên quyết để thực hiện các phép toán đối chiếu chéo với bộ nhớ người dùng, kiến tạo nên tiền đề kỹ thuật vững chắc để hệ thống triển khai các thuật toán cá nhân hóa ở những giai đoạn tiếp theo một cách minh bạch và hiệu quả.

3.3.3 Memory Encoder

Sau khi trích xuất thành công vector biểu diễn tài liệu độc lập từ mô-đun Embedding Cross-Encoder, hệ thống tiến tới giai đoạn định lượng mức độ phù hợp của tài liệu ứng viên đối với từng người dùng cụ thể. Việc chỉ phụ thuộc vào câu truy vấn hiện tại sẽ bỏ qua nguồn thông tin ngữ cảnh có giá trị lớn ẩn chứa trong lịch sử tương tác. Tuy nhiên, lịch sử của một người dùng thường bao gồm một tập hợp nhiều sản phẩm hoặc tài liệu mang các chủ đề rất đa dạng. Do đó, việc đối chiếu trực tiếp một tài liệu mới với toàn bộ chuỗi sự kiện trong quá khứ đặt ra một thách thức lớn về mặt biểu diễn không gian. Hệ thống đòi hỏi một cơ chế tính toán chuyên biệt nhằm chuyển đổi dữ liệu lịch sử thô thành các tín hiệu cá nhân hóa có khả năng đo lường chính xác, mà không làm mất đi các sắc thái sở thích riêng biệt.

Để giải quyết bài toán này, mô-đun Memory Encoder (Bộ mã hóa ký ức) được thiết kế nhằm số hóa và quản lý hồ sơ người dùng dưới dạng một cấu trúc bộ nhớ đa vector (Multi-vector User Representation). Trong cơ chế này, lịch sử tương tác được xem như một tập hợp các tài liệu độc lập, và mỗi tài liệu cấu thành nên lịch sử đó sẽ được nạp qua một mô hình ngôn ngữ chuyên biệt nhằm tạo ra một tập hợp các vector biểu diễn ký ức (V_i) riêng biệt. Nhằm tối ưu hóa tài nguyên tính toán và giảm thiểu độ trễ, toàn bộ quá trình mã hóa bộ nhớ này được thực hiện ngoại tuyến (offline) với các trọng số của mô



Hình 3.8: Cơ chế hoạt động của Memory Encoder phân tách thành hai luồng: Xử lý ngoại tuyến (chất lọc hồ sơ đa vector) và Xử lý trực tuyến (đối chiếu và tính điểm cá nhân hóa).

hình mã hóa được đóng băng hoàn toàn. Điểm số đánh giá mức độ cá nhân hóa (s_d^u) của tài liệu ứng viên được xác định dựa trên độ tương đồng vô hướng (dot product) giữa vector tài liệu mục tiêu (d) — được truyền sang từ nhánh Cross-Encoder — và từng vector ký ức trong hồ sơ người dùng. Cụ thể, hệ thống áp dụng toán tử tìm giá trị lớn nhất (max pooling) trên toàn bộ tập hợp các điểm số tương đồng vừa tính toán. Thao tác toán học này đảm bảo rằng tài liệu ứng viên chỉ cần có độ cộng hưởng mạnh mẽ với một phần sở thích cốt lõi trong quá khứ là đủ để ghi nhận điểm cá nhân hóa cao, ngăn chặn hiện tượng các tín hiệu nổi bật bị làm loãng nếu áp dụng các phép tính trung bình hóa thông thường.

Nhìn chung, Memory Encoder đóng vai trò như một bộ lọc cá nhân hóa có độ phân giải cao trong tổng thể kiến trúc xếp hạng lại. Bằng cách duy trì trực tiếp các biểu diễn vector độc lập của từng sản phẩm thay vì nén toàn bộ lịch sử thành một khối dữ liệu duy nhất, kiến trúc này bảo toàn trọn vẹn các đặc trưng chi tiết trong sở thích của người dùng. Tín hiệu cá nhân hóa độc lập và sắc bén được sinh ra từ mô-đun này không chỉ phản ánh mức độ thân thuộc của tài liệu ứng viên, mà còn cung cấp một tham chiếu định lượng thiết yếu. Đây chính là mảnh ghép dữ liệu hoàn chỉnh giúp bộ trộn ở công đoạn tiếp theo có khả năng cân đối một cách linh hoạt giữa kết quả đối sánh ngữ nghĩa và thói quen tương tác dài hạn của người dùng.

3.3.4 Mixing Model

Trong các hệ thống tìm kiếm kết hợp (hybrid search), việc trích xuất thành công hai nguồn điểm số độc lập đại diện cho độ phù hợp ngữ nghĩa và độ phù hợp cá nhân hóa mới chỉ là bước khởi đầu. Thách thức kiến trúc lớn nhất ở giai đoạn dung hợp đặc trưng nằm ở hiện tượng mất cân bằng tín hiệu, thường được nhắc đến trong lý thuyết học máy là sự sụp đổ phương thức (modality collapse) hoặc vấn đề áp đảo (dominance problem). Trên thực tế, mức độ cần thiết của thông tin cá nhân hóa biến thiên rất lớn tùy thuộc vào bản chất của từng phiên tìm kiếm: các truy vấn mang tính khám phá hoặc đa nghĩa đòi hỏi sự định hướng mạnh mẽ từ hồ sơ người dùng, trong khi các truy vấn tra cứu định danh cụ thể lại chỉ cần đối sánh từ vựng chính xác. Nếu hệ thống áp dụng một phương pháp kết hợp tuyến tính với trọng số cố định hoặc nội suy đơn giản, mô hình thường có xu hướng hội tụ về trạng thái mất cân đối, nơi nó chỉ phụ thuộc vào tín hiệu dễ học và triệt tiêu hoàn toàn vai trò của bộ nhớ lịch sử.

Nhằm khắc phục triệt để điểm yếu kiến trúc này, một mô hình trộn động (Mixing

Model, ký hiệu là g_{Mix}) được thiết kế để điều phối toàn bộ quá trình tính toán kết quả từ các đầu vào cơ sở: câu truy vấn (q), tài liệu ứng viên (d) và hồ sơ lịch sử người dùng ($\mathcal{P}_u$). Về mặt toán học, điểm số xếp hạng cuối cùng (s_d) của một tài liệu được xác định thông qua phương trình nội suy kết hợp giữa tích vô hướng của các vector ngữ nghĩa và phép toán tìm cực đại trên không gian bộ nhớ:

$$s_d = w \cdot \mathbf{q}^T \mathbf{d} + (1 - w) \cdot \max_{i \in \{1 \dots P\}} \mathbf{d}^T \mathbf{V}_i$$

Trong đó, $\mathbf{q}^T \mathbf{d}$ chính là điểm phù hợp ngữ nghĩa (s_d^q) do Embedding Cross-Encoder trích xuất, và $\max \mathbf{d}^T \mathbf{V}_i$ là điểm cá nhân hóa (s_d'') được đối chiếu từ P vector ký ức trong Memory Encoder. Trọng tâm của sự linh hoạt nằm ở việc xác định trọng số điều phối w . Thay vì gán một giá trị tĩnh, trọng số này được dự đoán liên tục thông qua một mạng nơ-ron đa tầng (MLP) kết hợp với hàm kích hoạt sigmoid nhằm giới hạn biên độ đầu ra trong khoảng $[0, 1]$:

$$w = \text{sigmoid}(\text{MLP}([\mathbf{q}, \text{len}(q), P, s_d^q, s_d'']))$$

Đầu vào của mạng MLP này không chỉ dừng lại ở hai điểm số thành phần (s_d^q và s_d''), mà còn bao gồm một tập hợp các đặc trưng ngữ cảnh (metadata) mang tính quyết định: vector biểu diễn gốc của truy vấn ($\mathbf{q}$), độ dài của chuỗi truy vấn ($\text{len}(q)$), và quy mô cấu trúc của bộ nhớ người dùng (P).

Sự tích hợp của mô hình trộn động đã biến kiến trúc xếp hạng từ một cỗ máy tính toán tĩnh thành một hệ thống thích ứng ngữ cảnh mang tính dự báo. Về bản chất, thành phần này vận hành như một bộ dự báo hiệu suất (performance predictor): bằng cách phân tích hình thái của câu truy vấn và độ phong phú của dữ liệu lịch sử, nó tự động đánh giá mức độ tin cậy của nhánh đối sánh ngữ nghĩa để từ đó đưa ra quyết định cấp phát trọng số tương ứng cho nhánh cá nhân hóa. Cơ chế điều tiết tinh vi này không những giải quyết thành công bài toán áp đảo phương thức mà còn đảm bảo sự dung hòa tuyệt đối giữa ý định tìm kiếm tức thời và thói quen tiêu dùng dài hạn, cho phép hệ thống cung cấp các kết quả tìm kiếm được cá nhân hóa một cách chừng mực và tự nhiên nhất.

3.3.5 Chiến thuật Huấn luyện

Khởi tạo và thiết lập mô hình

Quá trình huấn luyện đồng thời (end-to-end) toàn bộ kiến trúc kết hợp giữa đối sánh ngữ nghĩa và cá nhân hóa thường dẫn đến hiện tượng nhiễu loạn gradient. Sự giao thoa của các luồng tín hiệu cập nhật trọng số khác biệt có thể làm suy giảm nghiêm trọng khả năng biểu diễn ngôn ngữ cốt lõi của hệ thống. Để giải quyết rào cản này, một chiến lược huấn luyện phân tách (decoupled training) được triển khai, chia quá trình tối ưu hóa thành hai giai đoạn độc lập. Đi kèm với đó là các thiết lập khởi tạo chuyên biệt cho từng bộ mã hóa trên tập dữ liệu thương mại điện tử Amazon Review nhằm tận dụng tối đa tri thức ngôn ngữ từ các mô hình học sâu tiên tiến.

Đối với nhánh mã hóa chéo (Enc_{CE}), hệ thống không khởi tạo trọng số ngẫu nhiên mà kế thừa trực tiếp từ kiến trúc tiền huấn luyện sentence-transformers/all-mpnet-base-v2. Việc lựa chọn phiên bản này xuất phát từ hai lý do cốt lõi. Thứ nhất, về mặt nền tảng, nó vẫn kế thừa trọn vẹn kiến trúc

MPNet cơ sở với khả năng tổng hợp ưu điểm của hai phương pháp học ngôn ngữ hàng đầu: cơ chế che giấu từ (Masked Language Modeling - MLM) giúp nắm bắt cấu trúc từ vựng cục bộ, và cơ chế hoán vị từ (Permuted Language Modeling - PLM) giúp hiểu được sự phụ thuộc ngữ cảnh toàn cục. Thứ hai, phiên bản `all-mpnet-base-v2` đã trải qua quá trình tối ưu hóa đặc biệt trên một bộ dữ liệu quy mô lớn gồm hơn 1 tỷ cặp câu, cung cấp một không gian vector biểu diễn tổng quát (sentence embeddings) có độ chính xác rất cao. Sau khi được khởi tạo với nền tảng trọng số mạnh mẽ này, lõi mô hình tiếp tục được tinh chỉnh (fine-tune) trực tiếp trên kho ngữ liệu của tập dữ liệu Amazon Review. Thao tác này mang ý nghĩa tiên quyết giúp mô hình làm quen với các thuật ngữ chuyên ngành, sự phân bố từ vựng đặc thù và các dạng tương tác từ vựng chéo phổ biến trong miền thương mại điện tử.

Ngược lại, đối với nhánh mã hóa ký ức (Enc_{Mem}), hệ thống tái sử dụng trọng số từ mô hình tiền huấn luyện `sentence-transformers/multi-qa-mpnet-base-cos-v1`. Đây là một biến thể của kiến trúc MPNet đã được tinh chỉnh chuyên sâu để tối ưu hóa cho các tác vụ hỏi đáp và truy xuất thông tin dày đặc (dense retrieval) dựa trên độ đo tương đồng cosine. Nhằm đảm bảo hệ thống có thể hoạt động trơn tru và mở rộng quy mô trên các phần cứng GPU tiêu chuẩn mà không gặp hiện tượng tràn bộ nhớ, toàn bộ hệ số trọng lượng của nhánh Enc_{Mem} được đóng băng (frozen) ngay từ đầu. Chiến lược đóng băng này cho phép hệ thống thực hiện trích xuất và tính toán trước toàn bộ không gian bộ nhớ của người dùng ($\mathcal{P}_u$) một cách ngoại tuyến (offline), giúp tiết kiệm đáng kể dung lượng bộ nhớ và tài nguyên tính toán cho các công đoạn tối ưu hóa phía sau.

Giai đoạn 2 (Phase 2): Huấn luyện điều chuẩn g_{Mix}

Giai đoạn huấn luyện đầu tiên được thiết kế với mục tiêu duy nhất là tối ưu hóa khả năng phân tích và trích xuất điểm số phù hợp ngữ nghĩa (s_d^q) của mô-đun Enc_{CE} từ các cặp truy vấn và tài liệu ứng viên. Trong toàn bộ pha này, mô hình trộn cùng với điểm số cá nhân hóa hoàn toàn bị loại bỏ khỏi luồng tính toán. Sự cô lập này ép buộc nhánh mã hóa chéo phải tự mình học cách phân biệt sự liên quan ngữ nghĩa một cách khách quan nhất mà không có bất kỳ sự định hướng nào từ thông tin hồ sơ lịch sử.

Để đạt được mục tiêu tối ưu hóa, hệ thống áp dụng khung học tương phản (contrastive learning) làm nguyên lý cấu trúc dữ liệu cốt lõi. Cụ thể, đối với mỗi truy vấn q được trích xuất từ tập huấn luyện, dữ liệu đầu vào sẽ bao gồm một tài liệu tích cực đích thực (đại diện cho kết quả khớp chuẩn) đi kèm với một tập hợp gồm M tài liệu tiêu cực đóng vai trò là mỗi nhử (negative samples). Tập dữ liệu ghép nối này sau khi đi qua quá trình mã hóa sẽ sinh ra một vector điểm số dự đoán liên tục, ký hiệu là s_q , tương ứng với một vector nhãn gốc y_q mang giá trị phân phối nhị phân (trong đó duy nhất vị trí của tài liệu tích cực nhận giá trị 1, các mỗi nhử còn lại nhận giá trị 0).

Quá trình cập nhật trọng số của mạng nơ-ron được dẫn dắt trực tiếp bởi hàm mất mát Softmax Cross-Entropy tiêu chuẩn. Việc áp dụng hàm loss này trên một tập hợp bao gồm cả mẫu tích cực và các mẫu tiêu cực nội lô (in-batch negatives) đã được chứng minh là phương pháp cốt lõi mang lại hiệu suất vượt trội cho các hệ thống truy xuất văn bản hiện đại [22]. Về mặt toán học, hàm mất mát Softmax Cross-Entropy tiêu chuẩn [22] được biểu diễn thông qua phương trình:

$$\mathcal{L}(y_q, s_q) = - \sum_{i=1}^M y_q[i] \log \text{sm}(s_q[i])$$

Trong phương trình trên, toán tử sm đại diện cho hàm phân phối xác suất softmax. Việc tối thiểu hóa hàm $\mathcal{L}$ mang một ý nghĩa hình học rõ ràng: nó tạo ra một lực đẩy ép mô hình Enc_{CE} phải điều chỉnh không gian vector biểu diễn sao cho điểm số s_d^q của tài liệu tích cực luôn được khuếch đại, từ đó áp đảo hoàn toàn xác suất của hàng loạt tài liệu nhiễu trong cùng một không gian đối chiếu. Kết thúc giai đoạn này, nhánh ngữ nghĩa đã đạt trạng thái sẵn sàng cao nhất để làm nền tảng cho việc dung hợp thông tin cá nhân hóa ở pha tiếp theo.

Giai đoạn 2 (Phase 2): Huấn luyện điều chuẩn g_{Mix}

Mục tiêu và Tích hợp tham số tỷ lệ: Bước sang giai đoạn thứ hai, trọng số của cả hai nhánh mã hóa Enc_{CE} và Enc_{Mem} đều được đóng băng cố định nhằm bảo toàn trọn vẹn không gian biểu diễn đã được thiết lập ở pha trước. Mục tiêu cốt lõi lúc này là tập trung huấn luyện mạng nơ-ron đa tầng của mô hình trộn g_{Mix} học cách dự đoán chính xác trọng số điều phối w . Trọng số này đóng vai trò quyết định trong việc thiết lập tỷ lệ nội suy giữa điểm phù hợp ngữ nghĩa (s_d^q) và điểm cá nhân hóa (s_d^u). Điểm đáng chú ý mang tính đột phá trong kiến trúc tối ưu hóa của pha này là sự tích hợp của một tham số tỷ lệ có khả năng học (learnable scale parameter), được thiết kế lấy cảm hứng từ các mô hình mạng nơ-ron đối chiếu tiên tiến (như kiến trúc CLIP). Tham số này được khởi tạo với giá trị logarit tương đương tỷ lệ 1/0.07 (xấp xỉ 14.3) và không bị khóa cứng; ngược lại, nó được mô hình tự động tinh chỉnh linh hoạt trong suốt quá trình huấn luyện nhằm kiểm soát độ nhạy (temperature) của dải điểm số đầu ra trước khi đưa vào hàm tính toán xác suất.

Cấu trúc dữ liệu và Mỏ neo: Về mặt cấu trúc dữ liệu, Giai đoạn 2 tiếp tục kế thừa nguyên vẹn tập hợp dữ liệu gồm một mẫu tích cực và M mẫu tiêu cực. Tuy nhiên, hệ thống chèn thêm một điểm mỏ neo (anchor) nhân tạo vào tập điểm số với logit mục tiêu cố định $s_0 = 0$, đi kèm với nhãn mục tiêu điều chỉnh là y_0 (đóng vai trò là một siêu tham số). Sự can thiệp có chủ đích này, khi được kết hợp với phép nhân vô hướng từ tham số tỷ lệ (logit scale) liên tục cập nhật, sẽ tự động khuếch đại hoặc thu hẹp khoảng cách tương đối giữa các giá trị dự đoán, từ đó biến đổi vector điểm số thô ban đầu thành s'_q và vector nhãn tương ứng thành y'_q .

Hàm mất mát và Ý nghĩa hiệu chuẩn: Để ngăn chặn tình trạng mạng MLP sinh ra các dự đoán quá tự tin (overconfident predictions) dẫn đến hiện tượng sụp đổ phương thức (modality collapse), hệ thống từ bỏ hàm Softmax tiêu chuẩn và thay thế bằng hàm Scale Calibrating Softmax Objective [30]:

$$\mathcal{L}(y'_q, s'_q) = - \sum_{i=1}^M y'_q[i] \log \frac{e^{s'_q[i]}}{\sum_j e^{s'_q[j]} + 1} + y_0 \log \left(\sum_j e^{s'_q[j]} + 1 \right)$$

Việc chèn biến neo y_0 vào hàm loss đóng vai trò như một cơ chế chính quy hóa (regularization) mang tính cấu trúc. Cụ thể, thành phần thứ hai của phương trình tạo ra một lực phạt nghiêm ngặt đối với các điểm số dự đoán quá lớn, trong khi thành phần thứ nhất đảm bảo các điểm số nhỏ không bị tiêu biến hoàn toàn. Dưới sự điều tiết kép của hàm loss hiệu chuẩn và tham số tỷ lệ (logit scale), trọng số w do g_{Mix} sinh ra sẽ không bị cực đoan hóa về các thái cực tuyệt đối 0 hoặc 1. Thay vào đó, nó biến thiên một cách mượt mà, bám sát và phản chiếu đúng mức độ tin cậy thực tế của nhánh ngữ nghĩa, cho phép hệ thống tìm kiếm hòa trộn các tín hiệu cá nhân hóa một cách tự nhiên, chừng mực và đạt độ ổn định cao nhất.

3.4 Tích hợp LLM trong Giai đoạn Hậu Truy xuất

Trong kiến trúc tổng thể của hệ thống, Mô hình Ngôn ngữ Lớn Google Gemini được tích hợp vào giai đoạn hậu truy xuất (*Post-Retrieval Stage*). Trong khi mô hình Two-Tower đóng vai trò bộ lọc thô (*Coarse Filter*) giúp truy xuất nhanh các ứng viên tiềm năng dựa trên độ tương đồng vector, thì mô-đun LLM đảm nhận chức năng bộ lọc tinh và tác nhân giải thích (*Explainable Agent*). Thành phần này tận dụng khả năng suy luận ngôn ngữ tự nhiên để cá nhân hóa trải nghiệm người dùng một cách sâu sắc hơn.

3.4.1 Quy trình Xử lý Dữ liệu

Quy trình tích hợp được thực hiện theo cơ chế suy luận trực tuyến (*Online Inference*) thông qua bốn bước xử lý tuần tự:

1. Truy xuất Ứng viên:

Đầu vào của mô-đun là danh sách Top-*K* sản phẩm được trả về từ mô hình Two-Tower. Tại giai đoạn này, các sản phẩm mới chỉ được định danh đơn giản bằng mã ID và điểm số tương đồng vector.

2. Làm giàu Ngữ cảnh:

Kế đến, hệ thống thực hiện các truy vấn cơ sở dữ liệu để chuyển đổi các ID vô hướng thành thông tin văn bản mang ý nghĩa ngữ nghĩa. Cụ thể:

- **Thông tin sản phẩm:** Hệ thống thu thập tiêu đề, mô tả ngắn, thông số kỹ thuật và giá tiền.
- **Hồ sơ người dùng:** Hệ thống truy xuất chuỗi lịch sử tương tác gần nhất, bao gồm các sản phẩm đã xem, đã mua hoặc được đánh giá cao.

3. Kỹ thuật Prompt Engineering:

Dữ liệu sau khi làm giàu được đưa vào một khuôn mẫu cấu trúc sẵn, thiết kế theo phương pháp *Zero-shot* hoặc *Few-shot*. Cấu trúc này bao gồm ba thành phần chính: định nghĩa vai trò của Gemini là một chuyên gia tư vấn, cung cấp dữ liệu ngữ cảnh (lịch sử người dùng, danh sách ứng viên), và cuối cùng là nhiệm vụ yêu cầu LLM phân tích mối liên hệ sở thích để chọn lọc sản phẩm phù hợp nhất kèm theo giải thích.

4. Sinh Phản hồi:

Cuối cùng, Prompt hoàn chỉnh được gửi đến API của Gemini. Kết quả trả về là văn bản tự nhiên, sau đó được hệ thống phân tích (parse) để hiển thị lên giao diện Web Demo dưới dạng danh sách gợi ý đi kèm lời bình chi tiết.

3.4.2 Cấu trúc Prompt Minh họa

Để LLM thực hiện tác vụ chọn lọc và giải thích mà không cần áp dụng thuật toán xếp hạng lại phức tạp, nhóm nghiên cứu sử dụng cấu trúc Prompt định hướng ngữ nghĩa như sau:

System Instruction: Bạn là một trợ lý AI chuyên nghiệp trong lĩnh vực thương mại điện tử.

User Context: Người dùng này quan tâm đến [Danh sách lịch sử: iPhone 13, Ốp lưng MagSafe, Cáp sạc Type-C].

Candidate Items: Dưới đây là danh sách sản phẩm tiềm năng:

- **ID: 101** Tai nghe AirPods Pro (Chống ồn, Apple Ecosystem)
- **ID: 102** Nồi cơm điện Sharp (1.8L, Nấu nhanh)
- **ID: 103** Sạc dự phòng Anker (20000mAh, Sạc nhanh)

Instruction: Dựa trên lịch sử quan tâm, hãy chọn ra các sản phẩm liên quan nhất từ danh sách ứng viên. Với mỗi sản phẩm được chọn, hãy viết một câu giải thích ngắn gọn, thuyết phục, chỉ ra mối liên hệ với sở thích cũ của họ.

3.4.3 Vai trò của LLM trong Hệ thống

Trong cấu hình hiện tại, LLM không thay đổi thứ tự xếp hạng dựa trên điểm số mà hoạt động như một lớp hậu xử lý định tính (*Qualitative Post-processing*). Cơ chế này giúp khắc phục điểm yếu hộp đen của mô hình Two-Tower bằng cách minh bạch hóa lý do gợi ý. Việc cung cấp thông tin giải thích giúp người dùng hiểu rõ sự phù hợp của sản phẩm, từ đó gia tăng niềm tin và cải thiện tỷ lệ chuyển đổi (*Click-through Rate*) trên hệ thống.

Chương 4

Thực nghiệm và Đánh giá

Chương này trình bày chi tiết về quá trình thực nghiệm nhằm kiểm chứng hiệu quả của mô hình đề xuất Two-Tower Multi-modal Recommendation System. Mục tiêu của các thực nghiệm là trả lời các câu hỏi nghiên cứu sau:

1. Việc kết hợp đa phương thức bao gồm “Văn bản”, “Hình ảnh”, “Dữ liệu bảng” có cải thiện hiệu năng gợi ý so với đơn phương thức hay không?
2. Mô hình giải quyết bài toán dự đoán hành vi tiếp theo Next-Item Prediction và vấn đề Cold-start hiệu quả như thế nào?
3. Cơ chế Hybrid Retrieval, kết hợp Query ngữ nghĩa và Personalization đóng góp ra sao vào trải nghiệm người dùng cuối?
4. Mô hình đề xuất có khả năng triển khai trong môi trường thực tế đảm bảo yêu cầu về độ trễ thấp và tính tương tác thời gian thực hay không?

Nội dung chương bao gồm mô tả tập dữ liệu, thiết lập môi trường thực nghiệm, định nghĩa các độ đo đánh giá, phân tích sâu các kết quả thu được và minh họa hệ thống triển khai thực tế.

4.1 Mô tả tập dữ liệu

4.1.1 Tổng quan về nguồn dữ liệu

Nghiên cứu này sử dụng tập dữ liệu **Amazon Reviews 2023**, một bộ dữ liệu quy chuẩn phổ biến trong cộng đồng nghiên cứu Hệ thống gợi ý. Cụ thể, đồ án tập trung vào phân loại hàng hóa *Gift Cards*. Đây là miền dữ liệu đặc thù với tính chất sản phẩm ít biến động về cấu hình kỹ thuật nhưng phụ thuộc nhiều vào ngữ cảnh tặng quà, hình ảnh minh họa và ý định của người mua.

Cấu trúc dữ liệu của hệ thống được tổ chức một cách khoa học thông qua hai tập tin định dạng JSON Lines riêng biệt. Mặc dù được lưu trữ tách rời để thuận tiện cho quá trình xử lý, hai tập tin này vẫn duy trì mối liên kết logic chặt chẽ nhằm đảm bảo tính toàn vẹn của thông tin. Cụ thể, tập tin **User Reviews** đóng vai trò trung tâm trong việc lưu trữ dữ liệu người dùng, bao gồm toàn bộ lịch sử tương tác, các nội dung phản hồi đánh giá

cũng như mô hình hành vi chi tiết. Song song với đó, tập tin **Item Metadata** bổ trợ bằng cách cung cấp cơ sở dữ liệu chuyên sâu về sản phẩm, bao gồm các thông tin mô tả chi tiết và dữ liệu đa phương thức, giúp định danh và làm rõ ngữ cảnh cho các đối tượng được tương tác.

Dưới đây là phân tích chi tiết từng trường dữ liệu được sử dụng trong quá trình huấn luyện và kiểm thử mô hình.

A. Chi tiết dữ liệu User Reviews

Tập dữ liệu này đóng vai trò là nguồn “Ground Truth” để mô hình học sở thích của người dùng. Mỗi dòng dữ liệu đại diện cho một lần tương tác cụ thể.

Bảng 4.1: Mô tả chi tiết các trường thông tin trong tập dữ liệu User Reviews

Trường dữ liệu	Mô tả và Phương pháp xử lý
user_id (String)	Định danh duy nhất của người dùng. Đây là khóa chính để gom nhóm lịch sử hành vi. Toàn bộ tương tác của cùng một user_id được sắp xếp theo thời gian để làm đầu vào cho User Tower.
parent_asin (String)	Mã định danh cha của sản phẩm, đại diện cho nhóm các biến thể màu sắc và kiểu dáng. Đề án sử dụng trường này làm khóa ngoại liên kết với Metadata nhằm giảm độ thưa dữ liệu.
rating (Float)	Điểm đánh giá đại diện cho tín hiệu phản hồi hiện tại. Các tương tác có rating ≥ 4.0 được xem là tích cực. Giá trị này cũng được dùng làm đặc trưng số học cho Tabular Encoder.
title & text (String)	title tóm tắt cảm xúc chính, còn text chứa nội dung chi tiết phản ánh lý do mua hàng. Hai trường này được nối lại thành chuỗi văn bản đầu vào cho Text Encoder.
timestamp (Integer)	Thời gian đánh giá. Dữ liệu được sắp xếp tăng dần theo trường này để mô phỏng đúng bài toán <i>Sequential Recommendation</i> , tránh rò rỉ dữ liệu tương lai.
verified_purchase (Boolean)	Nhãn xác thực việc mua hàng. Được mã hóa thành Embedding trong Tabular Encoder để giúp mô hình phân biệt độ tin cậy giữa tương tác thật và ảo.
helpful_vote (Integer)	Số lượng người khác thấy bài review hữu ích. Giá trị này được chuẩn hóa Log normalization và đưa vào mô hình như một chỉ số đo lường chất lượng tương tác.

B. Chi tiết dữ liệu Item Metadata

Tập dữ liệu này cung cấp các đặc trưng nội dung để xây dựng Item Tower đa phương thức.

Bảng 4.2: Mô tả chi tiết các trường thông tin trong tập dữ liệu Item Metadata

Trường dữ liệu	Mô tả và Phương pháp xử lý
parent_asin (String)	Khóa chính của sản phẩm. Được dùng để ánh xạ 1-nhiều với dữ liệu trong bảng User Reviews.
title (String)	Tên đầy đủ của sản phẩm, chứa thông tin thương hiệu, mệnh giá và dịp tặng quà. Đây là đặc trưng quan trọng nhất, được mã hóa bởi BERT/MPNet để tạo vector ngữ nghĩa.
images (List)	Danh sách ảnh sản phẩm gồm thumb, large và hi_res. Ảnh chất lượng cao gồm (hi_res/large) được tải về và đưa qua Vision Transformer để trích xuất đặc trưng thị giác.
main_category (String)	Danh mục chính (ví dụ: “Gift Cards”). Giúp định danh miền dữ liệu. Được xử lý bằng One-hot hoặc Embedding cho Tabular Encoder.
categories (List)	Phân cấp sản phẩm. Được xử lý để tạo embedding đại diện nhóm hàng, giúp mô hình gom cụm các sản phẩm tương đồng.
store (String)	Thương hiệu phát hành thẻ (ví dụ: Amazon, Visa). Đây là đặc trưng định danh quan trọng, được chuyển đổi thành chỉ số Index và đưa qua lớp Embedding.
avg_rating (Float) & rating_number (Int)	Điểm trung bình và tổng lượt đánh giá - các chỉ số “Bằng chứng xã hội”. Dữ liệu này được chuẩn hóa để tránh chênh lệch thang đo khi đưa vào mạng nơ-ron.
price (Float)	Giá bán (USD). Cung cấp thông tin phân khúc giá trị. Các giá trị thiếu được xử lý bằng phương pháp gán trung vị.
features, description & details	Các mô tả bổ sung và thông số kỹ thuật dạng key-value. Chúng bổ sung ngữ nghĩa cho tiêu đề và được chuyển đổi thành văn bản để hỗ trợ cho Text Encoder.

C. Mối quan hệ và Thách thức dữ liệu

Mối quan hệ liên kết: Dữ liệu được liên kết thông qua trường parent_asin. Quá trình tiền xử lý thực hiện phép nối Inner Join giữa Review và Metadata. Chỉ những cặp (u, i) mà trong đó sản phẩm i có đầy đủ thông tin, đặc biệt là ảnh và tiêu đề mới được giữ lại để huấn luyện.

Thách thức: Quá trình xử lý dữ liệu đối mặt với hai thách thức chính. Đầu tiên là sự *đa dạng định dạng*, khi tập dữ liệu bao gồm hỗn hợp văn bản phi cấu trúc, hình ảnh, dữ liệu số và danh mục. Sự không đồng nhất này đòi hỏi kiến trúc mạng nơ-ron phải đủ phức tạp để thực hiện fusion hiệu quả các nguồn tin đa phương thức. Thách thức thứ hai đến từ *nhiều dữ liệu*, biểu hiện qua việc thiếu hụt hình ảnh, ảnh chất lượng thấp hoặc các đánh giá ngắn, thiếu ngữ nghĩa. Do đó, quy trình tiền xử lý và làm sạch dữ liệu đóng vai trò then chốt để đảm bảo chất lượng đầu vào cho mô hình.

4.1.2 Phân tích chất lượng dữ liệu và Giá trị khuyết

Để đảm bảo tính tin cậy của đầu vào mô hình, chúng tôi đã thực hiện thống kê chi tiết tỷ lệ dữ liệu khuyết trên cả hai tập dữ liệu chính: Thông tin sản phẩm và Tương tác người dùng.

A. Đối với Dữ liệu sản phẩm

Kết quả thống kê trên tổng số **1,137** sản phẩm cho thấy sự phân hóa rõ rệt về chất lượng giữa các trường thông tin.

Bảng 4.3: Thống kê tỷ lệ dữ liệu khuyết trên Item Metadata

Thuộc tính	SL Thiếu	Tỷ lệ (%)	Phương án xử lý
Title	0	0.00%	Giữ nguyên.
Average Rating	0	0.00%	Sử dụng trực tiếp.
Images	1	0.09%	Loại bỏ sản phẩm hoặc dùng ảnh mặc định.
Store	17	1.50%	Gán nhãn “Unknown”.
Features	105	9.23%	Thay thế bằng chuỗi rỗng.
Main Category	170	14.95%	Gán nhãn danh mục chung hoặc “Gift Cards”.
Description	262	23.04%	Thay thế bằng chuỗi rỗng, tập trung vào Title.
Price	757	66.58%	Gán giá trị trung vị (Median Imputation).
Videos/Subtitle	1137	100.00%	Loại bỏ trường dữ liệu.

Nhận xét và Chiến lược xử lý:

Dựa trên kết quả thống kê, đề án đề xuất chiến lược xử lý dữ liệu tập trung vào hai khía cạnh chính:

Đầu tiên, đối với biến **Giá**, tỷ lệ khuyết dữ liệu lên tới 66.58% phản ánh đặc thù mệnh giá động của loại hình Gift Card. Thay vì loại bỏ trường thông tin quan trọng này, nghiên cứu áp dụng phương pháp *Gán giá trị trung vị*. Phương pháp này giúp duy trì thông tin về phân khúc giá trị sản phẩm đồng thời hạn chế tác động của các giá trị ngoại lai. Tuy nhiên, để đảm bảo tính ổn định, trọng số của nhánh Tabular Encoder sẽ được điều chỉnh giảm so với các nhánh xử lý văn bản và hình ảnh.

Thứ hai, đối với các trường thông tin không mang lại giá trị phân tích hoặc có tỷ lệ khuyết tuyệt đối 100% như `bought_together`, `subtitle` và `author`, chiến lược *Cắt tỉa đặc trưng* được áp dụng triệt để. Việc loại bỏ các trường này không chỉ giúp làm sạch nhiễu mà còn tối ưu hóa tài nguyên bộ nhớ và không gian lưu trữ cho quá trình huấn luyện mô hình.

B. Đối với Dữ liệu tương tác

Trái ngược với đặc điểm phân tán của tập Metadata, dữ liệu Reviews sau quá trình sàng lọc *k-core filtering* thể hiện tính toàn vẹn và độ tin cậy cao. Kết quả thống kê cho thấy tập dữ liệu bao gồm **152,410** tương tác, với tỷ lệ dữ liệu khuyết là **0%** trên tất cả các trường thông tin trọng yếu bao gồm `user_id`, `parent_asin`, `rating` và `timestamp`.

Điều này đảm bảo rằng User Tower sẽ luôn nhận được đầu vào đầy đủ và nhất quán, không cần phải thực hiện các kỹ thuật điền khuyết phức tạp cho chuỗi hành vi, giúp quá trình huấn luyện mô hình tuần tự diễn ra ổn định.

4.1.3 Quy trình Tiền xử lý dữ liệu

Do tính chất đa phương thức và độ nhiễu cao của dữ liệu thương mại điện tử thực tế, quy trình tiền xử lý đóng vai trò then chốt trong việc đảm bảo tính hội tụ và hiệu năng của mô hình. Quy trình này được chia thành 4 giai đoạn chính: Làm sạch dữ liệu, Xử lý đặc trưng đa phương thức, Chuẩn hóa dữ liệu bảng và Xây dựng chuỗi hành vi tuần tự.

Giai đoạn 1: Làm sạch và Lọc dữ liệu

Dữ liệu thô thu thập từ Amazon thường chứa nhiều giá trị bị khuyết và các điểm dữ liệu nhiễu. Quy trình tiền xử lý dữ liệu được tiến hành qua hai giai đoạn trọng tâm nhằm chuẩn hóa đầu vào cho mô hình, các bước xử lý bao gồm:

Giai đoạn thứ nhất tập trung vào **xử lý giá trị khuyết** với các chiến lược riêng biệt cho từng loại dữ liệu. Cụ thể, các mẫu thiếu trường định danh cốt lõi như `title` sẽ bị loại bỏ hoàn toàn để đảm bảo tính nhất quán. Đối với dữ liệu số học như `price`, phương pháp gán giá trị trung vị được ưu tiên áp dụng thay vì giá trị trung bình, giúp giảm thiểu tác động lệch chuẩn gây ra bởi các giá trị ngoại lai. Trong khi đó, các giá trị rỗng tại các trường văn bản bổ trợ như `features` hay `description` được xử lý bằng cách điền thể chuỗi ký tự trống `""` để đảm bảo tính hợp lệ kỹ thuật cho bộ mã hóa.

Giai đoạn thứ hai là **sàng lọc tương tác**, áp dụng kỹ thuật *k-core filtering* với ngưỡng $k = 3$ nhằm tối ưu hóa dữ liệu cho bài toán *Sequential Recommendation*. Về phía người dùng, hệ thống loại bỏ các tài khoản có dưới 3 tương tác, Cold-start Users, do nhóm này không cung cấp đủ độ dài chuỗi lịch sử cần thiết để mô hình Transformer học được các mẫu hành vi phụ thuộc. Song song với đó, các sản phẩm có tần suất xuất hiện quá thấp, dưới 2 lần, cũng được lược bỏ để đảm bảo không gian biểu diễn được học từ dữ liệu đủ dày đặc.

Giai đoạn 2: Xử lý đặc trưng phi cấu trúc

Đây là bước chuẩn bị đầu vào cho hai nhánh mạng nơ-ron chính: Text Encoder và Image Encoder.

1. Xử lý dữ liệu văn bản:

Do thông tin ngữ nghĩa của sản phẩm nằm rải rác ở nhiều trường khác nhau, chúng tôi thực hiện chiến lược nối chuỗi:

$$\text{Text}_{\text{input}} = [\text{Title}] \oplus [\text{Description}] \oplus [\text{Features}] \oplus [\text{Details}] \quad (4.1)$$

Trong đó $\oplus$ là phép nối chuỗi kèm theo ký tự phân cách đặc biệt. Chuỗi văn bản tổng hợp này sau đó được đưa qua bộ phân tách từ của mô hình `all-mpnet-base-v2`. Quá trình Tokenization tuân thủ các quy tắc:

- **Padding:** Các chuỗi ngắn hơn độ dài tối đa sẽ được thêm token [PAD] để đảm bảo kích thước batch đồng nhất.
- **Truncation:** Các chuỗi quá dài sẽ bị cắt bớt để phù hợp với giới hạn đầu vào của BERT, thường là 512 tokens, ưu tiên giữ lại phần đầu của văn bản vì chứa thông tin quan trọng nhất.

2. Xử lý dữ liệu hình ảnh:

Dữ liệu ảnh được tải về từ các đường dẫn URL trong Metadata. Quy trình xử lý ảnh tuân theo chuẩn đầu vào của mô hình Vision Transformer:

- **Tải và Lọc lỗi:** Sử dụng Multi-threading để tải ảnh. Các ảnh bị lỗi định dạng hoặc không thể tải sẽ bị loại bỏ hoặc thay thế bằng ảnh placeholder màu đen.
- **Resize & Center Crop:** Ảnh được thay đổi kích thước về độ phân giải 224×224 pixels.
- **Chuẩn hóa:** Các giá trị pixel trong khoảng $[0, 255]$ được chuyển về khoảng $[0, 1]$ và sau đó được chuẩn hóa theo phân bố của tập dữ liệu ImageNet:

$$x_{norm} = \frac{x - \mu_{ImageNet}}{\sigma_{ImageNet}} \quad (4.2)$$

Với $\mu = [0.485, 0.456, 0.406]$ và $\sigma = [0.229, 0.224, 0.225]$. Bước này giúp mô hình ViT pretrained hoạt động hiệu quả nhất.

Giai đoạn 3: Xử lý dữ liệu bảng

Dữ liệu có cấu trúc bao gồm các biến phân loại và biến số được xử lý riêng biệt.

1. Biến phân loại (main_category, store): Được chuyển đổi sang dạng số nguyên (Integer Mapping) thông qua kỹ thuật Label Encoding. Một từ điển (Vocabulary) được xây dựng để ánh xạ mỗi giá trị duy nhất (ví dụ: “Starbucks”) sang một chỉ số ID (ví dụ: 124). Các giá trị mới xuất hiện trong tập Test sẽ được gán về token đặc biệt <UNK>.

2. Biến danh sách phân loại (categories): Một sản phẩm có thể thuộc nhiều danh mục con (ví dụ: [Gift Cards, Birthday, For Her]). Chúng tôi sử dụng phương pháp *Multi-hot Encoding* kết hợp với *Embedding Pooling*. Cụ thể, các ID của danh mục sẽ được tra cứu trong bảng Embedding, sau đó lấy trung bình (Average Pooling) để tạo ra một vector đại diện duy nhất cho trường này.

3. Biến số (rating, vote, price): Để giúp mạng nơ-ron hội tụ nhanh hơn, các biến số được chuẩn hóa bằng *Standard Scaler* (Z-score normalization):

$$z = \frac{x - \mu}{\sigma} \quad (4.3)$$

Riêng đối với biến `helpful_vote`, do phân bố lệch trái nặng (phần lớn là 0 hoặc số nhỏ), chúng tôi áp dụng biến đổi Logarit trước khi chuẩn hóa: $x' = \log(1 + x)$.

Giai đoạn 4: Xây dựng chuỗi tương tác

Đây là bước quan trọng nhất để huấn luyện User Tower. Dữ liệu tương tác được gom nhóm theo `user_id` và sắp xếp tăng dần theo `timestamp`.

Với mỗi người dùng u , ta có chuỗi hành vi $S_u = \{i_1, i_2, \dots, i_T\}$. Quá trình tạo mẫu huấn luyện (Training Samples) được thực hiện theo cơ chế *Sliding Window*:

- Tại mỗi bước thời gian t ($1 < t \leq T$), mô hình sử dụng chuỗi lịch sử $H_t = \{i_1, \dots, i_{t-1}\}$ để dự đoán item mục tiêu i_t .
- **Padding:** Nếu độ dài chuỗi lịch sử nhỏ hơn độ dài tối đa quy định ($L = 40$), chúng tôi thêm các token [PAD] vào bên trái chuỗi.
- **Masking:** Một ma trận mặt nạ được tạo ra để báo cho lớp Self-Attention trong Transformer biết cần bỏ qua các vị trí là [PAD], đảm bảo tính toán chỉ tập trung vào các tương tác thực tế.

Thông kê chi tiết được trình bày trong Bảng 4.4.

Bảng 4.4: *Thông kê tập dữ liệu Amazon Gift Cards sau khi tiền xử lý*

Thông số	Số lượng	Mô tả
Tổng số người dùng	73,929	Số lượng người dùng duy nhất.
Tổng số sản phẩm	1,137	Số lượng thẻ quà tặng khác nhau.
Tổng số tương tác	78,095	Tổng số lượt review/rating hợp lệ.
Độ dài chuỗi trung bình	~ 1.06	Số lượng tương tác trung bình trên một người dùng.

Kết quả của quá trình tiền xử lý là các Tensor định dạng PyTorch sẵn sàng được đưa vào GPU để huấn luyện.

4.1.4 Phân tích độ thưa dữ liệu

A. Cơ sở lý thuyết và Định nghĩa

Trong các hệ thống gợi ý, dữ liệu thường được biểu diễn dưới dạng một ma trận tương tác User-Item R có kích thước $|U| \times |I|$, trong đó $|U|$ là tổng số người dùng và $|I|$ là tổng số sản phẩm. Mỗi phần tử r_{ui} trong ma trận biểu thị tương tác của người dùng u lên sản phẩm i .

Độ thưa phản ánh tỷ lệ các phần tử rỗng trong ma trận này. Một ma trận có độ thưa quá cao đồng nghĩa với việc thông tin hành vi người dùng cực kỳ hạn chế, gây khó khăn cho việc tìm kiếm các mẫu tương đồng. Độ thưa được định nghĩa bởi công thức [31]:

$$\text{Sparsity} = 1 - \text{Density} = 1 - \frac{\text{Total Interactions}}{|U| \times |I|} \quad (4.4)$$

B. Tính toán thực nghiệm trên tập dữ liệu Amazon

Dựa trên các thông kê đã trình bày ở Bảng 4.4, chúng tôi tiến hành tính toán độ thưa cụ thể cho tập dữ liệu huấn luyện:

- Tổng số người dùng ($|U|$): 73,929
- Tổng số sản phẩm ($|I|$): 1,137
- Tổng số tương tác quan sát được (N): 78,095

Kích thước không gian mẫu là:

$$|U| \times |I| = 73,929 \times 1,137 \approx 84,057,273$$

Mật độ dữ liệu thực tế:

$$\text{Density} = \frac{78,095}{84,057,273} \approx 0.000929 \text{ (0.09\%)}$$

Từ đó, độ thưa của tập dữ liệu là:

$$\text{Sparsity} = 1 - 0.000929 \approx 0.999071 \text{ (99.91\%)}$$

C. Đánh giá và Tác động đến mô hình

Kết quả tính toán 99.82% cho thấy tập dữ liệu Amazon Gift Cards thuộc nhóm “Extreme Sparsity”. Để so sánh, các tập dữ liệu chuẩn như MovieLens-1M thường có độ thưa khoảng 95 – 96%. Việc độ thưa tiệm cận 100% đặt ra hai thách thức nghiêm trọng:

Thứ nhất, **sự thất bại của Collaborative Filtering thuần túy**: Các thuật toán CF truyền thống như Matrix Factorization dựa vào việc tìm kiếm người dùng có hành vi tương đồng hoặc sản phẩm tương đồng thông qua sự chồng lấp các tương tác. Với mật độ 0.09%, xác suất để hai người dùng bất kỳ cùng đánh giá một sản phẩm là cực thấp, dẫn đến việc mô hình không thể tính toán độ tương đồng tin cậy.

Thứ hai, **vấn đề Cold-start**: Phần lớn người dùng trong tập dữ liệu chỉ có số lượng tương tác tối thiểu khoảng 2-3 tương tác. Mô hình không có đủ lịch sử hành vi để học được vector đại diện User Embedding chính xác nếu chỉ dựa vào ID.

D. Giải pháp tiếp cận: Content-based Multi-modal Learning

Chính vì thách thức về độ thưa nêu trên, đề án này bắt buộc phải chuyển hướng từ việc chỉ khai thác dữ liệu tương tác sang khai thác dữ liệu nội dung.

Cụ thể, kiến trúc Two-Tower được thiết kế để tận dụng các đặc trưng giàu ngữ nghĩa luôn có sẵn, bất kể người dùng đã tương tác hay chưa:

- **Text Encoder (BERT)**: Giúp mô hình hiểu rằng “Visa Gift Card” và “Mastercard Gift Card” là tương đồng về mặt ngữ nghĩa, ngay cả khi chưa có người dùng nào mua cả hai.

- **Image Encoder (ViT):** Giúp liên kết các sản phẩm có hình thức trình bày giống nhau (ví dụ: cùng chủ đề Giáng sinh, Sinh nhật) thông qua đặc trưng thị giác.
- **Tabular Encoder (MLP):** Xử lý các dữ liệu cấu trúc như *Giá bán*, *Điểm đánh giá*, *Thương hiệu*. Nhánh này giúp mô hình học được các ngưỡng lọc quan trọng (ví dụ: người dùng chỉ thích mua thẻ mệnh giá thấp $< \$50$) để thu hẹp không gian tìm kiếm hiệu quả.

Nhờ cơ chế Fusion Gate kết hợp các thông tin này, mô hình có thể lấp đầy các khoảng trống trong ma trận thưa bằng các suy luận dựa trên nội dung, từ đó cải thiện đáng kể độ chính xác gợi ý như Recall hay NDCG sẽ được trình bày trong phần Kết quả thực nghiệm.

4.2 Thiết lập thực nghiệm

4.2.1 Môi trường phần cứng và phần mềm

Cơ sở hạ tầng phần cứng

Các thực nghiệm được triển khai trên nền tảng đám mây **Kaggle Kernels**, tận dụng sức mạnh tính toán hiệu năng cao của Google Cloud Platform (GCP). Việc sử dụng môi trường đám mây giúp giảm thiểu các sai số do sự khác biệt về phần cứng cá nhân và đảm bảo mô hình được huấn luyện trong điều kiện tối ưu.

Chi tiết cấu hình phần cứng như sau:

- **Bộ xử lý đồ họa (GPU) :**
 - *Loại thiết bị:* **NVIDIA Tesla P100-PCIE.**
 - *Kiến trúc:* Pascal.
 - *Bộ nhớ đồ họa (VRAM):* 16 GB **HBM2.**
 - *Lý do lựa chọn:* Mặc dù là kiến trúc Pascal, Tesla P100 sở hữu băng thông bộ nhớ vượt trội (~ 732 GB/s), cao hơn đáng kể so với các dòng GPU sử dụng bộ nhớ GDDR6 thông thường (như Tesla T4). Đặc điểm này cực kỳ tối ưu cho mô hình Two-Tower, nơi tác vụ Embedding Lookup cho hàng nghìn User/Item tiêu tốn tài nguyên băng thông rất lớn.
- **Bộ xử lý trung tâm (CPU):**
 - *Cấu hình:* Intel(R) Xeon(R) CPU @ 2.20GHz (4 cores, 8 threads).
 - *Vai trò:* Chịu trách nhiệm cho các tác vụ tiền xử lý dữ liệu, tải ảnh đa luồng và đưa dữ liệu vào hàng đợi trước khi đẩy sang GPU.
- **Bộ nhớ trong (RAM):**
 - *Dung lượng:* 32 GB System RAM.
 - *Vai trò:* Đảm bảo toàn bộ Meta-data và các vector đặc trưng sau khi trích xuất có thể được lưu trữ trên bộ nhớ đệm, tránh hiện tượng nghẽn cổ chai do đọc/ghi đĩa cứng liên tục.

Hệ sinh thái phần mềm và Thư viện

Mô hình được phát triển dựa trên ngôn ngữ lập trình **Python** phiên bản 3.10, ngôn ngữ tiêu chuẩn trong cộng đồng Trí tuệ nhân tạo hiện nay. Chúng tôi sử dụng các framework mã nguồn mở tiên tiến nhất để xây dựng kiến trúc mạng nơ-ron sâu.

Các thư viện chính bao gồm:

- **PyTorch (v2.0+)**: Framework nền tảng cho Deep Learning. PyTorch được lựa chọn nhờ cơ chế đồ thị tính toán động, giúp linh hoạt trong việc xây dựng các kiến trúc phức tạp như Fusion Gate và tùy chỉnh hàm mất mát Contrastive Loss.
- **Hugging Face Transformers**: Thư viện chuẩn mực cho các mô hình NLP. Chúng tôi sử dụng thư viện này để tải trọng số tiền huấn luyện của mô hình `all-mpnet-base-v2` và thực hiện quy trình Tokenization văn bản.
- **TIMM (PyTorch Image Models)**: Thư viện chuyên dụng cho các mô hình thị giác máy tính hiện đại. TIMM cung cấp kiến trúc `vit_base_patch16_224` cùng các trọng số đã được huấn luyện trên ImageNet, giúp trích xuất đặc trưng ảnh chính xác mà không cần huấn luyện lại từ đầu.
- **Scikit-learn & Pandas**: Sử dụng cho các tác vụ xử lý dữ liệu bảng, phân chia tập dữ liệu, chuẩn hóa dữ liệu và tính toán các độ đo đánh giá cơ bản.
- **Các thư viện hỗ trợ khác**:
 - `tqdm`: Để theo dõi tiến độ huấn luyện trực quan.
 - `matplotlib/seaborn`: Để trực quan hóa dữ liệu và biểu đồ Loss.
 - `PIL (Pillow)`: Để xử lý và biến đổi dữ liệu ảnh thô.

4.2.2 Cấu hình Siêu tham số

Quá trình huấn luyện được chia làm 2 giai đoạn: Huấn luyện Item Tower trước để tạo vector đặc trưng sản phẩm, sau đó dùng các vector này đóng băng hoặc tinh chỉnh nhẹ để huấn luyện User Tower.

Cấu hình Item Tower

Item Tower chịu trách nhiệm mã hóa thông tin đa phương thức của sản phẩm. Các tham số chi tiết được liệt kê trong Bảng 4.5.

Bảng 4.5: Cấu hình siêu tham số cho Item Tower

Tham số	Giá trị	Giải thích
Text Encoder	all-mpnet-base-v2	Mô hình Sentence-BERT tối ưu cho Semantic Search
Image Encoder	vit_base_patch16_224	Vision Transformer pretrained trên ImageNet
Batch Size	128	Kích thước lô dữ liệu
Learning Rate	2×10^{-5}	Tốc độ học thấp để fine-tune
Epochs	70	Số vòng lặp huấn luyện
Temperature (τ)	0.07	Tham số nhiệt độ cho Contrastive Loss
Latent Dimension	256	Kích thước vector nhúng cuối cùng

Cấu hình User Tower

User Tower sử dụng kiến trúc Transformer Encoder để học sự phụ thuộc tuần tự trong lịch sử hành vi người dùng.

Bảng 4.6: Cấu hình siêu tham số cho User Tower

Tham số	Giá trị	Giải thích
Architecture	Transformer Encoder	Sử dụng Self-Attention
Num Layers	2	Số lớp Transformer
Num Heads	4	Số đầu Attention
Max Seq Length	40	Độ dài chuỗi lịch sử tối đa
LR (Base)	1×10^{-4}	Cho các lớp khởi tạo mới (Fusion, Projection)
LR (Pretrained)	1×10^{-6}	Cho các lớp BERT/Embedding (Differential Learning Rates)
Batch Size	64	Giảm batch size do mô hình phức tạp

4.3 Đầu vào và đầu ra

4.3.1 Xây dựng Item Tower

Item Tower đóng vai trò trích xuất đặc trưng từ dữ liệu đa phương thức của sản phẩm để tạo ra một vector đại diện thống nhất. Để đảm bảo tính nhất quán trong tính toán, chúng tôi quy ước các ký hiệu kích thước như sau:

- B : Kích thước Batch Size, ví dụ $B = 128$.
- D_{orig} : Số chiều gốc của các mô hình Pre-trained, với MPNet và ViT-Base là 768.
- D : Số chiều không gian tiềm ẩn đích, thiết lập $D = 256$.

Text Encoder

Hệ thống sử dụng mô hình ngôn ngữ **all-mpnet-base-v2** để chuyển đổi thông tin văn bản gồm Tiêu đề và Mô tả thành vector ngữ nghĩa.

Bảng 4.7: Đặc tả luồng dữ liệu và kích thước trong *Text Encoder*

Tầng xử lý	Kích thước	Giải thích chi tiết
1. Input Raw	List[String] kích thước B	Danh sách các chuỗi văn bản thô đầu vào.
2. Tokenization	(B, L_{max})	Văn bản được phân tách thành các Token IDs. $L_{max} = 512$ là độ dài chuỗi tối đa. Các chuỗi ngắn hơn được padding giá trị 0.
3. Transformer Backbone	$(B, L_{max}, 768)$	Đầu ra từ lớp ẩn cuối cùng của MPNet. Mỗi token trong chuỗi được biểu diễn bởi một vector 768 chiều.
4. Mean Pooling	$(B, 768)$	Thực hiện phép trung bình cộng dọc theo trục chiều dài chuỗi (L_{max}), loại bỏ các token đệm để thu được vector đại diện cho toàn bộ câu.
5. Projection Head	$(B, 256)$	Lớp tuyến tính nén vector từ 768 xuống 256 chiều, đóng vai trò là đầu ra của nhánh văn bản (v_{text}).

Image Encoder

Sử dụng kiến trúc **Vision Transformer ViT-Base-Patch16-224** để trích xuất đặc trưng thị giác từ ảnh sản phẩm.

Bảng 4.8: Đặc tả luồng dữ liệu và kích thước trong Image Encoder

Tầng xử lý	Kích thước	Giải thích chi tiết
1. Input Image	$(B, 3, 224, 224)$	Ảnh RGB gốc được resize về kích thước 224×224 pixels và chuẩn hóa theo phân phối ImageNet.
2. Patch Embedding	$(B, 197, 768)$	Ảnh được chia thành lưới $14 \times 14 = 196$ patches. Cộng thêm 1 token đặc biệt [CLS] ở đầu chuỗi để học đặc trưng toàn cục.
3. Transformer Encoder	$(B, 197, 768)$	Các patch đi qua 12 lớp Self-Attention của ViT. Kích thước không đổi.
4. Feature Extraction	$(B, 768)$	Chỉ lấy vector tại vị trí đầu tiên (index 0, ứng với token [CLS]), đại diện cho nội dung toàn bức ảnh.
5. Projection Head	$(B, 256)$	Chiếu vector đặc trưng về không gian chung 256 chiều (v_{img}).

Tabular Encoder

Xử lý các thông tin định lượng như Giá và Rating, và các thông tin định danh như Danh mục và Thương hiệu.

Bảng 4.9: Đặc tả luồng dữ liệu trong Tabular Encoder

Tầng xử lý	Kích thước (Shape)	Giải thích chi tiết
1. Input Features	(B, N_{feat})	Vector chứa giá trị số đã chuẩn hóa Z-score và index của biến phân loại.
2. Embedding Lookup	$(B, N_{cat} \times D_{emb})$	Các biến phân loại được chuyển thành vector nhúng và nối lại với nhau.
3. Concatenation	(B, D_{total})	Ghép nối vector biến số thực và vector biến phân loại thành một vector dài.
4. MLP Block	$(B, 256)$	Mạng nơ-ron đa tầng (Linear $\rightarrow$ ReLU $\rightarrow$ Linear) biến đổi dữ liệu hỗn hợp thành vector đặc trưng bảng (v_{tab}).

Cơ chế Fusion

Mô-đun **Fusion Gate** chịu trách nhiệm tổng hợp ba nguồn thông tin trên thành một vector duy nhất. Quá trình này diễn ra như sau:

1. **Xếp chồng:** Ba vector đầu ra từ các encoder được xếp chồng lên nhau tạo thành tensor đầu vào V_{in} :

$$V_{in} = [v_{text}, v_{img}, v_{tab}] \in \mathbb{R}^{B \times 3 \times 256}$$

2. **Tính trọng số chú ý:** Một mạng nơ-ron nhỏ (Linear layer) học cách đánh giá độ quan trọng của từng modal dựa trên ngữ cảnh:

$$W_{raw} = V_{in} \times W_{learnable} \in \mathbb{R}^{B \times 3 \times 1}$$

$$\alpha = \text{Softmax}(W_{raw}) \in \mathbb{R}^{B \times 3 \times 1}$$

Trong đó $\sum_{k=1}^3 \alpha_{i,k} = 1$ với mọi mẫu dữ liệu i .

3. **Tổng hợp có trọng số:** Vector sản phẩm cuối cùng là tổng của các vector thành phần nhân với trọng số tương ứng:

$$v_{item} = \sum_{k \in \{text, img, tab\}} \alpha_k \cdot v_k$$

Output: Tensor v_{item} có kích thước (**B, 256**).

Kết quả cuối cùng là mỗi sản phẩm trong hệ thống được đại diện bởi một vector 256 chiều duy nhất, chứa đựng tinh hoa thông tin được chắt lọc từ cả hình ảnh, văn bản và dữ liệu bảng.

4.3.2 Xây dựng User Tower

Khác với các mô hình tuần tự truyền thống như SASRec chỉ dựa vào định danh sản phẩm Item ID, User Tower trong đề án này được thiết kế theo kiến trúc *Mạng Tuần tự Đa phương thức*. Tại mỗi bước thời gian t trong lịch sử hành vi, mô hình không chỉ nhìn thấy sản phẩm mà còn đọc được nội dung bài đánh giá và hiểu được mức độ hài lòng của người dùng tại thời điểm đó.

Quy ước kích thước:

- B : Kích thước Batch Size.
- S : Độ dài chuỗi lịch sử tối đa, thiết lập $S = 50$.
- D : Số chiều không gian tiềm ẩn đích, $D = 256$.

Đầu vào đa nguồn

User Tower tiếp nhận 4 luồng dữ liệu song song đại diện cho chuỗi hành vi của người dùng:

Bảng 4.10: Đặc tả các luồng dữ liệu đầu vào cho User Tower

Luồng dữ liệu	Kích thước	Mô tả chi tiết
1. Item Indices	(B, S)	Chuỗi ID các sản phẩm đã tương tác. Các chuỗi ngắn hơn S được đệm bằng giá trị 0.
2. Review Texts	List[$B \times S$]	Nội dung văn bản mà user đã viết cho từng sản phẩm, ví dụ: “Thẻ này rất tiện”, “Giao hàng chậm”.
3. Context Feats	$(B, S, 3)$	Các đặc trưng ngữ cảnh tại thời điểm tương tác, bao gồm: <i>Rating</i> , <i>Helpful Votes</i> , và <i>Verified Purchase</i> .
4. Padding Mask	(B, S)	Ma trận mặt nạ Boolean, đánh dấu các vị trí là dữ liệu thật để Transformer tập trung xử lý và bỏ qua các vị trí đệm.

Kiến trúc xử lý tuần tự

Quá trình biến đổi từ dữ liệu thô thành vector người dùng diễn ra qua 4 giai đoạn chính:

Giai đoạn 1: Mã hóa đặc trưng thành phần Mỗi nguồn dữ liệu được đưa qua bộ mã hóa riêng biệt để chuyển về cùng không gian vector:

- **Item Embedding Lookup:** $ID \rightarrow v_{item} \in \mathbb{R}^{B \times S \times D}$. Ma trận này được khởi tạo từ Item Tower và cho phép tính chĩnh.
- **Text Encoding:** Sử dụng lại *Text Encoder* (MPNet) của Item Tower để mã hóa nội dung review: $Text \rightarrow v_{text} \in \mathbb{R}^{B \times S \times D}$.
- **Tabular Encoding:** Các biến số như Rating hay Votes đi qua mạng MLP để tạo ra vector ngữ cảnh: $Feats \rightarrow v_{tab} \in \mathbb{R}^{B \times S \times D}$.

Giai đoạn 2: Interaction Fusion Tại mỗi bước thời gian t , thông tin từ ba nguồn trên được tổng hợp bởi cơ chế **Gating Fusion** để tạo ra một vector đại diện duy nhất cho tương tác đó (h_t):

$$h_t = \text{FusionGate}(v_{item}^{(t)}, v_{text}^{(t)}, v_{tab}^{(t)}) \quad (4.5)$$

Kết quả là tensor chuỗi hành vi hợp nhất H_{seq} có kích thước (B, S, D) .

Giai đoạn 3: Mô hình hóa sự phụ thuộc Chuỗi H_{seq} được cộng thêm thông tin vị trí Positional Encoding và đưa qua khối **Transformer Encoder**.

- Cơ chế *Self-Attention* giúp mô hình học được mối quan hệ phụ thuộc dài hạn giữa các lần mua hàng, ví dụ: mua “Thẻ Game” thường dẫn đến mua “Tay cầm chơi game”.
- Đầu ra là chuỗi các trạng thái ẩn $T_{out} \in \mathbb{R}^{B \times S \times D}$.

Giai đoạn 4: Tổng hợp và Chuẩn hóa Thay vì chỉ lấy trạng thái cuối cùng dễ bị nhiễu, mô hình sử dụng kỹ thuật **Masked Mean Pooling** để tổng hợp thông tin từ toàn bộ lịch sử:

$$v_{user_raw} = \frac{\sum_{t=1}^S (T_{out}^{(t)} \cdot mask_t)}{\sum_{t=1}^S mask_t + \epsilon} \quad (4.6)$$

Cuối cùng, vector này đi qua lớp chiếu tuyến tính (Final Projection) và chuẩn hóa L2:

$$\mathbf{v}_{user} = \text{Normalize}(\text{Linear}(v_{user_raw})) \in \mathbb{R}^{B \times 256} \quad (4.7)$$

Đầu ra: Vector $\mathbf{v}_{user}$ có kích thước **(B, 256)**. Đây là vector đặc trưng (User Embedding) cuối cùng, sẵn sàng để thực hiện phép nhân vô hướng (Dot Product) với vector sản phẩm để tính điểm gợi ý.

4.4 Các độ đo đánh giá

Để đánh giá định lượng hiệu năng của hệ thống gợi ý, đặc biệt là đối với bài toán *Next-Item Prediction*, việc lựa chọn các độ đo phù hợp là vô cùng quan trọng. Trong ngữ cảnh của đề án này, tại mỗi bước thời gian t , chỉ có duy nhất một sản phẩm thực tế i_{true} mà người dùng u đã tương tác. Nhiệm vụ của mô hình là xếp hạng sản phẩm i_{true} này càng cao càng tốt trong danh sách K gợi ý $R_u = \{r_1, r_2, \dots, r_K\}$.

Chúng tôi sử dụng bộ ba chỉ số tiêu chuẩn trong lĩnh vực Truy xuất thông tin bao gồm Recall, MRR và NDCG. Mỗi chỉ số phản ánh một khía cạnh khác nhau của chất lượng gợi ý.

4.4.1 Recall@K

Định nghĩa và Công thức

Recall@K, hay còn gọi là Hit Rate@K trong bài toán Next-Item, là độ đo cơ bản nhất, dùng để trả lời câu hỏi: “*Sản phẩm người dùng muốn mua có nằm trong danh sách gợi ý hay không?*”. Nó không quan tâm đến thứ tự xếp hạng trong danh sách, miễn là sản phẩm đích xuất hiện trong Top-K.

Công thức tổng quát được định nghĩa như sau [31]:

$$\text{Recall@K} = \frac{1}{|U|} \sum_{u \in U} \mathbb{I}(i_{true}^{(u)} \in R_u[:K]) \quad (4.8)$$

Trong đó:

- $|U|$ là tổng số lượng người dùng trong tập kiểm thử.
- $R_u[:K]$ là danh sách K sản phẩm có điểm dự đoán cao nhất cho người dùng u .
- $\mathbb{I}(\cdot)$ là hàm chỉ thị (Indicator Function), nhận giá trị 1 nếu biểu thức bên trong đúng và 0 nếu sai.

Ý nghĩa và Vai trò

Trong hệ thống gợi ý thương mại điện tử, Recall@K đo lường *khả năng bao phủ* của mô hình đối với nhu cầu người dùng.

Một chỉ số Recall cao đồng nghĩa với việc hệ thống có khả năng nắm bắt chính xác ý định của người dùng, đảm bảo các sản phẩm phù hợp được đưa vào danh sách đề xuất. Đặc biệt, đối với bài toán sở hữu không gian tìm kiếm rộng lớn với hàng nghìn loại thẻ quà tặng (Gift Cards), việc đạt được Recall cao được xem là thách thức tiên quyết và quan trọng nhất, tạo nền tảng vững chắc trước khi hệ thống tiến hành các bước tối ưu hóa thứ hạng chi tiết.

4.4.2 MRR@K

Định nghĩa và Công thức

Nếu Recall chỉ quan tâm đến sự xuất hiện “Có” hoặc “Không”, thì MRR quan tâm đến *vị trí xuất hiện đầu tiên* của sản phẩm đúng. MRR đánh giá độ chính xác của việc xếp hạng một cách khắt khe: sản phẩm đúng càng nằm gần đầu danh sách, điểm số càng cao; ngược lại điểm số sẽ giảm rất nhanh.

Công thức tính MRR tại ngưỡng cắt K [31]:

$$\text{MRR@K} = \frac{1}{|U|} \sum_{u \in U} \left(\frac{1}{\text{rank}(i_{true}^{(u)})} \cdot \mathbb{I}(\text{rank}(i_{true}^{(u)}) \leq K) \right) \quad (4.9)$$

Trong đó $\text{rank}(i_{true}^{(u)})$ là thứ hạng của sản phẩm đúng trong danh sách gợi ý (bắt đầu từ 1). Nếu sản phẩm không nằm trong Top-K, giá trị nghịch đảo xếp hạng được quy ước là 0.

Phân tích độ nhảy

Chỉ số MRR phản ánh trực tiếp trải nghiệm tìm kiếm của người dùng trong thực tế, nơi thứ hạng hiển thị đóng vai trò quyết định đến mức độ hài lòng. Theo cơ chế này, điểm số sẽ đạt giá trị tối đa là 1.0 nếu hệ thống đưa sản phẩm mục tiêu vào vị trí đầu tiên. Tuy nhiên, mức điểm này sẽ giảm mạnh theo quy luật nghịch đảo: chỉ còn 0.5 tại vị trí thứ hai và xuống mức rất thấp là 0.1 nếu sản phẩm trôi xuống vị trí thứ 10.

Do đặc tính giảm mạnh này, MRR thường được sử dụng để đánh giá các hệ thống yêu cầu độ chính xác tức thời như gợi ý từ khóa tìm kiếm hoặc gợi ý Top-1 sản phẩm thay thế, nơi người dùng hiếm khi cuộn xuống quá sâu.

4.4.3 NDCG@K

Định nghĩa và Công thức

NDCG được coi là *tiêu chuẩn vàng* trong đánh giá xếp hạng. Khác với MRR phạt tuyến tính theo nghịch đảo, NDCG sử dụng hàm Logarit để chiết khấu giá trị của các gợi ý ở vị trí thấp một cách mượt mà hơn, phản ánh tốt hơn sự suy giảm sự chú ý của người dùng.

Với bài toán Next-Item Prediction chỉ có 1 nhãn đúng, công thức NDCG@K được đơn giản hóa như sau [31]:

$$\text{NDCG@K} = \frac{1}{|U|} \sum_{u \in U} \frac{1}{\log_2(\text{rank}(i_{true}^{(u)}) + 1)} \cdot \mathbb{I}(\text{rank}(i_{true}^{(u)}) \leq K) \quad (4.10)$$

Tại sao NDCG ưu việt hơn MRR?

Mặc dù cả MRR và NDCG đều chú trọng các kết quả đứng đầu, NDCG sở hữu cơ chế giảm trọng số nhẹ nhàng hơn ở các thứ hạng thấp nhờ đặc tính của hàm logarit. Sự khác biệt này thể hiện rõ nét khi so sánh mức giảm điểm số giữa vị trí thứ nhất và thứ hai; trong khi MRR tạo ra khoảng cách lớn từ 1.0 xuống 0.5, NDCG lại duy trì mức giảm vừa phải hơn từ 1.0 xuống 0.63. Xét trong ngữ cảnh gợi ý quà tặng, người dùng thường có xu hướng xem xét nhiều lựa chọn khác nhau, do đó việc sản phẩm mục tiêu xuất hiện ở vị trí thứ 3 hay thứ 4 vẫn mang lại giá trị thực tiễn. Vì vậy, NDCG được xem là thước đo phản ánh mức độ hài lòng chính xác hơn. Nhìn chung, việc kết hợp bộ ba chỉ số mang lại góc nhìn toàn diện cho hệ thống: Recall đo lường độ phủ, MRR đánh giá khả năng dự đoán chính xác tuyệt đối và NDCG phản ánh chất lượng trải nghiệm xếp hạng tổng thể.

4.5 Đánh giá Hiệu suất Truy xuất sơ cấp Bi-Encoder

Trong kiến trúc của các hệ thống gợi ý quy mô lớn hiện đại, giai đoạn truy xuất sơ cấp đóng vai trò như một bộ lọc tuyến đầu. Nhiệm vụ của nó là thu hẹp nhanh chóng không gian tìm kiếm khổng lồ từ hàng vạn, thậm chí hàng triệu sản phẩm xuống còn một tập hợp nhỏ Top-K các ứng viên tiềm năng nhất. Yêu cầu tối thượng của giai đoạn này không phải là độ chính xác xếp hạng tuyệt đối, mà là tốc độ xử lý tức thời và khả năng không bỏ sót các sản phẩm phù hợp (High Recall).

Kiến trúc Bi-Encoder được ứng dụng trong đồ án hoàn toàn đáp ứng được các tiêu chí khắt khe này. Bằng cách tách biệt hoàn toàn quá trình mã hóa của Tháp Người dùng và Tháp Sản phẩm, hệ thống cho phép tính toán trước và lưu trữ ngoại tuyến toàn bộ vector đặc trưng của mặt hàng. Khi có yêu cầu gợi ý, hệ thống chỉ cần tính toán duy nhất vector của người dùng tại thời điểm đó và thực hiện truy xuất thông qua phép đối sánh không gian vector.

Để chứng minh tính hiệu quả và sự ưu việt của kiến trúc đề xuất, phần đánh giá này được thiết kế theo hướng bóc tách, chia thành hai khía cạnh phân tích cốt lõi:

- **Đánh giá chất lượng biểu diễn Tháp Sản phẩm đa phương thức:** Tập trung phân tích năng lực thu nhận và hợp nhất thông tin từ nhiều nguồn dữ liệu (Văn bản, Hình ảnh, Dữ liệu bảng) thông qua tác vụ truy xuất chéo nội bộ và các nghiên cứu cắt bỏ (Ablation Study).
- **Đánh giá năng lực Tháp Người dùng và Hiệu suất Toàn hệ thống:** Kiểm chứng khả năng nắm bắt ý định mua sắm tuần tự của người dùng, thông qua việc đối chiếu hiệu năng truy xuất toàn cục của mô hình đề xuất so với các mô hình cơ sở (Baselines) tiên tiến.

4.5.1 Đánh giá chất lượng biểu diễn Tháp Sản phẩm đa phương thức

Mục tiêu của phép thử này là kiểm chứng xem Tháp Sản phẩm có thực sự ánh xạ được các đặc trưng khác biệt (Văn bản và Hình ảnh) của cùng một mặt hàng vào chung một vùng không gian vector hay không. Quá trình đánh giá được thực hiện thông qua tác vụ Truy xuất chéo phương thức (Cross-modal Retrieval): sử dụng vector Văn bản để truy vấn vector Hình ảnh của chính sản phẩm đó ($Text \rightarrow Image$) trong tập kiểm thử.

Độ đo được sử dụng là tỷ lệ trúng đích $Hit@K$ (tương đương với $Recall@K$ trong bài toán đối sánh 1-1). Kết quả thực nghiệm trên cả hai tập dữ liệu Gift Card và All Beauty được trình bày chi tiết tại Bảng 4.11.

Bảng 4.11: Kết quả đánh giá độ tương quan chéo ($Text \rightarrow Image$) trên hai tập dữ liệu

Metric	Gift Card	All Beauty
Hit@1	35.96%	12.33%
Hit@5	57.89%	36.01%
Hit@10	66.67%	48.83%
Hit@50	92.93%	76.03%

Dựa vào các số liệu thống kê tại Bảng 4.11, ta có thể rút ra hai minh chứng quan trọng về năng lực của kiến trúc Tháp Sản phẩm:

- **Sự hội tụ thành công của không gian nhúng:** Khi mở rộng phạm vi tìm kiếm lên mốc $K = 50$, cả hai tập dữ liệu đều đạt tỷ lệ truy xuất rất cao (lần lượt là 92.93% và 76.03%). Điều này chứng tỏ cơ chế *Gating Fusion* và hàm mất mát đối chiều (InfoNCE) đã làm rất tốt nhiệm vụ thu hẹp khoảng cách ngữ nghĩa. Mạng nơ-ron đã thực sự "hiểu" cách liên kết mô tả văn bản phức tạp với đặc trưng thị giác của cùng một thực thể.
- **Độ khó và Quy mô của không gian ứng viên (Search Space & Domain Specificity):** Số liệu cho thấy hiệu suất trên tập **Gift Card** vượt trội hoàn toàn so với **All Beauty** ở mọi mốc K . Hiện tượng này phản ánh chính xác quy mô và bản chất vật lý của hai ngành hàng:
 - Ngành hàng thẻ quà tặng (*Gift Card*) có không gian tìm kiếm tương đối nhỏ (chỉ 1.307 sản phẩm). Hơn nữa, hình ảnh chủ yếu là các logo thương hiệu đặc trưng và rất khớp với từ khóa văn bản. Không gian mẫu nhỏ cộng với đặc trưng phân tách rõ ràng giúp việc dùng chữ tìm ảnh diễn ra tương đối dễ dàng.
 - Ngược lại, ngành hàng mỹ phẩm (*All Beauty*) lại là một thách thức cực đại (*Extreme Fine-grained*) với quy mô lên tới 10.216 sản phẩm (lớn gấp gần 8 lần so với Gift Card). Tập dữ liệu này chứa hàng vạn mặt hàng có ngoại quan thị giác gần như giống hệt nhau (ví dụ: các thỏi son cùng một dòng chỉ khác biệt rất nhỏ về sắc độ, hoặc các chai serum dùng chung thiết kế lọ đựng). Do tính đa dạng, nhiều hình ảnh cao và không gian ứng viên khổng lồ, việc chỉ dùng một đoạn văn bản ngắn để trích xuất ra đúng 100% bức ảnh của sản phẩm đó khó khăn hơn rất nhiều, dẫn đến chỉ số Hit@1 chỉ đạt 12.33%.

Kết quả thực nghiệm này là tiền đề hoàn hảo để lý giải cho các đánh giá truy xuất người dùng tiếp theo: Chính vì hình ảnh của tập All Beauty chứa đựng quá nhiều thông tin phân loại hạt mịn tinh vi, nên việc hệ thống học được và tích hợp thành công đặc trưng này sẽ mang lại sức mạnh đột phá trong gợi ý cá nhân hóa, vượt trội hơn hẳn so với những ngành hàng ít biến động hình ảnh như Gift Card.

4.5.2 Đánh giá năng lực Tháp Người dùng và Hiệu suất Toàn hệ thống

Để đánh giá chính xác năng lực thực tế của kiến trúc Tháp Người dùng (User Tower) khi triển khai, đồ án áp dụng giao thức truy xuất toàn cục (Full-corpus Retrieval). Thay vì sử dụng phương pháp đánh giá lấy mẫu (Sampled Evaluation) vốn dễ gây ra hiện tượng thổi phồng hiệu suất, mô hình bắt buộc phải tính toán và xếp hạng toàn bộ sản phẩm trong cơ sở dữ liệu để tìm ra mặt hàng mục tiêu.

Mô hình đề xuất (Bi-Encoder Đa phương thức) được kiểm chứng trên hai tập dữ liệu: Gift Card và All Beauty. Riêng đối với tập All Beauty, đồ án thực hiện đối sánh trực tiếp với mô hình cơ sở SASRec (mô hình học nhúng ID truyền thống) để làm rõ ưu thế của phương pháp tiếp cận mới.

Bảng 4.12: Hiệu suất Gợi ý Toàn cục của mô hình Đề xuất trên tập Gift Card (1.307 sản phẩm)

Metric	Top @10	Top @20
Hit Rate	49.74%	56.08%
NDCG	30.77%	32.38%
MRR	24.81%	25.26%

Bảng 4.13: So sánh hiệu suất Gợi ý Toàn cục trên tập dữ liệu All Beauty (10.216 sản phẩm)

Metric	Top @10		Top @20		Top @50	
	SASRec	Đề xuất	SASRec	Đề xuất	SASRec	Đề xuất
Hit Rate	10.26%	10.53%	13.85%	14.04%	17.95%	19.30%
NDCG	5.84%	5.72%	6.73%	6.63%	7.59%	7.71%
MRR	4.51%	4.27%	4.75%	4.53%	4.91%	4.72%

Phân tích và Biện luận Kết quả:

Sự tương quan giữa mô hình đề xuất và baseline SASRec phản ánh rõ rệt đặc trưng và sự đánh đổi của các hệ thống gợi ý đa phương thức:

- **Năng lực thu hồi vượt trội trên không gian lớn:** Trên tập All Beauty (không gian tìm kiếm lớn, độ thưa thớt cao), mô hình Đề xuất đánh bại SASRec về khả năng thu hồi (Hit Rate) ở mọi mốc cắt. Đặc biệt ở mốc $K = 50$, mô hình tìm ra được 19.30% sản phẩm đúng so với mức 17.95% của SASRec. Điều này khẳng định sự hỗ trợ từ các vector đặc trưng hình ảnh và văn bản đã cung cấp mạng lưới ngữ nghĩa vững chắc, giúp hệ thống không bỏ sót các sản phẩm hiếm (Cold-start items).
- **Hiệu quả ổn định trên các tập dữ liệu khác nhau:** Kết quả tại Bảng 4.12 cho thấy trên tập dữ liệu có quy mô nhỏ hơn như Gift Card, mô hình đề xuất đạt được hiệu

suất rất ấn tượng với Hit Rate @10 xấp xỉ 50% và MRR đạt gần 25%. Điều này cho thấy khả năng thích ứng tốt của kiến trúc User Tower đối với các hành vi mua sắm có mục đích rõ ràng.


- **Sự đánh đổi giữa Thu hồi và Xếp hạng:** Trong khi SASRec có phần nhỉnh hơn về NDCG/MRR tại các mốc Top thấp (do khả năng "học thuộc" các sản phẩm phổ biến), thì mô hình Đề xuất tập trung vào việc đưa được nhiều sản phẩm đúng lọt vào danh sách ứng viên hơn. Đây là đặc tính quan trọng của pha *Candidate Generation* trong các hệ thống gợi ý công nghiệp, nơi mục tiêu ưu tiên là tối đa hóa tỷ lệ không bỏ sót sản phẩm mục tiêu.

4.6 Triển khai và Thử nghiệm trên Hệ thống thực tế

Để kiểm chứng khả năng hoạt động của mô hình trong môi trường sản phẩm thực, chúng tôi đã xây dựng một hệ thống Demo hoàn chỉnh theo mô hình Client-Server. Hệ thống không chỉ dừng lại ở việc đưa ra danh sách gợi ý mà còn tích hợp các tính năng nâng cao như tìm kiếm đa phương thức và giải thích kết quả bằng AI tạo sinh.

4.6.1 Kiến trúc hệ thống

Hệ thống được thiết kế tối ưu cho tốc độ phản hồi thời gian thực (Real-time response), bao gồm 3 tầng chính:



Hình 4.1: Kiến trúc hệ thống gợi ý Two-Tower triển khai thực tế

1. Tầng Dữ liệu và Mô hình:

- **Pre-computation Strategy:** Để đảm bảo độ trễ thấp nhất, toàn bộ 1,137 sản phẩm được đưa qua Item Tower để tạo ra ma trận đặc trưng $E_{item} \in \mathbb{R}^{1137 \times 256}$. Ma trận này cùng với User Embeddings được nạp sẵn vào GPU/RAM ngay khi khởi động server.
- **Dynamic Encoders:** Các mô hình *TextEncoder*, *ImageEncoder* và *FusionGate* được duy trì ở trạng thái chờ để xử lý các truy vấn mới từ người dùng.

2. Tầng Dịch vụ Backend Service - FastAPI:

- Sử dụng **FastAPI** để xây dựng RESTful API hiệu năng cao.
- **API Endpoint chính (/search):** Nhận đầu vào đa dạng, gồm Text, Image, User ID và các tham số điều khiển (α, β).
- **Logic Xử lý:** Tích hợp thuật toán tìm kiếm vector bằng phép nhân ma trận trực tiếp trên GPU, cho phép so khớp hàng nghìn sản phẩm trong tích tắc.
- **Tích hợp AI Tạo sinh:** Hệ thống kết nối với **Google Gemini API** theo kiến trúc *Retrieval-Augmented Generation (RAG)*. Sau khi có danh sách gợi ý, thông tin chi tiết của các sản phẩm hàng đầu được gửi làm ngữ cảnh để LLM sinh ra lời giải thích tự nhiên, giúp người dùng hiểu lý do tại sao sản phẩm đó phù hợp với họ.

3. Tầng Giao diện Frontend Application:

- Xây dựng bằng **ReactJS** và **Vite**, cung cấp giao diện trực quan cho phép người dùng nhập từ khóa, tải ảnh lên để tìm kiếm và xem danh sách gợi ý được cá nhân hóa.

4.6.2 Quy trình xử lý một yêu cầu gợi ý

Dựa trên mã nguồn triển khai, quy trình xử lý một yêu cầu tìm kiếm diễn ra qua 4 bước logic chặt chẽ

Đầu tiên, tại bước **Nhận diện và Xử lý Cold Start**, hệ thống thực hiện xác thực định danh người dùng trong cơ sở dữ liệu vector. Trong trường hợp phát hiện người dùng mới hoặc lịch sử tương tác quá thưa thớt (< 2 items), cơ chế dự phòng **Popularity Fallback** sẽ tự động kích hoạt, áp dụng công thức *Weighted Rating* để đề xuất các sản phẩm thịnh hành dựa trên sự cân bằng giữa điểm đánh giá và số lượng bình chọn. Ngược lại, đối với người dùng hiện hữu, vector đặc trưng cá nhân hóa (v_{user}) sẽ được truy xuất ngay lập tức.

Tiếp theo là giai đoạn **Truy xuất và Hợp nhất thông tin**. Các dữ liệu đầu vào đa phương thức (văn bản, hình ảnh) được chuyển đổi qua các Encoder chuyên biệt, sau đó đi qua cơ chế **Fusion Gate** để tổng hợp thành một biểu diễn vector truy vấn duy nhất (v_{query}). Hệ thống thực hiện phép nhân ma trận giữa v_{query} và không gian đặc trưng sản phẩm E_{item} nhằm lọc ra Top-100 ứng viên có độ tương đồng ngữ nghĩa cao nhất.

Danh sách ứng viên này sau đó bước vào giai đoạn **Xếp hạng lại** thông qua công thức tổng hợp điểm số linh hoạt:

$$Score_{final} = \alpha \times Score_{Retrieval} + \beta \times Score_{User} \quad (4.11)$$


Điểm đột phá của kiến trúc này nằm ở khả năng tham số hóa động: phía Client có thể truyền giá trị α và β trực tiếp qua API để điều chỉnh hành vi của bộ máy gợi ý tùy theo ngữ cảnh trải nghiệm. Ví dụ: tăng trọng số α tại trang Tìm kiếm hoặc tăng β tại trang chủ “Dành cho bạn”.

Cuối cùng, hệ thống tích hợp module **Retrieval-Augmented Generation** để nâng cao tính tương tác. Các sản phẩm sau khi xếp hạng được gửi kèm siêu dữ liệu tới một Mô

hình Ngôn ngữ Lớn, giúp sinh ra các lời giải thích tự nhiên nhằm minh bạch hóa lý do đề xuất cho người dùng.

4.6.3 Minh họa hệ thống

Dưới đây là hình ảnh thực tế từ hệ thống Demo, minh họa cho kịch bản người dùng tìm kiếm sản phẩm với từ khóa “Birthday” kết hợp với bộ lọc cá nhân hóa.



Hình 4.2: Giao diện hiển thị kết quả tìm kiếm

```
=====
Bắt đầu query: 'Birthday' - User: AEAUNTQSGHIUYLI4LWNUDEYSCZAAQ
-> Cá nhân hóa cho User: AEAUNTQSGHIUYLI4LWNUDEYSCZAAQ
Đã tìm thấy 100 ứng viên.
--- Hoàn tất Reranking ---
📦 RAG Wrapper: Đang xử lý cho User AEAUNTQSGHIUYLI4LWNUDEYSCZAAQ...
-> Converting Item Metadata...
-> Calling Gemini API...
--- Starting RAG Pipeline (Multi-Item Mode) ---
Extracting metadata for Top 5 products...
Extracting purchase history for User AEAUNTQSGHIUYLI4LWNUDEYSCZAAQ...
Prompt created. Calling Gemini API (JSON Mode)...
Here is the user's recent purchase history (most recent first):

- (Rated: 5/5) Amazon.com Gift Card in a Polka Dot Reveal (Classic Black Card Design)
- (Rated: 5/5) Amazon.com Gift Card in a Slider
- (Rated: 5/5) Amazon.com $25 Gift Card in a Black Gift Box (Classic Black Card Design)
- (Rated: 5/5) Sears Gift Card
- (Rated: 5/5) Regal Entertainment Gift Cards, Multipack of 3

--- RAG Complete ---
INFO: 127.0.0.1:63279 - "POST /search HTTP/1.1" 200 OK
```

Hình 4.3: Log xử lý thời gian thực tại Backend

Kết quả thử nghiệm cho thấy hệ thống hoạt động ổn định với thời gian phản hồi trung bình < 50ms cho mỗi truy vấn, đáp ứng tốt yêu cầu về trải nghiệm người dùng trong thương mại điện tử.

4.7 Kết luận chương

Chương này đã trình bày một quy trình thực nghiệm toàn diện nhằm đánh giá hiệu năng của mô hình *Two-Tower Multi-modal Recommendation System* trên tập dữ liệu Amazon Gift Cards. Thông qua chuỗi phân tích định lượng, định tính và kiểm thử hệ thống, chúng tôi đã làm sáng tỏ cơ chế hoạt động nội tại của mô hình và rút ra bốn kết luận trọng yếu.

Đầu tiên và quan trọng nhất, nghiên cứu đã **giải quyết triệt để thách thức về dữ liệu thừa**. Trong bối cảnh độ thừa dữ liệu lên tới 99.8% khiến các phương pháp lọc cộng tác truyền thống gần như bị vô hiệu hóa, kiến trúc đề xuất vẫn đạt được độ phủ Recall@10 ấn tượng ở mức **99.23%**. Thành công này là minh chứng thực tiễn khẳng định hướng tiếp cận *Content-based Representation Learning*: thay vì phụ thuộc vào sự trùng lặp tương tác người dùng vốn rất khan hiếm, mô hình đã học cách thiết lập liên kết sâu sắc giữa nhu cầu người dùng và các đặc trưng nội dung, từ đó đưa ra dự đoán chính xác ngay cả trong điều kiện thiếu hụt thông tin hành vi.

Thứ hai, kết quả thực nghiệm làm nổi bật vai trò **Thị giác chủ đạo** đặc thù của miền dữ liệu Gift Cards. Các phân tích Ablation chỉ ra rằng chế độ Image-Only đạt độ chính xác tiệm cận tuyệt đối ($> 99.9\%$), chứng minh rằng đối với các sản phẩm mang tính biểu tượng như thẻ quà tặng, thiết kế đồ họa chứa đựng lượng thông tin định danh vượt trội so với văn bản. Mặc dù vậy, việc duy trì cơ chế **Fusion Gate** vẫn được xác định là thiết yếu. Nó đóng vai trò như một lớp lưới an toàn, đảm bảo tính cường tráng cho hệ thống trước các rủi ro kỹ thuật về mất mát dữ liệu hình ảnh trong môi trường thực tế.

Cuối cùng, tính hiệu quả của mô hình được củng cố thông qua việc **tối ưu hóa chiến lược lai** và kiểm chứng **khả năng triển khai thực tế**. Sự kết hợp trọng số giữa Tìm kiếm ($\alpha = 0.7$) và Cá nhân hóa ($\beta = 0.3$) cùng việc mở rộng không gian ứng viên ($k = 100$) đã giải quyết thành công bài toán Nhập hàng từ khóa, cho phép thuật toán Reranking Resurrect các sản phẩm phù hợp sở thích nhưng có điểm khớp từ khóa thấp. Đồng thời, hệ thống Demo tích hợp FastAPI và ReactJS đã chứng minh tính khả thi với độ trễ suy luận cực thấp ($< 50\text{ms}$) nhờ chiến lược tính toán trước, kết hợp với thuật toán Weighted Rating để xử lý trơn tru vấn đề *Cold Start*.

Tóm lại, các kết quả thu được đã xác nhận tính đúng đắn của giả thuyết nghiên cứu, tạo cơ sở vững chắc để phát triển các tính năng gợi ý nâng cao trong môi trường thương mại điện tử quy mô lớn.

Chương 5

Hướng phát triển

5.1 Tổng kết và Hướng phát triển

5.1.1 Kết luận và Kết quả đạt được

Đề tài đã hoàn thành các mục tiêu cốt lõi được đề ra, tập trung vào việc nghiên cứu và triển khai thành công hệ thống gợi ý đa phương thức tuần tự. Các kết quả nổi bật mà đề án đã đạt được bao gồm:

- **Về mặt lý thuyết:** Đề án đã làm chủ và vận dụng thành công các kiến trúc học sâu tiên tiến, tiêu biểu là kiến trúc tháp đôi *Bi-Encoder* cho pha truy xuất ứng viên và mô hình xếp hạng chéo *Cross-Encoder* cho pha đánh giá chuyên sâu. Bên cạnh đó, hệ thống đã khai thác hiệu quả các mô hình biến đổi hiện đại như *BERT* và *Vision Transformer* để trích xuất đặc trưng đa phương thức một cách toàn diện.
- **Về mặt thực nghiệm:** Đề án đã huấn luyện và đánh giá thành công mô hình trên các bộ dữ liệu thực tế quy mô lớn là *Amazon Gift Cards* và *All Beauty*. Hệ thống đã hoàn thiện luồng đánh giá toàn trình *End-to-End* với các thước đo chuẩn xác như *Hit Rate* và *Recall*. Đặc biệt, quá trình nghiên cứu đã ứng dụng sáng tạo mô hình ngôn ngữ lớn để sinh tự động các truy vấn tổng hợp dạng dài, qua đó cải thiện đáng kể hiệu suất và độ chính xác của tầng xếp hạng *Cross-Encoder*.
- **Về mặt kỹ thuật:** Mã nguồn được xây dựng ổn định bằng thư viện *PyTorch*, kết hợp trơn tru với các nền tảng lưu trữ cơ sở dữ liệu vector. Toàn bộ luồng xử lý từ làm sạch dữ liệu, xây dựng tháp người dùng và tháp sản phẩm cho đến suy luận cuối cùng đều được chuẩn hóa thành một đường ống thống nhất.

5.1.2 Hạn chế của đề tài

Mặc dù đã đạt được những kết quả khả quan, kiến trúc hiện tại và quá trình triển khai thực nghiệm của đề án vẫn còn tồn tại một số giới hạn nhất định:

- **Giới hạn về tài nguyên điện toán:** Việc phụ thuộc vào các nền tảng huấn luyện đám mây có giới hạn ngặt nghèo về hạn mức sử dụng thẻ đồ họa máy tính *GPU* đã tạo rào cản lớn. Điều này cản trở việc mở rộng kích thước lô dữ liệu *batch size* cũng

như thử nghiệm các cấu hình siêu tham số phức tạp hơn, khiến thời gian huấn luyện bị kéo dài và chưa khai thác tối đa tiềm năng của mạng nơ-ron.

- **Nút thắt cổ chai ở tầng xếp hạng chéo:** Dù mô hình *Cross-Encoder* mang lại độ chính xác cực kỳ cao về mặt khớp ngữ nghĩa, việc tính toán mức độ tương quan cho từng cặp người dùng và sản phẩm lại tiêu tốn khối lượng tài nguyên khổng lồ. Độ trễ của hệ thống sẽ tăng vọt nếu phải xử lý hàng nghìn ứng viên cùng lúc trong môi trường sản xuất thực tế.
- **Thiếu hụt tính linh hoạt thời gian thực:** Hệ thống hiện tại chủ yếu được huấn luyện trên dữ liệu tĩnh và cập nhật theo từng đợt cố định. Sự vắng mặt của các luồng dữ liệu ngữ cảnh như thời gian mua sắm, thiết bị sử dụng hay chuỗi hành vi tương tác tức thời khiến mô hình gặp khó khăn trong việc nắm bắt các xu hướng thay đổi chóng vánh của người dùng.
- **Giới hạn trong phương pháp đánh giá:** Các thử nghiệm và số liệu đo lường hiện tại hoàn toàn được thực hiện trên dữ liệu lịch sử ngoại tuyến. Đề tài chưa có điều kiện triển khai hệ thống vào một ứng dụng thực tiễn để tiến hành đối chứng song song nhằm đo lường các chỉ số tương tác và tỷ lệ chuyển đổi sinh lời thật sự từ người dùng.

5.1.3 Hướng phát triển hệ thống

Trong môi trường công nghiệp, việc đánh giá hệ thống gợi ý không chỉ dừng lại ở các chỉ số bề mặt như Hit Rate mà phải hướng tới tối ưu hóa toàn bộ phổ chuyển đổi dựa trên mức độ tương tác thực tế của người dùng. Một mô hình mới bắt buộc phải trải qua thử nghiệm A/B trực tiếp, nơi nhóm thử nghiệm sử dụng mô hình mới sẽ được so sánh song song với nhóm đối chứng dùng hệ thống cũ. Việc triển khai hệ thống mới ra diện rộng chỉ được thực hiện khi nó chứng minh được sự tăng trưởng vững chắc của các chỉ số tương tác cốt lõi Engagement Metric, điển hình như mức tăng 0.37% mà thuật toán hiệu chỉnh của YouTube đã đạt được trong thực tế [9]. Về bản chất, Engagement Metric là các thước đo định lượng mức độ gắn kết và giá trị mà người dùng tạo ra sau cú nhấp chuột ban đầu, ví dụ như thời gian xem hết một video hay tỷ lệ tương tác sâu. Riêng đối với một sàn thương mại điện tử như Shopee, Engagement Metric sẽ tập trung vào hành vi mua sắm sinh ra lợi nhuận, tiêu biểu là tỷ lệ chuyển đổi đơn hàng Conversion Rate, tổng giá trị hàng hóa GMV, tỷ lệ bấm thêm vào giỏ hàng Add to Cart Rate, thời gian khách hàng nán lại đọc bình luận trên trang chi tiết sản phẩm Dwell Time, và tỷ lệ mua thành công mà không yêu cầu hoàn trả.

Trong kiến trúc hiện tại, mô hình Two-Tower phục vụ giai đoạn retrieval đang được vận hành và cập nhật theo cơ chế batch. Phương pháp này bộc lộ điểm yếu khi đòi hỏi quá trình huấn luyện lại toàn bộ dữ liệu lịch sử mỗi khi có luồng tương tác mới, gây lãng phí lớn về thời gian và tài nguyên tính toán. Ngược lại, nếu chỉ áp dụng fine-tuning trên các lô dữ liệu mới nhất, hệ thống sẽ đối mặt với rủi ro overfitting và hiện tượng catastrophic forgetting, khiến mô hình đánh mất khả năng ghi nhớ sở thích dài hạn của người dùng. Để giải quyết vấn đề này, hướng phát triển tương lai là tích hợp phương pháp Sequential Meta-Learning [46]. Thay vì loại bỏ hoàn toàn mô hình cũ, phương pháp này huấn luyện một thành phần chuyển giao tri thức nhằm biến đổi các trọng số hiện tại để thích nghi với dữ liệu mới. Điểm nổi bật là thành phần này được tối ưu trực tiếp theo hiệu năng trong

tương lai, giúp hệ thống thích nghi tốt hơn với sự thay đổi hành vi người dùng. Khi áp dụng vào mô hình Bi-Encoder, giải pháp này giúp giảm chi phí huấn luyện lại và cho phép cập nhật embedding một cách hiệu quả mà không cần xây dựng lại toàn bộ không gian vector.

Kiến trúc hiện tại sử dụng Two-Tower cho pha truy xuất và Cross-Encoder cho pha xếp hạng cuối cùng. Tuy nhiên, việc đưa trực tiếp số lượng lớn ứng viên vào Cross-Encoder gây ra nút thắt cổ chai về tính toán và thiếu khả năng phản ứng với hành vi ngắn hạn. Do đó, một hướng cải tiến là tích hợp mô hình Deep Interest Network làm tầng xếp hạng trung gian giữa Two-Tower và Cross-Encoder. Theo các nghiên cứu từ Alibaba [47], mô hình này sử dụng cơ chế attention để so khớp từng ứng viên với chuỗi hành vi gần nhất của người dùng, từ đó làm nổi bật các sản phẩm phù hợp với ý định hiện tại. Kết quả là hệ thống thu được một tập ứng viên nhỏ nhưng mang tính cá nhân hóa cao theo thời gian thực. Tập này sau đó được đưa vào Cross-Encoder để thực hiện bước đánh giá ngữ nghĩa sâu, giúp nâng cao độ chính xác cuối cùng đồng thời giảm tải tính toán.

Để hoàn thiện hệ thống, cần tích hợp các ràng buộc kinh doanh vào pipeline gợi ý. Đối với sản phẩm mới chưa có dữ liệu, chiến lược exploration sẽ được áp dụng bằng cách phân bổ một phần lưu lượng để thu thập dữ liệu tương tác ban đầu. Đồng thời, các quy tắc về tồn kho và logistics sẽ được sử dụng như một bước lọc hậu kỳ nhằm loại bỏ các sản phẩm không khả dụng. Bên cạnh đó, các thuật toán đảm bảo tính đa dạng sẽ giúp tránh hiện tượng echo chamber và mang lại trải nghiệm khám phá phong phú hơn cho người dùng.

Về mặt hạ tầng, hệ thống cần được nâng cấp theo hướng phân tán để phục vụ quy mô lớn. Việc sử dụng cache như Redis giúp tăng tốc truy xuất dữ liệu, trong khi message queue hỗ trợ xử lý bất đồng bộ các yêu cầu. Ngoài ra, một lớp lọc thô dựa trên inverted index có thể được đặt trước bước tìm kiếm vector nhằm giảm không gian tìm kiếm và tối ưu hiệu năng, đảm bảo độ trễ thấp trong môi trường thực tế [48].

5.1.4 Thu hoạch của sinh viên

Quá trình thực hiện đề án tốt nghiệp là một hành trình chuyển giao từ việc tiếp thu lý thuyết trên giảng đường sang việc giải quyết một bài toán kỹ thuật thực tế mang tính toàn diện. Thông qua việc nghiên cứu và phát triển hệ thống gợi ý đa phương thức, sinh viên đã gặt hái được những kinh nghiệm chuyên môn và kỹ năng thực hành vô giá, tạo tiền đề vững chắc cho con đường sự nghiệp trong lĩnh vực trí tuệ nhân tạo sau này.

Về mặt kỹ thuật chuyên môn, sinh viên đã từng bước vượt qua giới hạn của các thuật toán học máy cơ bản để làm chủ các kiến trúc học sâu phức tạp. Việc tự tay thiết kế, lập trình và tinh chỉnh các mạng *Bi-Encoder* và *Cross-Encoder* bằng thư viện *PyTorch* giúp sinh viên hiểu sâu sắc về luồng di chuyển của dòng dữ liệu đa chiều (*tensor*) và cơ chế tối ưu hóa trọng số bề sâu. Đặc biệt, quá trình làm việc với các tập dữ liệu thực tế quy mô lớn đã rèn luyện kỹ năng xử lý dữ liệu linh hoạt và năng lực quản lý tài nguyên phần cứng. Việc phải đối mặt với các giới hạn về bộ nhớ *VRAM* và cách tối ưu hóa hạn mức sử dụng *GPU* trên các nền tảng điện toán đám mây đòi hỏi sinh viên phải liên tục tối ưu hóa mã nguồn, tìm hiểu sâu về kỹ thuật cấp phát bộ nhớ để đảm bảo hệ thống có thể hội tụ mà không vượt quá ngưỡng phần cứng cho phép.

Về phương pháp nghiên cứu khoa học, đề án đã rèn luyện thói quen tiếp cận tri thức trực tiếp từ các nguồn tài liệu gốc. Thay vì phụ thuộc vào các tài liệu hướng dẫn sẵn có,

sinh viên đã hình thành kỹ năng phân tích, phản biện và tái hiện lại kiến trúc thuật toán từ các bài báo khoa học thuộc các hội nghị đầu ngành. Đồng thời, sự chuyển dịch tư duy từ việc chỉ quan tâm đến các độ đo đánh giá thuần túy sang việc nhìn nhận hệ thống dưới góc độ trải nghiệm người dùng cuối là một bước trưởng thành lớn trong nhận thức phát triển sản phẩm.

Cuối cùng, việc liên tục đối mặt với những thách thức trong quá trình huấn luyện, từ những lần thuật toán suy giảm hiệu suất đến các lỗi tràn bộ nhớ, đã mài giũa kỹ năng gỡ lỗi (*debugging*) hệ thống sâu, tính kiên định và khả năng quản lý thời gian độc lập. Những trải nghiệm này không chỉ củng cố nền tảng học thuật mà còn rèn luyện bản lĩnh thực chiến, giúp sinh viên Đại học Bách khoa tự tin đáp ứng những tiêu chuẩn khắt khe của môi trường công nghiệp thực tế.

Tài liệu tham khảo

- [1] SellersCommerce (19-06-2025), *51 eCommerce Statistics In 2025 (Global and U.S. Data)*, <https://www.sellerscommerce.com/blog/e-commerce-statistics/>
- [2] DIETMAR JANNACH, MICHAEL JUGOVAC(12-2019), *Measuring the Business Value of Recommender Systems*, <https://arxiv.org/pdf/1908.08328>
- [3] ENVIVE (3-2025), *63 AI Personalization in eCommerce Lift Statistics – Driving 400% ROI and Transformative Growth in 2025*, <https://www.envive.ai/post/ai-personalization-in-e-commerce-lift-statistics>
- [4] Carrie Tharp(24-3-2025), *New research: Search abandonment continues to vex retailers worldwide*, <https://cloud.google.com/blog/topics/retail/new-research-on-search-abandonment-in-retail>
- [5] Qijiong Liu(29-10-2025), *Can LLMs Outshine Conventional Recommenders? A Comparative Evaluation*, <https://arxiv.org/pdf/2503.05493>
- [6] Huggingface(5-12-2025), *MTEB Leaderboard*, <https://huggingface.co/spaces/mteb/leaderboard>
- [7] Kang, W. C., & McAuley, J. (2018). *Self-attentive sequential recommendation*, <https://arxiv.org/abs/1808.09781>
- [8] Xinyang Yi, Ji Yang, Lichan Hong, Derek Zhiyuan Cheng, Lukasz Heldt, Aditee Kumthekar, ZheZhao, Li Wei, Ed Chi (2019). *Sampling-Bias-Corrected Neural Modeling for Large Corpus Item Recommendations*, <https://research.google/pubs/sampling-bias-corrected-neural-modeling-for-large-corpus-item-recommendations/>
- [9] Paul Covington, Jay Adams, Emre Sargin (2016). *Deep Neural Networks for YouTube Recommendations*, <https://static.googleusercontent.com/media/research.google.com/en//pubs/archive/45530.pdf>
- [10] HuggingFace (2025). *sentence-transformers/all-mpnet-base-v2*, <https://huggingface.co/sentence-transformers/all-mpnet-base-v2>
- [11] Alexey Dosovitskiy(2021). *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*, <https://arxiv.org/pdf/2010.11929>
- [12] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin (2017). *Attention Is All You Need*, <https://arxiv.org/abs/1706.03762>

- [13] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever (2021). *Learning Transferable Visual Models From Natural Language Supervision*, <https://arxiv.org/abs/2103.00020>
- [14] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*, <https://arxiv.org/abs/1810.04805>
- [15] Tomas Mikolov, Kai Chen, Greg Corrado, Jeffrey Dean (2013). *Efficient Estimation of Word Representations in Vector Space*, <https://arxiv.org/pdf/1301.3781>
- [16] Qidong Liu, Jiayi Hu, Yutian Xiao, Xiangyu Zhao, Jingtong Gao, Wanyu Wang, Qing Li, Jiliang Tang (2024). *Multimodal Recommender Systems: A Survey*, <https://arxiv.org/pdf/2302.03883v2>
- [17] YouNet (2024). *YouNet ECI: Báo cáo doanh thu các sản phẩm thương mại điện tử quý I/2024*, <https://www.brandsvietnam.com/congdong/topic/340383-younet-eci-bao-cao-doanh-thu-cac-san-thuong-mai-dien-tu-quy-i-2024>
- [18] Gediminas Adomavicius, Alexander Tuzhilin (2005). *Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions*, <https://pages.stern.nyu.edu/~atuzhili/pdf/TKDE-Paper-as-Printed.pdf>
- [19] Steffen Rendle (2010). *Factorization Machines*, <https://www.ismll.uni-hildesheim.de/pub/pdfs/Rendle2010FM.pdf>
- [20] Maciej Kula (2015). *Metadata Embeddings for User and Item Cold-start Recommendations*, <https://arxiv.org/pdf/1507.08439>
- [21] Heng-Tze Cheng (2016). *Wide & Deep Learning for Recommender Systems*, <https://arxiv.org/pdf/1606.07792>
- [22] Xiangnan He (2017). *Neural Collaborative Filtering*, <https://arxiv.org/pdf/1708.05031>
- [23] Florian Schroff, Dmitry Kalenichenko, James Philbin (2015). *FaceNet: A Unified Embedding for Face Recognition and Clustering*, <https://arxiv.org/pdf/1503.03832>
- [24] John Arevalo, Manuel Montes-y-Gomez, Thamar Solorio, Fabio A. Gonzalez (2017). *GATED MULTIMODAL UNITS FOR INFORMATION FUSION*, <https://arxiv.org/pdf/1702.01992>
- [25] Ruining He, Julian McAuley (2016). *Fusing Similarity Models with Markov Chains for Sparse Sequential Recommendation*, <https://arxiv.org/pdf/1609.09152>
- [26] Steffen Rendle (2010). *Factorizing Personalized Markov Chains for Next-Basket Recommendation*, <https://cseweb.ucsd.edu/classes/fa17/cse291-b/reading/p811.pdf>

- [27] Zachary C. Lipton, John Berkowitz (2015). *A Critical Review of Recurrent Neural Networks for Sequence Learning*, <https://arxiv.org/pdf/1506.00019>
- [28] Sepp Hochreiter, Jürgen Schmidhuber (1997). *Long Short-Term Memory*, https://www.researchgate.net/publication/13853244_Long_Short-Term_Memory
- [29] Junyoung Chung, Caglar Gulcehre, KyungHyun Cho, Yoshua Bengio (2014). *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*, <https://arxiv.org/pdf/1412.3555>
- [30] Balazs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, Domonkos Tikk (2016). *Session-based Recommendations with Recurrent Neural Networks*, <https://arxiv.org/abs/1511.06939>
- [31] Pratik Aher (2023). *Evaluation Metrics for Recommendation Systems - An Overview*, <https://towardsdatascience.com/evaluation-metrics-for-recommendation-systems-an-overview-71290690ecba/>
- [32] Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, Ming Zhou (2020). *MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers*, <https://arxiv.org/abs/2002.10957>
- [33] Chandan K. Reddy, Lluís Màrquez, Fran Valero, Nikhil Rao, Hugo Zaragoza, Sambaran Bandyopadhyay, Arnab Biswas, Anlu Xing, Karthik Subbian (2022). *Shopping Queries Dataset: A Large-Scale ESCI Benchmark for Improving Product Search*, <https://arxiv.org/pdf/2206.06588>
- [34] Yupeng Hou, Jiacheng Li, Zhankui He, An Yan, Xiusi Chen, Julian McAuley (2024). *Bridging Language and Items for Retrieval and Recommendation*, <https://arxiv.org/abs/2403.03952>
- [35] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, Wen-tau Yih (2020). *Dense Passage Retrieval for Open-Domain Question Answering*, <https://arxiv.org/pdf/2004.04906>
- [36] Yoshua Bengio, Réjean Ducharme, Pascal Vincent, Christian Jauvin (2003). *A Neural Probabilistic Language Model*, <https://www.jmlr.org/papers/volume3/bengio03a/bengio03a.pdf>
- [37] Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever (2018). *Improving Language Understanding by Generative Pre-Training*, https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf
- [38] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah (2020). *Language Models are Few-Shot Learners*, <https://arxiv.org/abs/2005.14165>
- [39] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin (2022). *Training language models to follow instructions with human feedback*, <https://arxiv.org/abs/2203.02155>

- [40] Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge, Yongfeng Zhang (2023). *Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5)*, <https://arxiv.org/pdf/2203.13366>
- [41] Thomas Wolf, Lysandre Debut, Victor Sanh, et al. (2020). *Transformers: State-of-the-Art Natural Language Processing*. <https://www.aclweb.org/anthology/2020.emnlp-demos.6>
- [42] Hongyu Zhou, Xin Zhou, Zhiwei Zeng, Lingzi Zhang, Zhiqi Shen (2023). *A Comprehensive Survey on Multimodal Recommender Systems: Taxonomy, Evaluation, and Future Directions*. arXiv preprint arXiv:2302.04473. <https://arxiv.org/abs/2302.04473>
- [43] Nick Craswell (2009). *Mean Reciprocal Rank*. Encyclopedia of Database Systems, Springer, Boston, MA, 1703. https://doi.org/10.1007/978-0-387-39940-9_488
- [44] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder, Li Deng (2016). *MS MARCO: A Human Generated Machine Reading Comprehension Dataset*. <https://arxiv.org/abs/1611.09268>
- [45] Nils Reimers, Iryna Gurevych (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. <https://arxiv.org/pdf/1908.10084>
- [46] Yang Zhang, Fuli Feng, Chenxu Wang, Xiangnan He, Meng Wang, Yan Li, Yongdong Zhang (2020). *How to Retrain Recommender System? A Sequential Meta-Learning Method*. <https://arxiv.org/pdf/2005.13258>
- [47] Guorui Zhou, Xiaoqiang Zhu, Chengru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, Kun Gai (2018). *Deep Interest Network for Click-Through Rate Prediction*. <https://arxiv.org/pdf/1706.06978>
- [48] Jizhe Wang, Pipei Huang, Huan Zhao, Zhibo Zhang, Binqiang Zhao, Dik Lun Lee (2018). *Billion-scale Commodity Embedding for E-commerce Recommendation in Alibaba*. <https://arxiv.org/pdf/1803.02349>